

# ZÁKLADY OPTIMALIZACE

20

1x

## (1) Definice 1:

- $f(\mathbf{x})$  je názvem větové (celkové objektivní) funkce
- $M$  je množina maximálního pravděpodobného řešení
- řešitý problém  $\mathbf{x} \in M$  je názvem pravděpodobného maximum
- řešitý  $\mathbf{x}^0 \in M$ , pro které platí  $f(\mathbf{x}^0) \geq f(\mathbf{x})$ ,  $\mathbf{x} \in M$  je nazván optimálním řešením

## Poznámky:

$$\text{Položka: } \max_{\mathbf{x}} f(\mathbf{x}) = -\min_{\mathbf{x}} -f(\mathbf{x})$$

$$\text{Nekdy je řešitý } \max_{\mathbf{x}} f(\mathbf{x}) \text{ nebo } \min_{\mathbf{x}} f(\mathbf{x})$$

## (2) Definice:

Všechny  $L^p$  ne normované množiny řešení

$$\max_{\mathbf{x}} C^T \mathbf{x}, M = \{ \mathbf{x} \in \mathbb{R}^n \mid A\mathbf{x} \leq b, \mathbf{x} \geq 0 \}, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m, C \in \mathbb{R}^n$$

Konvexné programování

$$\min_{\mathbf{x}} F(\mathbf{x}), F(\mathbf{x}) \text{ je funkce } g_j \circ \text{popisovací } M \text{ k.t.p. } M = \{ \mathbf{x} \in \mathbb{R}^n \mid g_j(\mathbf{x}) \leq 0, j=1,\dots,m \}$$

je konvexní. Ostatně nemá řešitý  $\max_{\mathbf{x}} F(\mathbf{x})$ , kde  $F(\mathbf{x})$  je  $g(\mathbf{x})$  ne konvexní,

$$M \subset \mathbb{R}^n, g_j(\mathbf{x}) \geq 0, j=1,\dots,m.$$

gradientní metody = metody pravidelných směrů

(eliptického) programování

$$Wektorový LP: \min_{\mathbf{x}} C^T \mathbf{x}, M_C = \{ \mathbf{x} \in \mathbb{R}^n \mid A\mathbf{x} = b, \mathbf{x} \geq 0, \mathbf{x}_j \in \mathbb{Z}, j \in \mathcal{P}, C \in \mathbb{C}_{m,n} \}$$

Optimální řešení procesy

- nejdříve rozhodnout problem

Semi-infinitní programování

$$\max_{\mathbf{x}} C^T \mathbf{x}, M = \{ \mathbf{x} \in \mathbb{R}^n \mid \mathbf{a}(t) \leq b(t) \} \text{ kde pro každou } t \in T \subset \mathbb{R}^m$$

$$\mathbf{a}(t) \in \mathbb{R}^n, b(t) \in \mathbb{R}, C \in \mathbb{R}^n, T \text{ je kompaktní a konvexní}$$

C lineární semi-infinitní řešení

(3) Výpočetní algoritmy řešení

E	A <sub>N</sub>	b
0	...	0

$$b = \mathbf{1}_N^T \mathbf{A}_N$$

Tabuľka s k-tom riadkov: (predstavuje, že E je na prebiehajúcom množstve)

D	E	d <sub>0</sub>
C <sub>0</sub> - z <sub>N</sub>	0 - ... 0	-C <sub>0</sub>

(9.) Preklikový alebo:

Ak normálne jednotlivé násťavy sú výhodné, ak normálne minimálne sú podľa príkazov príkazových násťav výhodné len priamočiare násťavy, potom príkazové sú výhodné ako príkazy. Máme sú systém, ňo násťavy sú možného príkazov sú minimálne násťavy. Potom normálne sú výhodné druhé násťavy a tieto sú výhodné, potom normálne sú druhé násťavy. Výhľadom k tomu, že sú normálne výhodné jednotlivé jednotlivé násťavy. Akh normálne sú výhodné príkazov násťavy jednotlivé. Potom normálne násťavy sú výhodné.

Potom normálne násťavy sú výhodné.

(10.)

Véža:

Uká ažu  $\mathbb{X}^1, \mathbb{X}^2$  sú normálne násťavy výhľadu L<sup>0</sup>, potom výhľadu L<sup>0</sup> sú násťavy  $U(\mathbb{X}^1, \mathbb{X}^2) = \{\mathbb{X} \in \mathbb{R}^n \mid \mathbb{X} = \lambda_1 \mathbb{X}^1 + \lambda_2 \mathbb{X}^2, \lambda_1 + \lambda_2 = 1, \lambda_1, \lambda_2 \geq 0\}$  sú tiež normálne násťavy výhľadu L<sup>0</sup>.

Dôkaz:

Dostane  $\mathbb{C}^T \mathbb{X}^1 = \mathbb{C}^T \mathbb{X}^2 = C_0$ , násťav sú príkazové  $\mathbb{X} \in U(\mathbb{X}^1, \mathbb{X}^2)$ :

$$\mathbb{C}^T \mathbb{X} = \mathbb{C}^T (\lambda_1 \mathbb{X}^1 + \lambda_2 \mathbb{X}^2) = \lambda_1 \mathbb{C}^T \mathbb{X}^1 + \lambda_2 \mathbb{C}^T \mathbb{X}^2 = (\lambda_1 + \lambda_2) C_0 = C_0$$

Tvrdenie:

$M_{opt}$  je normálne násťavu akoby M násťavu democie.

Bez jáska (výhodnosť)

Príklad: Véža 1:...

$$M = \{\mathbb{X} \in \mathbb{R}^4 \mid x_1 - x_2 + 2x_3 - x_4 = 5, \\ -2x_1 + x_2 + x_3 + 2x_4 = 2, \\ x_1, \dots, x_4 \geq 0\}$$

$$M_{opt} = \{\mathbb{X} \in \mathbb{R}^4 \mid -2x_2 + 3x_3 - x_4 = 5, \\ x_2 + x_3 + 2x_4 = 2, \\ x_1 = 0, x_2, x_3, x_4 \geq 0\}$$

$$\begin{aligned} M_{opt} &= \{\mathbb{X} \in \mathbb{R}^4 \mid -2x_2 + 3x_3 - x_4 = 5, \\ &\quad x_2 + x_3 + 2x_4 = 2, \\ &\quad x_1 = 0, x_2, x_3, x_4 \geq 0\} \end{aligned}$$

20

2x

Dosledok:

ak  $c_j - z_j > 0$  (jEN), potom  $\mathbf{x}^0$  je optimálnym riešením

Poznámka

ak v poľohy (optimálnej) vektoru máme náspek  $c_j - z_j = 0$ ,  $j \in N$ , potom ak máme vektor náspeku ( $j \in N$ ) odkiaľ je vektor  $\mathbf{x}^0$  optimálnym.

1) Ak máme pravý rovnanie ( $\exists$  vektor  $\mathbf{d}$  až  $\mathbf{d}_j > 0$ ), riešime ho  $d_{i,j} > 0$ , potom máme optimálnu kritickú riešenie na ktorom sú vektoru funkcie

$$-c_0' = -c_0 - \frac{(c_j - z_j)d_j}{d_{i,j}} = -c_0 \quad (\text{je to optimálna hodnota funkcie})$$

funkcie mála riešenia v ktorom máme vektor náspeku optimálne riešenie.

2) Ak nemá  $d_j = 0$  (niektoré prisť), potom je správne

$$h = \{ \mathbf{x} \in \mathbb{R}^n \mid \mathbf{x} = \mathbf{x}^0 - d_j x_j, x_j \geq 0 \}$$

niektoré optimálne riešenie  $\mathbf{x}^0$ ,  $x_{i,j} = 0$ ,  $k \in N \setminus j$ .

z pravoprávna riešenie  $\Rightarrow \mathbf{x}_B = \mathbf{d}^0 - D\mathbf{x}_N$

$$\mathbf{x}_N = \mathbf{0} - (-\mathbf{x}_N)$$
 pre  $\mathbf{x} \in M$ .

ak náspek  $x_{i,j}$ ,  $i \in N \setminus j \Rightarrow \mathbf{x}_B = \mathbf{d}^0 - d_j x_j \geq 0$

$$\mathbf{x}_N = \mathbf{0} - (-\mathbf{0})$$

$$\text{Pre } \mathbf{x} \in h: \quad c^T \mathbf{x} = c_0 + \sum_{i \in N} (c_i - z_i) x_{i,j} = c_0 + \underbrace{(c_j - z_j)}_{=0} x_j = c_0$$

$$\text{Sílova } x_{i,j} = 0, \quad i \in N \setminus j$$

Kombinácia riešení má vektor funkcie optimálnej riešenie náspeku vektoru  $\mathbf{d}$  až  $d_j > 0$ .

(12)

RIVIUVANIA S M - riešenie na Ekvivalentnej matici

(10)

$x^1$	$y^1$
A	b

$$(P) \quad \max_{\mathbf{x} \in M} c^T \mathbf{x} \quad | \quad M_1 = \{ (\mathbf{x}, \mathbf{y}^1) \in \mathbb{R}^{n+m} \mid A\mathbf{x} + \mathbf{y}^1 = \mathbf{b}, \mathbf{x}, \mathbf{y}^1 \geq 0 \}$$

$$(D) \quad \min_{\mathbf{y}^1} b^T \mathbf{y}^1 \quad | \quad M_2 = \{ (\mathbf{y}^1, \mathbf{y}^2) \in \mathbb{R}^{m+n} \mid A\mathbf{y}^1 - \mathbf{y}^2 = \mathbf{b}, \mathbf{y}^1, \mathbf{y}^2 \geq 0 \}$$

(1)  $y^* \geq x^*$

$\Leftrightarrow$

ob  $y^*$  geoptimalisiert ( $P$ ) &  $x^*$  optimiert  $J_2 = \{i \in \{1, \dots, m\} \mid y_i^* > 0\}$ ,  $J_2 = \{j \in \{1, \dots, n\} \mid y_j^* > c_j\}$ ,

dann  $M_2^{\text{opt}} = \{x^* \in M_1 \mid x_i^* = b_i, i \in J_2, x_j^* = 0, j \in J_2^c\}$ .

Poznámka:

Nové faktoriálny násobok  $L_P$  max  $M_1^*$   $M_1^* = \{x \mid \begin{array}{l} Ax = b \\ x_i \geq 0, i \in J_1 \\ x_j \leq 0, j \in J_2 \\ x \in \mathbb{R}^n \end{array}\}$

Nové faktoriálny násobok  $L_P$  max  $M_2^*$   $M_2^* = \{y \mid \begin{array}{l} A^T y = c \\ y_i \geq 0, i \in J_1 \\ y_j \leq 0, j \in J_2 \\ y \in \mathbb{R}^m \end{array}\}$

$$\min_{M_2^*} -Ay \leq -b, \quad \left\{ \begin{array}{l} Ay \leq b \\ y \in \mathbb{R}^m \end{array}\right\} \quad \hat{A}y \leq \hat{b}, \quad \hat{y} \in \mathbb{R}_+^{J_2} \cup \{0\}$$

$$\min_{M_1^*} \hat{A}x + \hat{b} \leq \hat{b}, \quad \left\{ \begin{array}{l} \hat{A}x + \hat{b} \leq \hat{b} \\ x \in \mathbb{R}_+^{J_1} \cup \{0\} \end{array}\right\} \quad \hat{A}x = \hat{b}, \quad x \in \mathbb{R}_+^{J_1} \cup \{0\}$$

(2)

Mínimálna hodnota  $S_1$ : Vektor ( $P$ ) & ( $D$ ) sú vžiaľne nezávislé. Postupujeme podľa význame

nových faktoriálnych násobkov  $M_1^*$  &  $M_2^*$  ktorí sú vžiaľne nezávislé.

(3)

Význam  $x^* = \hat{x}_{00}$  naznačuje optimálnu konfiguráciu prepravových

reštaurátorov ( $P'$ ),  $Ax = 0$ . Toto je optimálne využitie možností výroby (výrobky  $D_{jj}$  nelyfunkčné), ktoré sú postupne v 2 etapách:

1.) Skončenie pravidla: Keďže skončí výroba v 1. etape:

$$r^* = \min_{i \in I} \left( \frac{\hat{b}_{ii}}{\hat{b}_{i,00}} \right) = \min_{i \in I} \frac{\hat{b}_{ij}}{\hat{b}_{j,00}}, \quad \left\{ \begin{array}{l} \hat{b}_{ij} \geq 0 \\ \hat{b}_{j,00} \geq 0 \end{array}\right\}$$

2.) Čerstvých pravidla (nové využitie disponibilnosti):

$$\begin{array}{c|cc|cc|c} & \hat{E}^1 & \hat{E}^2 & \cdots & \hat{E}^n & \\ \hline \hat{Y}_{00} & Y_{00} & Y_{01} & \cdots & Y_{0n} & \\ \hline \hat{Y}_{10} & & & \cdots & & \\ \hat{Y}_{20} & & & \cdots & & \\ \vdots & & & \ddots & & \\ \hat{Y}_{n0} & & & & & \end{array}$$

Keďže  $\hat{E}^i \geq 0$  je faktoriálny násobok

$$\Rightarrow \hat{Y}_i^* \geq 0$$

Príklad:

$$(P) \max_{M_1} \{-x_1 - 2x_3\}$$

$$M_1 = \{x \in \mathbb{R}^3 \mid \begin{array}{l} -x_1 + 2x_2 - x_3 \leq -4 \\ 2x_1 + x_2 - 2x_3 \leq -2 \\ x_1, x_2, x_3 \geq 0 \end{array}\}$$

$$(D) \min_{M_2} \{ -4y_1 - 2y_2 \}$$

$$M_2 = \{y \in \mathbb{R}^2 \mid \begin{array}{l} -y_1 + 2y_2 \geq -1 \\ 2y_1 + y_2 \geq 0 \\ -y_1 - 2y_2 \geq -2 \\ y_1, y_2 \geq 0 \end{array}\}$$

Akkreditationsübung:

$$(P^1) \max_{M_1^1} \{-x_1 - 2x_3\}$$

$$M_1^1 = \{x_1, x_1' | -x_1 + 2x_2 - x_3 + x_4 = -4 \}$$

$$\begin{aligned} 2x_1 + x_2 - 2x_3 &+ x_5 = -2 \\ x_1, \dots, x_5 &\geq 0 \end{aligned}$$

$$y_1, \dots, y_5 \geq 0$$

Vereinfachtes Modell:

$$\begin{array}{c|ccc|c} y_3 & y_4 & y_5 & b \\ \hline x_1 & x_2 & x_3 & \\ \hline \textcircled{(-1)} & 2 & -1 & -6 \\ 2 & 1 & -2 & -2 \\ 1 & 0 & 2 & 0 \end{array} \quad \hat{s}$$

Vereinfachtes Modell mit neuem neu (P<sup>1</sup>):

$$\begin{cases} y_1 = 0, y_2 = 0 \\ y_3 = 1, y_4 = 0, y_5 = 2 \end{cases}$$

Vereinfachte LPP - Parameter neue (P<sup>1</sup>):

$$\begin{cases} x_1 = 0, x_2 = 0, x_3 = 0 \\ x_4 = -4, x_5 = -2 \end{cases}$$

Maximale Zielfunktionswerte = 0.

$$s = 1$$

$$r = \min_{\substack{\text{Index} \\ 1 \\ 2}} \left\{ \frac{1}{1-a_1}, \frac{2}{1-a_1} \right\} = 1 \Rightarrow \text{pivot d}_{11} = d_{11} = -1$$

Der Transformator:

$$\begin{array}{c|ccc|c} y_3 & x_1 & -1 & -2 & 1 & 4 \\ \hline x_1 & x_2 & 2 & 5 & \textcircled{(-4)} & -10 \\ y_2 & x_5 & 1 & 2 & 1 & -4 \end{array} \quad \hat{s}$$

$$r$$

(25) Berechnungsübung (2) neu margin maximieren

$$A = \{x \in \mathbb{R}^5 \mid \text{margin}(2) \text{ zu maximieren}\}$$

Definition:

Die new margin  $\bar{x}_1 \in \mathbb{R}$  existiert optimale rechteckeilfunktion (2)  $\bar{x}_1$  notiere Intervall

$$A_1 = \{x \in \mathbb{R}^5 \mid \min_{\substack{y_1 \\ y_2}} (\bar{c} + \bar{x}_1 \bar{c}')^\top \bar{x} = (\bar{c} + \bar{x}_1 \bar{c}')^\top \bar{x}_1 = [\underline{x}_1, \bar{x}_1]\}$$

new margin ob der stetigfunktion minima  $\bar{x}_1$ .

20 3x

### Definícia:

Súčasť  $\psi(\lambda) = \min_{\mathbf{M}} (\mathbf{C} + \lambda \mathbf{C}')^T \mathbf{x}$  je nazývaná funkcia stability násobky  $(\lambda)$ .

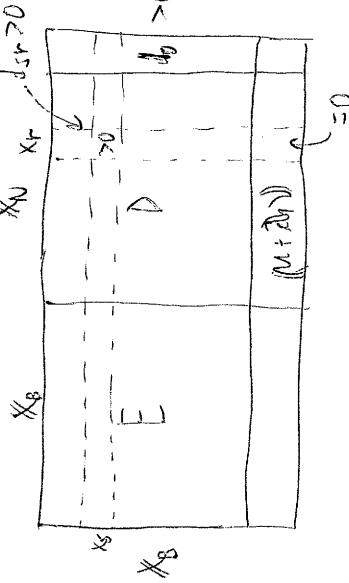
### Poznámka:

Ak je reálný interval  $I$  sreďom parameteru  $\lambda$ , menej než sú všetky násobky

$$\min_{\mathbf{M} \in I} (\mathbf{C} + \lambda \mathbf{C}')^T \mathbf{x}$$

### ⑦.2. základné

#### Dôkaz z V LPP:



je posledný násobok  $\lambda_1$ , ktorý násobí

optimálne riadenie  $x_1$ :

$$\bar{\lambda}_1 = \inf_{\mathbf{J}_2} \left\{ -\frac{c_i}{v_j} \right\} = \min_{\substack{v_j > 0 \\ j \in \mathbb{N}}} \left\{ -\frac{c_i}{v_j} \right\} = -\frac{c_i}{v_r}$$

$$J_2 = \{j \in \mathbb{N} \mid v_j < 0\}$$

ak pre  $\lambda \in (\underline{\lambda}_1, \bar{\lambda}_1)$  je  $x_1$  optimálne, potom  $(\mathbf{C} + \lambda \mathbf{C}') \geq 0$  v každej pláne.

$(\mathbf{C} + \lambda \mathbf{C}) \mathbf{x}_r = 0$  (zberiemeľný rozsah). Štvor 2 možnosti:

1.)  $d_r \leq 0 \Rightarrow \exists \lambda \in M \Rightarrow$  pre každé  $\lambda_1$ , pre ktoré  $(\mathbf{C} + \lambda \mathbf{C}) \mathbf{x}_r \leq 0$ , násobok

násobku násobky  $(\mathbf{C})$ .  $v_r < 0 \Rightarrow \lambda > -\frac{c_i}{v_r} = \bar{\lambda}_1$  a pre  $\lambda > \bar{\lambda}_1$  násobok násobku.

2.)  $d_r \neq 0 \Rightarrow \exists$  kladný násobok plánu  $\mathbf{x}_r$  ktorý násobí v každej plánovej

záloge a plánový násobok je na miere väčší než  $M$ . Vykonal sa 1 krok súčtu

určitej násobky  $\mathbf{x}_2 \rightarrow$  súčetný násobok násobku  $\mathbf{x}_1$ . Dôkaz je podobný ako pre  $\lambda_1$  a  $\lambda_2$  sú  $\lambda_1$ ) Časť intervalu  $(\underline{\lambda}_1, \bar{\lambda}_2)$  je skutočnosť,

-  $\forall \lambda \in (\underline{\lambda}_2, \bar{\lambda}_1)$  je optimálny násobok  $\mathbf{x}_2$ . Dôkaz je podobný ako pre  $\lambda_1$  a  $\lambda_2$  sú  $\lambda_2$ ) Časť intervalu  $(\underline{\lambda}_2, \bar{\lambda}_1)$  je skutočnosť,

-  $\langle \underline{\lambda}_2, \bar{\lambda}_1 \rangle$  je napäťová interval v hľadanej riešení,

- a  $\bar{\lambda}_1 \in (\underline{\lambda}_2, \bar{\lambda}_3)$ .  $\Rightarrow \bar{\lambda}_1 = \lambda_2$

Pre transformovanú násobku sú posledný násobok optimálne násobkov:

$$((\mathbf{C} + \lambda \mathbf{C})')' = (\mathbf{C} + \lambda \mathbf{C}) \geq 0 \quad \dots \text{ Akému násobku?}$$

$$\text{Násobok násobkov: } \lambda'_j = \lambda_j - \frac{c_i - \mathbf{c}' \mathbf{x}_r}{v_r} \quad \lambda'_j = \lambda_j - \frac{d_j}{v_r}$$

$$\lambda_2 = \sup_{v_j > 0} \left\{ -\frac{c_i}{v_j} \right\}$$

$$\bar{\lambda}_2 = \inf_{v_j > 0} \left\{ -\frac{c_i}{v_j} \right\}$$

Průběžný řízení kvadratických pravomočných funkcií platí:

$$y_s' = y_s - \frac{1 \cdot \text{Tr}}{\sqrt{s}} \Rightarrow y_s' > 0 \Rightarrow \lambda_2 \geq -\frac{\mu_s}{y_s'} \geq 0$$

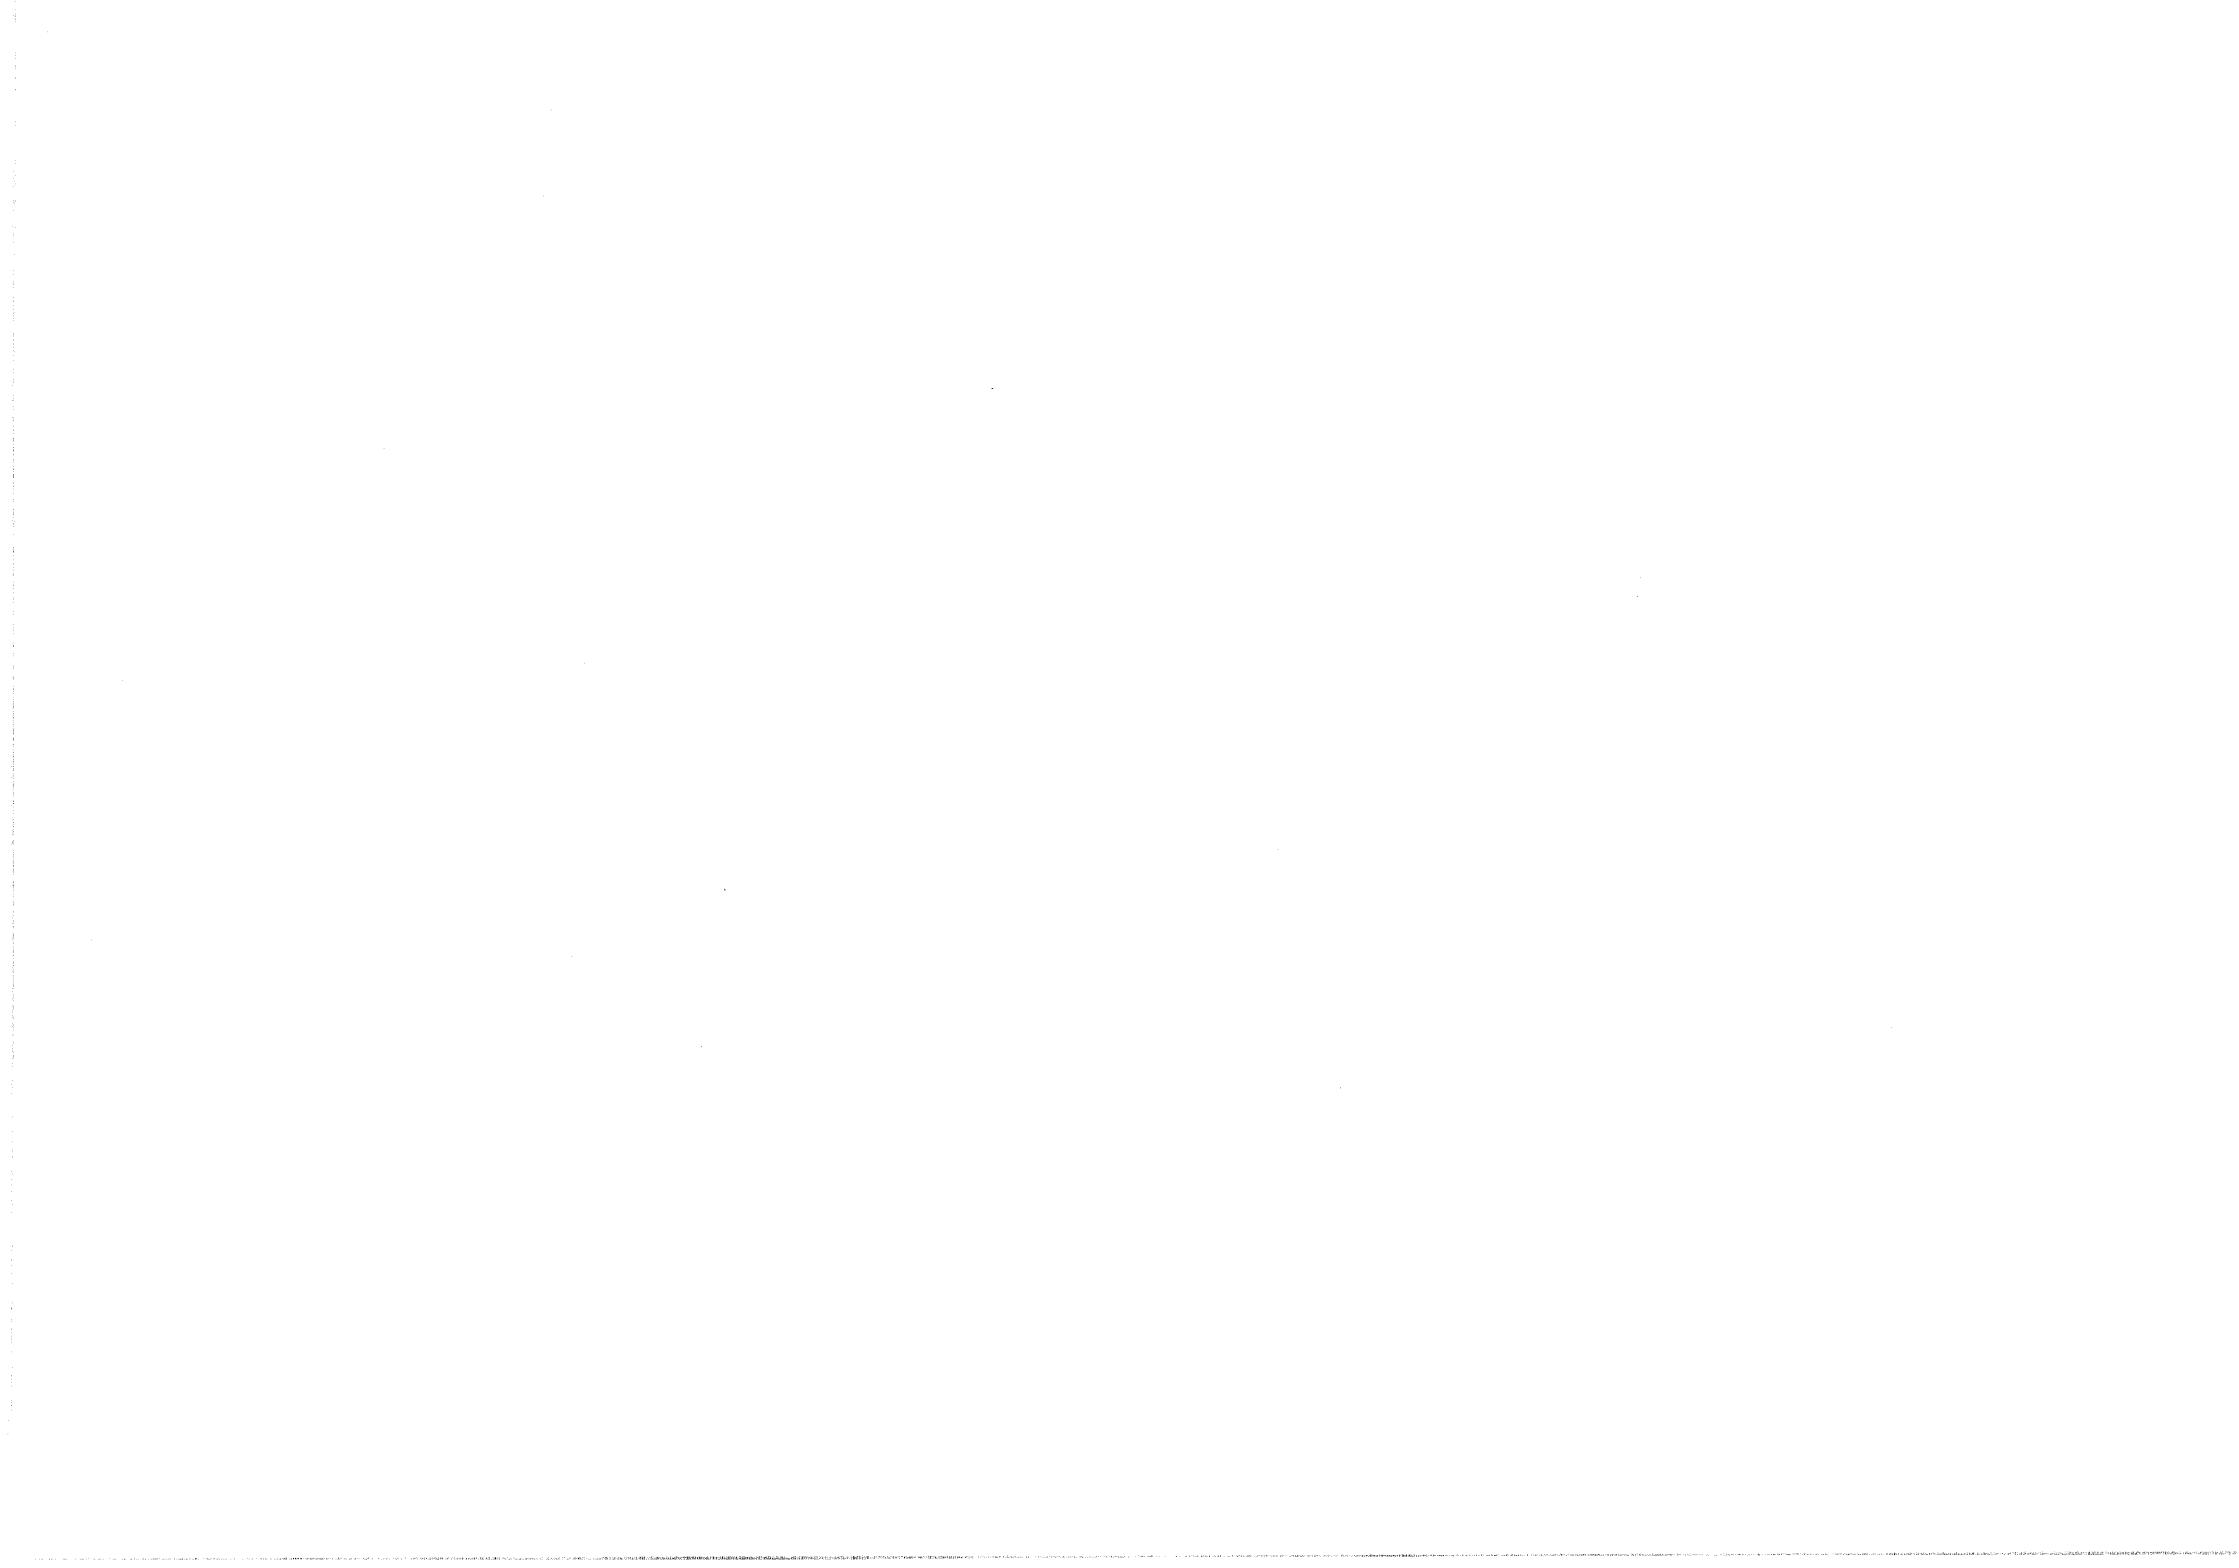
Při dleší správné předpokladu, že  $\bar{\lambda}_1 > \lambda_2 \Rightarrow \bar{\lambda}_1 > -\frac{\mu_s}{y_s'} \Rightarrow (\mu_s + y_s' \cdot \bar{\lambda}_1) > 0$   
speciálně rovněž:  $((\mu + \bar{\lambda}_1)y_s')' = (\mu + \bar{\lambda}_1)y_s'$  následuje:

$$((\mu_s + \bar{\lambda}_1)y_s')' = (\mu_s + \bar{\lambda}_1)y_s = (\mu_s' + \bar{\lambda}_1)y_s' = 0$$

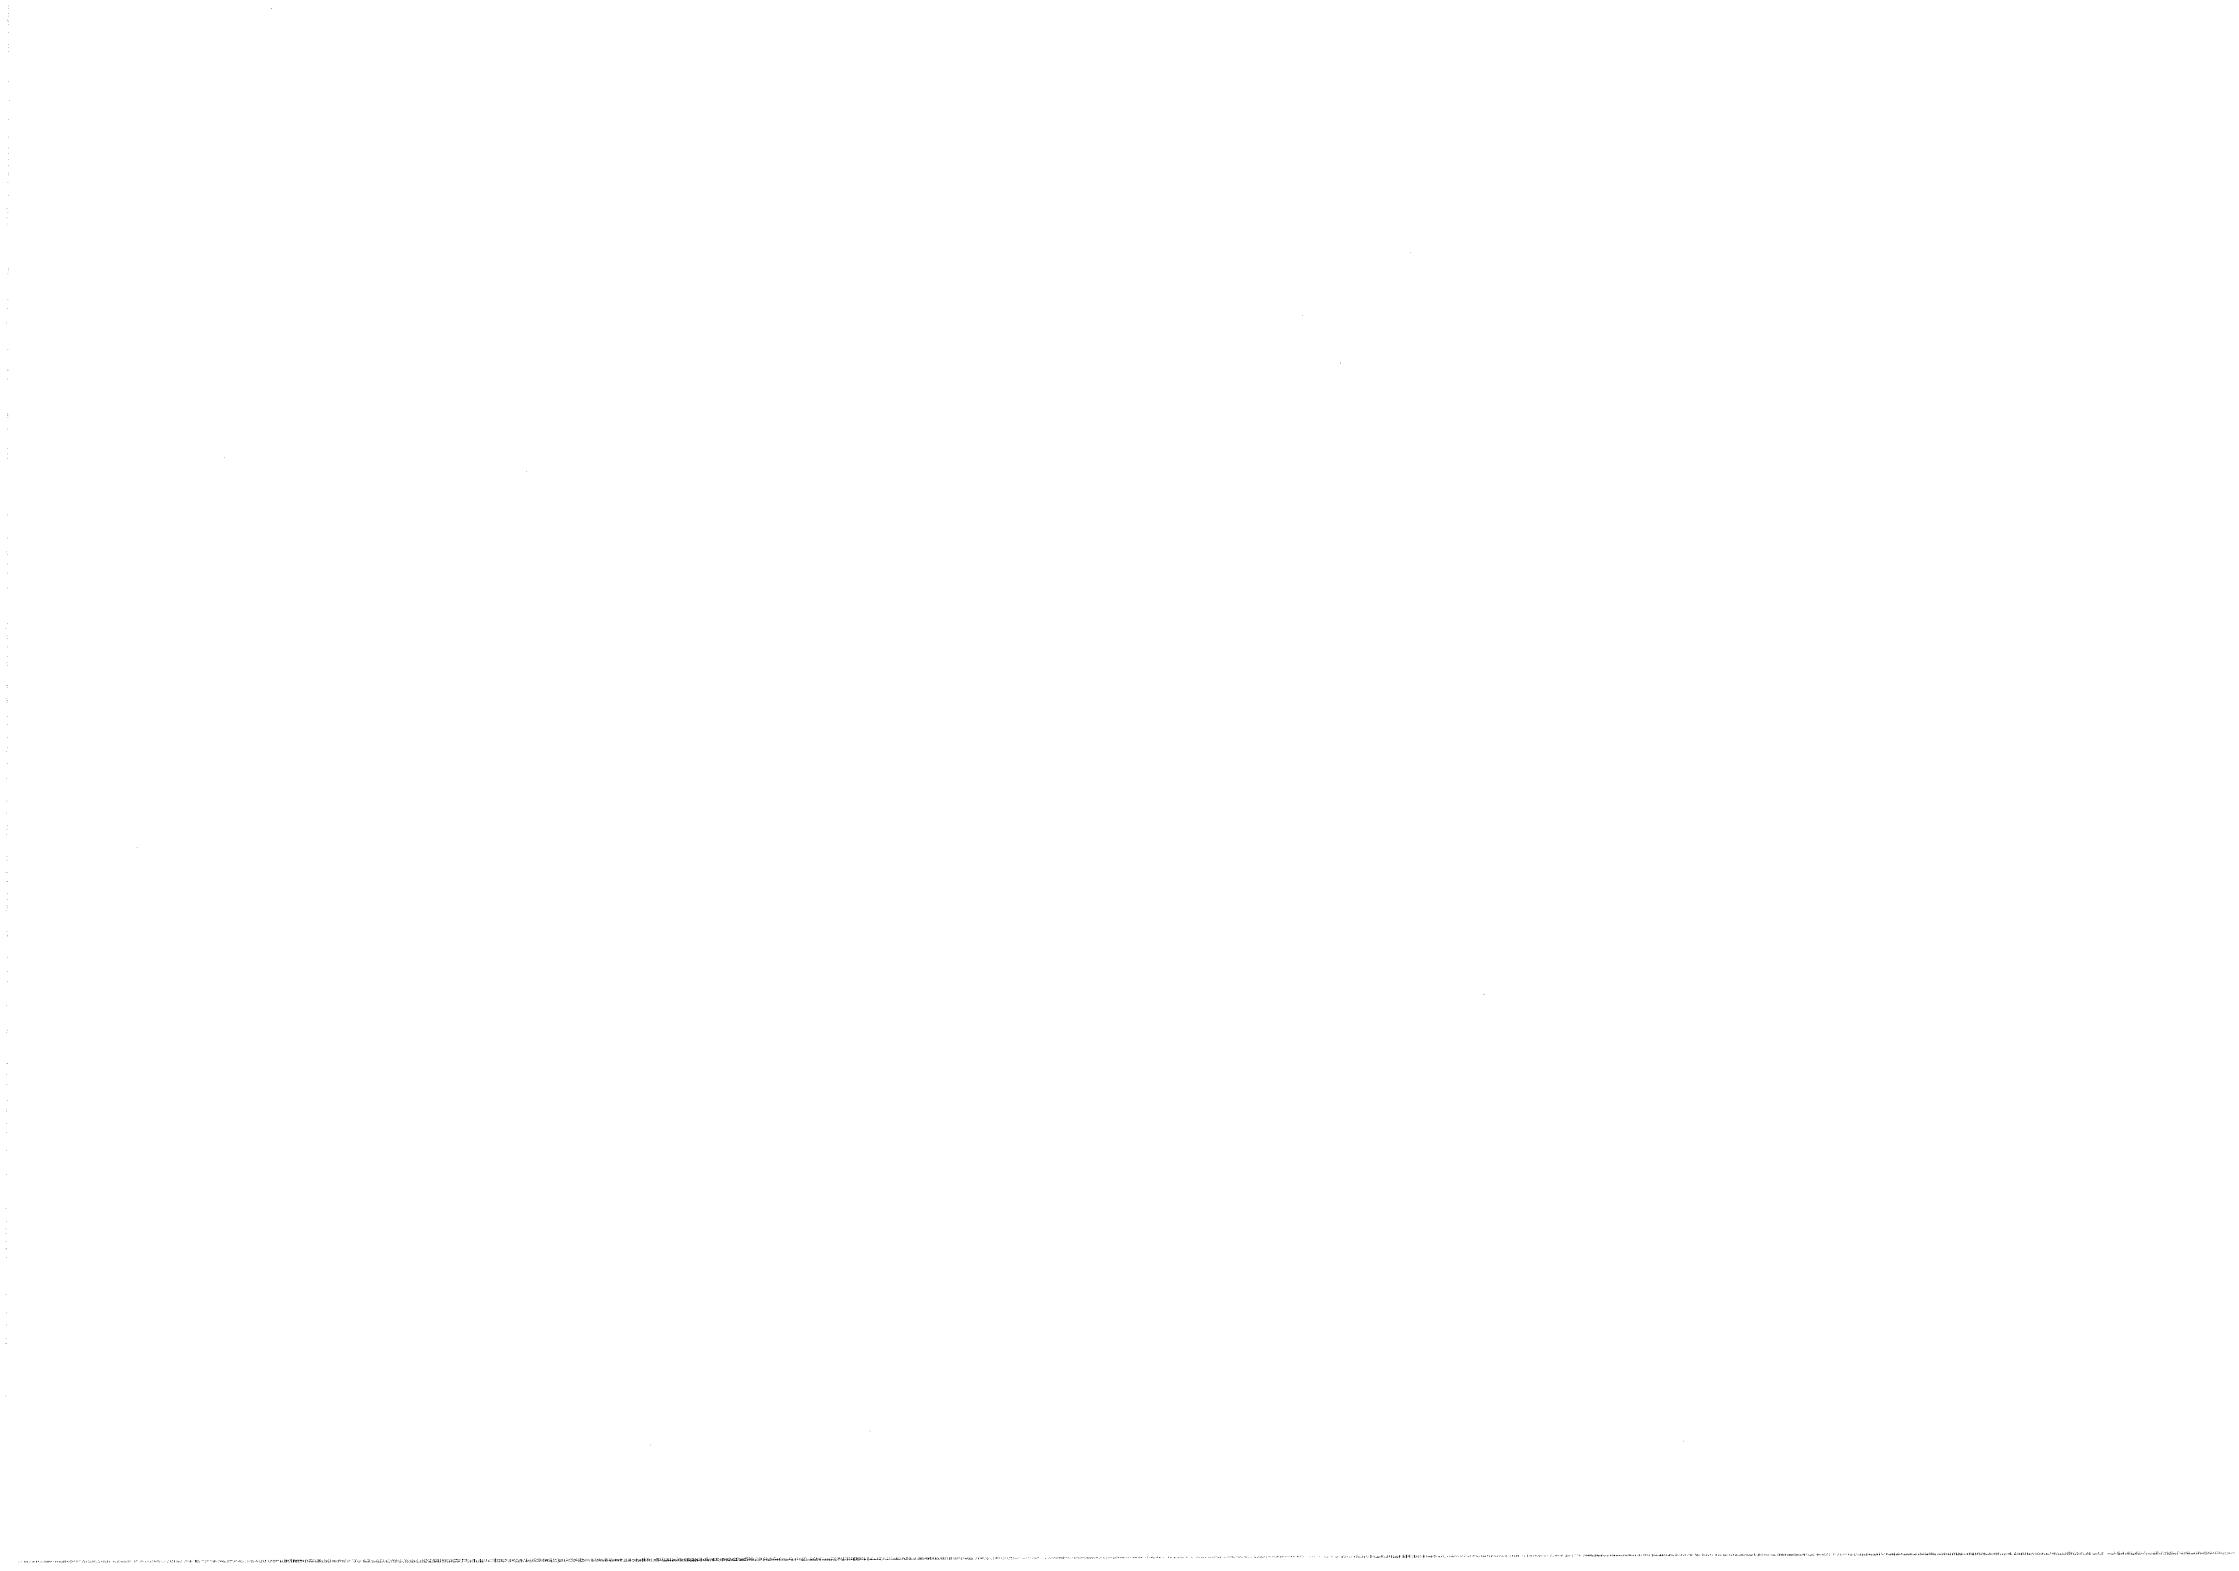
Průběžné řízení kvadratických pravomočných funkcií platí  $\mu_s' = \mu_s$  &  $y_s' = y_s$  (pouze výjimky)

$$\Rightarrow \text{spor } \{(\mu_s' + \bar{\lambda}_1)y_s) > 0\} \text{ násilné} \\ = 0 \}$$

Analogně pro  $\lambda_1$  (konečně).







$$y := x_2$$

$$\frac{4}{5}x + \frac{4}{3}y \leq 100$$

$$\frac{4}{5}x + y \leq 100$$

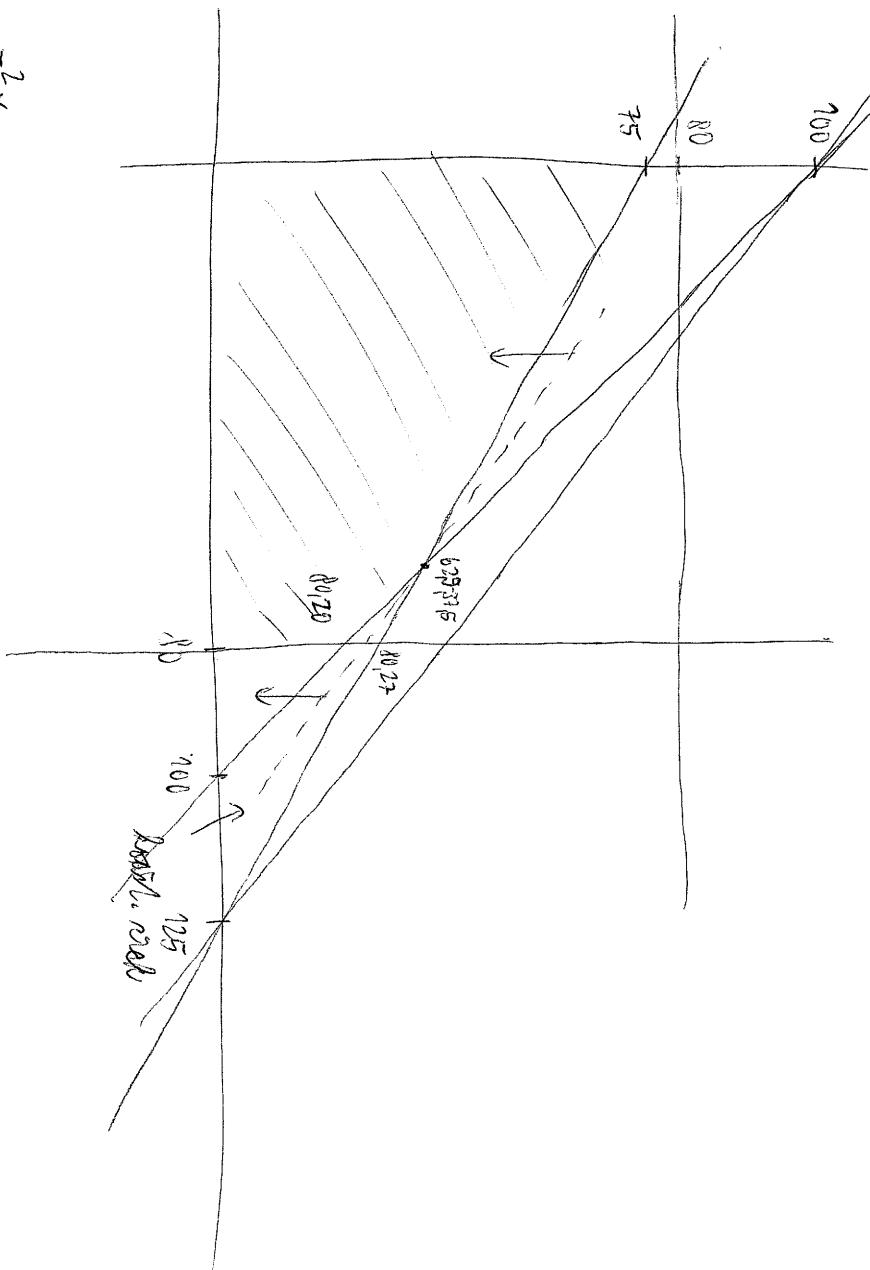
$$y = zisk_1 - \frac{2}{3}x$$

$$4000x + 6000y = zisk$$

$$x + y \leq 100$$

$$x \leq 80$$

$$y \leq 80$$

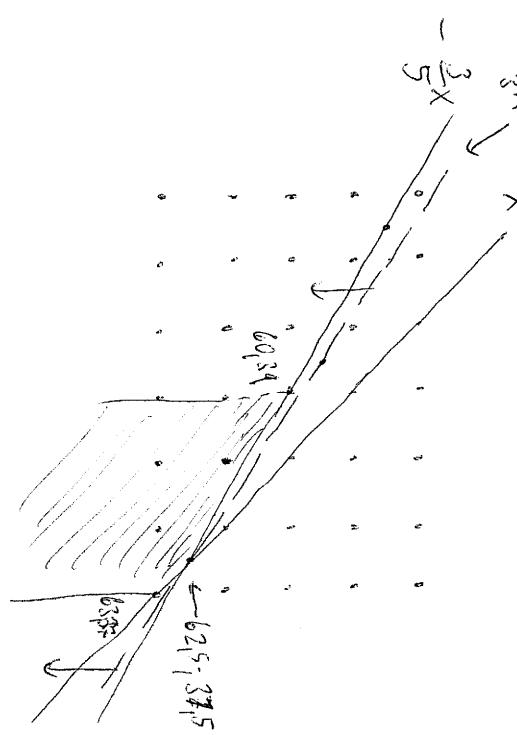


$$-\frac{2}{3}x - y$$

$$-\frac{3}{5}x - y$$

$$zisk_1 = \frac{2}{3} \cdot 60 + 39 = 79$$

$$zisk_2 = \frac{2}{3} \cdot 63 + 37 = 79$$



DFS si hlidame, jestli ohodnoceni danho vrcholu nepresahlo  $(n-1)/3$ , a pokud ano, tak ma zbytek stromu jiste mene nez  $(2n+1)/3$  vrcholu a v tomto miste muzeme graf rozdelit. Musi se jeste dokazat, ze takove rozdeleni bude odpovidat zadani, tj. v nejhorsim pripade ma prave prohlizeny vrchol dva potomky takove, ze je jejich ohodnoceni je  $(n-1)/3$ , tj. prave prohlizeny vrchol ma jiste  $(2n-2)/3 + 1$ , coz je prave rovno  $(2n+1)/3$ .

### 3) Zednický metr

Instance: ZM sestavajici z n segmentu o delkach  $x_1..x_n$  (prirozena cisla) spojenych po rade pomocí pantu a prirozeno cislo v.  
Otazka: Lze metr slozit do pouzdra o delce v?

Dokazte, ze ZM je NPU.

**Riešenie:** Prevedeme problem LOUPEZNICI na ZM. LOUP = mame n predmetu s ruznymi hodnotami, chceme je rozdelit na dve stejne cenne skupiny. Pro predmety s hodnotami  $x_1..x_n$ , definujeme instance ZM, kde delky segmentu budou  $v, v/2, x_1, x_2, \dots, x_n, v/2, v$ , kde v je dostatecne velke (napr. soucet vsech  $x_i$ ) a delka pouzdra bude v. Tato instance ZM je skutecne resitelna prave tehdys, pokud je resitelna puvodni instance LOUP.

### PISEMKA Z 31.1.2001:

- 1) Profesor Zweistein tvrdi, ze alg. na nalezeni SSK v orientovanem grafu lze zjednodusit nasledujicim zpusobem:
  - 1) vypustime fazi 2 (konstrukce GT)
  - 2) ve fazi 3 pracujeme s puvodnim grafem s tim, ze vrcholy bereme v poradi podle rostoucich casu opusteni  $f(i)$  z faze 1
- ma pravdu ?
- je profesor Zweistein intelligentnejsi nez Einstein ?

**Riešenie:** Samozrejme, ze pravdu nema. Protipriklad:



kde orientace v trojuhelniku je po smeru hodin. rucicek a horni hrana je zleva doprava, 1. faze zacne vlevo nahore, druhá faze (resp. treti) zacne vlevo dole (ma nejmensi  $f(i)$  - necht, def.) - druhá faze oznaci cely graf, coz zcela evidentne není SSK.

- 2) Necht  $G=(V,E)$  je orientovaný graf a  $w:E\rightarrow R$  vahova fce. Navrhnete polynomialni algoritmus, ktery rozpozna zda  $G$  obsahuje jednoduchy orientovany cyklus (tj bez opakovani vrcholu) negativni vahy (tj. soucet vah vsech hran cyklu je zaporny).

**Riešenie:** Dela se to pres nasobeni matic sousednosti na zaklade algoritmu z prvaku, ktery hledal sledy delky jedna, dva, ..., n (pouhym umocnovanim matici grafu). Pouzivame aritmetiku:  $a^0 = 0$ ,  $a^b = a+b$ . Pokud se v matici vyskytne zaporne cislo na diagonale, tak v grafu existuje prostra kruznice se zapornou vahou.

Na diagonale se muze v jednom miste objevit nejaka hodnota vicekrat, zajimaji nas ovsem pouze zaporne, protoze pokud se sled nekde krizi (prochazi vrcholem  $2x$ ), tak ho roztrhu na 2 kusy prave v tomto vrcholu a jeden z kusu musi byt zaporny (protoze cely sled byl zaporny) a to mohu opakovat, dokud nedostanu prostou kruznici.

- 3) Necht  $G$  a  $w$  jako vysle a necht  $s,t$  jsou z  $V$ . Uzazte, ze rozhodnout, zda v  $G$  existuje orientovana cesta (bez opakovani vrcholu) z  $s$  do  $t$  zaporne vahy je NPU problem.

**Riešenie:** Provedeme prevod z Hamilt. kruznice (nebo cesty) na tento problem, a to tak, ze mame neorientovany graf, kde mame najit Hamilt. kruznici (cestu). Z grafu udelame orientovany tak, ze kazdou hranu grafu puvodniho

nahradieme dvema orientovanymi (tam a zpet). Pak vybereme lib. vrchol i a ten zdvojime (dostaneme  $i_1$  a  $i_2$ ). Pak ohodnotime hranu vychazejici z  $i_1$  vahou  $-1$  a vsechny ostatni vahou  $-1$  (nebo tak aby to vyslo - to uz by se dopocitalo) a budeme hledat zapornou cestu z  $i_1$  do  $i_2$ . Tim je NP-uplny problem Hamilt. kruz. (cesta) preveden na nas problem => nas problem je NP-tezky. To ze to je NP je triv. (existuje polyn. velky certifikat na overeni - prave ta zaporna cesta). Z toho vseho dostaneme, ze nas problem je NP-uplny.

**Riešenie (yahoo):** Problem je jiste NP (certifikat je cesta z vrcholu s do t a tu v O(pocet hran) zjistim, zda je její vaha zaporna).

Na cvicenicich byl jako posledni priklad tato uloha : Je dan orient. ohodnoceny graf (i zap. hran) a dva vrcholy s, t. Otazka: Existuje z vrcholu s do vrcholu t orient. cesta vahy nejvyse k? Dokazali jsme, ze je to NPU problem. Pak tento problem (oznamim ho C) transformujeme na nas takto.

Vyvorim uplne stejny graf jako je instance problemu C tj. uplne stejne vrcholy, hranu, ohodnoceni. Navic k nemu pridam novy vrchol w, a hranu od vrcholu t do vrcholu w. Tuto hranu ohodnotim cislem  $-k-1$  (kde k je cislo z instance problemu C).

Transformace je polyn. (je  $O(n+m)$ ).

Je trivka dokazat, ze jestlize v grafu problemu C existovala orient. cesta z vrcholu s do vrcholu t vahy nejvyse k, pak v mem novem grafu existuje cesta z vrcholu s do vrcholu w zaporne vahy (dik hrane z t do w). Naopak je to stejne tak jednoduchy. Existuje-li cesta z s do w zap. vahy, pak v puvodnim grafu existuje cesta z s do t vahy nejvyse k.

### PISEMKA Z 9.1.2004

- 1) firma MatFyz-Oil vlastni ropne pole s n vrty, u kazdeho vrtu mame souradnice  $(x_{-i},y_{-i})$  kde pro  $i \neq j$  jsou  $x_{-i} \neq x_{-j}$ . Ropoved stavi rusky subkontraktory, ktery umi stavet jenom rovne (ale zato umi vyvest ropu ze zeme rovnou do trubky). Takze hlavní ropoved povede rovnobezne s osou x a kolmo na nej pujdou pripojky od jednotlivych vrtu.  
Ukol: navrhnete algoritmus který spocita optimalni polohu hlavního ropovedu (optimalizacni kriterium je minimalizovat celkovou delku pripojek) s co nejlepší casovou slozitosti.

**Riešenie:** Jde o nalezeni medianu mezi  $y_{-i}$ ...takze  $O(n)$

- 2) Jaka je slozitost HK pro nadkubicke grafy (nadkubicky graf: Pro kazdy vrchol v plati  $\deg(v) > 3$ )?  
Navrhnete polynomialni algoritmus, nebo dokazte ze je NPU.

**Riešenie:** Je to NPU.. nejlepe prevedenim na Ham kruznici normalni (rozdvojeni podmerecnych vrcholu a vhodne pridani rozumneho podgrafu, aby se zvedl stupen vrcholu), nebo lze celkem jednoduse a s mensim rizikem chyb recyklovat dukaz z prednasky pro HK prevedem VP (s vhodnou upravou pro zvyseni stupnu).

- 3) Jaka je slozitost NM pro acyklickie neorientovane grafy?  
Navrhnete polynomialni algoritmus, nebo dokazte ze je NPU.

**Riešenie:** Lze v  $O(n+m)$  pomocí DFS...v maximalni nez. mnozine jsou listy a nejsou jejich rodice...induktivne se da dopocitat její velikost. (ale chtelo to trochu prodokazovat)

### PISEMKA Z 14.1.2004 (v predchdzich letech uz byla)

- 1) Mame  $G=(V,E)$ . Vezmeme jeho komponentovy graf  $G'=(V',E')$  kde kazdy vrchol predstavuje jednu SSK a hranu jsou mezi  $v_1, v_2$ , pokud v  $G$  vede hrana z nejakeho vrcholu z  $v_1$  do nejakeho vrcholu ve  $v_2$ . Ma se ukazat, ze:  
 $(A,B) \in E' \Rightarrow f(B) < f(A)$

## 1. Gomoryho Ijoritamus

$$(1) \max_{\mathbf{x}} \mathcal{L}(\mathbf{x})$$

$$\mathcal{M}_c = \{\mathbf{x} \in \mathbb{R}^n \mid A\mathbf{x} = b, \mathbf{x} \geq 0, x_i \in \mathbb{Z}, i \in C \subseteq \{1, \dots, n\}\}$$

$$h(A) = m_1 \quad 1 \leq m_1 \leq n \quad A \in \mathbb{R}^{m_1 \times n} \quad b \in \mathbb{R}^{m_1}$$

$$M = \{x \mid Ax = b, x \geq 0\}$$

1) měříme někam (2): a) měříme nějakou, protože  $M = \emptyset \Rightarrow M_c = \emptyset \rightarrow$  konc.

Dreiecksplättchen:  $M \geq \lambda \cdot d_{\text{min}}^2$ ,  $\alpha < \sigma$ .

Unter großgedruckten Romanen liegt wahrscheinlich der T. Gom. dgl.

b)  $\exists \mathbb{X}^{\text{opt}} \in \mathcal{M}_C \rightarrow \mathbb{X}^{\text{opt}}$  je reálné (1)  $\rightarrow$  koncov

$$\text{Training } k = \min_{i \in C} \left\{ x_i^{\text{out}} \in \mathbb{Z} \right\}$$

## Oreophylax

Druhá vlastností algoritmu musí platiť  $x_i = C^T \mathbf{x}_i$ ,  $\forall i \in \{1, \dots, n\}$ .

Let my readers no longer marvel me now:  $X_k = d_{k0} - \sum_{j \in N} d_{kj} X_j$  ( $X_i = d_{i0}$ )

$$(3) X_k = [d_{k0}] + \boxed{d_{k0}} - \sum [d_{ki}] X_i - \sum [d_{ki}] X_i \Rightarrow -\boxed{d_{k0}} + \sum [d_{ki}] X_i = -X_k + [d_{k0}] - \sum [d_{ki}] X_i$$

11

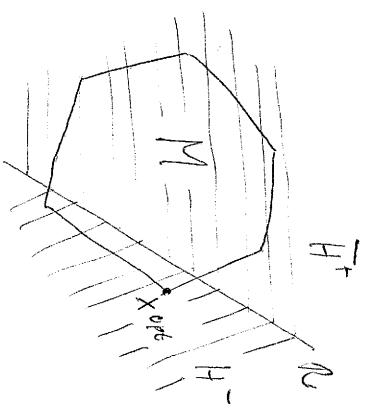
$$(4) \quad R = \{ x \in \mathbb{R}^n \mid -\boxed{d_{k_0}} + \sum_{j \in N} [\boxed{d_{kj}}] x_j = 0 \}$$

Vefte

Dyrektorium R. woj. Śląskiego połączony

$$H^+ = \{ x \in \mathbb{R}^n \mid -\frac{b_{kj}}{d_{kj}} + \sum_{j \in J_{kN}} x_j < 0 \}$$

plast x opt eH<sup>-</sup> n M<sub>c</sub>C<sub>H<sup>+</sup></sub>.



## 6. cvičení

- Definujme problém LOUP (loupežníci) následovně:

Instance: Přirozená čísla  $a_1, \dots, a_n$

Otázka: Existuje podmnožina  $T$  množiny indexů  $S = \{1, \dots, n\}$  taková, že  $\sum_{i \in T} a_i = \sum_{i \in S \setminus T} a_i$ . Dokážte, že LOUP je NP-úplný problém.

Certifikat: Mnoziny.

Pomocí SP.

Řešit SP pro b nebo  $A \cdot b$  je ekvivalentní.

$$b >= 1/2A \dots b' = b$$

$$b < 1/2A \dots b' = (A - b)$$

$$a_{\{n+1\}} = b' \cdot (A - b) = 2b' \cdot A$$

$$SP: K = \{a_1, \dots, a_n\}, b$$

Umím počít.

$$LOUP(\{a_1, \dots, a_n\} + \{a_{\{n+1\}}\})$$

$$\Rightarrow SP \text{ má řešení. } SUM(S \setminus \{a_{\{n+1\}}\}) = b'$$

$$SUM(S)a_{\{i\}} + a_{\{n+1\}} = b' + SUM(K \setminus S)a_{\{i\}} + a_{\{n+1\}}$$

$$SUM(O)a_{\{i\}} = SUM(O)a_{\{j\}}$$

$$SUM(O)a_{\{i\}} = (A + 2b \cdot A)/2 = b' = SUM(O)a_{\{j\}}$$

$$At' a_{\{n+1\}} \in O. Pak P je řešením SP.$$

$\Leftarrow$

$$LOUP(\{a_1, \dots, a_n\} + \{a_{\{n+1\}}\}) \text{ má řešení}$$

$$SUM(O)a_{\{i\}} = SUM(O)a_{\{j\}}$$

$$SUM(O)a_{\{i\}} = (A + 2b \cdot A)/2 = b' = SUM(O)a_{\{j\}}$$

$$At' a_{\{n+1\}} \in O. Pak P je řešením SP.$$

- Nejkratší cestu mezi dvěma vrcholy v neorientovaném váženém grafu lze nalézt pomocí Dijkstrova algoritmu, pokud jsou zadány váhy na hranách nezáporné. Jak se změní složitost této úlohy, pokud povolíme, aby byly váhy záporné?

NP-C. Hamiltonovská cesta je NP-C (pomocí HK). A toto lze pomocí Hamiltonovská cesty (váhy volím -1)

Nejkratší cesta kde váhy celá císla, problem OptPath.

$$1) \quad HK < HC.$$

Hamiltonovská cestka (HC) je NP-C.

Certifikát seznam vrcholu cesty

Mam neor. graf G. A chci HK.

At umím HC. Vezmu G, volim vrchol x. Přidam x' a spojim ho s vrcholem G tz.  $e(x,y) \Leftrightarrow e(x',y), e_{...} \text{hrana.}$

Hledam HC(x,x').

Pokud ex. HC, tak v posledním kroku místo do x' přejdu do x a mam HK. Pokud ex. HK, tak v posledním kroku místo do x přejdu do x' a mam HC.

$$2) \quad HC < OptPath.$$

Pokud umím najít nejkratší  $\Leftrightarrow$  umím rozhodnou, zda ex. délky nejvys k.

$\Rightarrow$  jen porovnám délku cesty s  $k_{\underline{k}}$

$\Leftarrow$  snízováním  $k_{\underline{k}}$  se doberu k minimu.

pulním interval  $\underline{k} \leq k \leq (max vaha(v)) * (n-1)$ , pak připadne  $k / 2$  a dal bud  $\underline{k} / 2 + \underline{k} / 4$  nebo  $\underline{k} / 4$  atd.

A po  $\log_2(k)$  kroicích mame min, je to tak? To ale zavisi na  $\underline{k}$  nemelo by se to spis delat jinak? Omezit to pomocí polynomu s n. Co když je treba  $\underline{k} = 2^{\lceil 2^{\lceil n \rceil} \rceil}$ ?

Rozhod. problem má certifikát danou cestu. Je to OK důvod pro nalezení OptPath do NP?

### Dоказ:

Ne  $x^{\text{opt}}$  plati  $x_j^{\text{opt}} = 0$ ,  $j \in N$ . Po dosadení do (4) dostaneme

$$-\boxed{d_{k0}} + \sum_{j \in N} \boxed{d_{kj}} \cdot 0 = -\boxed{d_{k0}} < 0 \Rightarrow x^{\text{opt}} \in H^-.$$

Zároveň  $x \in M_c$  kultivace nevse u dosáhne do (3):

$$-1 \leq -\boxed{d_{k0}} \leq -\boxed{d_{k0}} + \underbrace{\sum_{\substack{j \in N \\ j \geq 0}} \boxed{d_{kj}}}_{\in \mathbb{Z}} x_j = -x_k + \underbrace{[\boxed{d_{k0}}]}_{\in \mathbb{Z}} - \underbrace{\sum_{j \in N} [\boxed{d_{kj}}] x_j}_{\in \mathbb{Z}}$$

### Poznámka:

Praktické NLP ťažením krokov kultivace musíť niesť názov  $\max_{M \cap H^+} C^T X$  (praktické kult. ťaženie)

zahrnuje pravdepodobnosť

$$-\boxed{d_{k0}} + \sum_{j \in N} \boxed{d_{kj}} x_j - x_{n+1} \geq 0 \rightarrow x_{n+1} = -\boxed{d_{k0}} + \sum_{j \in N} \boxed{d_{kj}} x_j$$

A. g. mzdoh

Praktické NLP ťažením s tými (kultivuj kultúrnych premenív) je jedinou riadom krokov  $-\boxed{d_{k0}}$ , kde kultiv. ťaž. mzdoh na kultúrky. Po ľahnej transformácii kultivuj posledný riadok opäť mymehome.

Napríklad novou NLP ťažencom krokov kultivace niesť názov  $\max_{M \cap H^+ \cap H_1 \cap \dots \cap H_n} C^T X$ .

### Konečnosť

Na praktickom ťažení M je obmedzené v  $C$ , ťaž. ťaž. konštanty

pedestálom možné uholby násamej naprievom DSM, kultiv. mzdohame ťažku grafikou DSM (M-mzdoh).

### Definícia:

Praktické  $X \in \mathbb{R}^n$  nazívame tezikograficky klasifik (M-klasifik), ak

neu  $i \in \{1, \dots, n\}$  plati  $x_i \neq 0$  plati  $x_i > 0$ . Časť:  $X > 0$

Príklad:  $X = (0, 0, 1, -100, -200, -300) \succ 0$



## Definición:

zpravidla, řeč k jí textologicky větší skupině (naučného) vývoje.

Družinu  $\tilde{X} \equiv (\mathbb{C}^r X, X) = (x_0, X)$ , kde  $X \in M$  a  $X$  budeme nazývat rozšírením rešení NLSky (2). Množinu všech rozšírených rešení nazívame  $\tilde{M}$  a málo  $\tilde{M} = \{(x_0, X) \in \mathbb{R}^{n+1} \mid X_0 = \mathbb{C}^r X, X \in M\}$ .

### Definição:

\* nævne Lexikografiskt optimum (L-optimaJnum) resonans (2), skrivel

### Poznámky:

卷之三

$$\begin{aligned} \max_{\mathcal{M}_C} \quad & \mathbb{E}[\mathbb{X}] + \mu \text{sd}_{\mathbb{X}} = X_0 \\ \mathcal{M}_C = \{ & (\mathbb{X}, \mathbb{X}') \in \mathbb{R}^{n+m} \mid A\mathbb{X} + \mathbb{X}' = \mathbf{b}, \quad \mathbb{X}, \mathbb{X}' \geq 0, \quad X_{ij}, X'_{ij} \in \mathbb{Z}, \quad x \in C \} \\ C = \{ & \theta_1, \theta_2, \dots, \theta_{n+m} \}. \end{aligned}$$

Dreigipfelklast = Dreiklang mit gleicher Amplitude,  $C < 0$ .

$$M = \{x, x' \mid A(x + x' = b; x, x' \geq r)\} \Rightarrow x' = b - Ax$$

zurückgeworfene:  $X_0 = C - (-C^t X)$

Výroba výrobků  
čl. - ředitel:

$x_0$	$x_1$	$\dots$	$x_n$	$R_n$
		$-a$		$R_0$
	$-E$			
		$a$	$0$	

Schulte T. normale L-normen, Thm, ob platti

$$R_j \succ r_{\text{max}} \quad j = 1, \dots, n.$$

6

Xnum  
A  
B

Abulpha für Normalbau.

## Definición

Solvability  $T$  normative L- $n$

A hand-drawn diagram consisting of two intersecting lines forming a cross. Below the intersection point, there is a polygonal shape resembling a pentagon or irregular hexagon. Inside this shape, the numbers 0, 3, 4, and 5 are written vertically.

2

Salvador T. Madero, Lázaro Cárdenas, Alfonso Robles

卷之三

三

## Tvrdenie:

Nedegenerované príručné hľadáku máme n r -optimálny hľadáku je h -optimálny.

### Bez dôkazu

Máme nás 3 vety h -metódy pre 1. krok (následne následne následne h -optimálny).

### 1. veta h -metódy

Ak platí  $b > 0$  (resp.  $b \geq 0$  v E -mobilármiu násobok), potom máme h -optimálne riadenie ( $x^{opt} = b$ ,  $x^{opt} = 0$ ).

Dôkaz:

Rovnaky ako na DS M.

### 2. veta h -metódy

Ak existuje r hľadáku, ňo  $b_r < 0$ ,  $a_{rj} \geq 0$  ( $j=1, \dots, m$ ); potom  $\exists j \in \{1, \dots, m\}$  sú nezároveň máčene (2) v Aekar až (1).

### 3. veta h -metódy

Nachádzame sklenené nedopokoľky 1. až 2. vety h -metódy.

Premaďom  $r \equiv \min \{i \in \{1, \dots, m\} \mid b_i = 0\}$ , kev.  $\min \frac{R_j}{a_{rj}} = \frac{R_r}{|a_{rr}|}$ .

Jednoznačne určený pravik  $a_{rr} \neq 0$  je pravdom.

Or transformovať hľadáku do hľadáku s r -optimálnym hľadákom.

Dôkaz:

$$\text{II. čl: } R'_r = \frac{\sum_{j=1}^m a_{rj} b_j}{\sum_{j=1}^m a_{rj}} > 0 \quad \text{II. čl: } R'_j = R_j - \frac{R_r}{\sum_{j=1}^m a_{rj}} > 0$$

2)  $a_{rj} \geq 0 \rightarrow 0 <$

3)  $a_{rj} < 0 \cdot 2 \leq 0 \Rightarrow$

$$\Rightarrow \frac{R_r}{a_{rr}} > \frac{R'_r}{a_{rr}} \Rightarrow R'_r > \frac{R_r \cdot a_{rj}}{a_{rr}} \Rightarrow R'_j > 0 \Rightarrow h - optimálne hľadáku$$

$$\text{II. čl: } R'_0 = R_0 - \frac{R_r \cdot a_{r0}}{\sum_{j=1}^m a_{rj}} < R_0 \quad \square$$

Poznámka:

h -metóda je konácia, pretože máme konáciy pravik ktorí sú plati  $R'_0 < R_0$  v Aekar sú následne máčene hľadáku do hľadáku, ktorí sú akor máčiaci.

## Metody řešení vektorového programování

### 1. Metody průběžných směrů (gradientní)

Výplňte se průběžnou řešenou sloužící a) kladné směr, nebo funkci f(x),  
b) kladné dílčí řešení

### 2. Metody relaxace na K-T podmínkách

Výplňte w kladná řešení programu:  $\min_{\mathbf{x}} \{ \mathbf{x}^T C \mathbf{x} + \mathbf{p}^T \mathbf{x} \}, \quad M = \{ \mathbf{x} \mid A \mathbf{x} \leq \mathbf{b}, \mathbf{x} \geq \mathbf{0} \}$

### 3. Metody vektorové approximace (metody nejlepších reziduí)

Mozíme řešit vektorové úlohy takzvanou "ředovodcovou" metódou (řešení polyedrovou) w rámci nového řešení. Objektiv optimální řešení w množinu řešení  
OK.

### 4. Metody vektorové approximace

## Metoda Franka a Wolfe

$$\text{Uloha: } \min_{\mathbf{x}} f(\mathbf{x}), \quad M = \{ \mathbf{x} \in \mathbb{R}^n \mid A \mathbf{x} \leq \mathbf{b}, \mathbf{x} \geq \mathbf{0} \}, \quad A \in \mathbb{R}^{m \times n}, \quad \mathbf{b} \in \mathbb{R}^m$$

$f$  - konvexní a má správné 1. partiální derivace ( $\triangleright M$ ,  $\mathbf{0}$ -obsahuje množinu).

### Předpoklad:

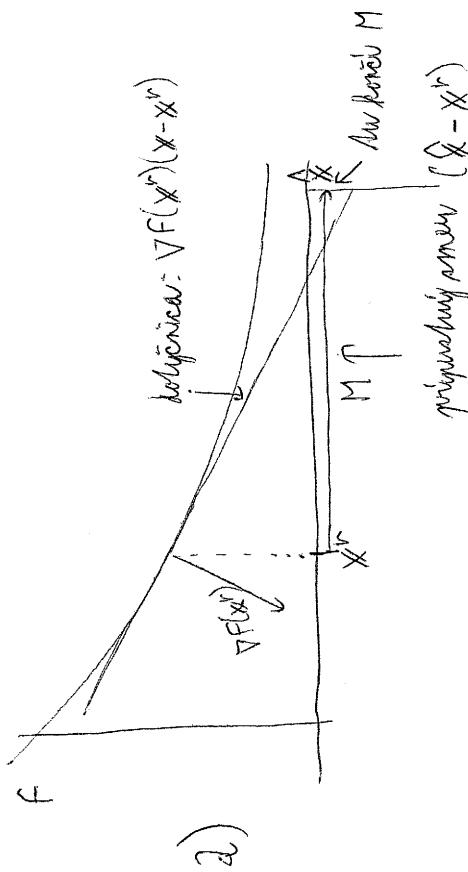
Funkce  $\nabla f(\mathbf{x}^r)(\mathbf{x} - \mathbf{x}^r)$  je reálna obdobou na  $M$  pro  $\mathbf{x} \in M$ .  
(tato požadavky splňují, když  $M$  ohraničené.)

### Náplň:

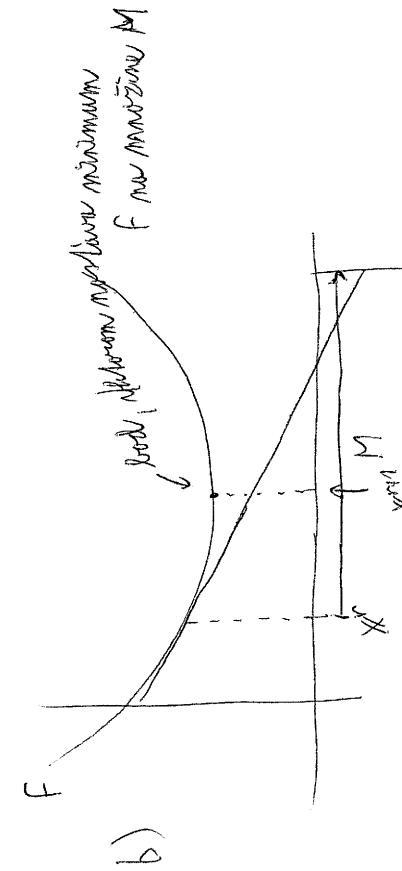
Výplňte se nachází  $M$ . Řešení  $\min_{\mathbf{x}} \Theta = \nabla f(\mathbf{x}) \Rightarrow M = \emptyset \Rightarrow$   
 $\Rightarrow$  reálná řešení nemá řešení

množina řešení řešení nachází  $\mathbf{x}^* \in M$

... notwendige, nach  $\hat{x}^r \in M$ . D.h.:



$$\begin{aligned} F(\hat{x}^r + \lambda(\hat{x} - \hat{x}^r)) \\ \text{durch Kehrw.: } \hat{x} - \hat{x}^r \\ \hat{x}^{r+1} = \hat{x} \end{aligned}$$



Sei  $\hat{x}^r \in M$ .

Dann ist  $\min_M Vf(\hat{x}^r)^T(\hat{x} - \hat{x}^r)$  durch notwendige opt. müssen der  $\min_M Vf(\hat{x}^r)^T \hat{x}$ ,

bedeuten nur der nullvektor. D.h. min  $M Vf(\hat{x}^r)^T \hat{x}$ .

D.h. notwendige Bedingung opt. müssen  $\hat{x} \in M$ . D.h.:

$$Vf(\hat{x}^r)^T(\hat{x} - \hat{x}^r) \leq 0, \quad \forall \hat{x} \in M, \quad Vf(\hat{x}^r)^T(\hat{x} - \hat{x}^r) \leq 0.$$

1. Vektor:

## 2. Veta:

Nech  $\nabla F(\hat{x}^r)^T (\hat{x} - \hat{x}^r) < 0$ ,  $\nabla F(\hat{x})^T (\hat{x} - \hat{x}^r) = 0$ , potom platíme  $\hat{x}^{r+1} = \hat{x}$ ,  
platíme také  $F(\hat{x}^{r+1}) \leq F(\hat{x}^r)$ .

## Dоказat:

Načádajme, že  $f(\hat{x}^r + \lambda(\hat{x} - \hat{x}^r))$  pro  $\lambda \in (0, 1)$ .

$$\varphi(\lambda) = f(\hat{x}^r + \lambda(\hat{x} - \hat{x}^r)), \quad \lambda \in (0, 1)$$

$$\varphi'(\lambda) = \nabla f(\hat{x}^r + \lambda(\hat{x} - \hat{x}^r))^T (\hat{x}^r - \hat{x}^r)$$

$$\varphi'(0^+) = \nabla f(\hat{x}^r)^T (\hat{x} - \hat{x}^r) < 0 \Rightarrow \varphi'(0) \leq 0 \Rightarrow \varphi(0) \leq \varphi(\lambda^*)$$

zároveň platí pro  $\lambda^* > 0$

Platíme následující, že platí  $\min_{\lambda \in (0, 1)} \varphi(\lambda) = \varphi(1)$ .

Pro faktur uprostřed pravidelnosti, tedy že  $\exists \lambda \in (0, 1)$  tak, že  $\varphi(\lambda) < \varphi(1) \Rightarrow$

$$\Rightarrow f(\hat{x}^r + \lambda(\hat{x} - \hat{x}^r)) < f(\hat{x}).$$

$$\begin{aligned} 0 > f(\hat{x}^r + \lambda(\hat{x} - \hat{x}^r)) - f(\hat{x}) &\geq \nabla f(\hat{x})^T (\hat{x}^r + \lambda(\hat{x} - \hat{x}^r) - \hat{x}) = \\ &= \underbrace{(1-\lambda)}_{\geq 0} \end{aligned}$$

## 3. Veta:

Nech  $\nabla F(\hat{x}^r)^T (\hat{x} - \hat{x}^r) < 0$ ,  $\nabla F(\hat{x})^T (\hat{x} - \hat{x}^r) = 0$ , potom definujeme

$\hat{x}^{r+1} \equiv \hat{x}^r + \lambda_r (\hat{x} - \hat{x}^r)$ , platíme  $f(\hat{x}^{r+1}) \leq f(\hat{x}^r)$  a  $\lambda_r$  je maximální  
rozdíl  $\nabla F(\hat{x}^r + \lambda(\hat{x} - \hat{x}^r))^T (\hat{x} - \hat{x}^r) = 0$ .

## Dоказat:

Načádajme  $\nabla F(\hat{x}^r + \lambda(\hat{x} - \hat{x}^r))^T (\hat{x} - \hat{x}^r)$  je nejdešší méně než  $0$ .

Platí rovněž je faktur větší než  $\varphi'(\lambda)$ .

Dokážeme  $\varphi'(0) = \nabla F(\hat{x}^r)^T (\hat{x} - \hat{x}^r) \leq 0$ , platíme  $\lambda_r > 0$ ,  
a  $\varphi'(1) = \nabla F(\hat{x})^T (\hat{x} - \hat{x}^r) > 0$ , musí  $\exists \lambda_r \in (0, 1)$  tak, že  $\varphi'(\lambda_r) = 0$ ,

A. f.  $\nabla F(\hat{x}^r + \lambda_r(\hat{x} - \hat{x}^r))(\hat{x} - \hat{x}^r) = 0 \Rightarrow$  multi amer  $x_r$  take, so  $\hat{x}^{r+1} = \hat{x}^r + \lambda_r(\hat{x} - \hat{x}^r) \in M$ .

$$F(x^r + \lambda_r(\hat{x} - \hat{x}^r)) < F(\hat{x}^r), \text{ telor } \min_{\{0,1\}} \psi(x) = \psi(x_r)$$

$\infty$

$$\text{plusz } \psi'(x_r) = 0.$$

Algorytmus (obmazne konsolidator)

Uvodny krok: Rozjime  $\min_M \Theta$ . W multimediu  $\rightarrow$  koniec,  $M = \emptyset$ .

Bezny krok r =

1. Rozjime  $x^r \in M$ . Nek optimale retezce nelyby  $\min_M F(\hat{x}^r)^T(\hat{x} - \hat{x}^r)$  jen  $\hat{x} \in M$ .
2. Ak je  $\nabla F(\hat{x}^r)^T(\hat{x} - \hat{x}^r) = 0$ , potom je  $\hat{x}^r$  opt. retezce v konte.
3. Ulo je  $\nabla F(\hat{x}^r)^T(\hat{x} - \hat{x}^r) < 0$  a  $\nabla F(\hat{x})^T(\hat{x} - \hat{x}^r) \leq 0$ , potom  $\hat{x}^{r+1} = \hat{x}$ , ir  $i = r+1$  chodna r.

## Cirgavova - konv.

o rozvoj klaučov až po II. sv. válce (samočinné počítací)

obecná lit.

A. Lásček a kol.: Optimalne programovanie (1983) (1)

M. Maňas: Optimizačné metody (1979)

E. Polak: Computational methods in optimization (1971)

D. G. Luenberger: Introduction to linear and nonlinear programming (1973)

## Dělení optimalizačních disciplín

Def 1: Níže máme  $\max_{x \in M} (\min) f(x)$ , kde  $f(x): \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $M \subset \mathbb{R}^{m \times n}$

základními nároky na matematické optimizační metody (mat. programování)

### I. Kriterium

a) objektiv optimálníace -  $f$  je koncna a objektiv použitelný

b) diskrétní optimizační -  $M$  končina (spoc) (kombinatorika)

### II. Kriterium

a) deterministická optimizačníace

### III. Kriterium

a) užívá ma některý extrimum (max)  $f(x)$

$$\min_{x \in \mathbb{R}^n} f(x)$$

(nepřesného množstva  $M$ )

$$\min_{x \in \mathbb{R}^n} f(x)$$

• Představíme a konzervativní metody

$$P = \min_{x \in \mathbb{R}^n} \{f(x) + r_i \delta(x)\}$$

$$r_i \rightarrow 0$$

$$B = \min_{x \in \mathbb{R}^n} \{f(x) + r_i \delta(x)\}$$

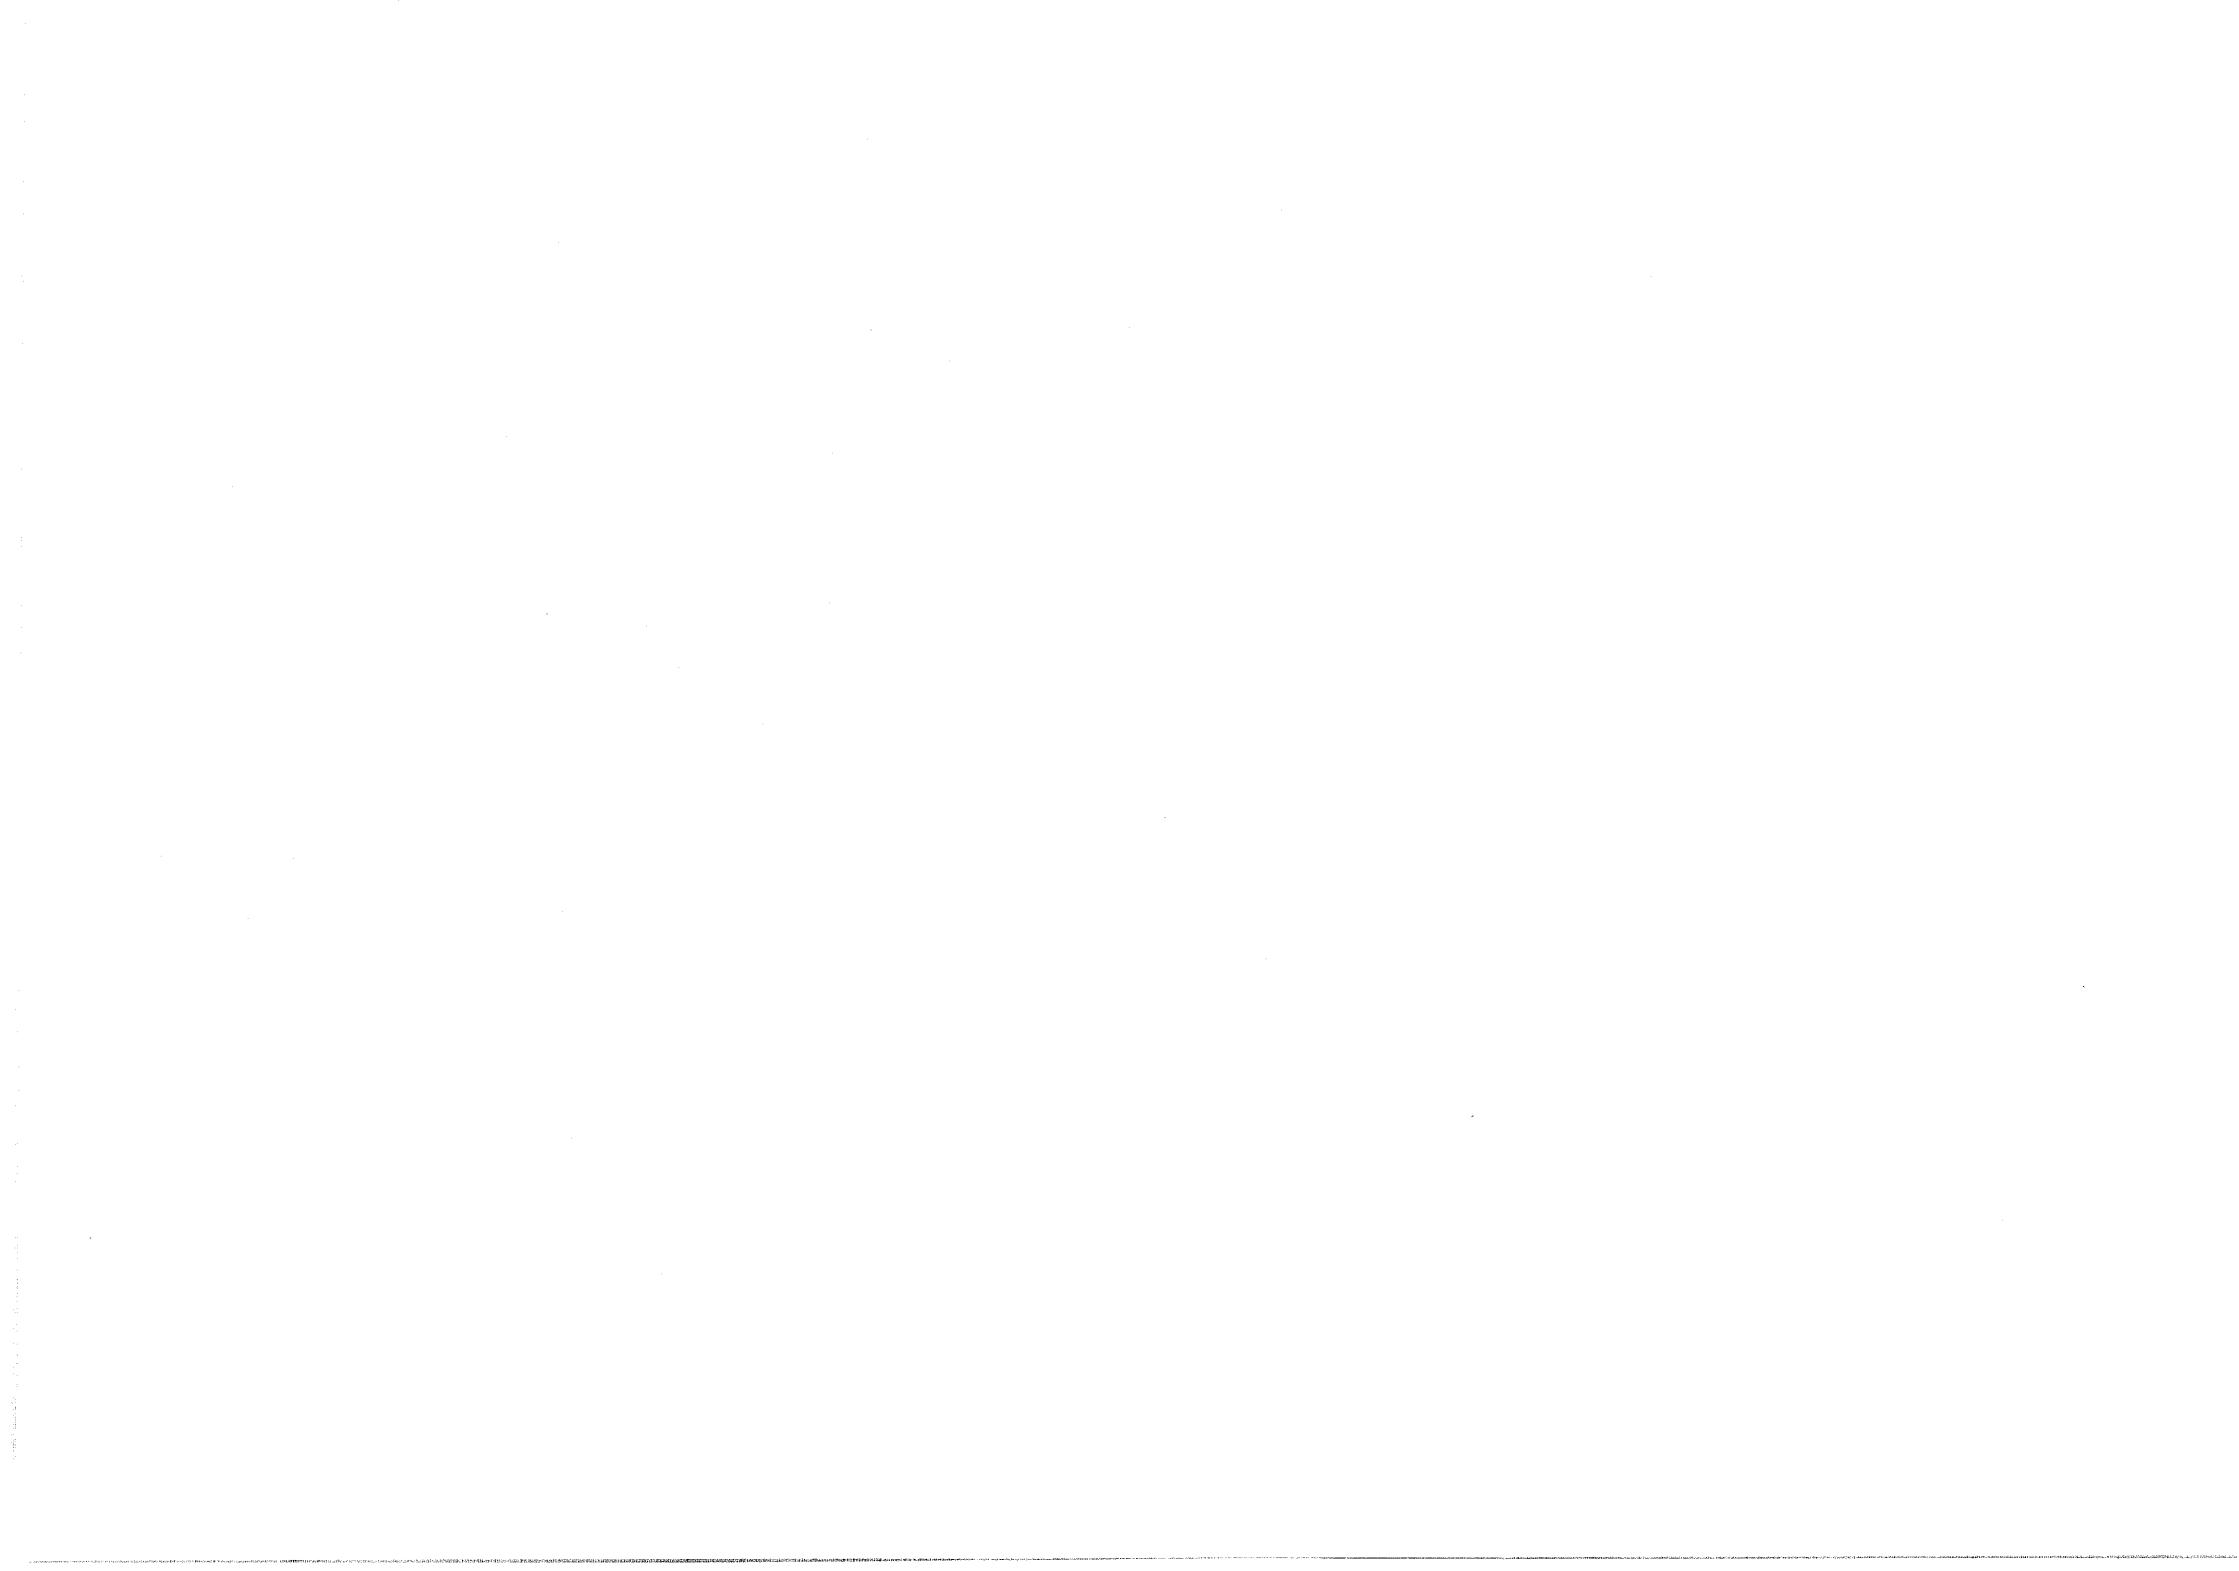
$$\min_{x \in \mathbb{R}^n} f(x)$$

$$f(x) \geq f(x^\circ) \quad x \in M$$

pro minimální cláve f(x) na  
možné požadující režimy

$$f(x) \leq f(x^\circ), \quad x \in M$$

$$f(x) \leq f(x^\circ), \quad x \in M$$



2.) u'lohy na matematiky se dají min  $f(x)$  |  $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $H \subseteq \mathbb{R}^m$

$$H = \left\{ x \in N \mid g_i(x) \leq 0, i=1, \dots, m \right\}$$

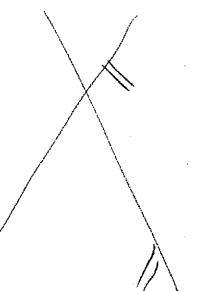
(2)

### a) lineární programování

$$f(x) = C^T x \quad | \quad C \in \mathbb{R}^m \quad (\text{lineární})$$

$$H = \left\{ x \in \mathbb{R}^n \mid Ax \leq b, A \in \mathbb{R}^{m \times n}, B \in \mathbb{R}^{n \times n} \right\}$$

- o existenciální metoda ( $\Leftrightarrow$  vnitřního "simplicova" metodou)



II

→ základní města ne základu (zásadou) nr 1

- o princip duality (primitivní  $\leftrightarrow$  počítačový)  
→ lineární & dualní simplexová metoda

### b) ne-lineární programování

- o alternativní funkce  $\alpha f_1, f_2, \dots, f_n$  méně lineární

o konvexní a rozezn. konvexní, speciální

- konvexní funkce  $\Rightarrow$  globální 'extremum' = globální 'extremum'

### c) parametrické programování

- o  $C_1$  urč. perov  $\rightarrow$  intervalová analýza

- o nezávislé parametry  $\alpha_1, \alpha_2, \dots, \alpha_n$  určují se výjimečně jako funkce dalších programujících (parametru)

### d) extenzivní programování

- o vše kritériální funkce (rekordové) programování
  - o eliptická funkce je rekordová  $f(x) \Rightarrow f_1(x), \dots, f_n(x)$

### d) dynamické programování

- o kritériální max. rekordové procesy
  - o dinamické ... Bellmannovo princip optimality
  - o projekce ... Hookeova strategie je optimální.

### e) význam programování principu optimality (maxima)



g) hovoríme hovor  $\Rightarrow$  maximální programace

h) semidefinované programování

$$\bullet M = \sum_{i=1}^n x_i \in \mathbb{R}^m \mid g_i(x) \leq 0, \quad i = 1, \dots, n$$

(2)

29.02.2008

(3)

### Dopravní problém

1. Klasický - dopravní 'problém' (užloha LP)

• formulace: Je dán set  $V_1, \dots, V_m$  místností, kde myslíme 'jejdou'

myšlenek a možných  $a_i > 0$  'k' (ne všechny jsou jednoduché)

a stejných místnostech je dán  $S_1, \dots, S_m$  společného, které 'rozdělují' místnosti

například  $x_{ij} > 0$  'kj' (ne všechny ...)

Je dán  $c_{ij} \geq 0$  'kj' cena za dopravu jednotky myšlenek z  $i$  do  $j$ .

Předp.: Na každou místnost má dopravu rovnou lineární.

• Nezameňte  $x_{ij}$  ... množství myšlenek došlo myšlenka  $S_j$  'kj'

$$M = \left\{ x_{ij} \in \mathbb{R}_{m \times m} \mid \sum_{i=1}^m x_{ij} = b_j, \quad \sum_{j=1}^n x_{ij} = a_i, \quad x_{ij} \geq 0 \quad \forall i, j \right\}$$

charakteristika splňování podmínek ekonomickej 'normality'

$$\sum_{i=1}^m x_{ij} * a_i = \sum_{j=1}^n b_j$$

• neplatí myšlenku 'nakoupit domluvku'

• neplatí myšlenku 'společně s myšlenkou jít domluvu' (ještě výše)

• neplatí myšlenku 'cenu'  $\Rightarrow$  neplatí myšlenku 'cenu'  $\Rightarrow$  neplatí myšlenku 'cenu'

$$\min \sum_{i=1}^m \sum_{j=1}^n c_{ij} * x_{ij}$$

$\exists x_{ij} \in M$

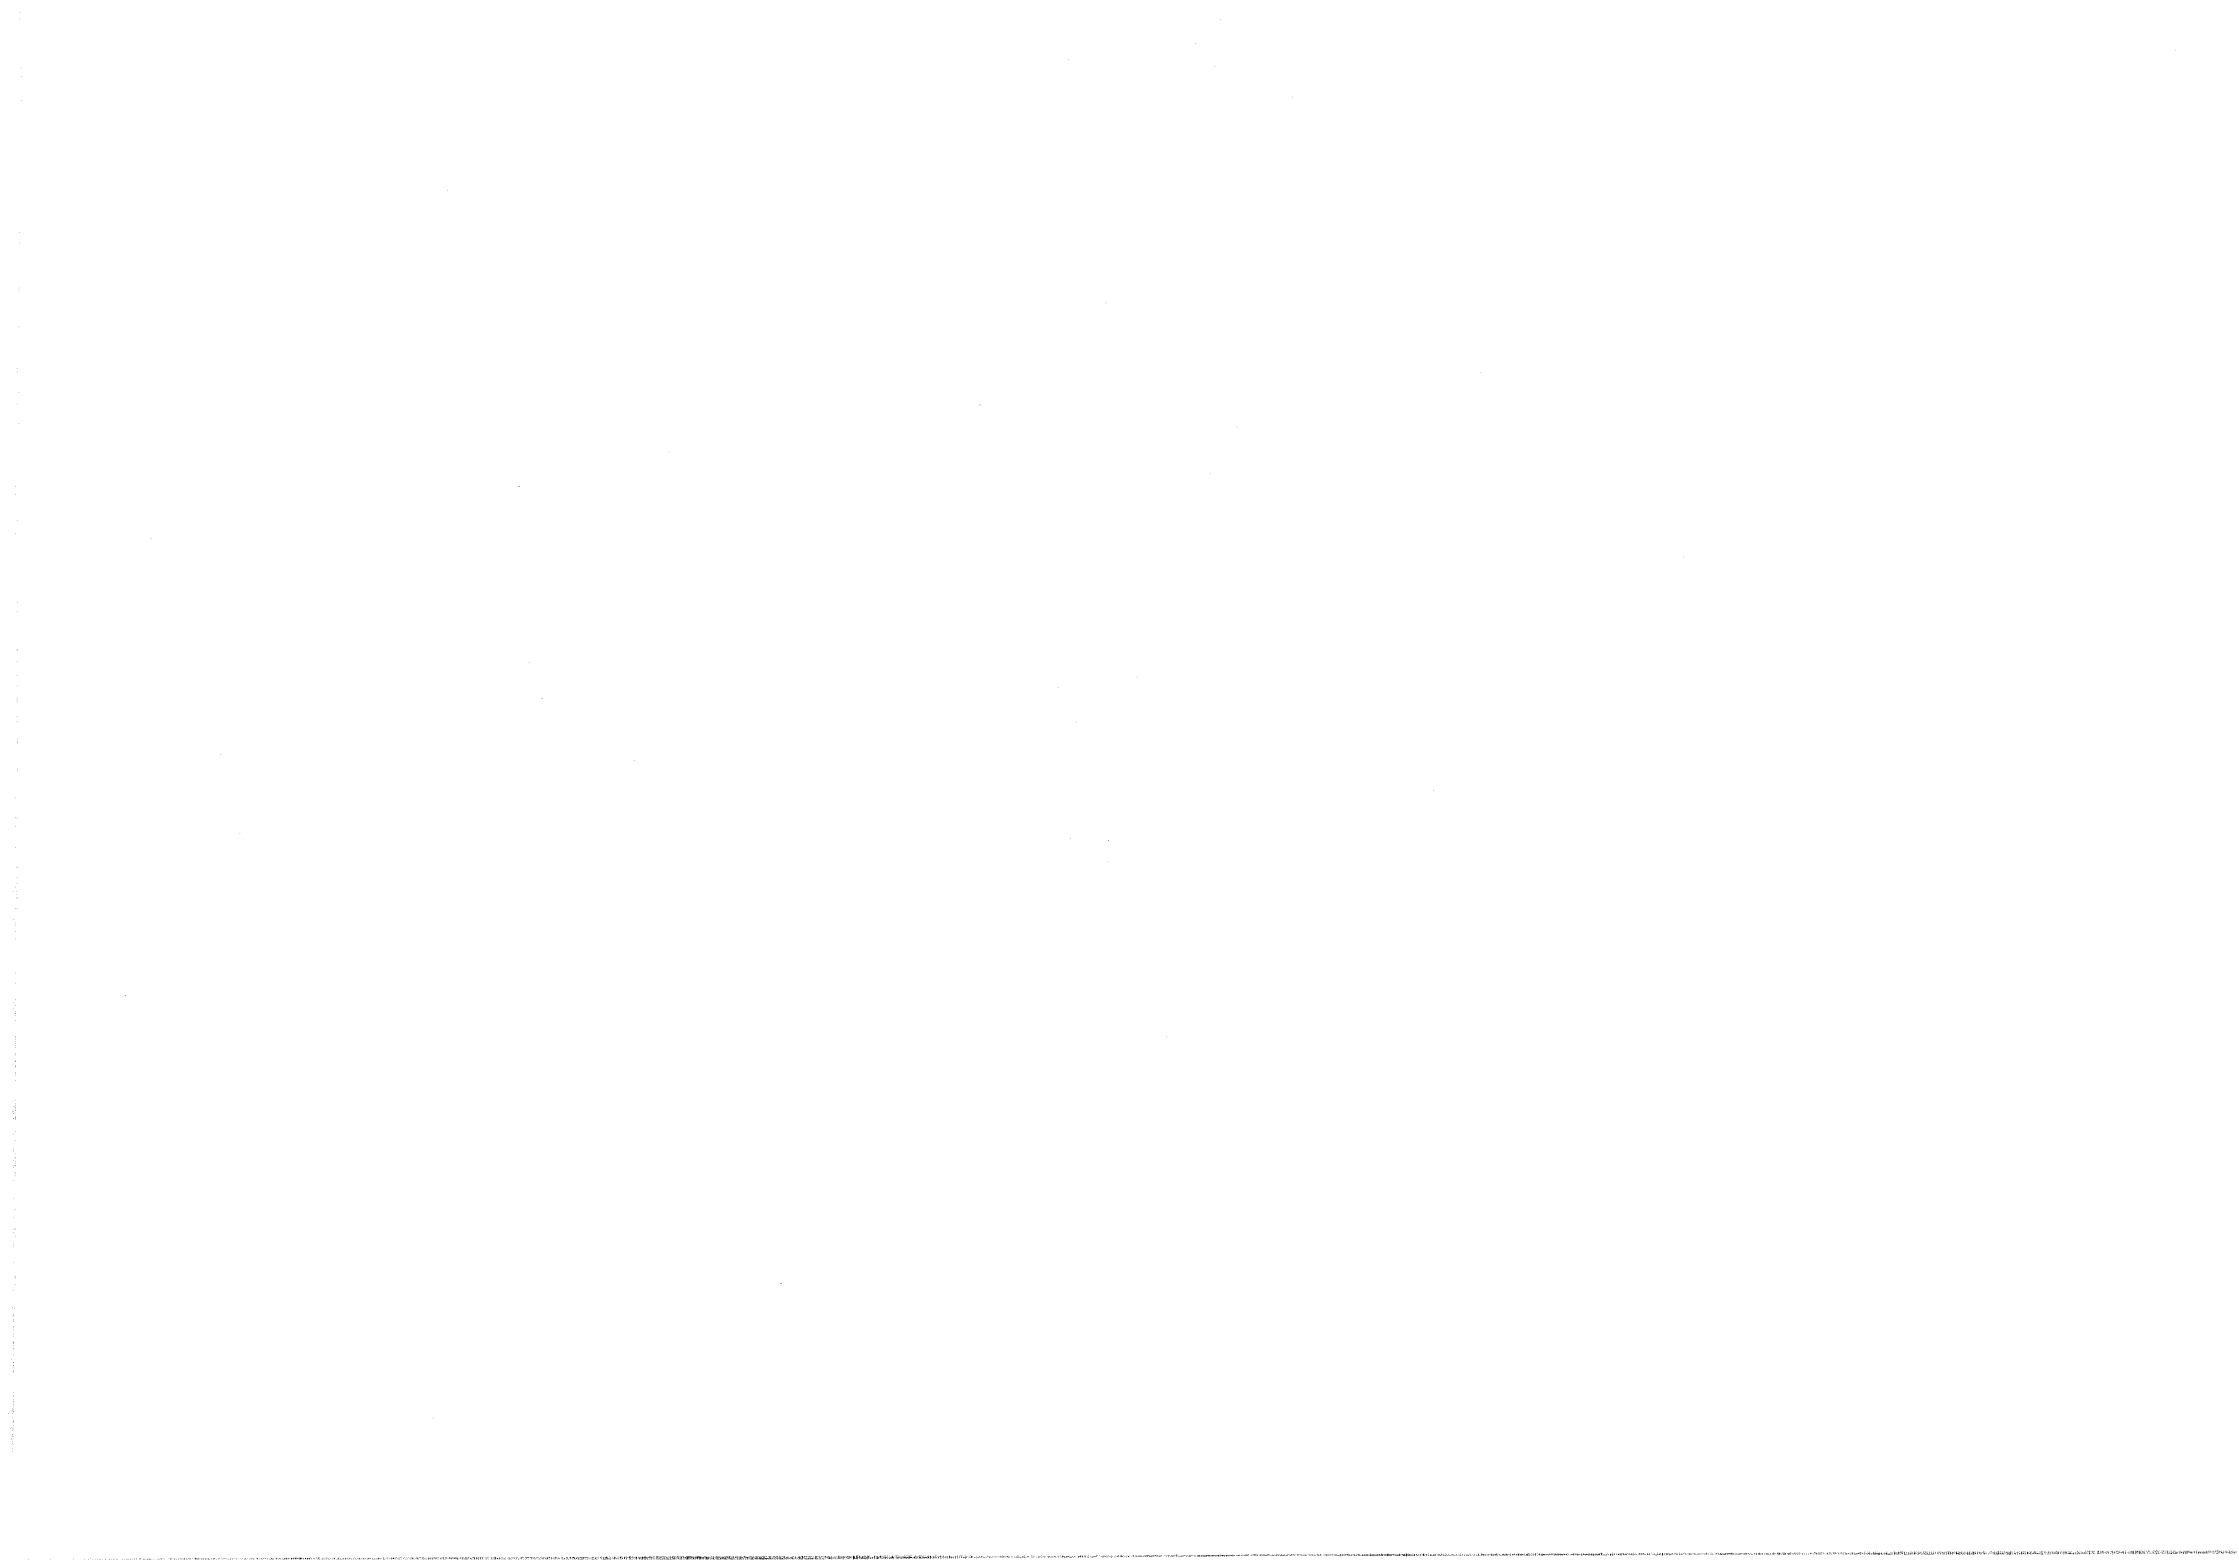
• neplatí myšlenka 'dopravovat me srdcem' (ještě výše)

- například  $m \times n$  proví  $m+n+m+n$

2. 'Dopravní' problem na lineárním se znamená dopravy (užloha me lineární programací)

$$\bullet \text{definice formulace, ale } c_{ij} (x_{ij}) = d_{ij} + e_{ij} \cdot x_{ij}$$

$$\min \sum_{i=1}^m \sum_{j=1}^n (d_{ij} * x_{ij} + e_{ij} * x_{ij}^2) \quad (\text{konečná užloha})$$



### 3. Dopravní problem & zceložedijní problem s konz.

- 'dopravní' formulace, ale  $M_C = \{x_{ij} \in \mathbb{R}^{m \times n} \mid \sum_{i=1}^m x_{ij} = b_j, \sum_{j=1}^n x_{ij} = a_i, x_{ij} \geq 0\}$

$$x_{ij} \in M \cup \{0\}, \quad b_j, a_i \in \mathbb{Z}$$

$$\min_{M_C} \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij}$$

### 4. Dopravní problem parametricky (parametrické programování)

- Formulace 'stojína', ale  $a_i \sim a_i + \lambda a'_i, \quad b_j \sim b_j + \lambda b'_j, \quad \lambda \in \mathbb{R}$

$$\text{Potom } M^* = \left\{ x_{ij} \in \mathbb{R}^{m \times n} \mid \sum_{i=1}^m x_{ij} = b_j, \sum_{j=1}^n x_{ij} = a_i + \lambda a'_i, \quad x_{ij} \geq 0, \quad b'_j \leq b_j \right\}$$

$$\min_{M_C} \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij}$$

- může sladať doby stability - -  $\lambda^2$  je se stojíny něčím

5. Dopravní 'problem' fakt už lze řešit využitím 'parametrického programování', obecně řešitelnost  $\dots \{ \lambda \}$  programu nebo řešení!

- nejdříji minima hledat a už programovat, ale i maximální hledat a už hledat
- definice 'formulace', ale  $\underline{\text{zde}}$  už 'ložit'  $\min \sum_{i=1}^m \sum_{j=1}^n (c_{ij} + \lambda x_{ij}) \rightarrow$  když min

$$\min_{M_C} \left\{ \sum_{i=1}^m \sum_{j=1}^n (c_{ij} + \lambda x_{ij}) - \sum_{i=1}^m z_i \right\}$$

### 6. Dopravní 'problem' jeho náloha dynamického programování

$$c_{ij} (\mathbf{x}_{ij}) \dots \text{nužme 'funkce'} x_{ij} \rightarrow \mathbf{x}_{ij}, \quad \min \sum_{i,j} c_{ij} (\mathbf{x}_{ij})$$

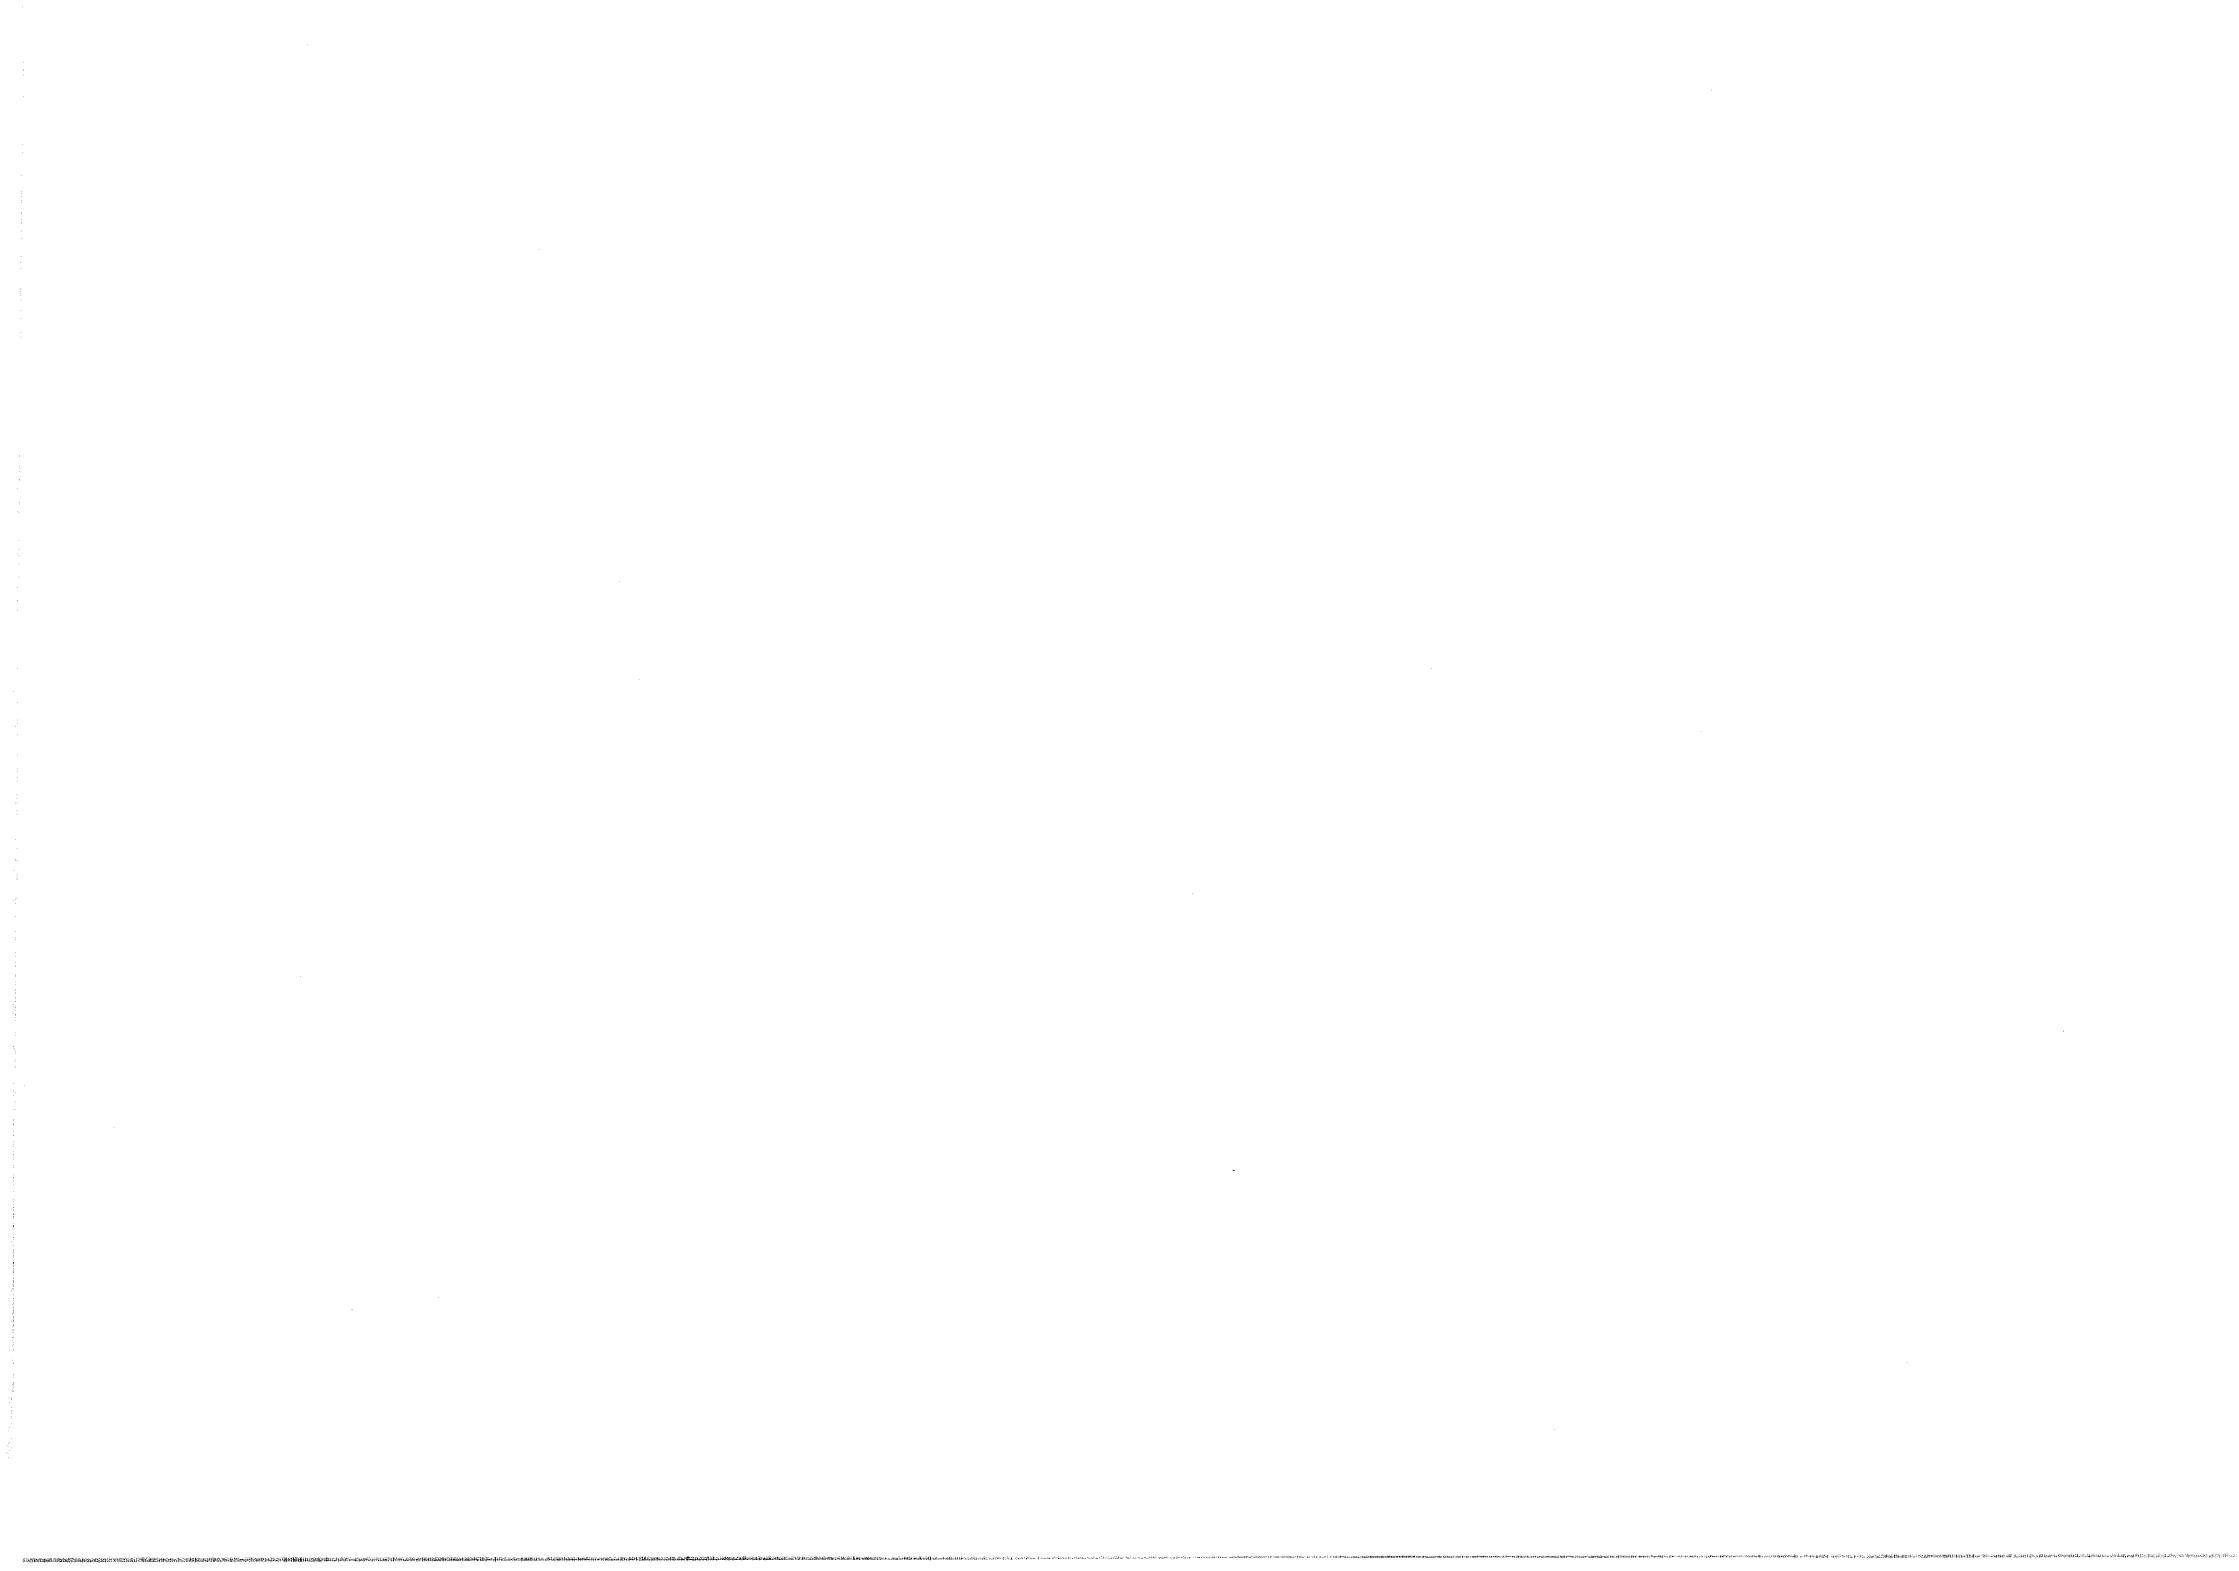
~~nehardozav~~,  $0 \leq x_{ij} \leq a_i, \quad a = (a_1, \dots, a_m), \quad b_j = 1, \dots, m$

$$\sum_i x_{ij} = b_j$$

stanovit  $\rightarrow \mathbf{x}_j^*$  - - minima 'nužební', když 'když' náročné na řešení

$$0 \leq x_j^* \leq a$$

- zadán použití výpočtu stanovit  $x_1^* = a$
- $x_2^* = x_1^* - \text{definice } x_1^*$



20

⑤

Práleček následkem lineárního programování

Def 3: Možnosti  $\{ \mathbf{x} \in \mathbb{R}^n \mid \mathbf{a} \mathbf{x} \leq \mathbf{b}, \mathbf{a} \neq 0, \mathbf{a} \in \mathbb{R}^m; \mathbf{b} \in \mathbb{R}^m \}$   
 nezáporné poloprostor v  $\mathbb{R}^n$ .

Možnosti  $\{ \mathbf{x} \in \mathbb{R}^n \mid \mathbf{a} \mathbf{x} = \mathbf{b}; \mathbf{a} \neq 0; \mathbf{a} \in \mathbb{R}^m; \mathbf{b} \in \mathbb{R}^3 \}$  nezáporné  
 množinovou (poloprostor dimenze  $m-1$ )

Práleček konečného počtu množin nezáporných poloprostoru nezáporné  
 konvexeho polyedru.

Def 4: Násoben LP ne nezáporného konvexního množinu množinu  $\mathbf{C}^T \mathbf{x}$   
 $\min_{\mathbf{x}} \mathbf{C}^T \mathbf{x} ; \mathcal{M} = \{ \mathbf{x} \in \mathbb{R}^n \mid \mathbf{A} \mathbf{x} = \mathbf{b}, \mathbf{x} \geq 0 \} ; \mathbf{A} \in \mathbb{R}^{m \times n} ; \mathbf{b} \in \mathbb{R}^m$   
 $\mathbf{C} \in \mathbb{R}^m$ .

Simplex kota' me lada' možnosti:

1) násoben LP ne nezáporného konvexního

- 2)  $\mathbf{b} \geq 0$
- 3)  $\mathbf{C} \neq \mathbb{I}_{m \times m} \mathbf{A}$
- 4)  $1 \leq m < n$
- 5)  $\text{rk}(\mathbf{A}) = m$

Přírody: (z minimálního konvexního množinu)

a)  $\# \mathbf{A} \mathbf{x} \leq \mathbf{b}_{\geq 0} \rightarrow \mathbf{A} \mathbf{x} + \mathbf{g} = \mathbf{b} ; \mathbf{g} \geq 0 \mid \min_{\mathbf{x}} \{ \mathbf{C}^T \mathbf{x} + \mathbf{g}^T \mathbf{x} \}$

$\mathcal{M}' = \{ \mathbf{x}, \mathbf{g} \mid \mathbf{A} \mathbf{x} + \mathbf{g} = \mathbf{b} ; \mathbf{x} \geq 0 ; \mathbf{g} \geq 0 \}$

doplněk množiny nezáporného konvexního množinu dimenze  $m-1$ , ale je řešitelné jiným problemu je řešitelné

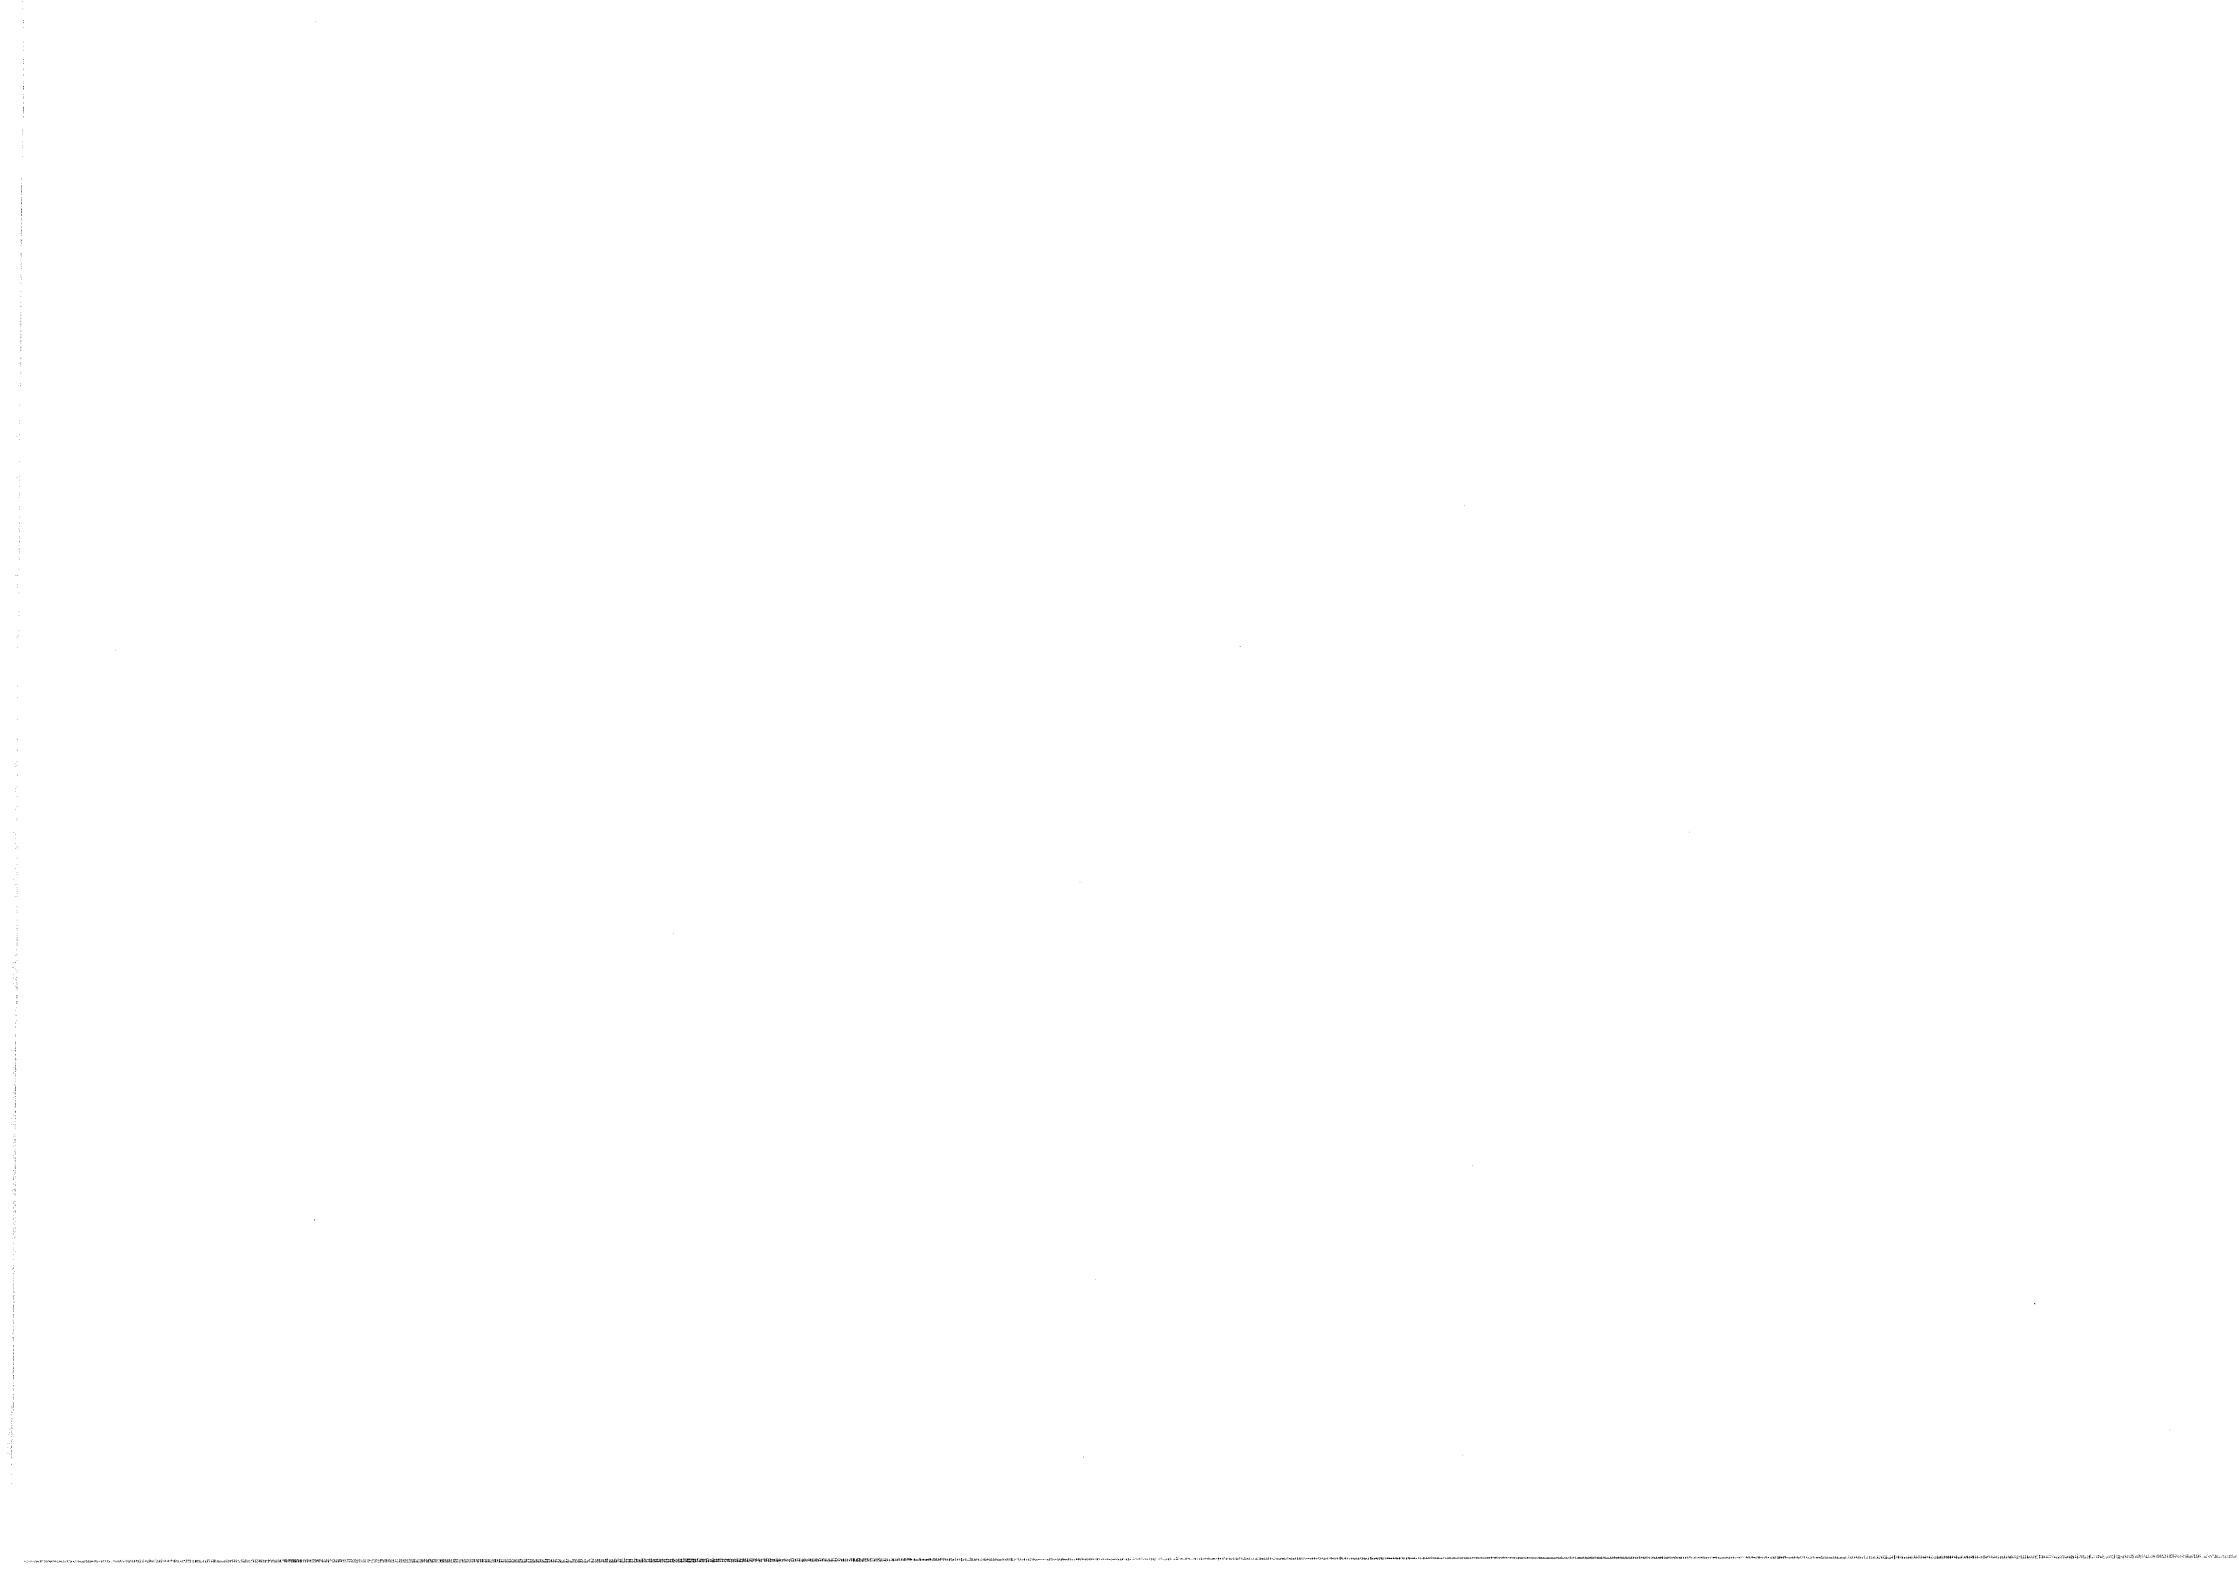
b)  $\mathbf{A} \mathbf{x} \geq \mathbf{b}_0 \rightarrow \mathbf{A} \mathbf{x} - \mathbf{g} = \mathbf{b}_0 ; \mathbf{g} \geq 0$

$\mathbf{A} \mathbf{x} - \mathbf{g} + \mathbf{w} = \mathbf{b}_0 ; \mathbf{g}, \mathbf{w} \geq 0$

z násobka násoben - jiný problém

$\min_{\mathbf{x}} \mathbf{C}^T \mathbf{x} + \mathbf{K}^T \mathbf{w} ; \mathbf{K} = K_1, \dots, K_m ; K_i > 0$

$\mathcal{M}'' = \{ \mathbf{x}, \mathbf{g}, \mathbf{w} \in \mathbb{R}^{m+2m} \mid \mathbf{A} \mathbf{x} - \mathbf{g} + \mathbf{w} = \mathbf{b}_0 ; \mathbf{x}, \mathbf{g}, \mathbf{w} \geq 0 \}$



na bo projeckovací pravou stranu.

$$\min_{\mathbf{X}_1} \sum_{i=1}^m \mu_i \cdot$$

opt. res.  $\mu = 0 \Rightarrow$  max. něž.  $\mu = 0 \Rightarrow$  max. něž. res.  
něž. nálež. a pokračující SA, ale  
maximální dopříložnost krit. nálež.

$$c) H = \{ \mathbf{x} \mid A\mathbf{x} = b \}$$

$$\mathbf{x} = \mathbf{x}^+ - \mathbf{x}^- \quad \mathbf{x}_i^+ = \max \{ 0, x_i \} \geq 0$$

$$x_i^- = \max \{ 0, -x_i \} \geq 0$$

$$H^1 = \{ \mathbf{x}^+, \mathbf{x}^- \in \mathbb{R}^{2n} \mid A\mathbf{x}^+ - A\mathbf{x}^- = b, \mathbf{x}^+ \geq 0, \mathbf{x}^- \geq 0 \}$$

$$\min_{\mathbf{X}^1} \{ C^T \mathbf{x}^+ - C^T \mathbf{x}^- \}$$

Princip nálež. LP na koncového stanoviště

• předp.  $b(A) = m \Rightarrow \exists$  koncový počet neg. matic  $A \in \mathcal{C} A$   
Dodatek (BÚNO)  $A = (A_B, A_N)$ , kde  $A_B$  je neg. matici násobku  
podoby  $A\mathbf{x} = b$  podoby  $A_B\mathbf{x}_B + A_N\mathbf{x}_N = b$ , kde  $\mathbf{x} = (\mathbf{x}_B, \mathbf{x}_N)$   
Svijejšího způsobem rozdělme  $C = (C_B, C_N)$ . Potom maximální  
nálež. odpadne na dvoj.  $\min_{\mathbf{X}_1} (C_B^T \mathbf{x}_B + C_N^T \mathbf{x}_N)$ .

$$H = \{ \mathbf{x}_B, \mathbf{x}_N \mid \mathbf{x}_B = \underbrace{A_B^{-1} b}_{A_1} - \underbrace{A_B^{-1} A_N}_{D} \mathbf{x}_N \geq 0 \quad | \quad \mathbf{x}_N \geq 0 \}$$

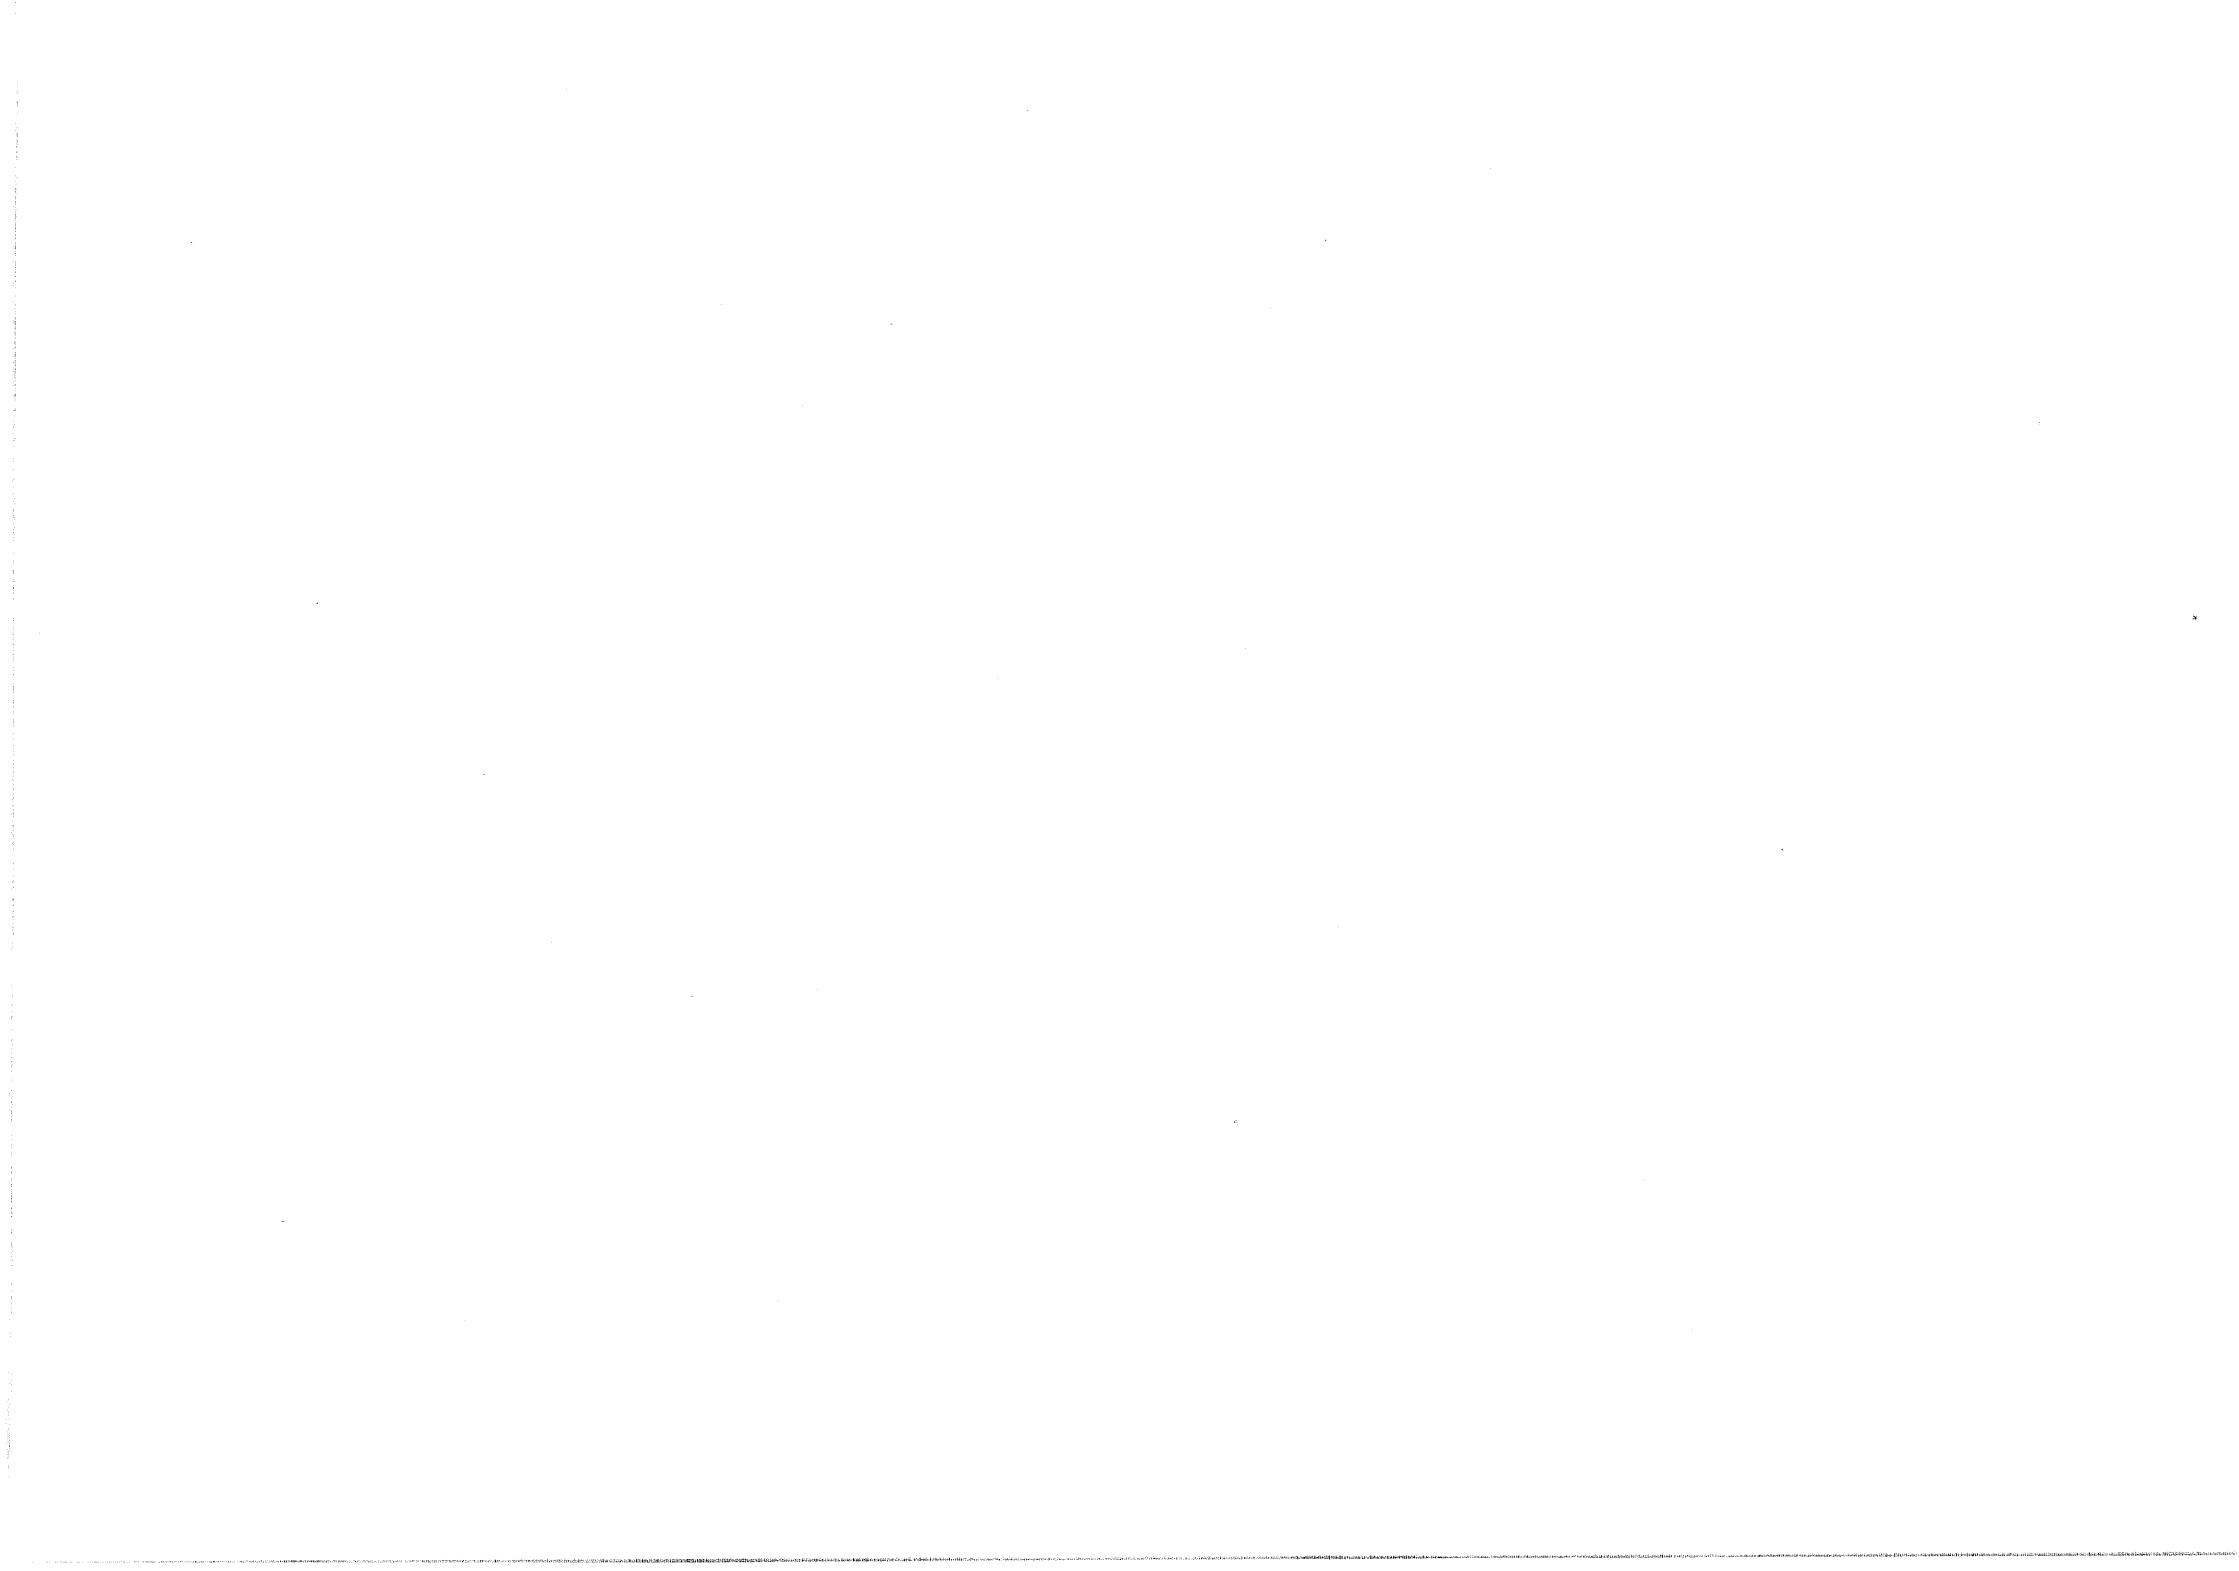
$$\equiv \{ \mathbf{x}_B, \mathbf{x}_N \mid (A_B^{-1} b - D \mathbf{x}_N)^T \geq 0 \quad | \quad \mathbf{x}_N \geq 0 \} \equiv$$

$$C_B (A_B^{-1} b - A_B^{-1} A_N \mathbf{x}_N) + C_N \mathbf{x}_N = \underbrace{C_B^T A_B^{-1} b}_{C_0} + \underbrace{C_N (C_N - C_B A_B^{-1} A_N)}_{-D^T C_0} \mathbf{x}_N$$

$$= C_0 + (C_N - D^T C_0) \mathbf{x}_N$$

$$\boxed{\begin{aligned} d^0 &= A_B^{-1} b \\ D &= A_B^{-1} A_N \end{aligned}}$$

Ukazujeme vlastností lineár. f. (nap. vlastnosti pravdělivé funkce) a potom se  
 $\min_{\mathbf{X}_1} \{ C_0 + (C_N - D^T C_0) \mathbf{x}_N \}$   
dle vlastností propojit na konci.



69

02.03.2007

$$\underline{\text{BEN}}: \forall \text{ Symmetrie } \text{ basida } A_B = E \Rightarrow A^{-1} = E.$$

Daf 5: ~~X~~ B matyraime ne k'zorevən fəzic k'zəch pro-weswurjek / X N matyraime

$(\mathbb{X}_B, \mathbb{X}_N) = (\mathcal{O}^{\circ}, \mathcal{O})$  many value basic begin number. Je-li:

$\alpha \geq 0$ , park vulnerability or propensity toward participation present. If  $\beta_1 \alpha > 0$ , park job or moderate wage, prop. base. res.

Hodowla u'love' fura kca n' p'up' bas. res. Je. C X = C<sub>o</sub>.

Jabuka SH	
$c_B$	$x_B$
$x_B$	$c_N$
1	$x_N$
1	1
0	0
0	$c_N - x_N$
-	$-c_0$
$\Delta^0$	
$m+1$	

$$10 \cdots 0 | c_n - z_n | - r_0 = \text{Kürzungslinie} \quad \text{oder} \quad k$$

No V. SH: jezdíte na T pladu?  $P_N - Z_N \geq 0$ , potom je pravděpodobně správné klasifikace!

L.V. S!:  $\text{Jenner} - \text{he or I slumped he}$   
 $\epsilon_L - \epsilon_R < 0$ ,  $\dot{\epsilon}_L \geq 0$   $\epsilon \in B$ , posterior.

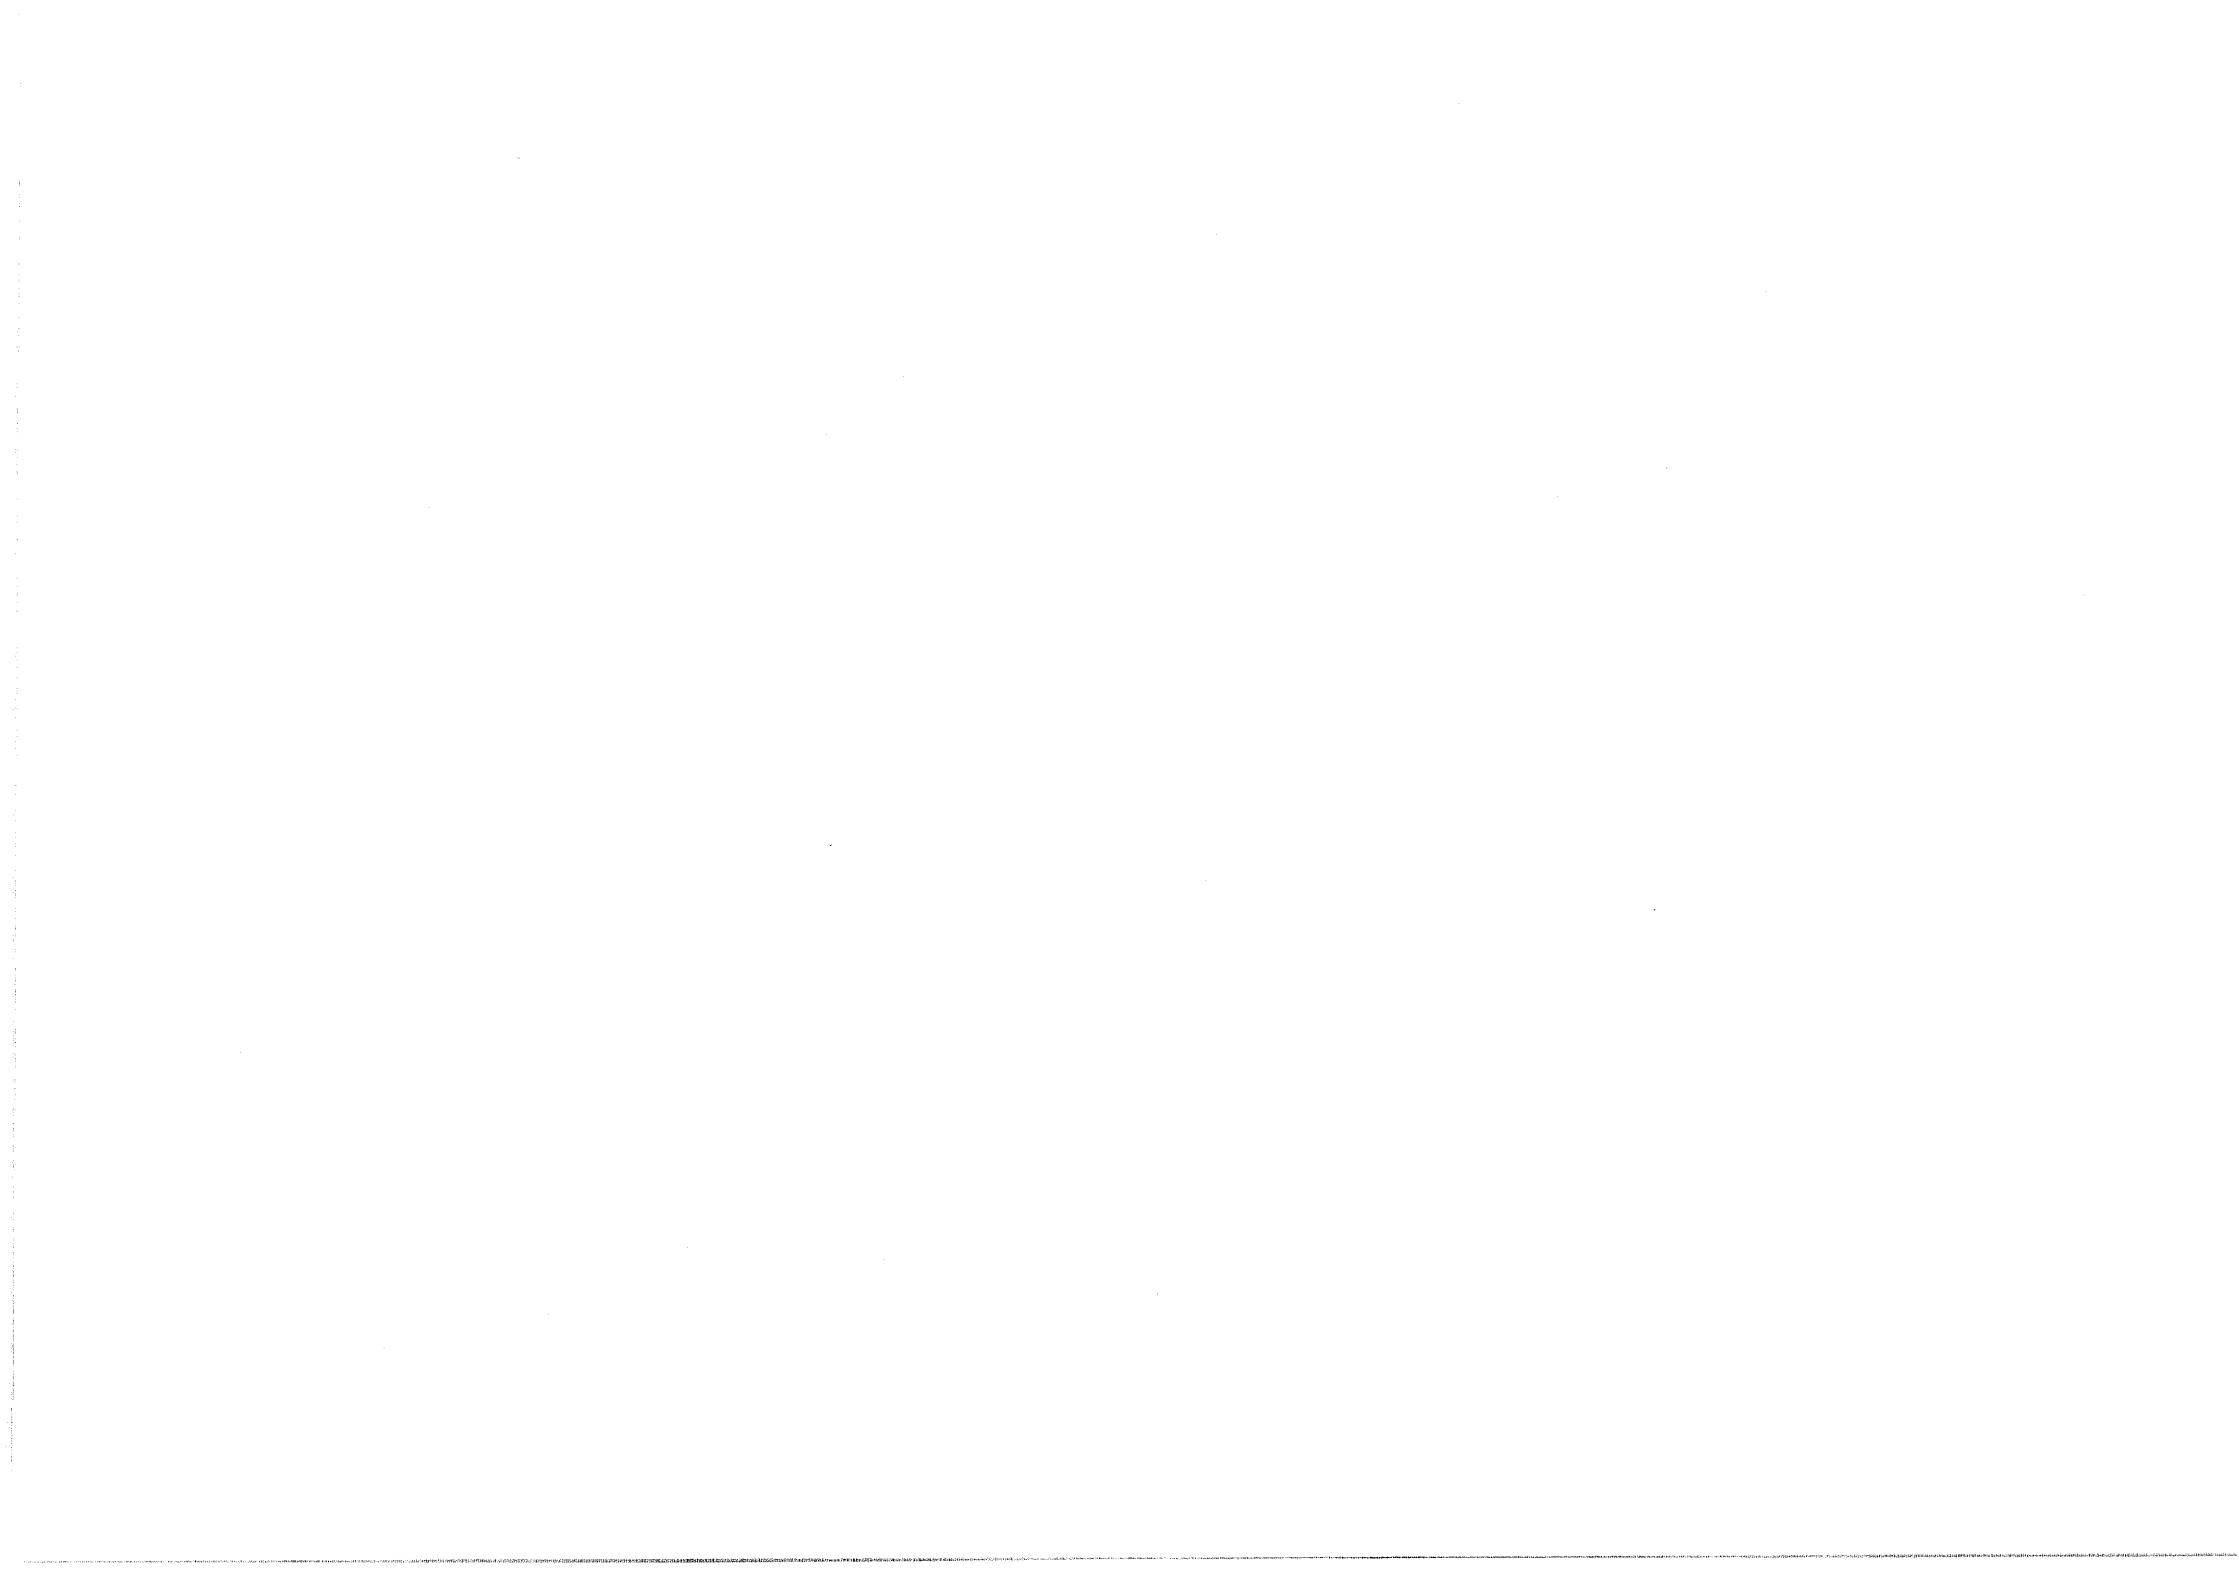
J.V. SM: Nejprve - k oplývající predpohledové 1. ani 2. v. SM i potom u klicový  
 ploupanec  $\min_{j \in N(\text{notrebované})} (c_j^d - z_j) = c_s^d - z_s^d$ .  
 Klicový rádele určuje faktor  $\min_{d > 0} \left\{ \frac{d \alpha}{d x} \right\} = \frac{\alpha}{x}$  a je to jeho průměr.

Transformace  $T$  je pozitivná dle  $\lambda_{\min}^2 > 0$ . Dostavíme nové přípravné listy  $(X_1, X_2)$   
 $\underline{\text{Rozv:}} \quad \text{Blandovo pravidlo nezádaje minim } \sum_{j=1}^{n-1} c_j - z_j \equiv c_n - z_n \quad a$   
 $\lambda \in N$   
 $X = (X_1, X_2)$

$$\frac{d_{so}}{d_{sw}} = \frac{\min\left\{ \frac{d_{so}}{d_{in}} \right\}}{\max\left\{ \frac{d_{so}}{d_{in}} \right\}} = d_{so} / d_{sw}$$

prv determiner ~ prisition  
explicat the determiner  $S = \min\{J \in \mathcal{N} \mid c_J - z_J = 0\}$  or  $r = \min\{\text{per} \mid \min_{j \in J} \left\{ \frac{c_j}{z_j} \right\} = \left\{ \frac{c_j}{z_j} \right\}\}$

Wij doen nu ook heel veel meer voor het milieu. De meeste materialen worden nu gerecycled.



Definice 6:

Množina  $M_{opt} = \{x^* \in M \mid \min c^T x = c^T x^*\}$  nazýváme 

monožinou nejč. opt. res. u 'obecné' LP.

$\exists$ -li  $x^* = (d^*, 0) \geq 0$  je opt. res. až v řešení SM. Nechť  $c_j - z_j \geq 0$

jste hodnota  $\alpha$  poslední ('optimální') kroků, tzn. optimální  $J = \{j \in N \mid c_j - z_j > 0\}$  a nechť  $\varrho_0$  je opt. hodnota cílové funkce. Při  $j \in N - J$  je  $c_j - z_j = 0$ .

Veta 1: Pokud  $M_{opt} = \{x \in M \mid x_j = 0, j \in J\}$ .

$$\text{Důkaz: } \text{Pro } x \in M \text{ platí } c^T x = c_0 + (c_N - z_N)^T x_N = \dots = c_0 + \sum_{j \in J} (c_j - z_j) x_j + \sum_{j \notin J} (c_j - z_j) x_j =$$

$$\text{Hodina je } x \in M, \text{ kde máji' nula v } c^T x = c_0$$

$$\Rightarrow c_0 + (c_N - z_N)^T x_N = c_0 + \sum_{j \in J} (c_j - z_j) x_j = c_0 \Rightarrow x_j = 0, j \in J \quad (\times)$$

Optimal ... za když sloupe se negativně jde o hodnotu  $= 0$ .

$\Rightarrow$  když je res. jediná  $\Rightarrow$  je jich už mnoho.

Degenerace: Cyklus. Vrátka obdobovou!

Def 7: Různa je u SM množina 'degenerace', když je alespon 1 jeho res. se degenerací.

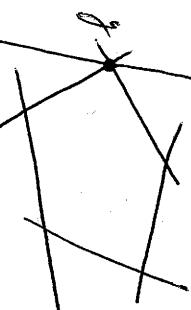
$\exists$ -li prvn. res. res. (do, 0) degen.  $\Rightarrow d_{ii} = 0$  alespon pro 1  $i \in B$ .

$\exists$ -li speciál.  $i = \#$  potom pro konf. faktury  $-c_i = -c_0 - \frac{(c_N - z_N) \cdot d_{iB}}{d_{ii}}$

$\Rightarrow$  nejmenší nejednotka cílové funkce, t.j.  $c^T x' = c^T x = -c_0$

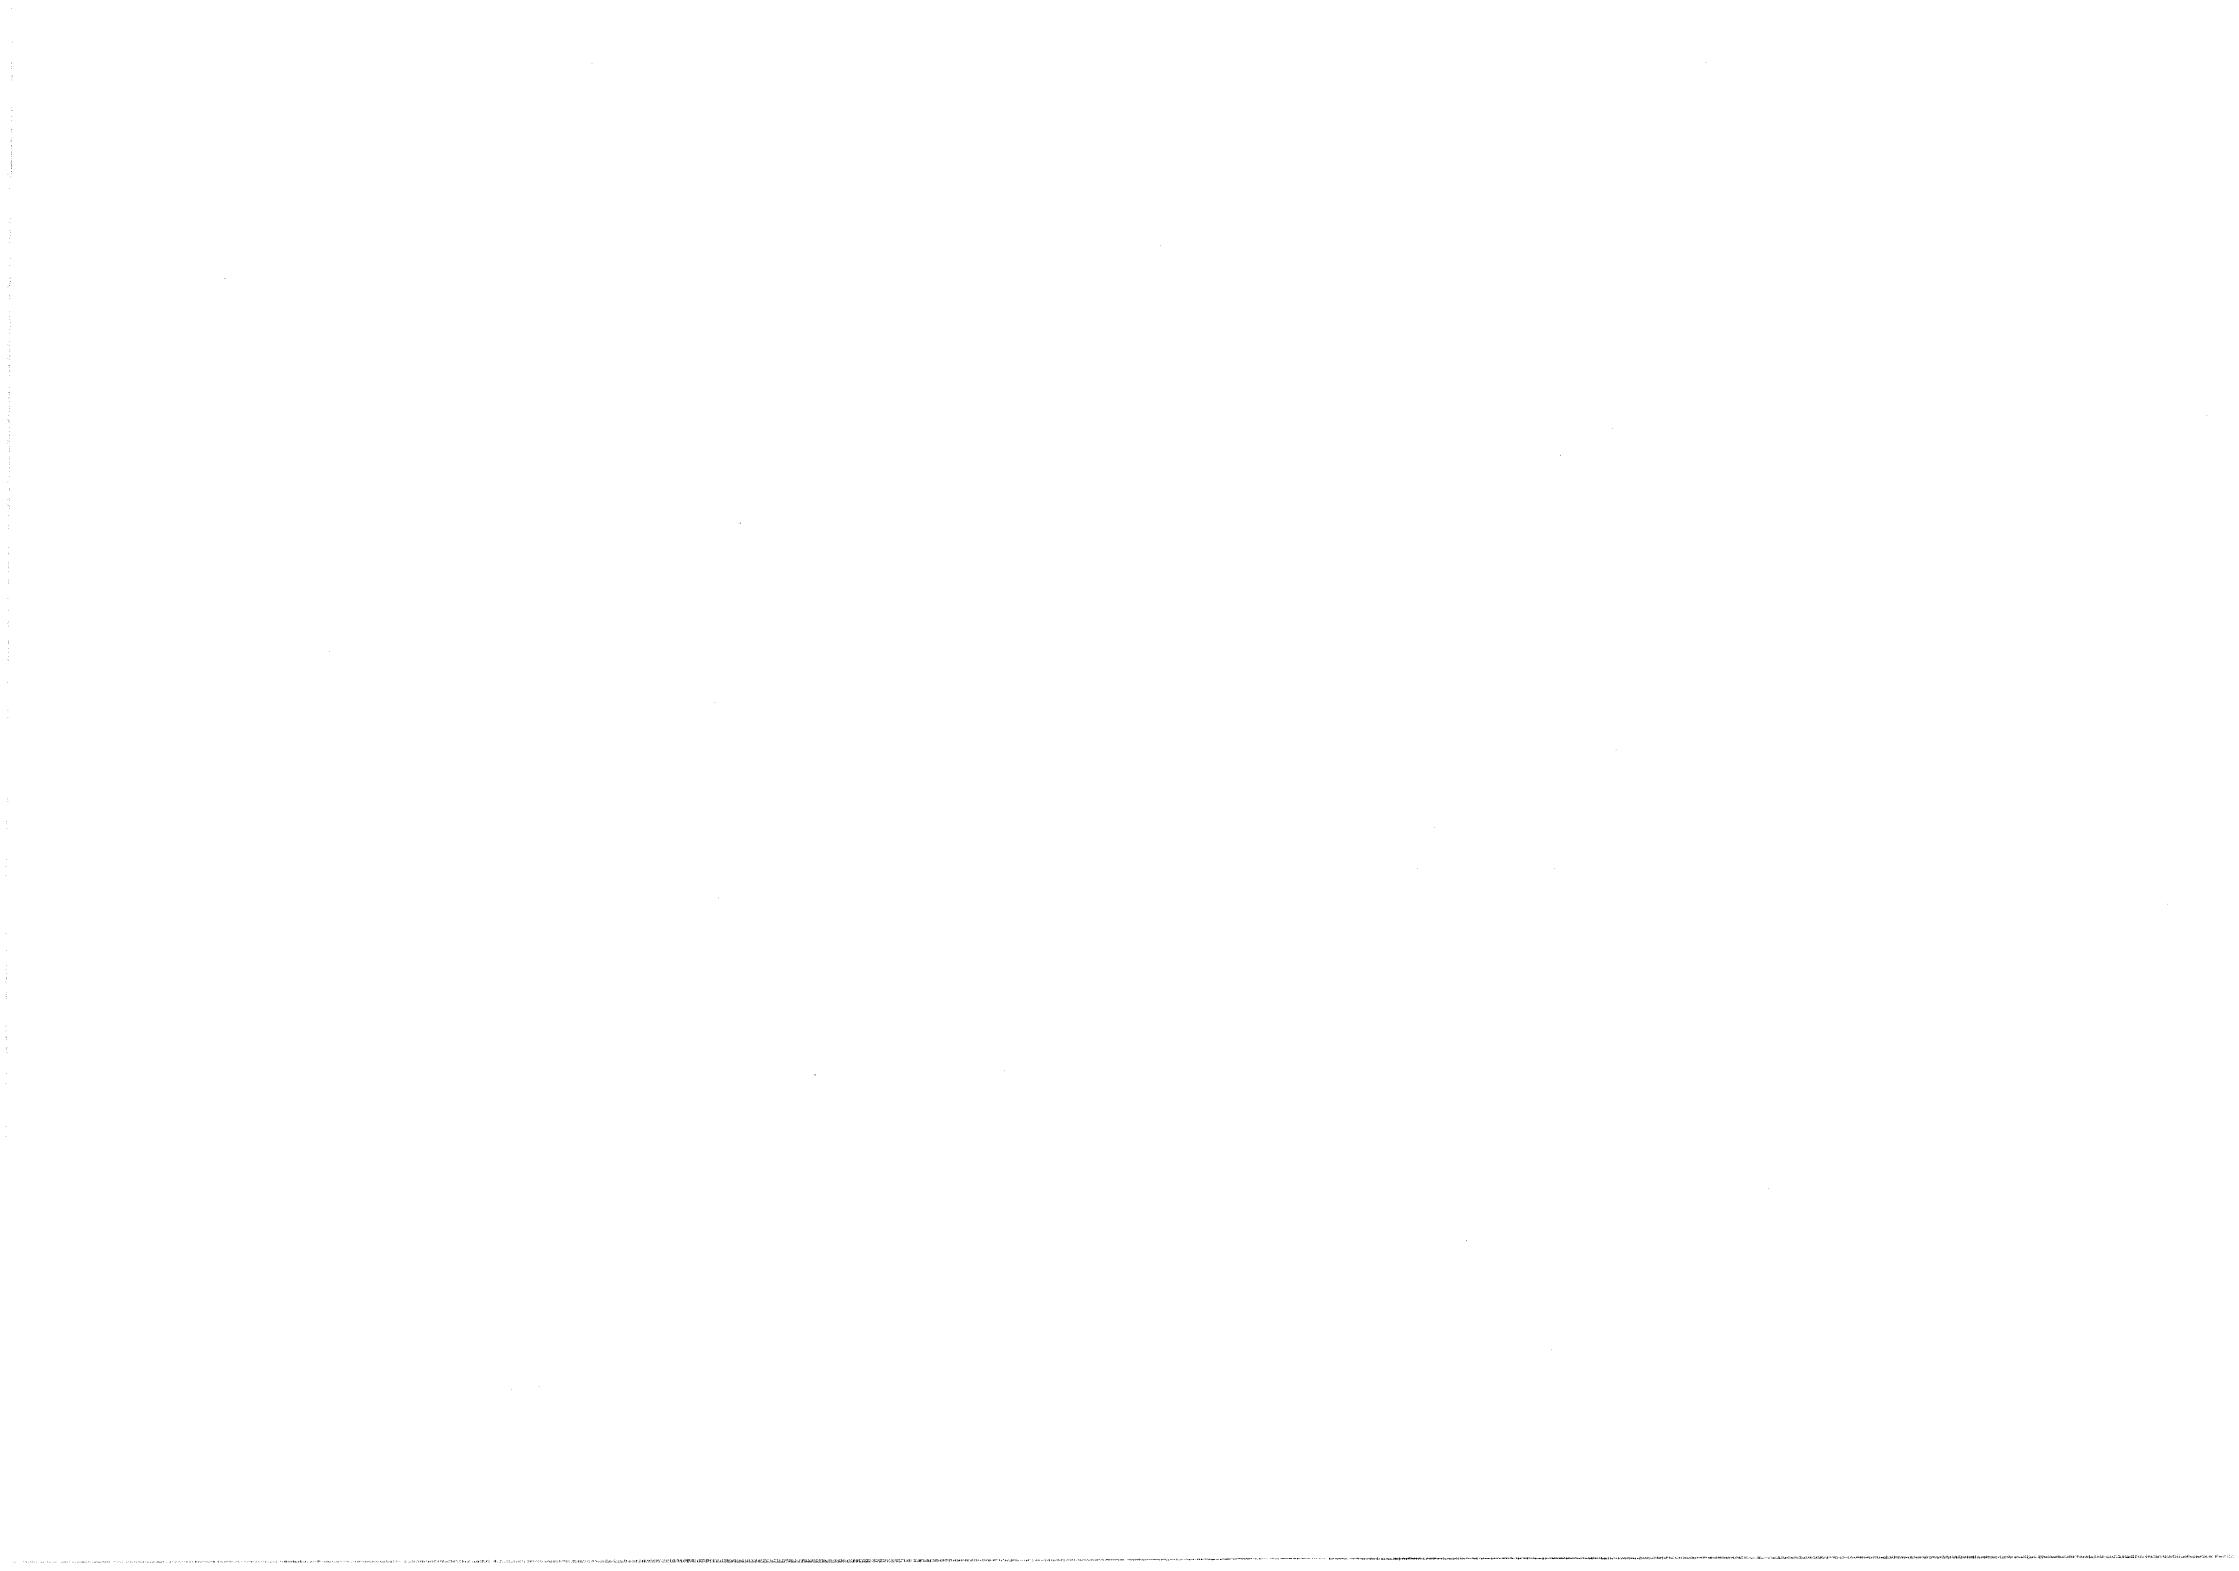
Hodnota by se měla  $\rightarrow x^k \rightarrow x^{k+1} \rightarrow \dots \rightarrow x^L$ , průcesem

$C^T x^k = C^T x^{k+1} = \dots = C^T x^L = C^T x^*$ . Kroků by byly cyklus a SM by selhalo.

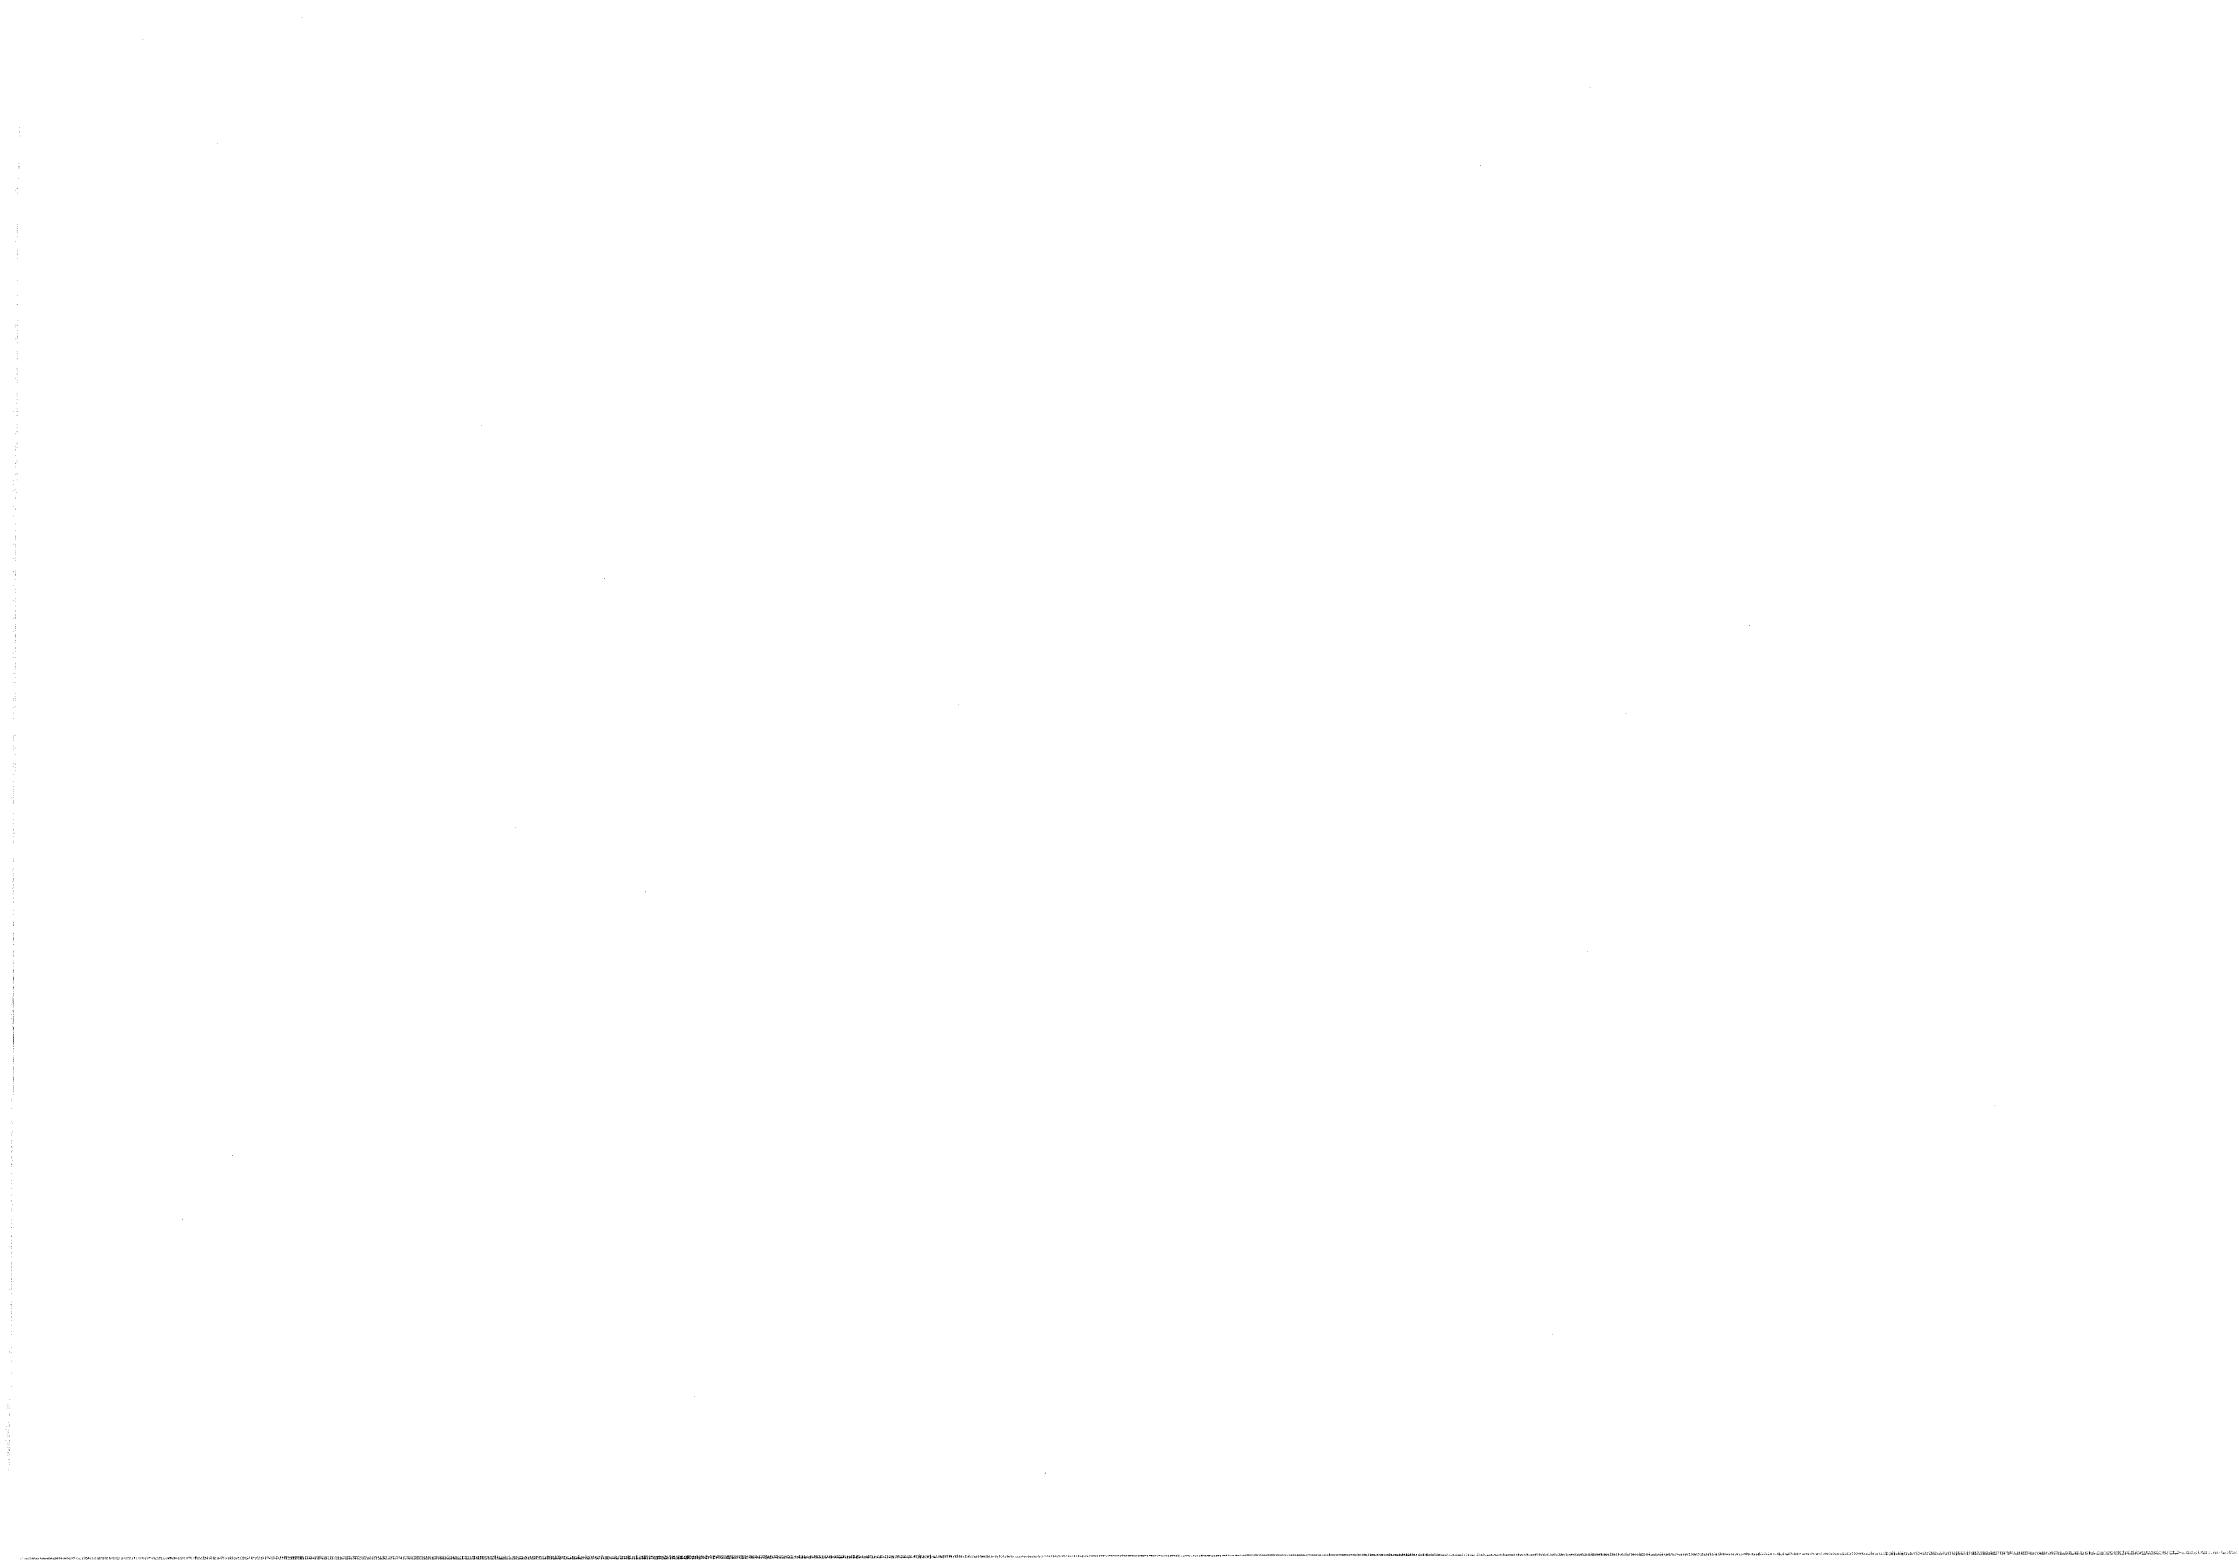


$y$  je výjdečná 3-mi  
drobnou novou  
mjedovou

$\Rightarrow$  tři samy když ale jinak  
mjedovou







### 3. Prandtl-Görtler'schen' modell

• horis' od had' # kolo:  $\tau(m, n) \leq m^{\frac{1}{m}} (n+1)^4 \cdot \frac{2\pi}{5} (1 + \frac{2\pi}{k^2})$

4. Prandtl'sche 'probleme'  $\rightarrow$  # kolo: maxima' na m a je  $< (2m, 3m)$   
 5. Norweg'sc' ne' kolo:  $m < 50$  i  $m < 150$  je  $\tau < \frac{3}{2} m$ . (Plane' horis' pro m netz')

Algorithmus für LP - in 'Lobing'

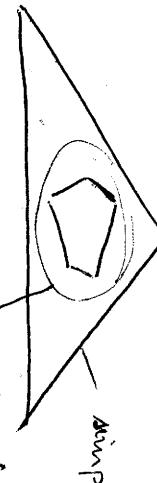
1. Eliminatoren' metoda (Chanc) 1979



ellipsoid - na 1/2 & woy' ta an' kolo je' M

$\rightarrow$  horis' & obere' Ma opf je' an'wick

2. Karmarkarova 'projektivna' metoda 1984  $\rightarrow$  polynomia'ln'



simplex ...  $\rightarrow E_n$  ma' n+n kolo

### Principle duality

Def: Vlozen LP a normálnum' vlozen

$$(P) \max_{M_1} c^T x, \quad M_1 = \{x \in \mathbb{R}^n \mid Ax \leq b, \quad x \geq 0\}, \quad A \in \mathbb{R}^{m \times n}, \quad b \in \mathbb{R}^m$$

normálnum' vlozen a vlozen a normálum' vlozen

$$(D) \min_{M_2} b^T y, \quad M_2 = \{y \in \mathbb{R}^m \mid A^T y \geq c, \quad y \geq 0\}$$

normálnum' vlozen LP.

$$\begin{array}{c|cc|c} y & & A & \\ \hline & & & b \end{array}$$

Lemmat 1: je-li  $M_1 \neq \emptyset$ ;  $M_2 \neq \emptyset$  potom platí:  $c^T x \leq b^T y$ ,  $\forall x \in M_1, \quad y \in M_2$ .

$$\text{d.k.: } M_1 \neq \emptyset \Rightarrow \exists x: \quad A x \leq b / \left. \begin{array}{l} y \geq 0 \end{array} \right\} \Rightarrow y^T A x \leq y^T b$$

$$M_2 \neq \emptyset \Rightarrow \exists y: \quad A^T y \geq c / \left. \begin{array}{l} y \geq 0 \end{array} \right\} \Rightarrow y^T A^T y \geq c^T y \geq 0$$

$$\Rightarrow c^T x \leq b^T y$$

Lemmat 2: je-li  $M_1 \neq \emptyset, \quad M_2 \neq \emptyset$ , potom  $\exists$  horis' sup  $c^T x$  na  $M_1$  a

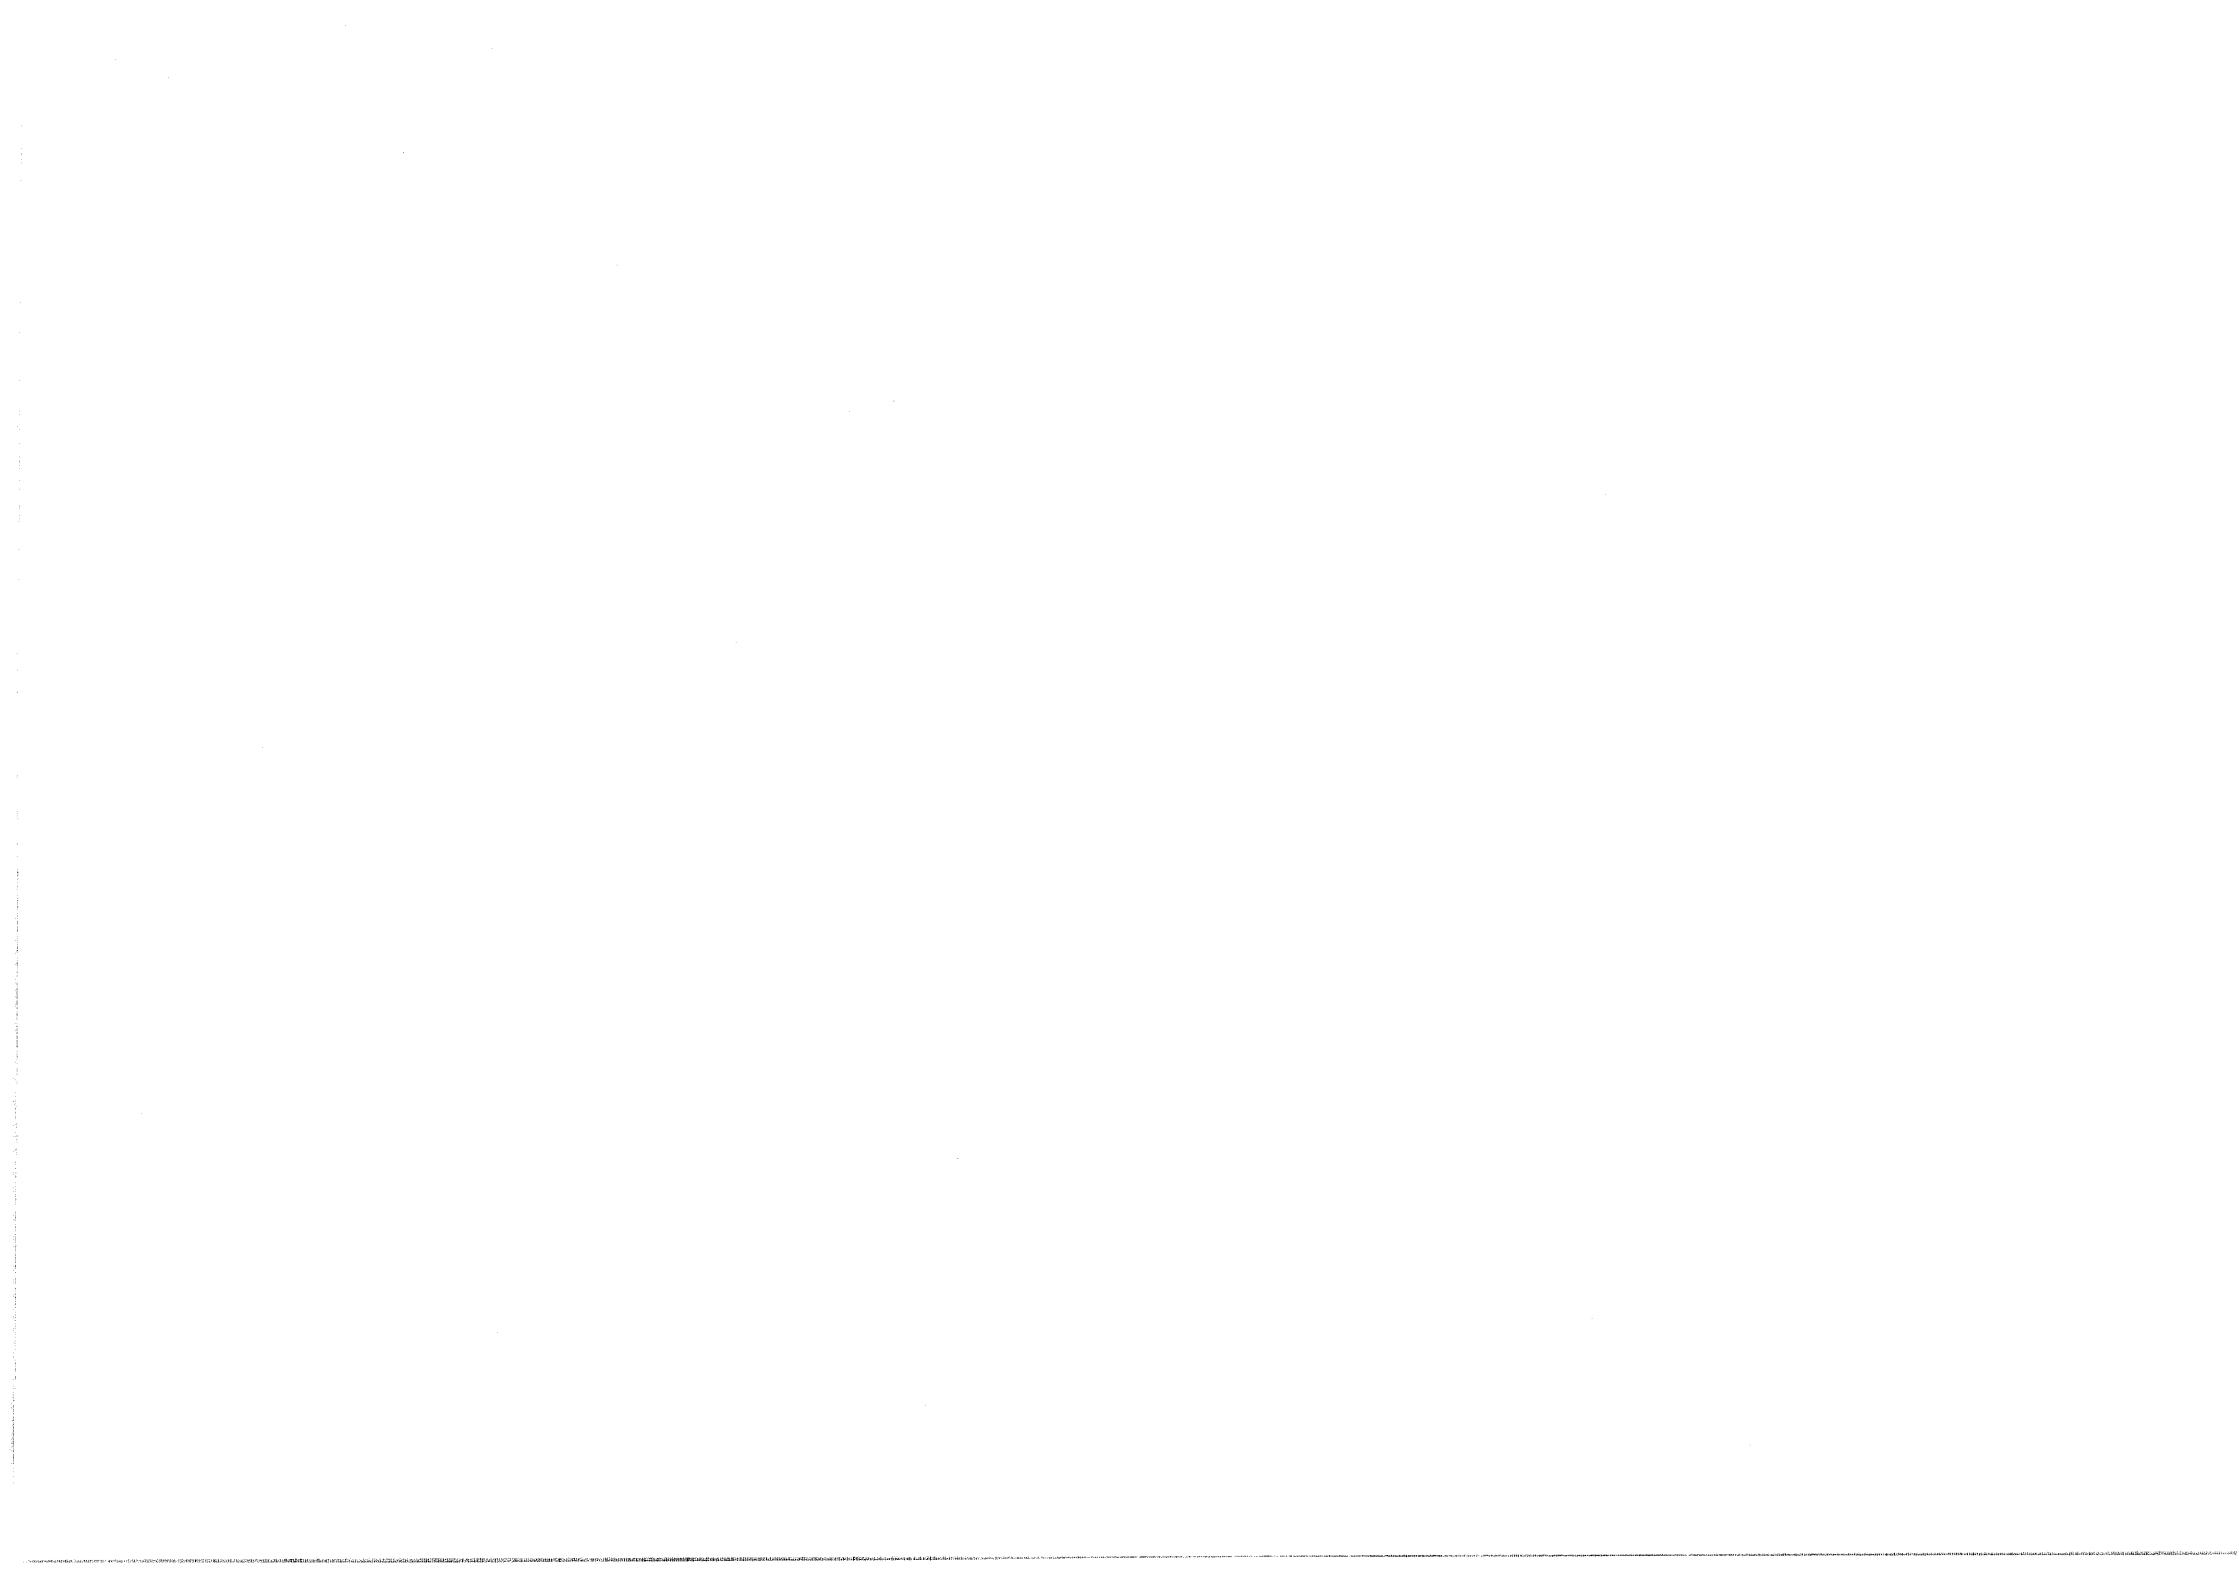
horis' inf  $b^T y$  na  $M_2$ .

je:  $\exists x \in M_1$   $\exists y \in M_2$ ,  $c^T x \leq b^T y$ ,  $\forall x \in M_1$

$$\Rightarrow \exists m_1 = \sup_{M_1} c^T x$$

$$\Rightarrow \exists m_2 = \inf_{M_2} b^T y$$

$$2.4.2 \Rightarrow \exists x \in M_1 \quad \exists y \in M_2 \quad c^T x \leq b^T y \quad \forall x \in M_1$$



Lemma 3: Jeżeli  $M_1 \neq \emptyset$  a  $\exists m_1$  (np.  $M_2 \neq \emptyset$  a  $\exists m_2$ ) i istnieje  $\underline{y}^0 \in M_2$

$$y^0 \in M_2 \text{ tak, że } b_i^T y^0 \leq m_{m_1}$$

(np.  $\exists x^0 \in M_1$  1. klasa,  $c^T x^0 \geq m_2$ ).

$D_2 : (\Leftrightarrow \text{funkcja } v)$

Vida: (Principle duality)

$\{x - b\}^T M_1 + \emptyset \neq \{M_2 + \emptyset\}$ , potom  $\exists$  opt. niz  $x^0$  w klasie (P) a opt. niz  $y^0$

$$\text{wtedy (D) a } M_1 = \{x^0 \in M_1 \mid C^T x^0 = b^T y^0\}$$

$$D_2 : L_2 \Rightarrow \exists m_1, m_2 \stackrel{L_3}{\Rightarrow} \exists x^0 \in M_1 \Rightarrow C^T x^0 \geq m_2 \geq m_1 \geq b^T y^0$$

$$\Rightarrow C^T x^0 = m_2 = m_1 = b^T y^0$$

Dalsze dalsze:

1)  $\{x - b\}^T y^0 \geq m_1$  (P) wtedy (D) opt. niz! tak ho ma "dalsza"

a plaski rozwiazunek funkcjonalny kodnotw. istot. klocka.

(M1 - xi) (P) opt. niz  $\Rightarrow M_1 \neq \emptyset$   $\exists m_1 \Rightarrow \exists y^0 \in M_2$  a takie  $M_2 \neq \emptyset$

a jasne zplywanie "princip duality"

2)  $\{x - b\}^T x^0$  akurat nie moga! ma  $M_1$  i potom je  $M_2 = \emptyset$ .

( $x - b$ )^T y^0 zawsze mniejsza na  $M_2$  i potom je  $M_1 = \emptyset$

3) Szwadron optimizacj:

$\{x - b\}^T x^0$  w klasie (P)  $\Rightarrow A x^0 \leq b$ ,  $x^0 \geq 0$ . Dzienicie  $C^T x^0$  jest  $A^T x^0$  (Principle duality)

$$a_{k_1}^T x^0 \leq b_1 \quad k_1 \notin I_n \quad | \quad (x_j^0 = 0 \quad j \in J_1 \quad x_j^0 > 0 \quad j \notin J_2)$$

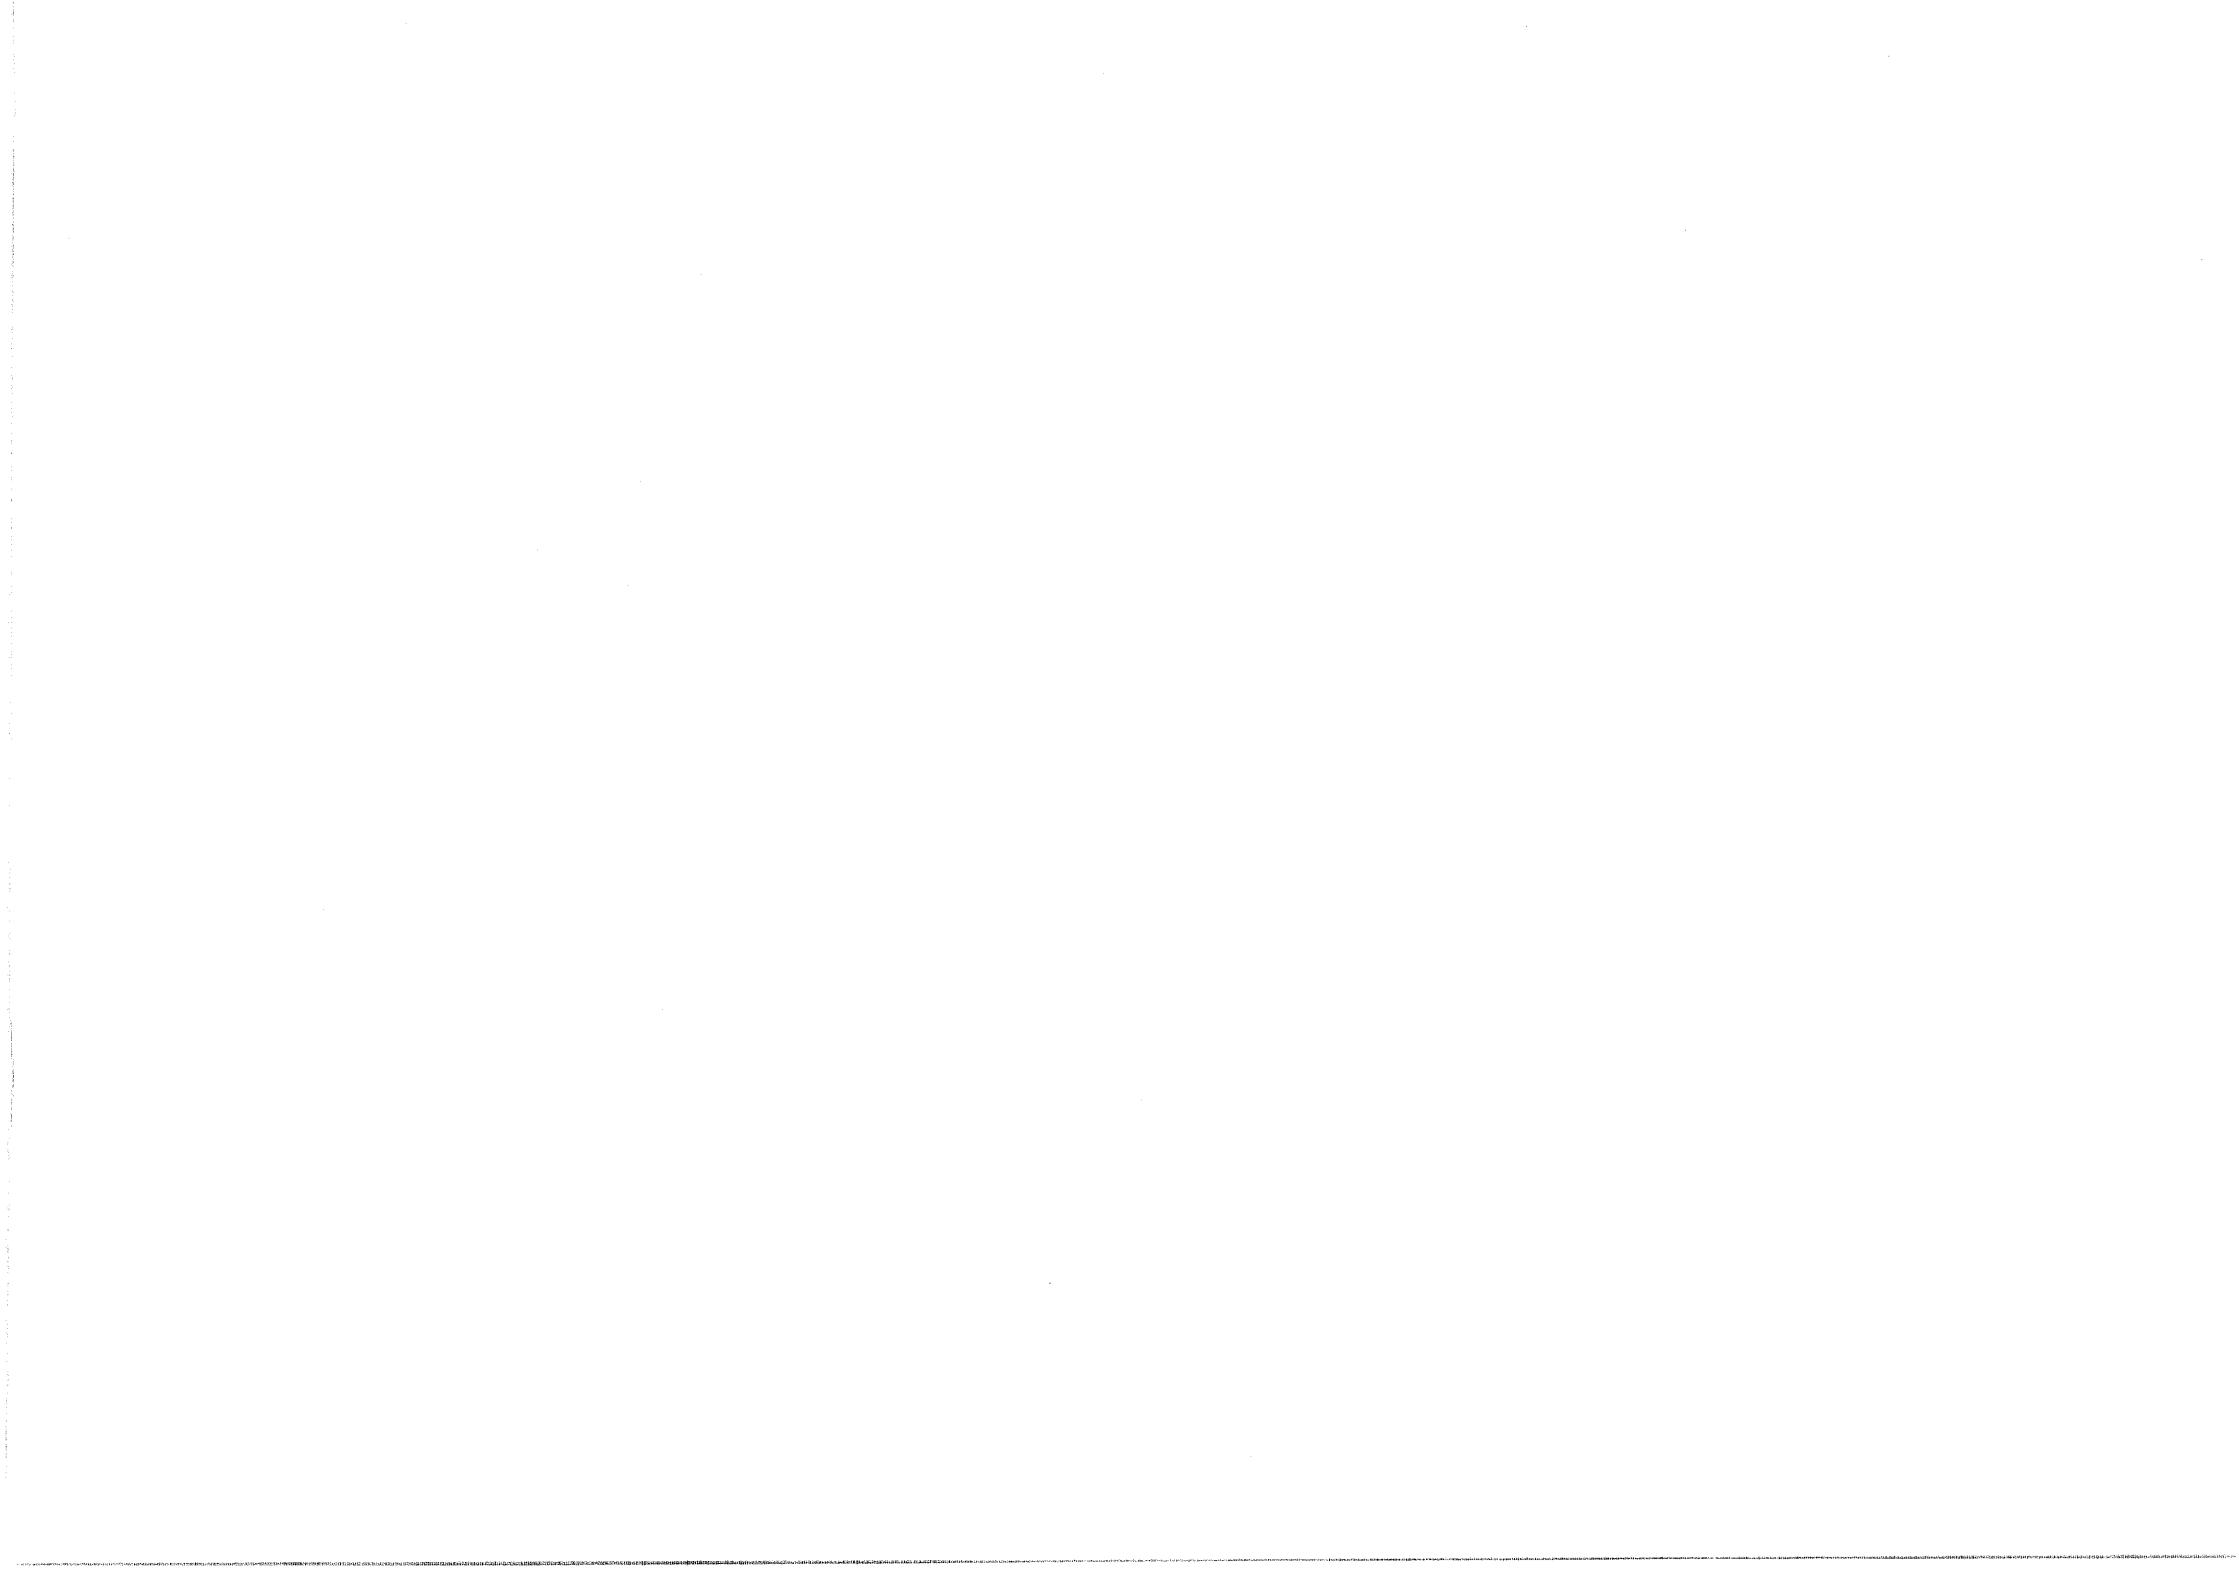
$$\text{Podsum } H_{\text{opt}}(D) = \left\{ y^0 \in M_2 \mid y_{j_1}^0 = 0 \quad j_1 \notin I_n \quad y_j^0 a_j^T = c_j \quad j \notin I_n \right\}$$

$$\begin{aligned} (2) L_1 \text{ a } P_D &= \underbrace{C^T x^0}_{y^0} = \underbrace{y^0 A^T x^0}_{b^T y^0} \Rightarrow (C - y^0 A^T) x^0 = 0 \\ &= \sum_{j \in J_1} (c_j - y^0 a_j^T) x_j^0 + \sum_{j \notin J_1} (c_j - y^0 a_j^T) x_j^0 = 0 \end{aligned}$$

$$\Rightarrow c_j = y^0 a_j^T \quad j \in J_1$$

$$\Rightarrow y^0 A^T (A^T x^0 - b) = 0 \Rightarrow \sum_{i \in I_n} y_{j_1}^0 (a_{k_1}^T x^0 - b_{k_1}) + \sum_{j \in J_1} y_j^0 (a_j^T x^0 - b_j) = 0$$

$$\Rightarrow y_{j_1}^0 = 0 \quad j_1 \notin I_n$$



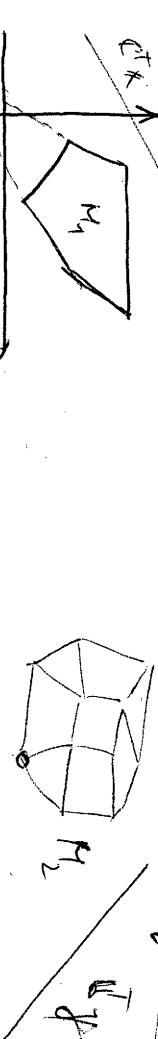
4) Restmont

$C^T x = b^T y$  plaus "präzise" a optimale kubisch Kettech.

$\Rightarrow$  PD  $\Rightarrow$  je - xi  $\star^0, y^0$  opt röß (P), (D)  $\Rightarrow C^T x^0 = b^T y^0$

$\Rightarrow$  Prädik,  $x^0$   $\star^0$  nur opt. röß (P)  $\Rightarrow C^T x^0 < C^T x^{\text{opt}} \leq b^T y^0$

a. node nücke: plaus  $C^T x^0 = b^T y^0$  



restliche reziprozante röß (P)

$$C^T x^0 = b^T y^0$$

$$C^T x^k = b^T y^k$$

$$y^k \in M_2 \quad \forall k$$

$$C^T x^k = b^T y^k \quad y^k \in M_1 \quad \Rightarrow \text{opt}$$

$\nabla \max y^k \in M_2$  bei simplex

(5)

21.03.2008

2) gesehen ac I\_m:

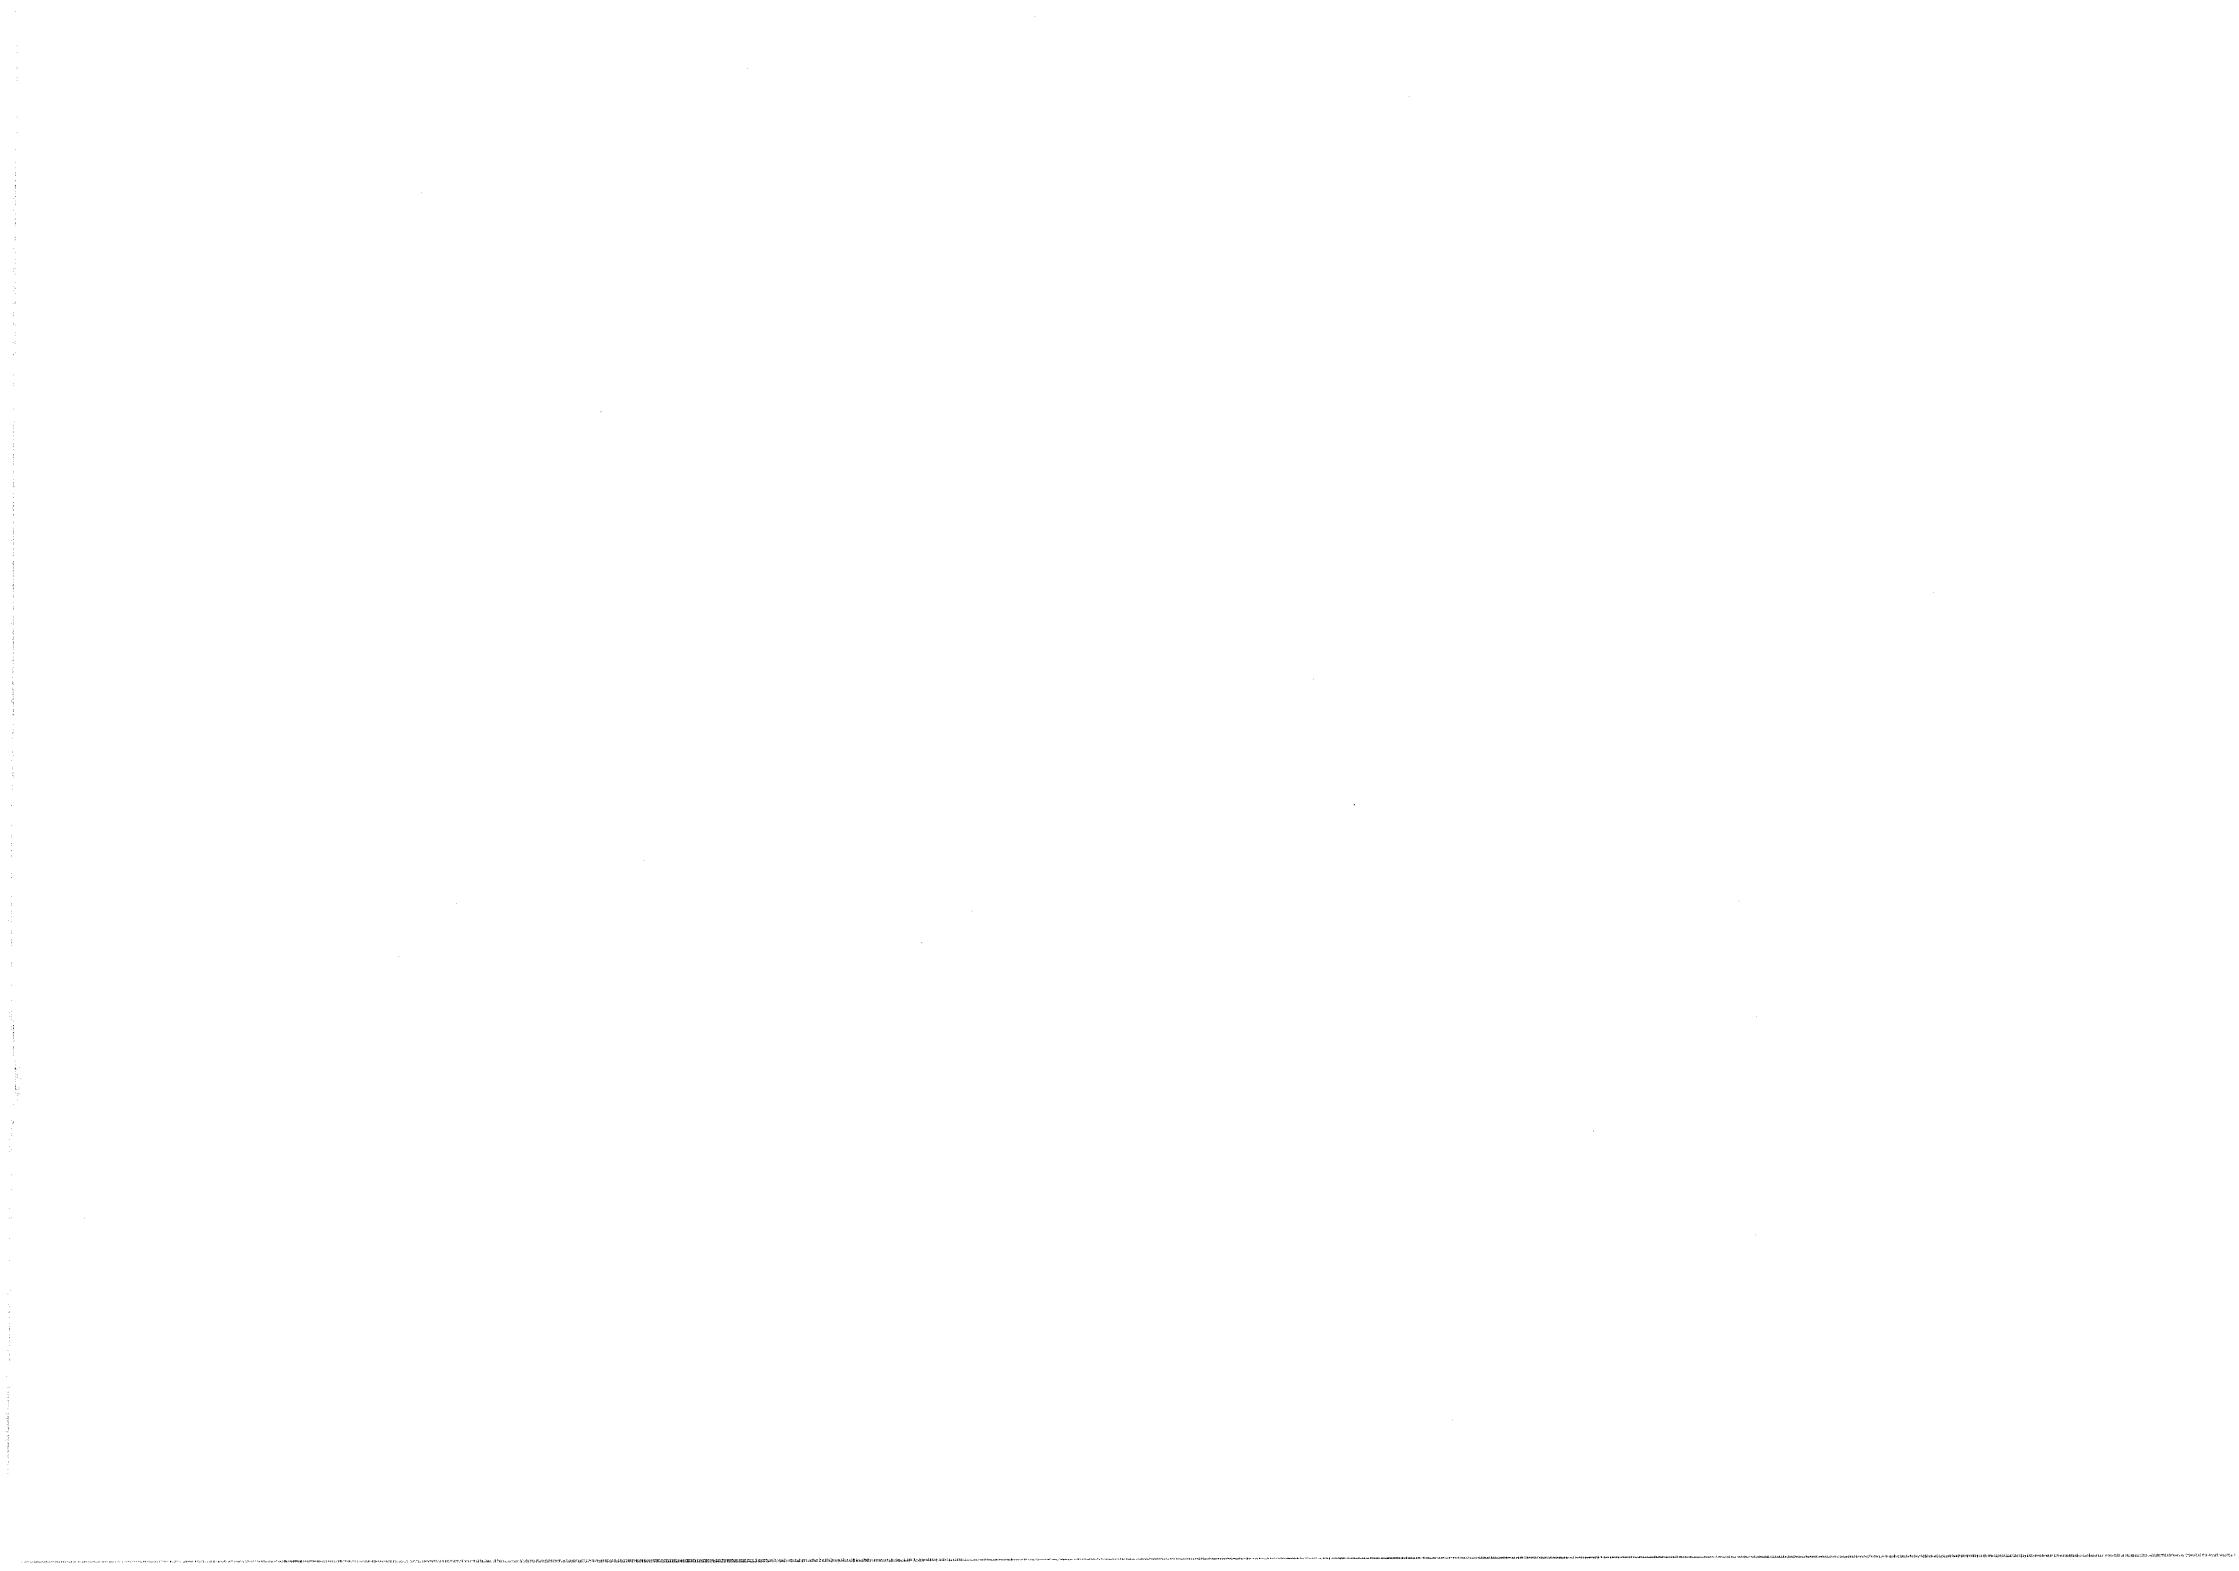
Nicht nutzbar! ST

$x_1$	$x_2$	$x_3$	$x_4$	$x_5$	$x_6$	$x_7$	$x_8$	$x_9$	$x_{10}$	$x_{11}$	$x_{12}$	$x_{13}$	$x_{14}$	$x_{15}$	$x_{16}$	$x_{17}$	$x_{18}$	$x_{19}$	$x_{20}$
1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1

$x_1$	$x_2$	$x_3$	$x_4$	$x_5$	$x_6$	$x_7$	$x_8$	$x_9$	$x_{10}$	$x_{11}$	$x_{12}$	$x_{13}$	$x_{14}$	$x_{15}$	$x_{16}$	$x_{17}$	$x_{18}$	$x_{19}$	$x_{20}$
1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1

$x_1$	$x_2$	$x_3$	$x_4$	$x_5$	$x_6$	$x_7$	$x_8$	$x_9$	$x_{10}$	$x_{11}$	$x_{12}$	$x_{13}$	$x_{14}$	$x_{15}$	$x_{16}$	$x_{17}$	$x_{18}$	$x_{19}$	$x_{20}$
1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	1

(12)



Pranidha

Nephrine transf. Albion

Sloping back see me number (3)

proteins are known to increase (prostaglandins) or decrease (cortisol)

poorly Mr. Shoup  
See *Spiranthes formosa*

de la we (episode 1). On sait que l'actrice habite

Dual line sum (lexicov. max. 1000 )

Dual linear programming problem

Maximize  $C^T x$        $x \in \mathbb{R}^m$        $Ax \leq b$ ,       $x \geq 0$

Minimize  $b^T y$        $y \in \mathbb{R}^n$        $A^T y \geq C$ ,       $y \geq 0$

Gestern war ich wieder in Wittenberg.

$$\begin{aligned} \text{Sektorielle } & \\ (1') \quad \max_{\mathbf{x}'} & c^T \mathbf{x}' + b' \quad | \quad \mathbf{x}' = \{(\mathbf{x}_1^*, \mathbf{x}') \in \mathbb{R}^{n+m} \mid A\mathbf{x} + \mathbf{x}' = b, \mathbf{x}_1 \geq 0\} \\ M_1' & \\ \text{reinen dualen} & \mathbf{x}' = (x_{m+1}, \dots, x_{n+m}) \end{aligned}$$

$$(3') \min_{y \in \mathbb{R}^m} \|H_2^T y\|_2 = \left\{ (y, y') \in \mathbb{R}^{m+m} \mid A^T y - y' = 0, y^T y' \geq 0, y' = (y_{m+1}, \dots, y_{m+m}) \right\}$$

Prepokolad:  $C \leq \sigma$  (wir 'warten', alle reihen!)

Wychoń! Kacikie! reśne! u'łok. (?) a (D)!

$(\#_1, \#_2) = 0$   $\Rightarrow$   $\#_1 = 0$   $\wedge$   $\#_2 = 0$   $\rightarrow$   $\text{je triviale 1-Forme}$

'Ghosh' Ashokha dhalu' Am.  
(Post) 8pm

objie de m' piedue ' la bulle

A hand-drawn graph of a piecewise function  $f(x)$  on a Cartesian coordinate system. The horizontal axis is labeled  $x$  and the vertical axis is labeled  $y$ . The function is zero for  $x \leq 0$ . For  $x > 0$ , the function consists of two parts: one increasing linear segment from the point  $(0, 0)$  to  $(1, 1)$ , and another decreasing linear segment from  $(0, 0)$  to  $(1, -1)$ .

R-hey Brook:

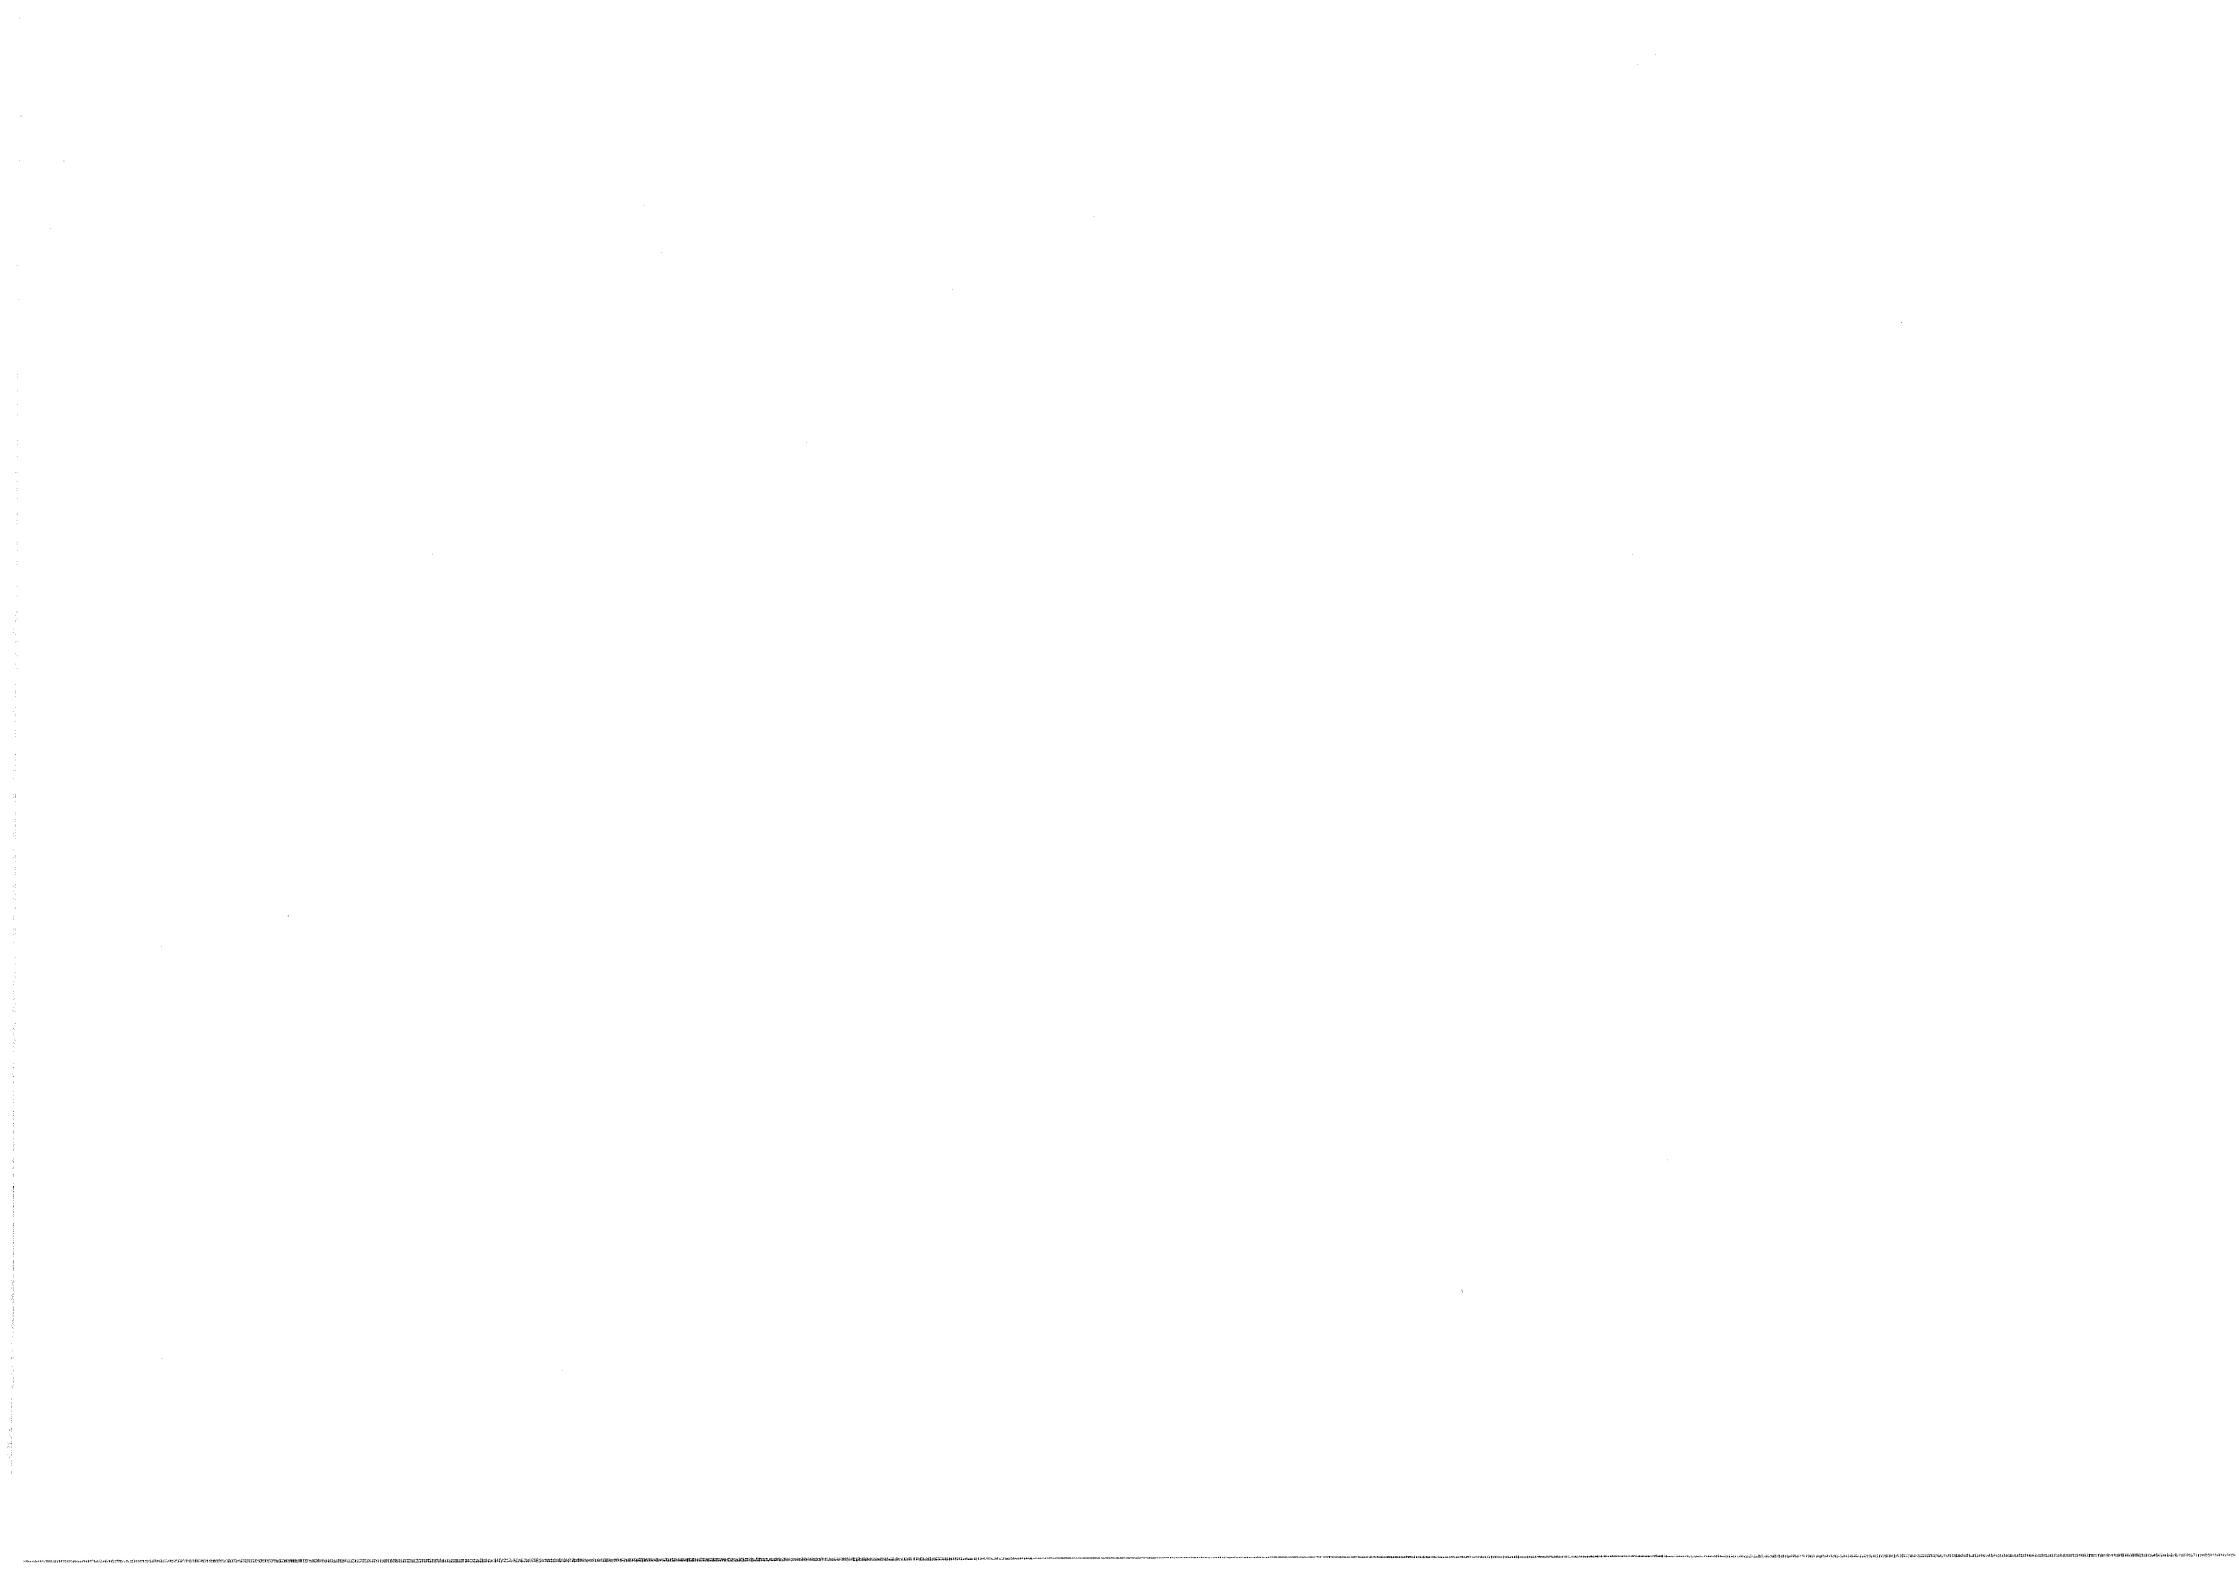
$$\frac{(\gamma(y))_{Bd}}{(\gamma(x))_N}$$

*Y. H.:*  
-principles behind mouse milking (D)

- kritische minimale Wölfung ( $\tau^*$ )

$$(\mathbf{x}_1 \mathbf{x}_1^T)^B = \mathbf{H}_0 \quad (\mathbf{x}_1 \mathbf{x}_1^T)^N = \sigma$$

Die einzige russische Reaktion auf die  
Kampagne des.



### 1. Věta DSH:

Platí-li v k-ému kroku DSH  $d^0 \geq 0$ , potom  $(\mathbf{x}, \mathbf{x}')_B = d^0$ ,  $(\mathbf{x}, \mathbf{x}')_N = 0$ , je opt. něj užší  $\mathcal{P}^0$  a hodnotou užší 'funkce'  $d_{00}$  a průměrnou 'část'  $(\mathbf{x}_B, \mathbf{x}_N)$  je opt. něj užší  $\mathcal{P}$  a opt. hodnota užší 'funkce'  $d_{00}$ .

Dále  $(y, y')_B = d^0, (y, y')_N = 0$ , je opt. něj užší  $\mathcal{D}'$ , a průměrnou 'průměrnou část'  $(y_B^*, y_N^*)$  je opt. něj užší  $\mathcal{D}$  a opt. hodnotou užší 'funkce'  $d_{00}$ .

$$\underline{\text{Dk:}} \quad \text{Proteče } [(\mathbf{x}, \mathbf{x}')_B, (\mathbf{x}, \mathbf{x}')_N] \in \mathcal{M}_1 \subset [(\mathbf{y}, \mathbf{y}')_B, (\mathbf{y}, \mathbf{y}')_N] \in \mathcal{M}_2 \quad (\text{vzády})$$

$$\Rightarrow (\mathbf{x}_B, \mathbf{x}_N) \in \mathcal{M}_1 \quad \& \quad (y_B^*, y_N^*) \in \mathcal{M}_2 \quad \Rightarrow \\ \Rightarrow \text{proteče } \mathbf{C}^T \mathbf{x} = \mathbf{b}^T \mathbf{y} = d_{00} \quad (\text{protože dimenze kruhu } \mathcal{P}_D) \\ \text{Optimalita } \mathbf{x} \text{ resp. } \mathbf{y} \text{ pro užší } \mathcal{P} \text{ resp. } \mathcal{D}$$

Neck. něj.

$$\begin{array}{c} \text{D} \\ \diagdown \quad \diagup \\ d^0 \quad < 0 \\ \diagup \quad \diagdown \\ \mathbf{A}^T \mathbf{y} - \mathbf{b}' = \mathbf{c} \\ \mathbf{y}' = -\mathbf{c} + \mathbf{A}^T \mathbf{d} \\ \mathbf{b}' = \mathbf{b} - \mathbf{A} \mathbf{x}_N \end{array}$$

Závěta DSH:

Existuje - li index  $s \in B$  tak, že  $d_s^0 < 0$  a  $d_{sJ} \geq 0, j \in N$ .

Potom neexistuje reálný užší  $\mathcal{P}_1, \mathcal{D}_1$ .

Dk:  $s$ -tý rádek post. tabulek je například

$$x_s (resp. x'_s) = d_s^0 - \sum_{j \in N} d_{sj} \underbrace{(x, x')_j}_{\leq 0} < 0$$

$$\text{ale } M_1 \text{ má } (x_s, x'_s) \geq 0 \Rightarrow M_1 = \emptyset \Rightarrow M_1 = \emptyset \Rightarrow$$

$$\Rightarrow \text{neck. něj. } (\mathcal{P}) \stackrel{PD}{\Rightarrow} \text{neck. něj. } (\mathcal{D})$$



### 3. Věta DSH 1

Nicht negativ splining pravděpodobnosti 1. až 2. VDSM.

Degenerace

$$\min \left\{ x_i \in \mathbb{R} \mid d_i^0 < 0 \right\} \equiv \text{if } \exists i \text{ such that}$$

$$\min \left\{ \begin{array}{l} \text{ver} \\ \text{min} \end{array} \left\{ \begin{array}{l} \frac{d_i^0}{|d_{ij}|} \\ \frac{d_i^0}{|d_{ik}|} \end{array} \right\} = \frac{d_i^0}{|d_{ik}|} \right\} \equiv \frac{d_i^0}{|d_{ik}|} \text{ for some } i \in \mathbb{N} \setminus \{k\}$$

pro transformaci degenerací (a dodatečném pro několik výjimek)  
 a  $E(d_{ik})$  dosudové pravděpodobnost  $\hat{p}_k$ , res.  $(y_1, y')^*$  užívají  $(D')^*$   
 a obecně když  $(*, *)^*$  užívají  $(P')$  pravděpodobnost  $\hat{p}_k$  když je  $d_{ik}^*$  finální až po krok 2. rezimích je  $d_{ik}^* = d_{ik} - \frac{d_{ik}^0 \cdot d_{ik}}{d_{ik}}$

a plní  $d_{ik}^* \leq d_{ik}$ . Nenásobka  $-d_{ik}$  degenerace plní  $d_{ik}^* < d_{ik}$ .

$$\boxed{\text{Dk: } \begin{cases} d_{ik} < 0 \\ (y_1, y')^* : d_j^0 = d_j^0 - \frac{d_{ij} \cdot d_{ik}}{d_{ik}} \geq 0 \end{cases}}$$

charakteristické množství  $\lambda_k^* \geq 0$ .

$$\Rightarrow \text{potom } d_{ik} < 0 \Rightarrow d_{ik}^* \geq 0$$

$$\Rightarrow \text{potom } d_{ik}^* < 0 \Rightarrow \frac{d_{ik}^0}{|d_{ik}|} > \frac{d_{ik}}{|d_{ik}|} \Rightarrow \frac{d_{ik}^0}{d_{ik}} < \frac{d_{ik}^0}{d_{ik}} \Rightarrow$$

$$\Rightarrow d_{ik}^* > \frac{d_{ik}^0 \cdot d_{ik}}{d_{ik}} \Rightarrow d_{ik}^* \geq 0$$

$$d_{ik}^* = \frac{d_{ik}^0}{d_{ik}} > 0 \geq 0$$

Dovídáme je  $(y_1, y')^* \in M_2^0$

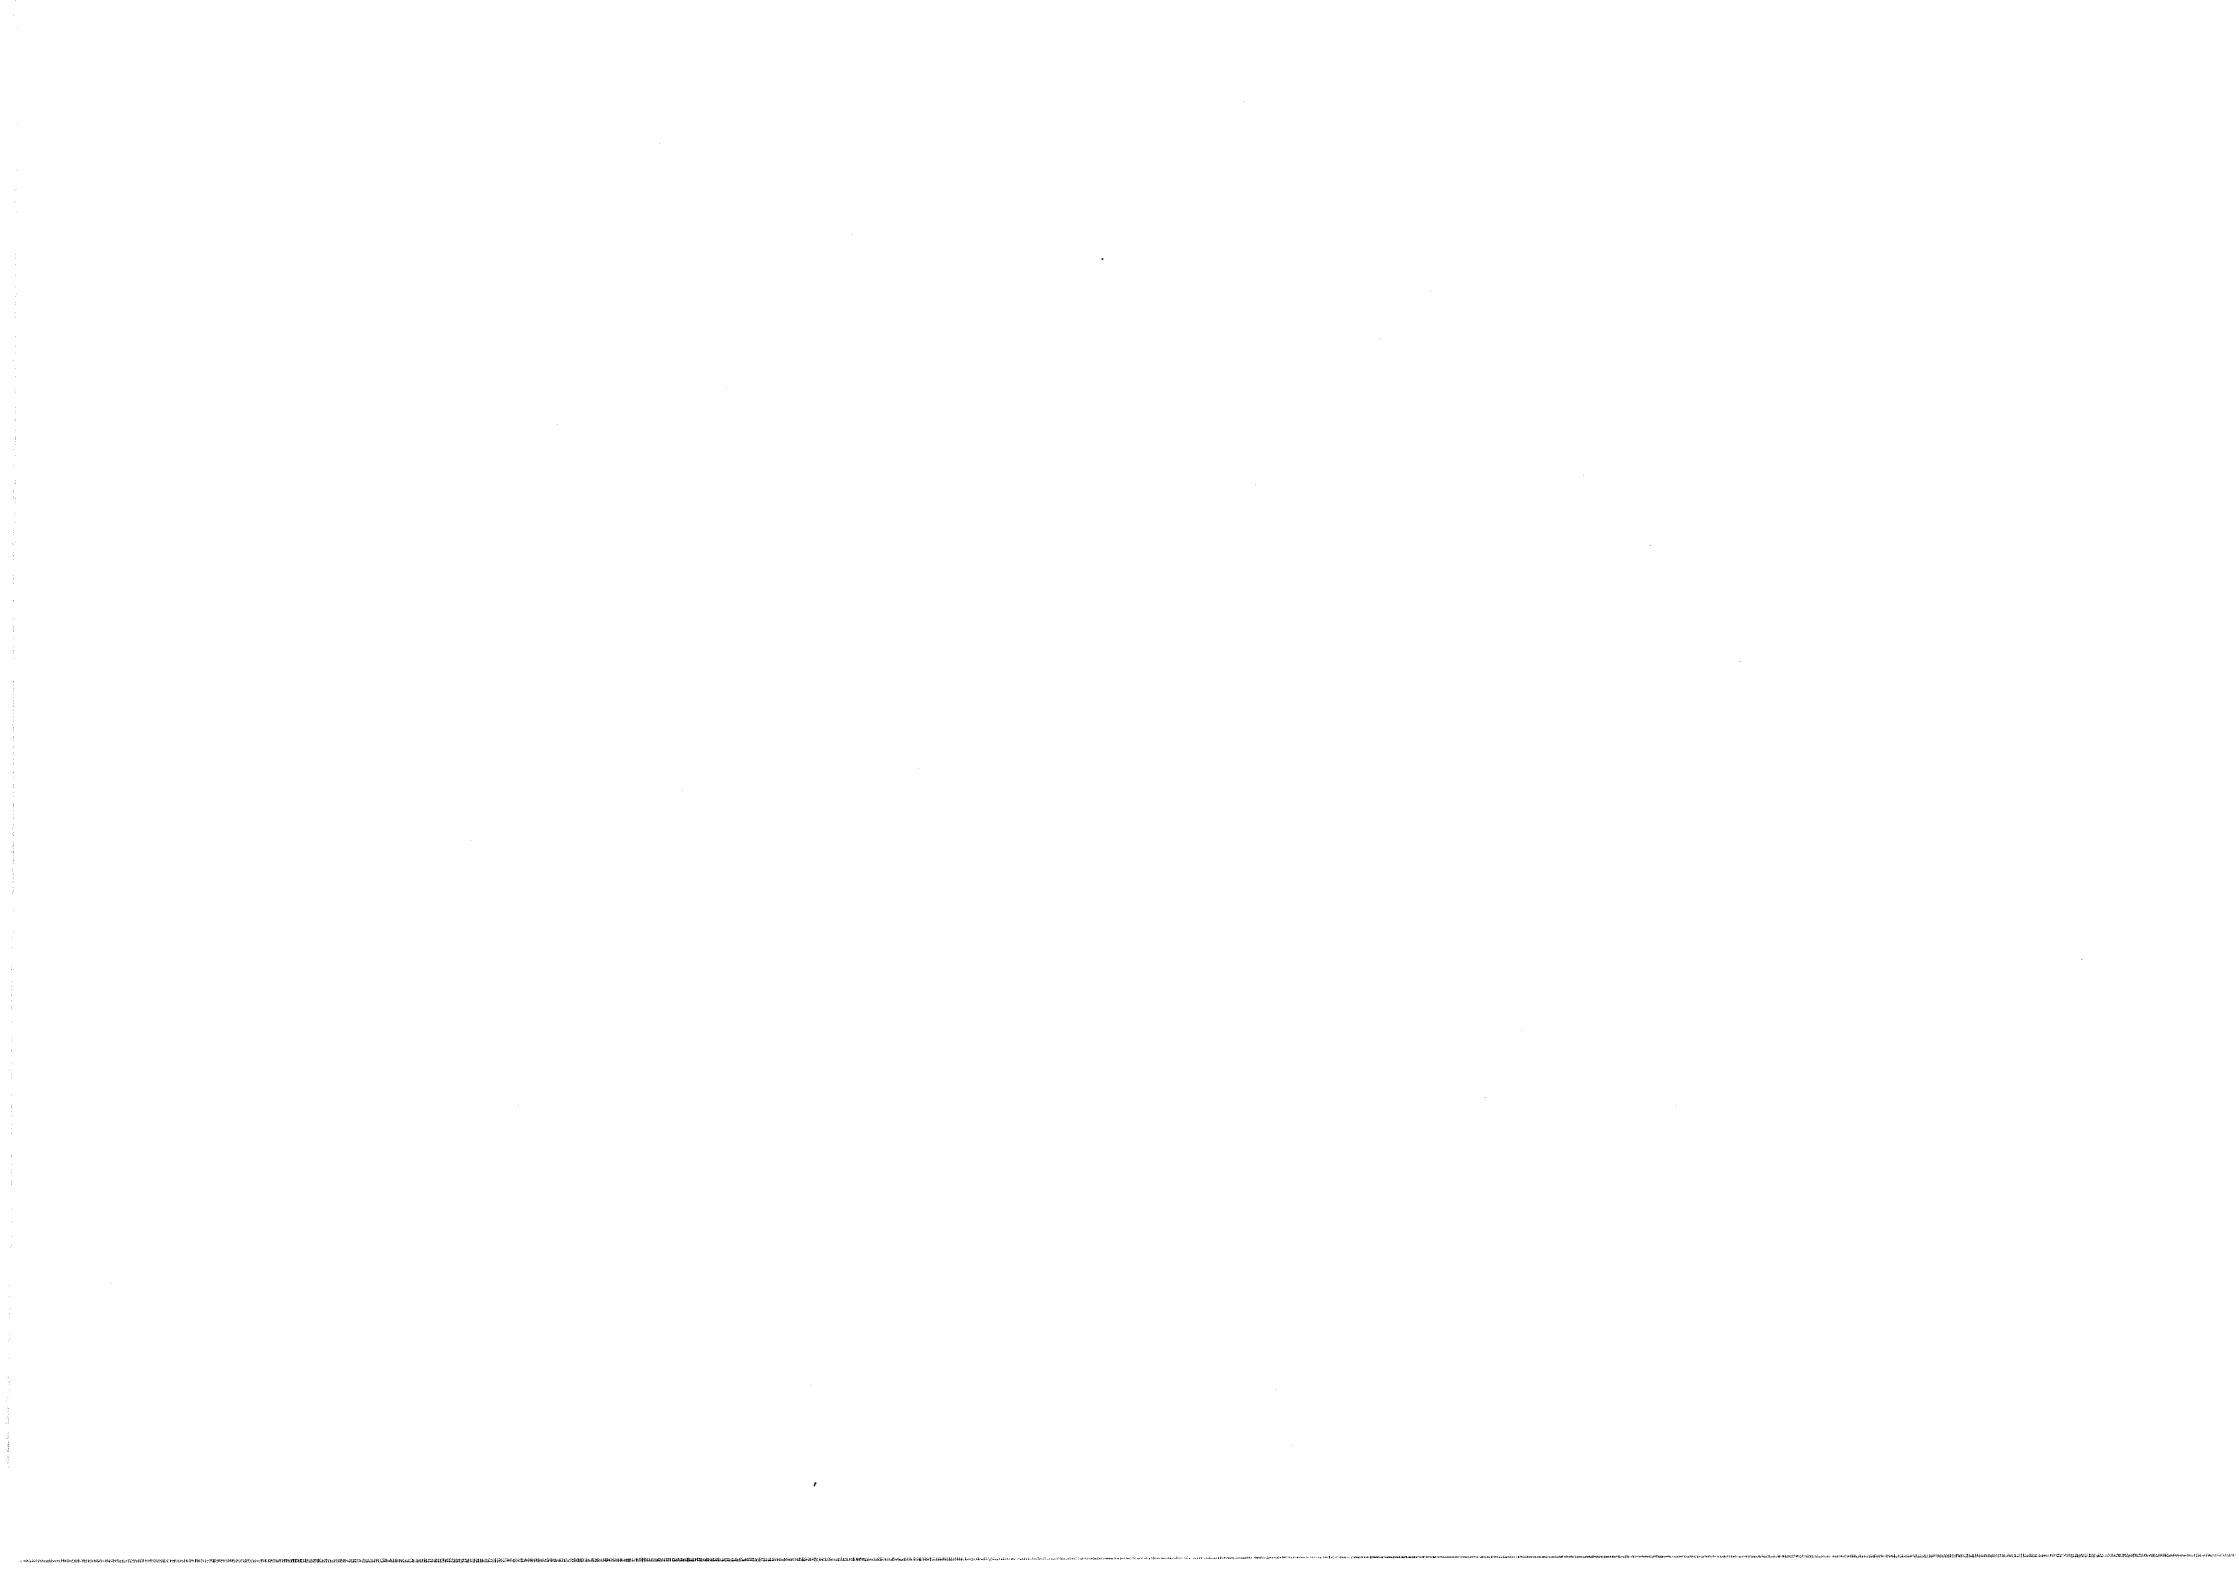
$$\text{Podle druhého množství je } d_{ik}^* = d_{ik} - \frac{d_{ik}^0 \cdot d_{ik}}{d_{ik}} \leq d_{ik}.$$

Poznámka:

Pokud množství degenerace  $(d^0 > 0) \Rightarrow d^* > 0 \Rightarrow d_{ik}^* < d_{ik}$   $\square$

Metoda je koncna' - mame pouze mnoho méně kroků než a koncového Blandova pravidlo

Pom: Dva krok: SM se da' učit i bez předchozí kroku  $C^T \leq 0$



Když máte tu pouze 1 DSH?

$$\max C^T \mathbf{x} \quad | \quad M = \sum_{x \in M} \mathbf{x} \leq A \mathbf{x} + b, \quad \mathbf{x} \geq 0$$

$$C < 0 \quad | \quad b < 0 \quad | \quad \text{není řešení}$$

$$A \mathbf{x} + \mathbf{x}' - w = b$$

(6)

28.03.2008

(16)

### Celosíselné 'programování'

Definice 1: Uloha  $\max f(\mathbf{x})$ , kde  $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $M \subset \mathbb{R}^n$

$$M = \left\{ \mathbf{x} \in \mathbb{R}^n \mid g_i(\mathbf{x}) \leq 0 \quad (i=1, \dots, m), \quad x_j \in \mathbb{Z}, \quad j \in \mathcal{C} \subseteq \{1, \dots, n\} \right\}$$

$g_i(\mathbf{x}): \mathbb{R}^n \rightarrow \mathbb{R}$  + maximální obecnou ulohou celočíselného programování.

Je-li  $C = \{1, \dots, m\}$ , potom máme 'cislo' užití a je-lá.

$C \not\subseteq \{1, \dots, m\}$  a máme 'užití' užití.

Metody: 1) řešený měřivořiv (methody řešení)

2) Kombinatorické

3) Průblikové metody

4) Speciální metody pro spec. problém (casto se opakují)

1) Gomory



Definice 2: Uloha  $\max C^T \mathbf{x}; \quad \mathbf{x} \in \mathbb{R}^n; \quad \mathbf{x} \in M$

$M_C = \left\{ \mathbf{x} \in \mathbb{R}^n \mid A \mathbf{x} \leq b, \quad \mathbf{x} \geq 0, \quad x_j \in \mathbb{Z}, \quad j \in C, \quad C \subseteq \{1, \dots, m\}, \quad A \in \mathbb{R}^{m \times n}, \quad b \in \mathbb{R}^m \right\}$

'maximální uloha lineárního čísložádor' (pokud  $C = \{1, \dots, m+n\}$ )

je to samé 'číslo' (pokud  $C \subseteq \{1, \dots, m+n\}$ ) celosíselného programování

Poznámka:

Nevím odkud  $A \mathbf{x} \leq b$  může zjít.  $A \mathbf{x} + \mathbf{x}' = b, \quad \mathbf{x}' \geq 0$

$$\mathbf{x}' = (x_{m+1}, \dots, x_{m+n})$$

Definice 3: Uloha  $\max_{M'} C^T \mathbf{x}$ , kde  $M = \left\{ \mathbf{x} \mid A \mathbf{x} \leq b, \quad \mathbf{x} \geq 0 \right\}$  máy vše

úpravenou ulohou 'programování' (1).

Poznámka: Budeme řídit 'programování' 'ulohou'  $k(2)$

$$(k') \max_{M'} C^T \mathbf{x}, \quad M' = \left\{ (\mathbf{x}, \mathbf{x}') \in \mathbb{R}^{m+n} \mid A \mathbf{x} + \mathbf{x}' = b, \quad \mathbf{x}_1 \mathbf{x}_{m+1} \geq 0 \right\}$$



# Mjölkanka 1. Gomoryho alg.

Reální číslovou užitkovou funkcií - ex loc. program.

Necht "n" n - dimenzijskou algoritma opt. res.  $(x_1^*, x_2^*)^*$  v "lucky" (2).  
Jedná se  $(x_1^*, x_2^*)^* \in H_C'$  protože je  $x_1^*$  opt. res. (1).

Jedná se  $(x_1^*, x_2^*)^* \notin H_C'$  samekdy  $\forall_{k \in K}$  mimoživý  $H_{\text{opt}}$ .

Necht  $x_k^n \notin \mathbb{Z}$

$$x_{k'}^1 \Rightarrow x_k = x_k^n - \sum_{j \in N} d_{kj} x_j \quad \text{role dle } x_k^n = d_{kk}$$

jsem pochopily a poslední. Na báli by  $(x - d_{kj})$  rádecké.

Zavedeme-li označení pro  $b \in \mathbb{R}$   $b = [b] + \{b\}$   
potom  $[b]$  nejblížejší celočíslo vlevo od  $b$  a  $\{b\}$  je zbytek.



$$\text{Tedy } 0 \leq \{b\} < 1, \text{ a dle } x_k = [d_{kk}] + \{d_{kk}\}$$

$$- \sum [d_{kj}] x_j - \sum [d_{kj}] x_j = 0$$

$$\text{Veta 1: } \text{funkce } R = \left\{ (x_1, x_2) \in \mathbb{R}^{m+n} \mid -\boxed{d_{kk}} + \sum_{j=0}^m \boxed{d_{kj}} x_j = 0 \right\}$$

je "sečnovou množinou" a vlastnosti:  $H^+ \subset R$

$$(x_1, x_2)^* \in H^-, \quad H_C' \subset \overline{H^+}, \quad \text{kde } \overline{H^+}$$

$$H^- = \left\{ (x_1, x_2) \in \mathbb{R}^{m+n} \mid -\boxed{d_{kk}} + \sum_{j=0}^m \boxed{d_{kj}} x_j < 0 \right\}$$

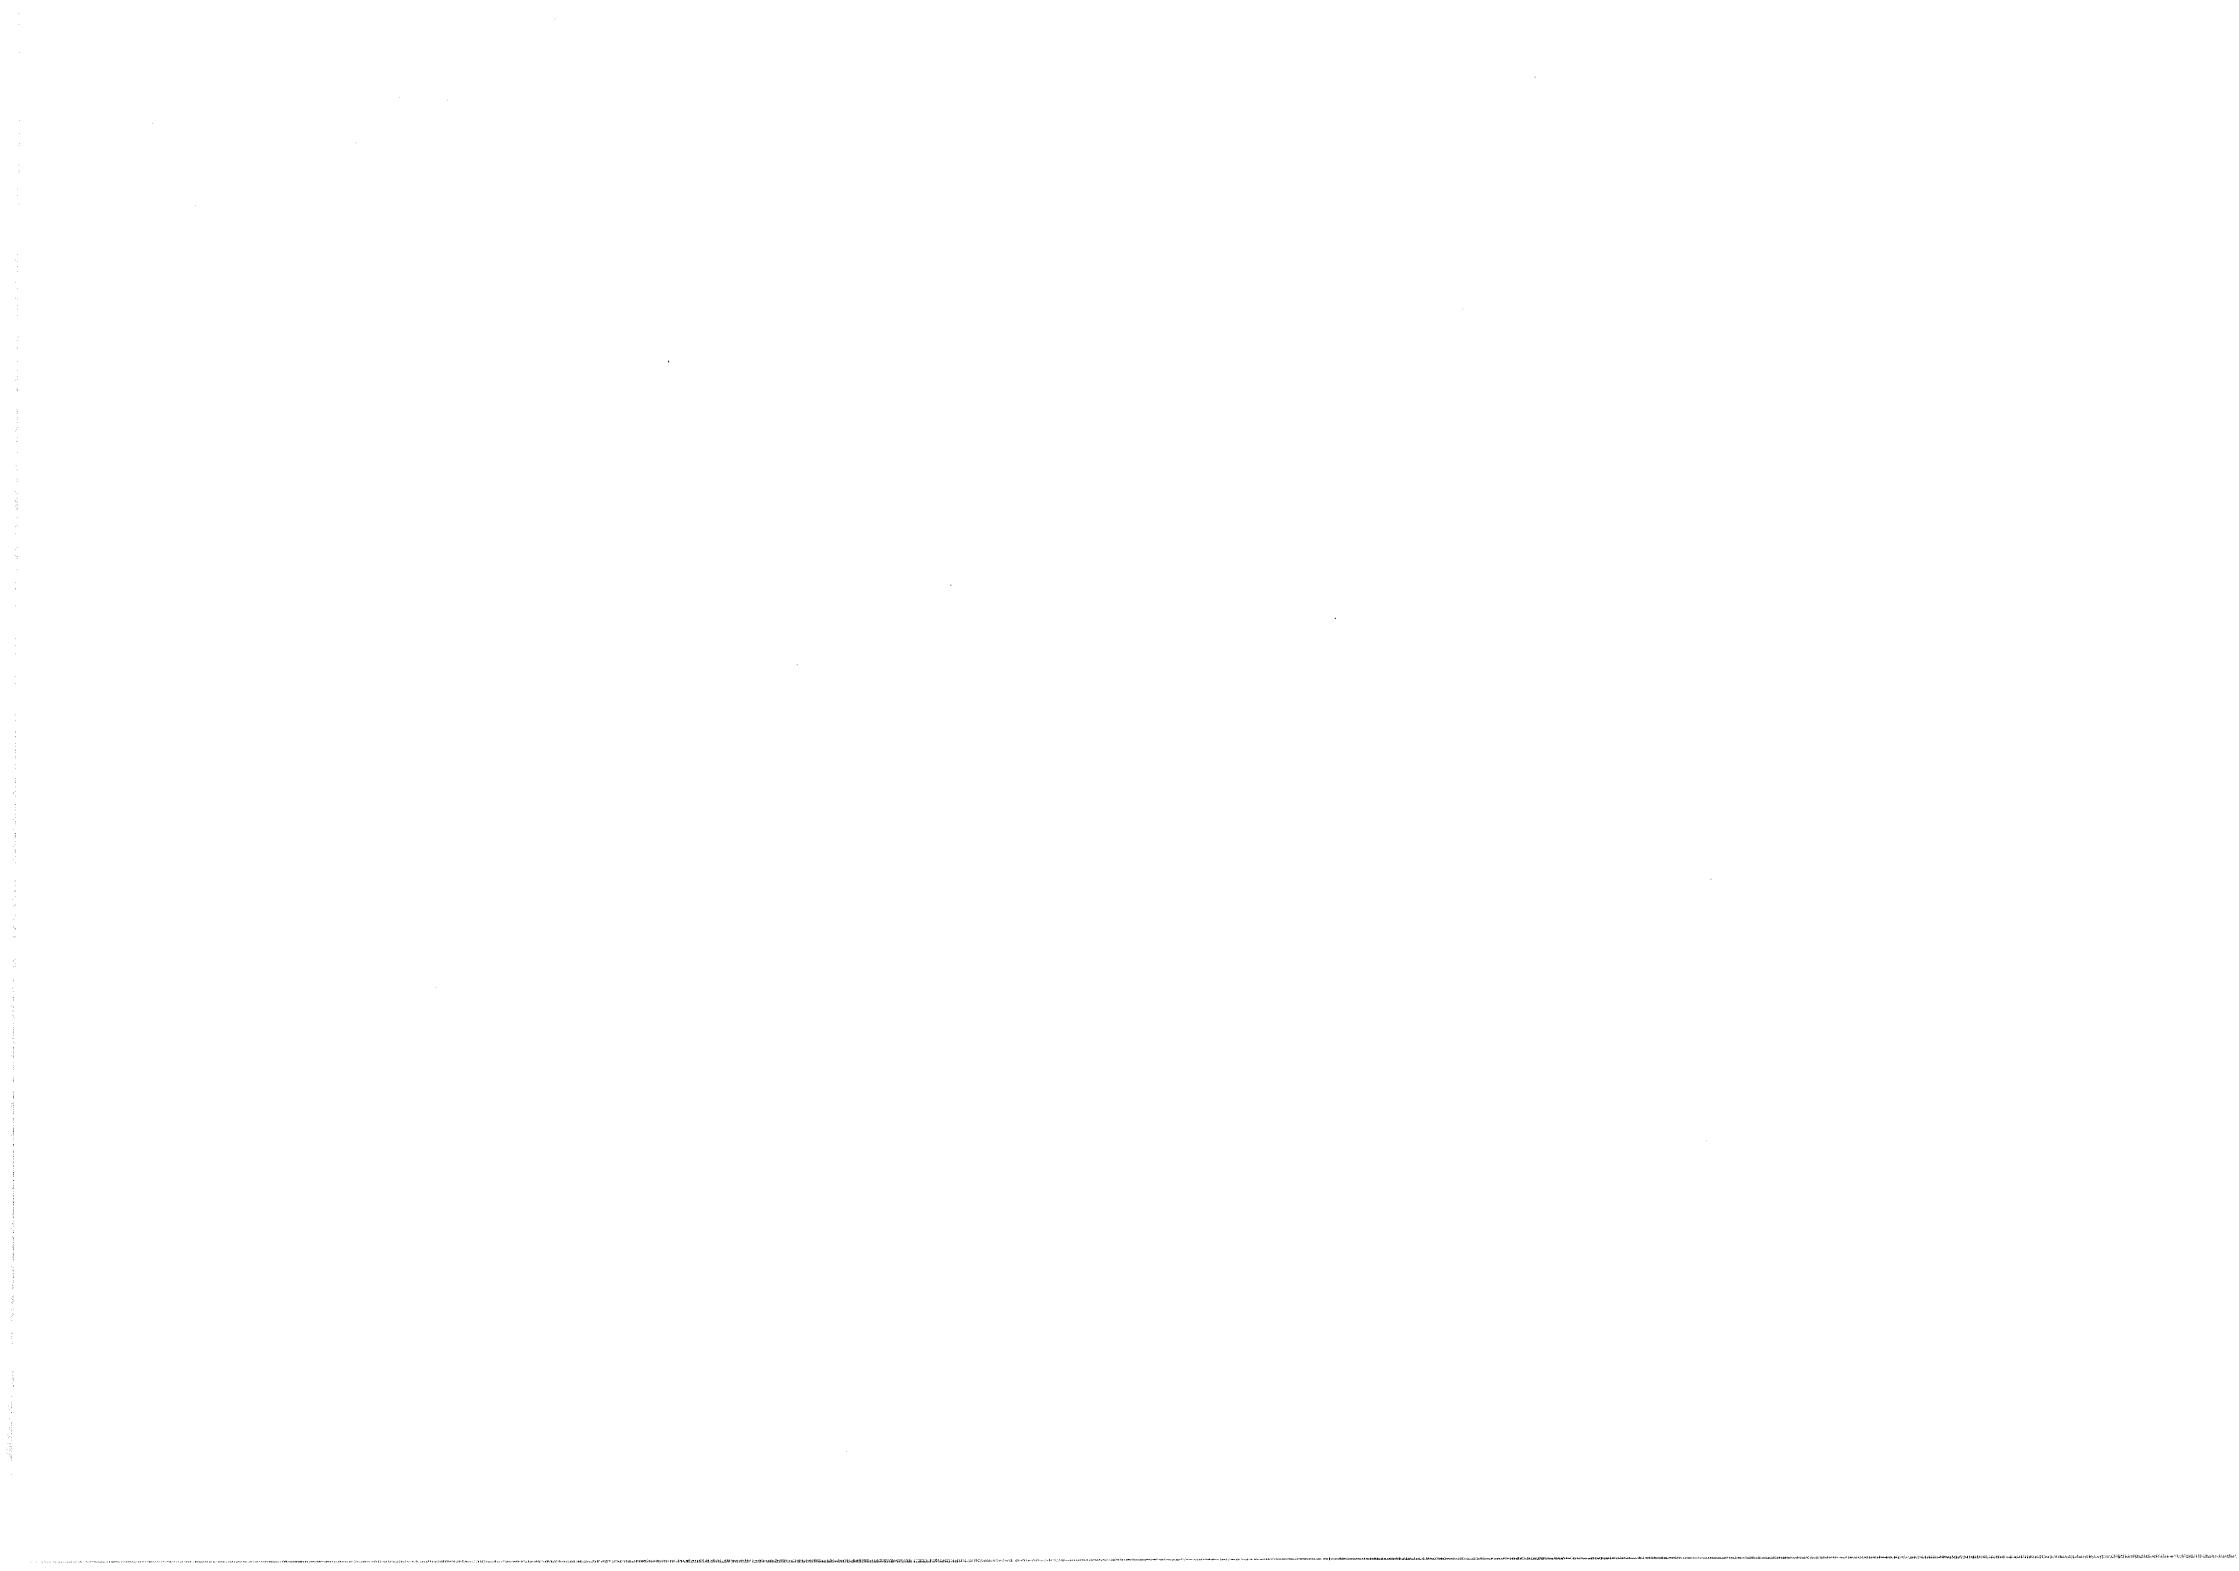
$$\overline{H^+} = \left\{ \begin{array}{c} \dots \\ \dots \\ \dots \\ \dots \\ \dots \end{array} \geq 0 \right\}$$

$$\text{d.l.: } P_{\text{opt}} (x_1, x_2)^* \text{ plati } (x_1, x_2)_B^* = \text{choose}, \quad (x_1, x_2)_N^* = 0$$

Tedy po dosazení  $(x_1, x_2)^*$ :

$$-\boxed{d_{kk}} + \sum_{j \in N} \boxed{d_{kj}} \cdot 0 < 0 \Rightarrow (x_1, x_2)^* \in H^-$$

Zvolíme li  $(x_1, x_2)^* \in H_C'$   $\Rightarrow$  proti k - dom novouci



$$x_k = \text{dok} - \sum_{j \in N} \text{dej}_j x_j = [\text{dok}] + \boxed{\text{dok}} - \sum_{j \in N} [\text{dej}_j] x_j - \sum_{j \in N} [\text{dej}_j] x_j$$

$\in \mathbb{Z}$

$$- \boxed{\text{dok}} + \sum_{j \in N} \boxed{[\text{dej}_j]} x_j = -x_k + [\text{dok}] - \sum_{j \in N} [\text{dej}_j] x_j$$

$\in \mathbb{Z}$

~~Polakacijine da la rezervuva~~ shpiku u lošoj max C<sub>T</sub> M- $\frac{1}{1+t}$

$$\max_{\mathcal{T}} \mathcal{L}$$

•) Když počítáme dle  $\in \mathbb{Z}$  (ale dle  $\neq \mathbb{Z}$ )  $\Rightarrow$  výsledek je  $\emptyset$

卷之三

gedruckt von

卷之三

do je budoucne pracovat s lexikografií by ordinace kmen (k-optimální kmeny množství) jednotlivých náloh max &  $\tau_k$   
 $H_1^+ H_2^+ \dots H_m^+$

Postlethwait prechr. Jr. M<sup>c</sup> # 9

$$\mathcal{X} = (0, \dots, 0, 1) - 100\epsilon$$

Definition 4:  $x \in \mathbb{R}^n$  maximeert R-functie, als er een plan  $x_k > 0$

$\hat{x} = \arg \min \{ x^T x - 2x^T b + b^T b \}$ , over  $x \in \mathcal{X}$ .  
 \* je  $x$ -margin, generalise je  $x = 0$  vector  $x \in \mathcal{X}$ .

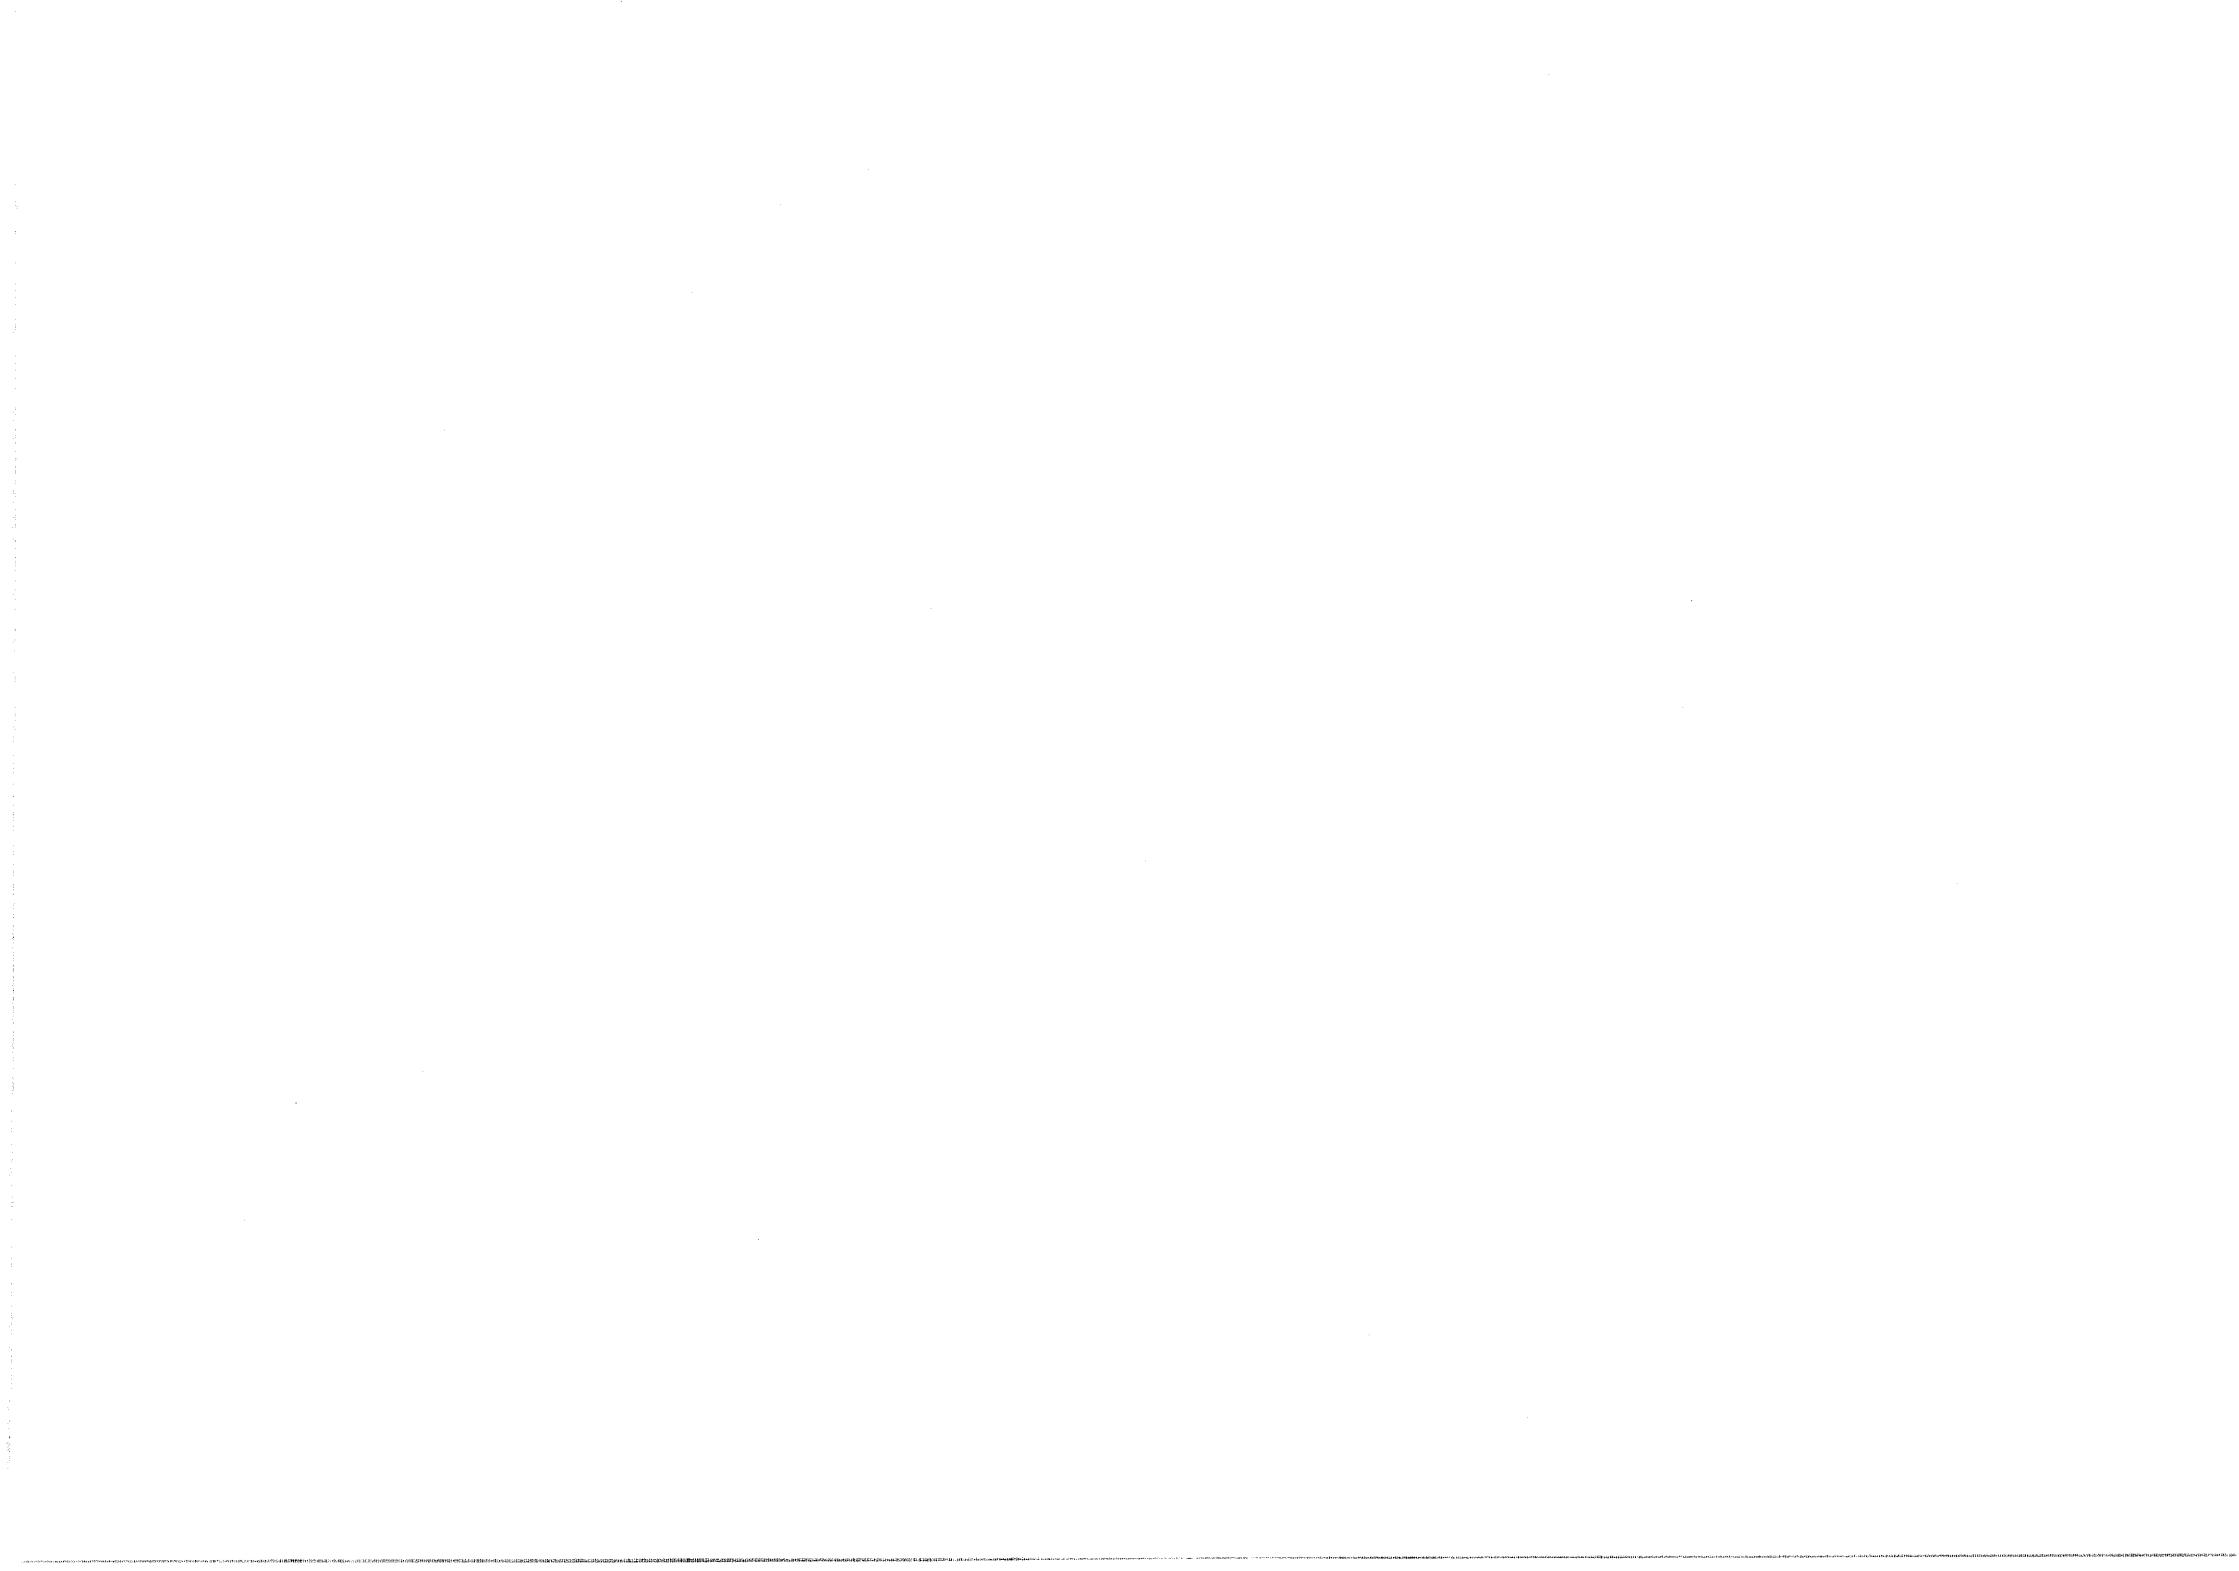
Def:  $C^T *$   $\equiv_{\text{def}} x_0 \mid x \in M^1 \text{ a body } (*, *) \in M^1$   
 Provoljena promjena načina odgovara  $x_1$  isto nejednačenje  $*$   $x_1 \in \{x_1 - m\}$

Beta:  $\text{je}-\text{ki}$  M one zero a  $M_{\text{opt}} \neq \emptyset$ , koton  $\exists x$ -opt res. milohy max  $C^T x$ .  
Dk: Kine Mokt =  $\{x \in M \mid x_j = 0 \text{ } \forall j \in J_0\}$ ,  
 $J_0 = \{j \in N \mid c_j - x_j < 0\}$ ,  
 koton y res. dabarey

a Mopt  $\neq \emptyset$ , one gen  $\Rightarrow$  konkav' poliedren.

$\alpha \mapsto \text{opt}(\alpha)$  is continuous if  $\mathcal{M}$  is closed and convex. If  $\mathcal{M}$  is not closed, we can still show that  $\text{opt}(\alpha)$  is lower semicontinuous.

$M_{\text{opt}}$  - To ex. a open hor  $M^*$



Pohled  $M^1_{\text{opt}} = \{x_{\text{opt}} + \mathcal{S}\}$ , potom je L-opt. mísír opačnou  
principie minimu  $\max_{M^1_{\text{opt}}} x_2$  ažd.  $\rightarrow$  koncov ( $\Rightarrow$  lebo je pravému

$$M^1_{\text{opt}}$$

duslina' si neplie

Družinka:

X<sub>n+1</sub>  
X<sub>n+2</sub>

Ajednot' duslina:

$x_0$	$-c$	0
-------	------	---

$-E$	0
------	---

$x^1$	$\ll$
-------	-------

$A$	$b$
-----	-----

Pričo  $c < 0$ :

(7)

04.04.2008

L-metoda (Lexikografická duslina' metoda)  $(x_{m+1}, \dots, x_{m+n})$

Riešenie ukolku smer  $C^T x^1$ ,  $M^1 = \{(x^1, x^1) \in \mathbb{R}^{m+n} \mid A^T x^1 + x^1 = b^1, x^1 \geq 0\}$ ,  $A \in \mathbb{R}^{m \times n}$

$$b \in \mathbb{R}^m \quad c \in \mathbb{R}^n$$

$R_n \dots R_1$

$R_0$

$x_0$	$-c$	0
-------	------	---

$$x^1 = 0 - (-x)$$

$x_0$	$-c$	0
-------	------	---

$A$

$b$

poznam: L-hodnota aleží v oblasti DSM jež je pre hľadanie hľadane na k. rádeke a pridávame  $x^1 = 0 - (-x)$  duslou platí

k. a d. rada DSM.

Obrázok: L-hodnota jež je v oblasti DSM jež je pre hľadanie hľadane na k. rádeke a pridávame  $x^1 = 0 - (-x)$  duslou platí

Def: L-hodnota má maximálnu L-normu' pohľad platiť že  $R_j > 0$

$j \in N^*$

nebalanica'



Pozn: Vyjádření  $\lambda$ -balantu je vzhledem k "pravidlu"  $\mathcal{D} \leq \mathcal{D}$   $\lambda$ -normaliz.

Věda: Průměrné mudegovské krit. něžné! je  $\lambda$ -optimální právě když

$\lambda$ -li ještě používá  $\lambda$ -balantu  $\lambda$ -normaliz.

$$\frac{\text{Dobice}}{\text{Dobice}} \cdot \text{obecne knoku } \lambda\text{-metody maje } \lambda\text{-balantu}$$

$$\frac{x_0}{x_1} \Rightarrow \frac{R_0}{R_0 + \sum_{i=1}^N x_i}$$

$$(\mathcal{D}_0)_B = 0$$

$$(\mathcal{D}_0)_N = 0$$

$\uparrow$   $\lambda$ -metoda odstavného degenerace (cyklu)  $\lambda > 0$

Podle A.V. DSM máme opt. růž. zadání nízky.

Další opt. něžna! (potom existuje) dostatečné balantu  $\lambda$  prodeje kvalitní

Pro kvalitu mirov. ch  $d_{\lambda R} > 0$  by pro první kvalitu platila

$$R'_0 = R_0 - \frac{R_R \cdot d_{\lambda R}}{d_{\lambda R} + d_0}$$

a)  $\lambda$ -li  $\lambda$ -balantu  $\lambda$ -normální  $\Rightarrow R'_0 < R_0 \Rightarrow \lambda$ -opt. něžna!  $(x_0, \lambda)$  =  $d_B$

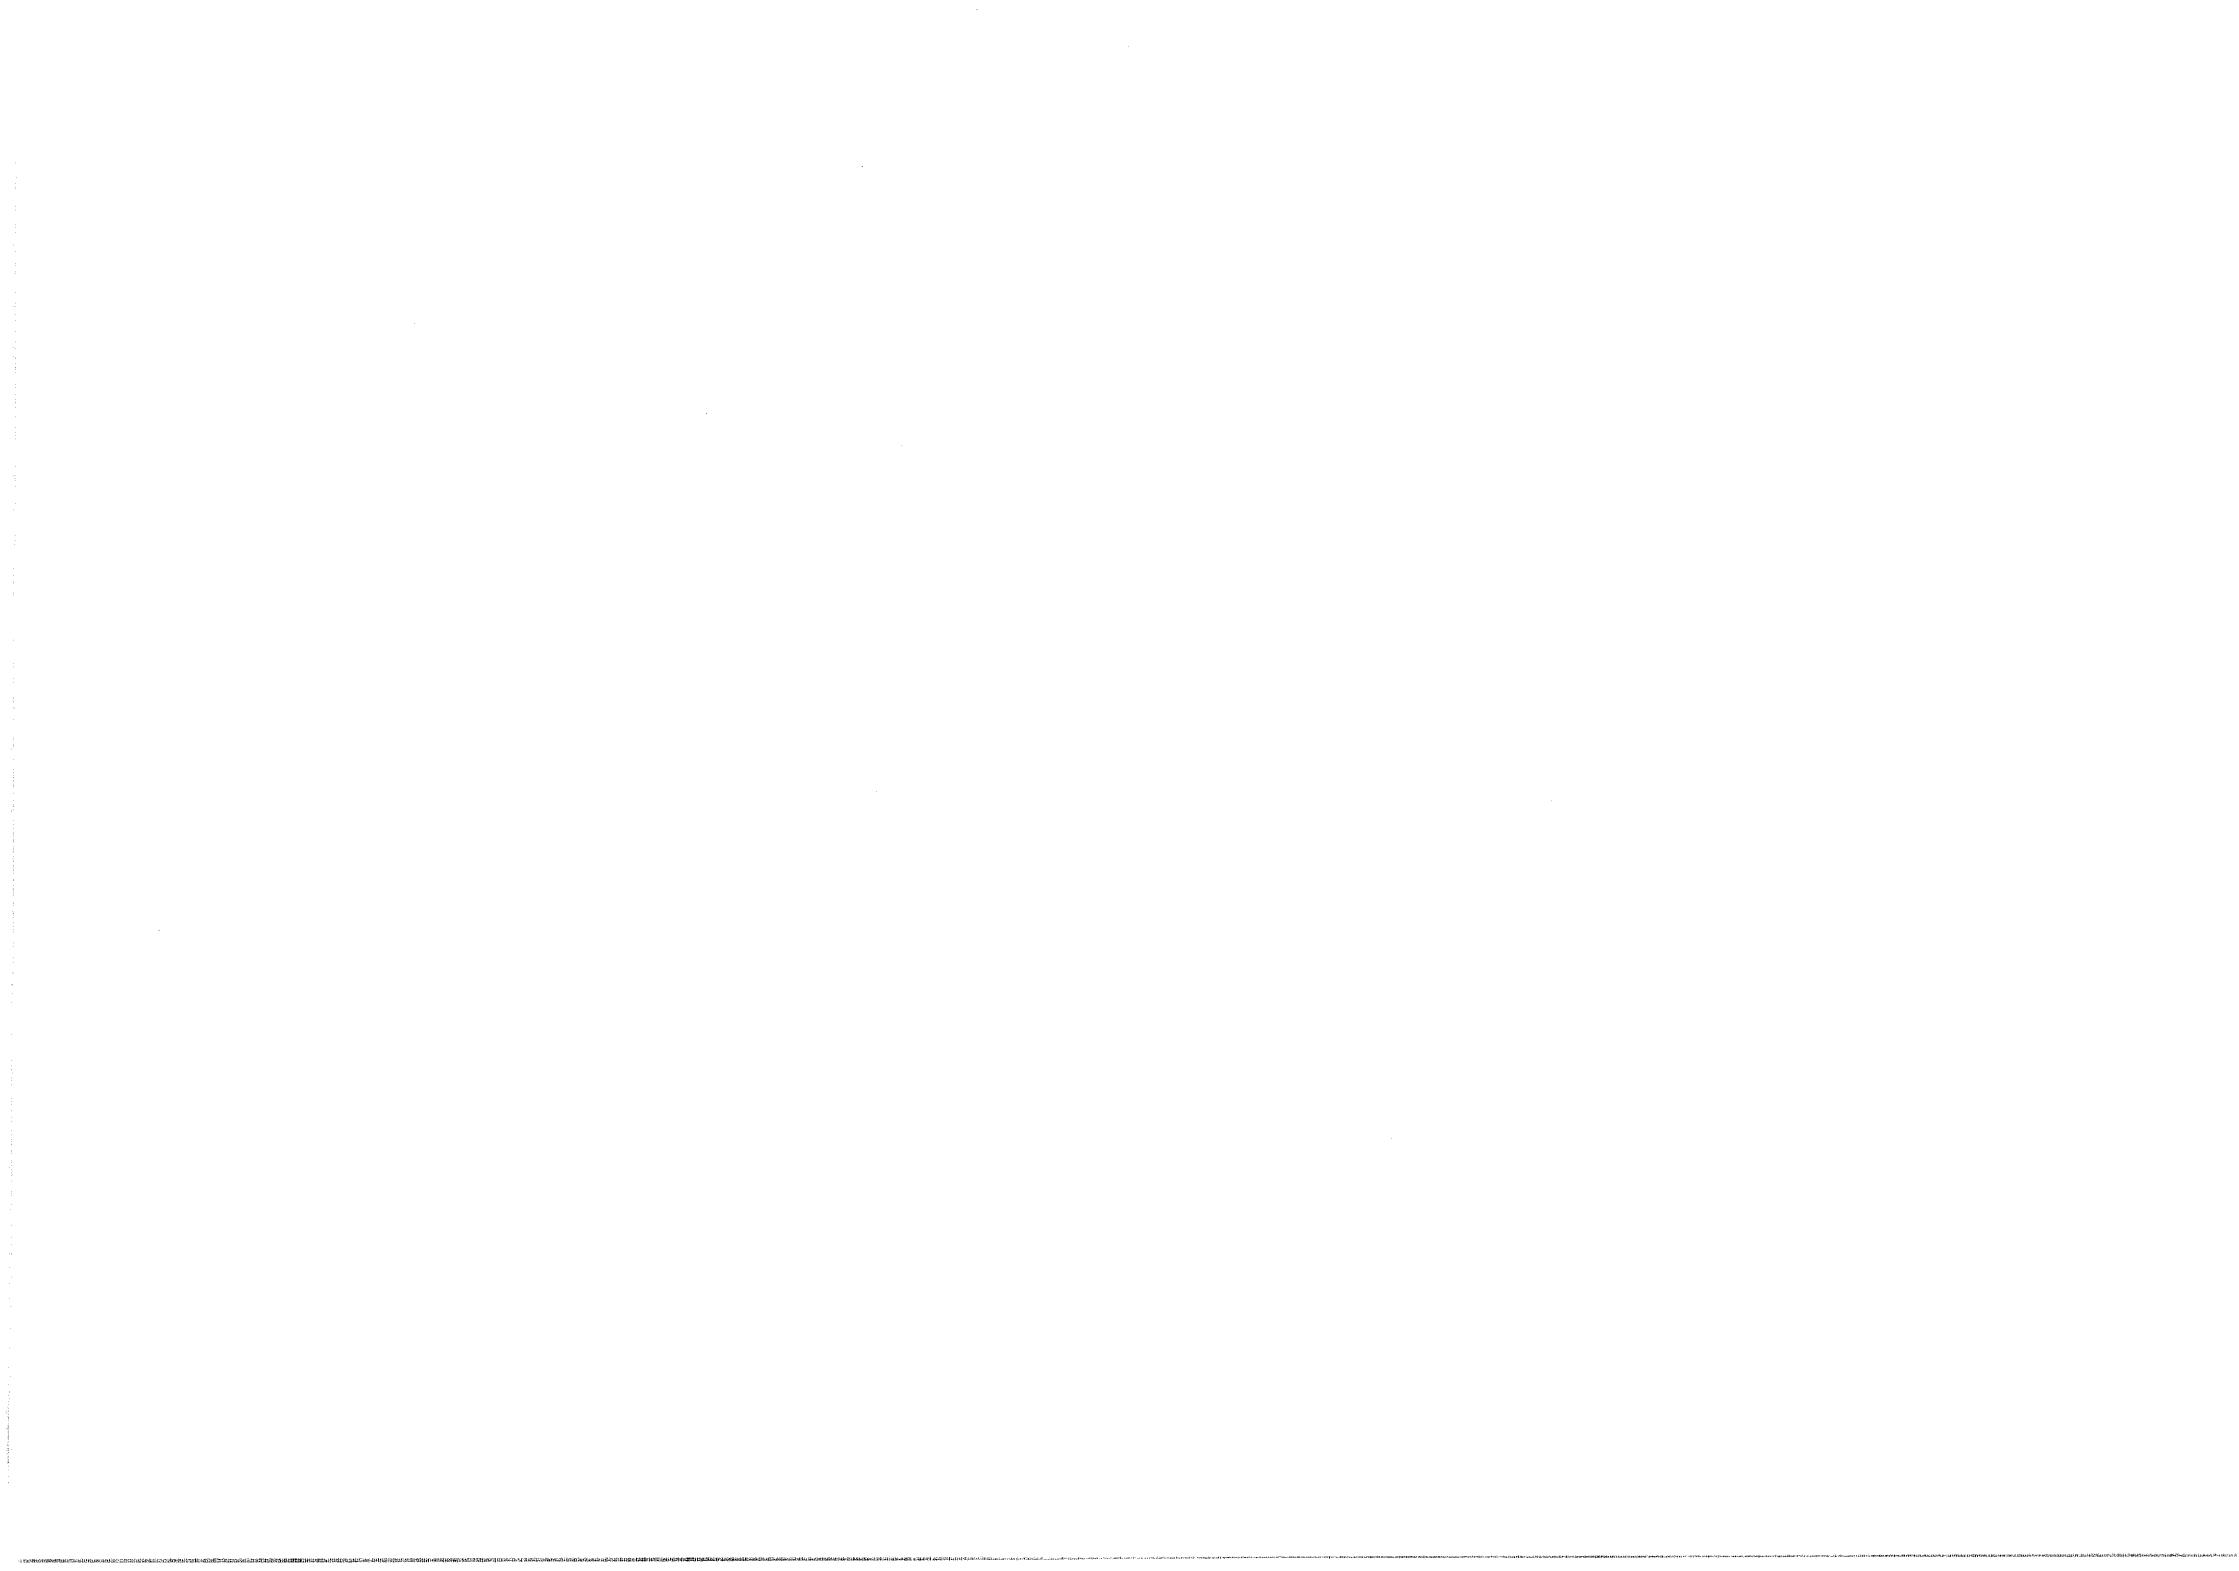
b)  $\lambda$ -li  $(x_0, \lambda) = d_B$   $\lambda$ -opt. něžna! pak kvalitní jiné! opt. něžna! prodeje

$$R'_0 = R_0 - \frac{R_R \cdot d_{\lambda R}}{d_{\lambda R} + d_0} \Rightarrow R'_0 > 0 \quad \text{pro lib. } \lambda \quad \square$$

1. věta  $\lambda$ -metody:  $\lambda$ -li  $\lambda$ -balantu  $d_B = (\mathcal{D}_0)_B > 0$ ,  $(\mathcal{D}_0)_N = 0$  a kvalita je  $\lambda$ -normalní potom jsou všechny  $\lambda$ -opt. něžny zadání nízky.

2. věta  $\lambda$ -metody:  $\lambda$ -li  $\lambda$ -balantu rádu  $\lambda$  tak, že  $d_{\lambda R} < 0$ ,  $d_{\lambda R} > 0$ ,  $j \in N$ , potom neexistuje žádání nízky.

$\lambda$ : krytí a  $\lambda$ -něžna DSM



3. něha R-metody: Nejsou-li všechny předpoklady 1. ani 2. kružnice (21) splněny, pak je  $\min_{i \in N} \{ r_i = 1, \dots, m \mid d_{i0} < 0 \}$ ,

$$\max_{j \in N} \left\{ \frac{R_j}{|d_{j0}|} \right\} = \frac{R_x}{|d_{x0}|}$$

jednotnáček  
ně. dle  $x$  - E matic

$d_{x0} < 0$ . Dostavujeme opět R-metodu! Kolmicku.

a procedura transformaci R - hálka lze omezit

$$R'_x = \frac{R_x}{d_{x0}} \neq 0 \quad \text{a} \quad d_{x0} > 0 \quad \Rightarrow \quad R'_x \neq 0$$

$$\begin{aligned} j \in N \setminus \{x\} \\ R'_j = R_j - \frac{r_j^0}{d_{j0}} \end{aligned} \quad \begin{aligned} d_{j0} < 0 \quad \Rightarrow \quad R'_j \neq 0 \\ \Rightarrow \frac{R_x}{d_{x0}} \neq \frac{R_j}{d_{j0}} \Rightarrow R_j \neq \frac{R_x}{d_{x0}} \cdot d_{j0} \\ \Rightarrow R'_j \neq 0 \Rightarrow \text{opět R-metoda! kolmicka.} \end{aligned}$$

$$Jako R'_0 = R_0 - \frac{r_0^0}{d_{00}} < 0 \quad \square$$

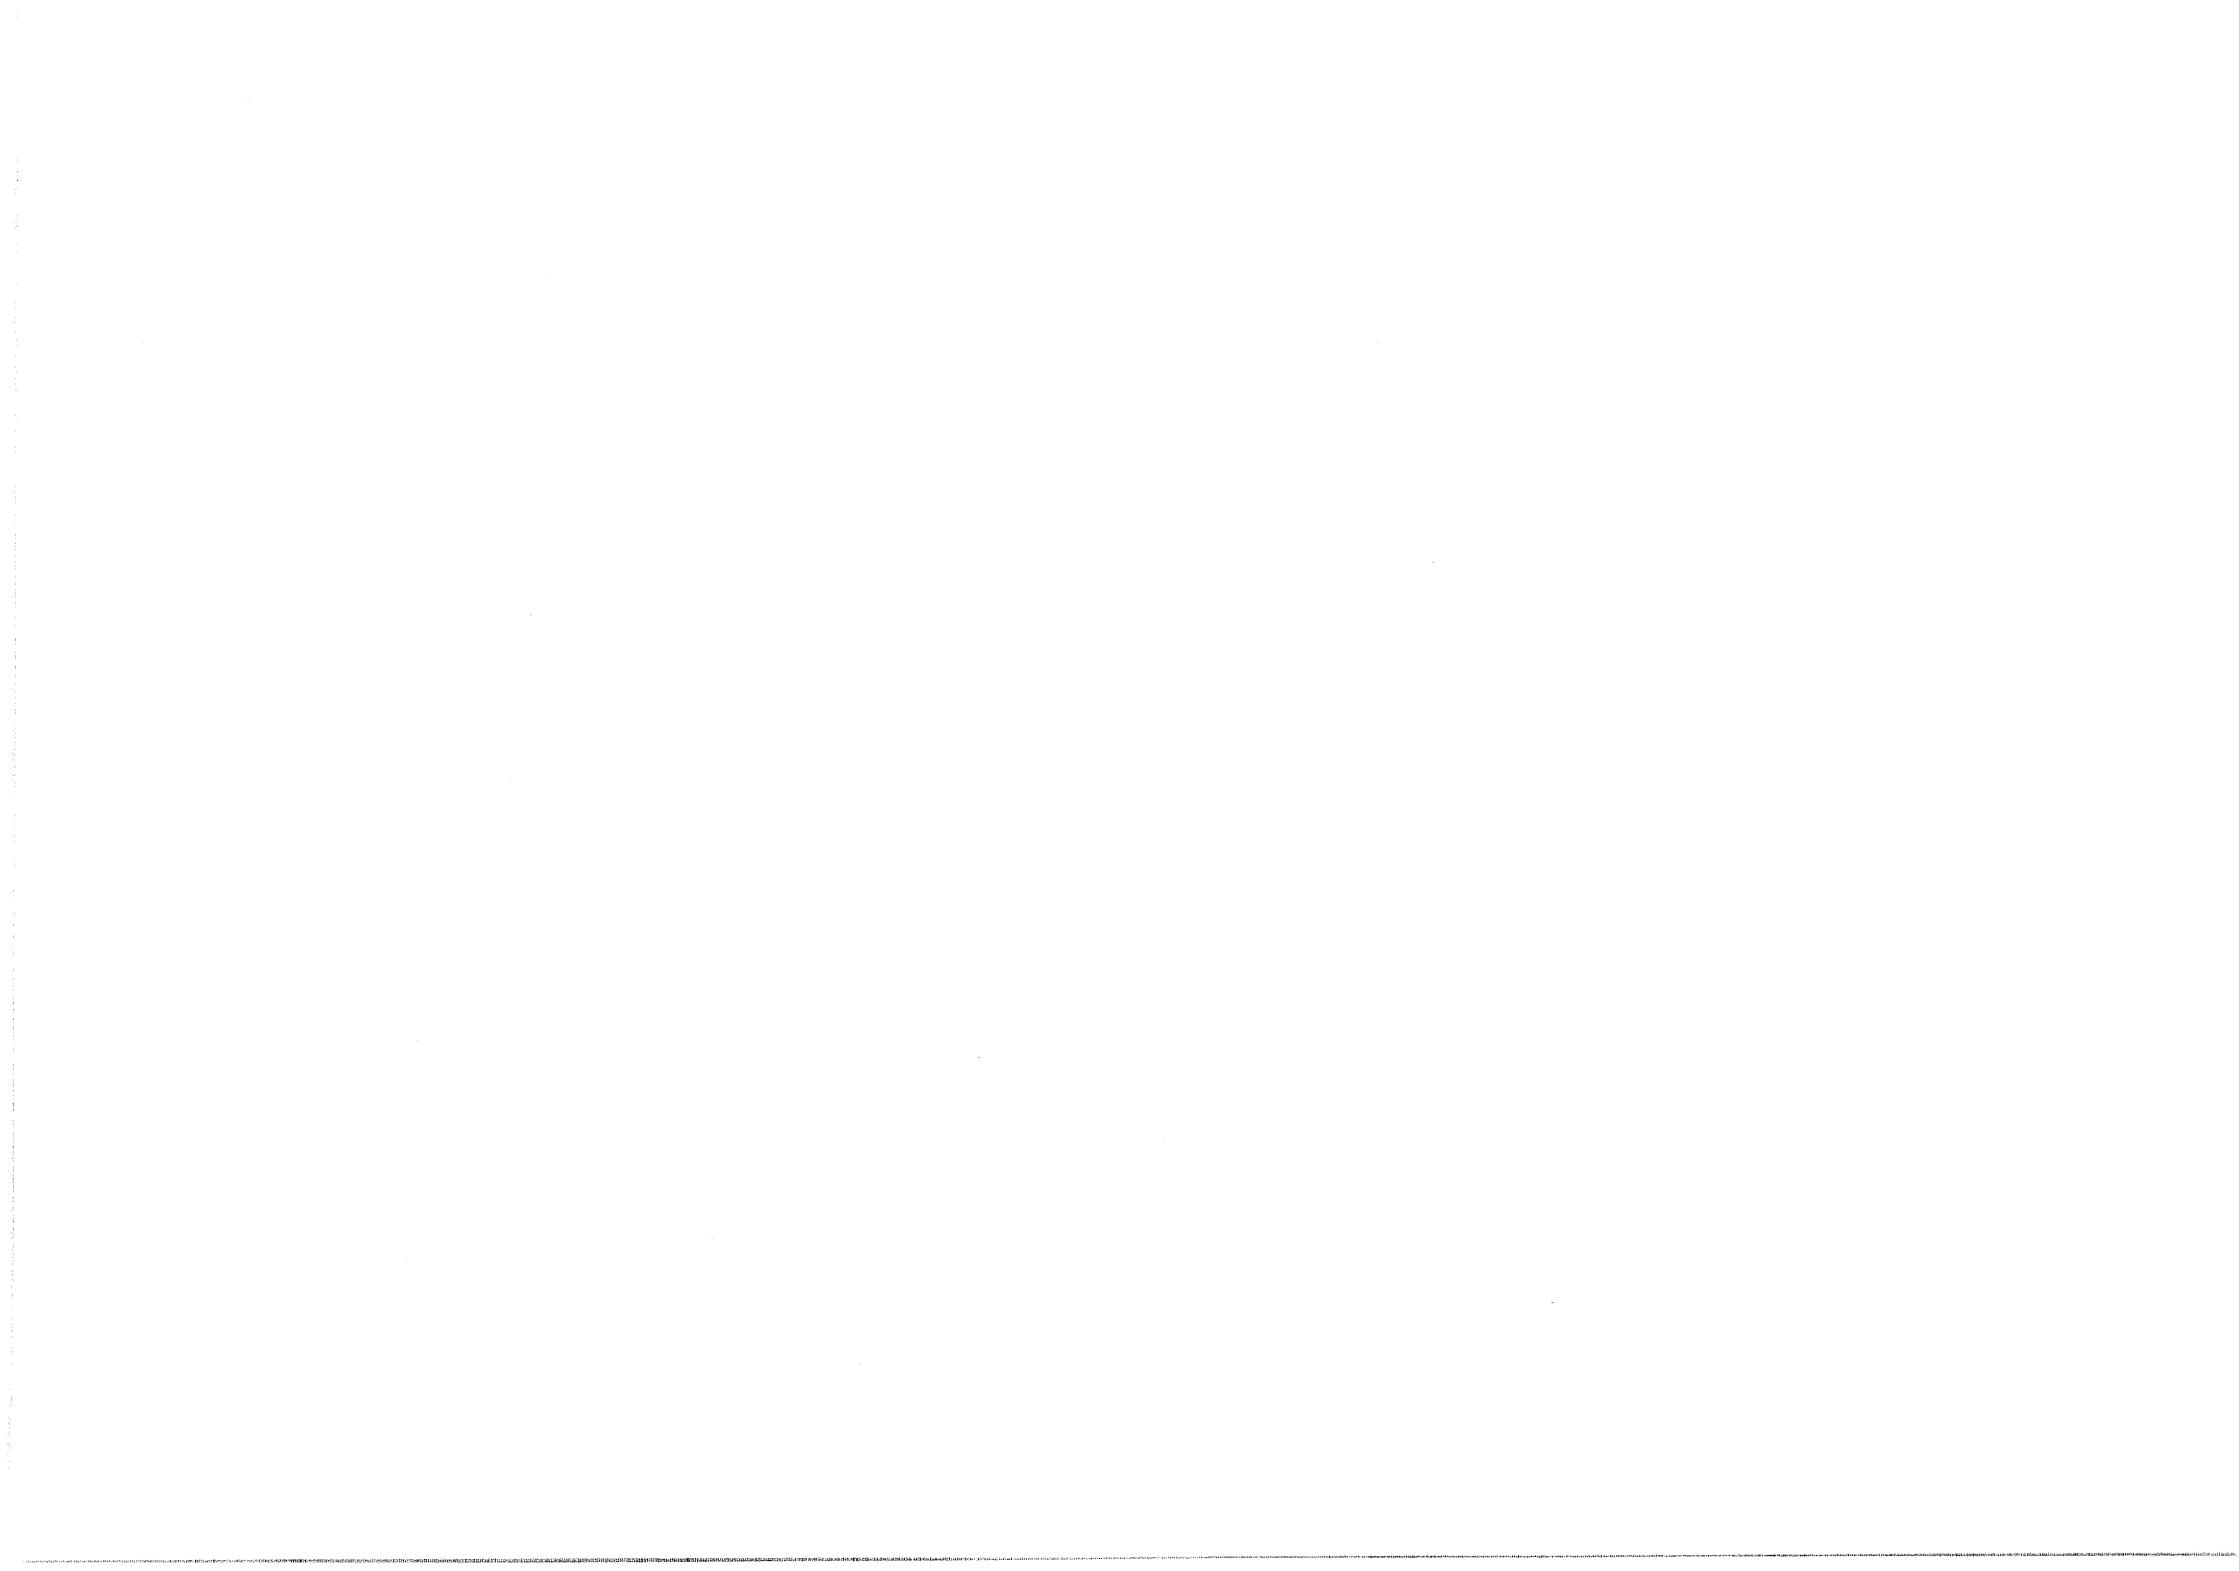
Tzv.: jediný rozdíl opolu DSH je, že kř. něžk může být

$$\boxed{\begin{matrix} 0 & \dots & 0 & -1 & 0 & \dots & 0 & 0 \end{matrix}}$$

$\downarrow R_0$

Pozn.: L-metoda je "konečná" protože každých řešení je pouze konečný, protože a množství se může zvětšit k  $R'_0 > R_0$ .

Lag-



# 1. Gomoryho alg.

Rézv' evatou u'lohu

$$\text{max } C^T \mathbf{x}, M_C^1 = \left\{ (\mathbf{x}_1, \mathbf{x}') \in \mathbb{R}^{m+n} \mid A\mathbf{x} + \mathbf{x}' = b, \mathbf{x}_1, \mathbf{x}' \geq 0, x_{11} - x_{m+n} \in \mathbb{Z} \right\}$$

$$\text{Prichy: } 1) C^T \mathbf{x} = \mathbf{c}^T \mathbf{x}_0 \in \mathbb{Z}$$

$$2) M \text{ je onezna'}$$

3) n'zácluv' krokem mnoha 'na' degenerace

$$4) C < 0$$

1. krok: R-metodou řešme u'lohu

$$\max_{M_C^1} C^T \mathbf{x}$$

R-dy' krok: R-metodou řešme u'lohu

$$(1) \quad \max_{M_C^1 \cap H_1^+ \cap H_2^+ \cap \dots \cap H_{n-1}^+} C^T \mathbf{x}$$

$$(2) \quad \text{max. rézv. u'lohy } (\mathbf{x}) \Rightarrow M_C^1 \cap H_1^+ \cap \dots \cap H_{n-1}^+ = \emptyset \Rightarrow M_C^1 = \emptyset \text{ (konec.)}$$

$$(3) \quad \exists \text{ R-opt. rézv. } (\mathbf{x}_1, \mathbf{x}') \text{ opt. } \in M_C^1 \Rightarrow \text{maximální záduš' u'lohy}$$

$$(4) \quad \exists \text{ R-opt. rézv. } (\mathbf{x}_1, \mathbf{x}') \text{ opt. } \notin M_C^1$$

$$\text{čím: } R = \min \{ x_i \in \{0, 1, \dots, m+n\} \mid d_{i0} \notin \mathbb{Z} \}$$

a nové tabuľky súčinnosti R-dy' rádeľ

$$X_k \begin{bmatrix} d_{k1} \\ \vdots \\ d_{kn} \end{bmatrix} \quad \begin{bmatrix} d_{k0} \\ \vdots \\ -x_{m+n+m+n+1} \end{bmatrix}$$

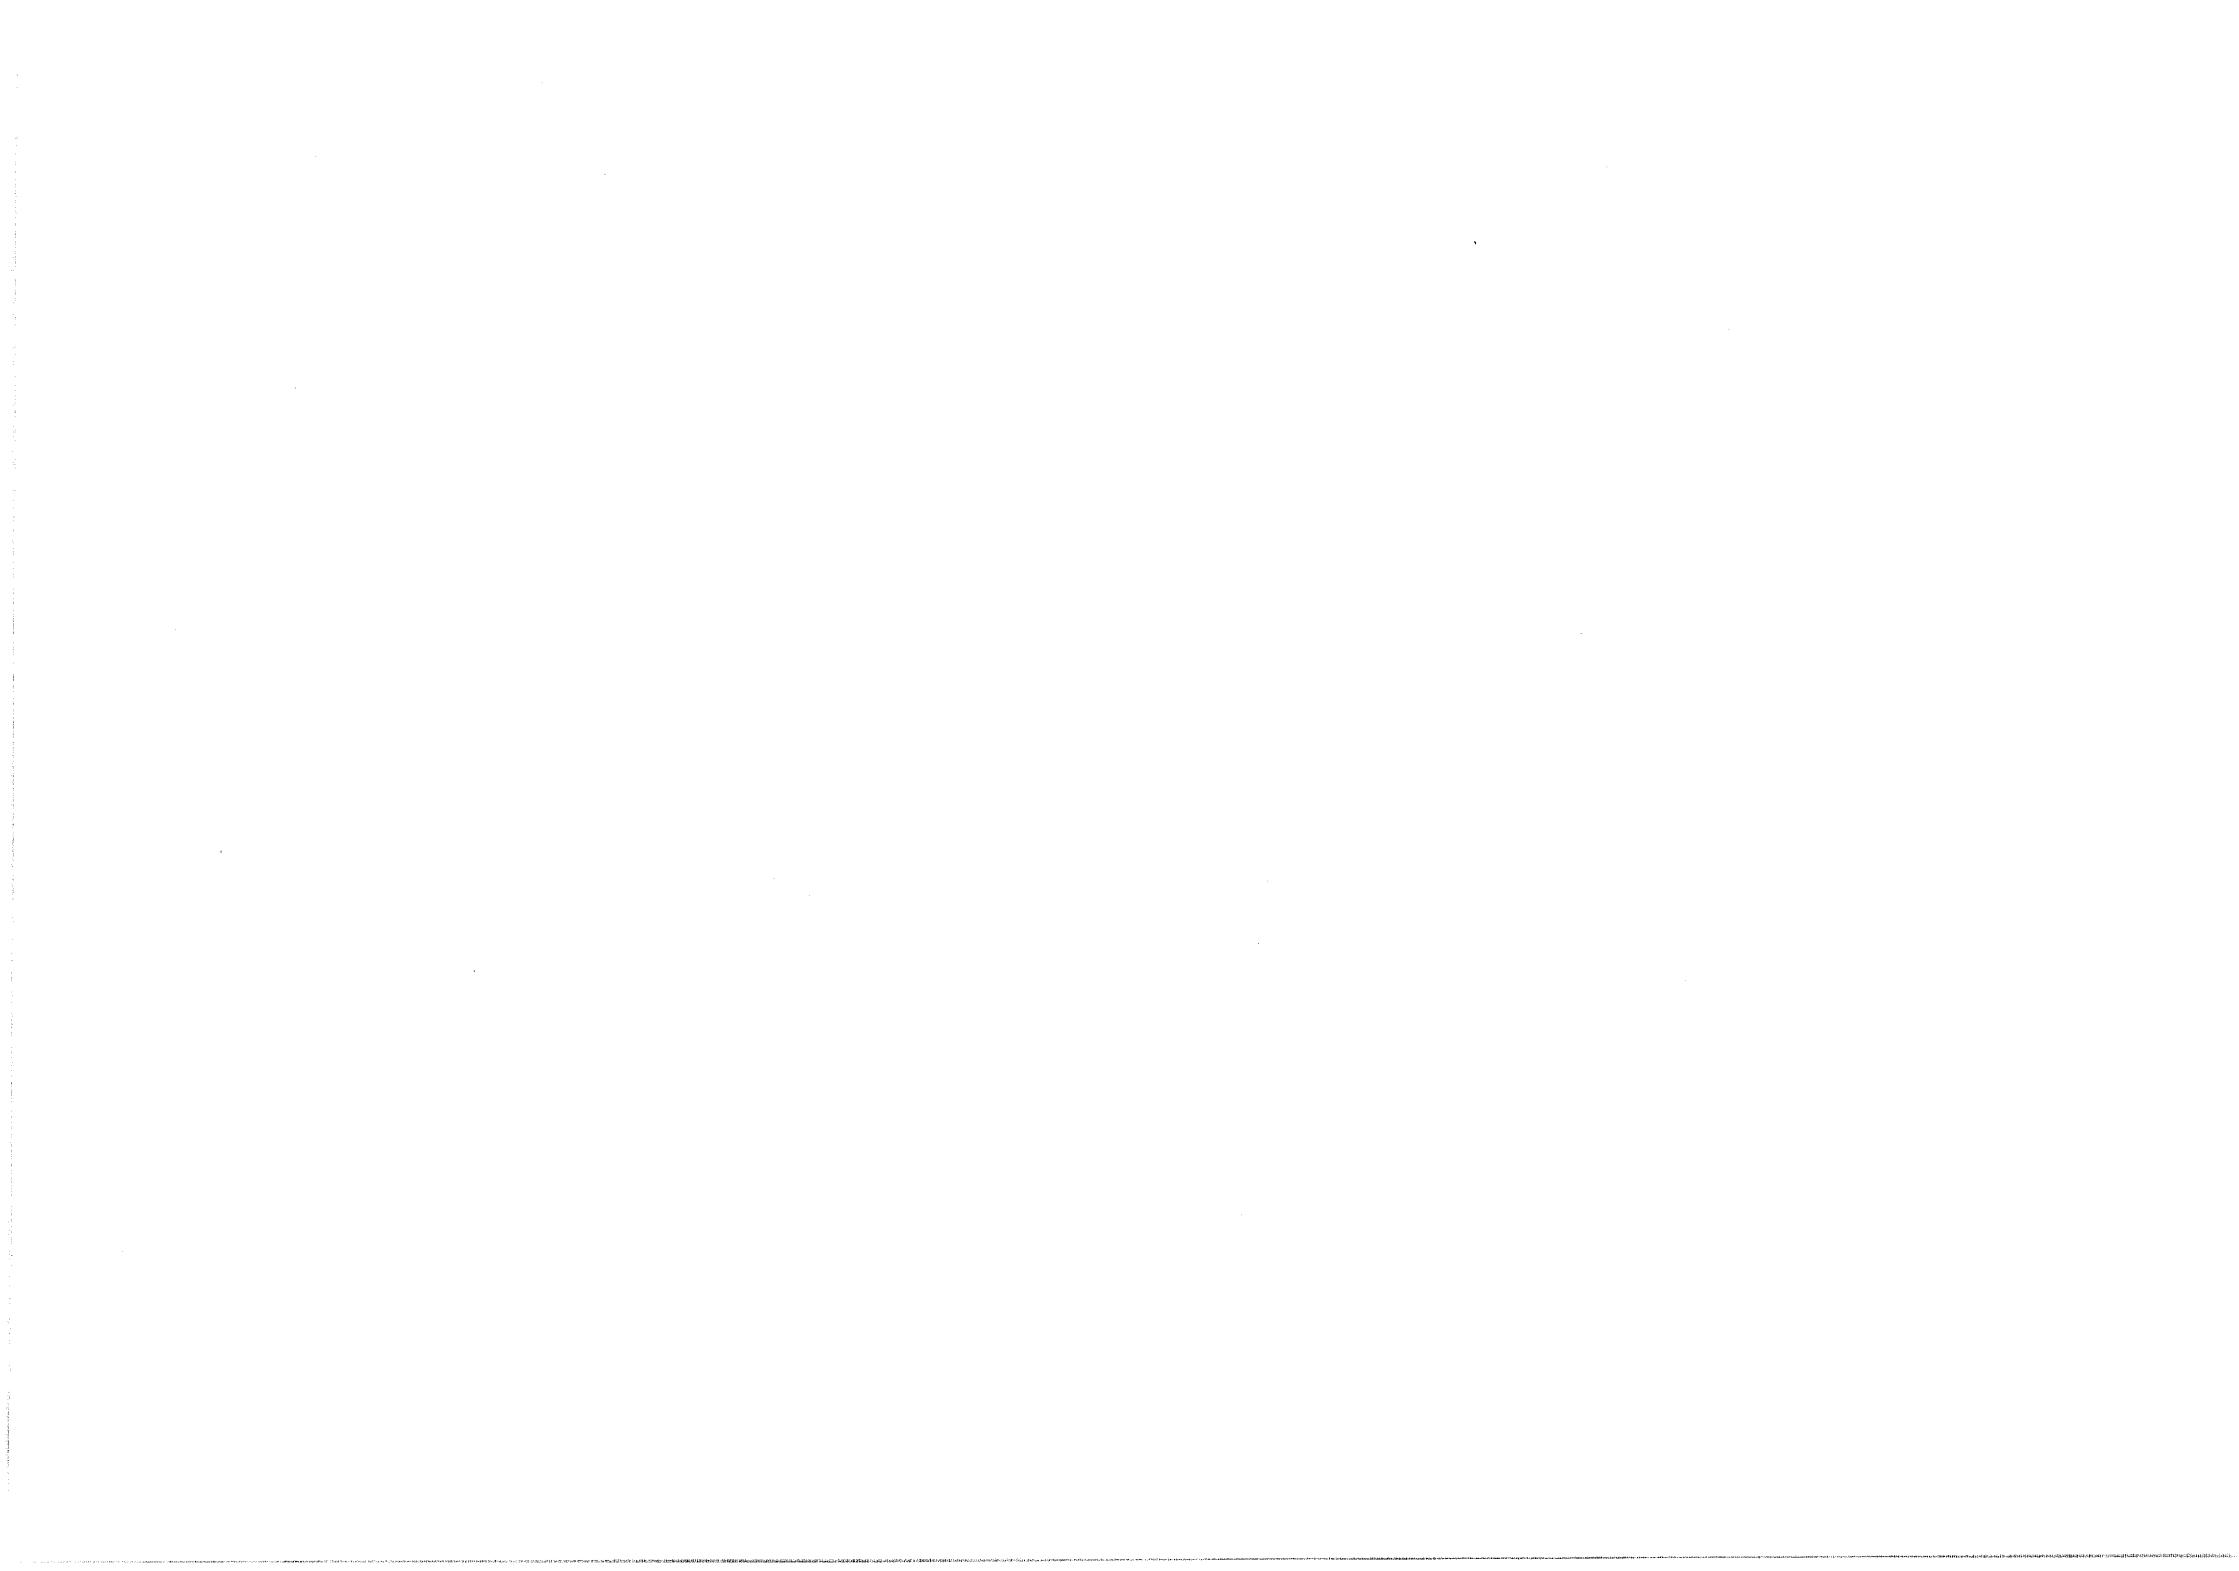
$$a \text{ u'lohu' rúž.} \quad -d_{k0} + \sum_{j \in N} d_{kj} x_j \geq 0 \quad \rightarrow \quad H_n^+$$

čož prenáme na tvor

$$X_m + m + n + 1 = -d_{k0} + \sum_{j \in N} d_{kj} x_j \quad a \text{ R postedel'}$$

nové u'lohu' rádeľ jeho postedel'

$$X_{m+n+m+n+1} \begin{bmatrix} -d_{k1} \\ \vdots \\ -d_{k0} \end{bmatrix}$$



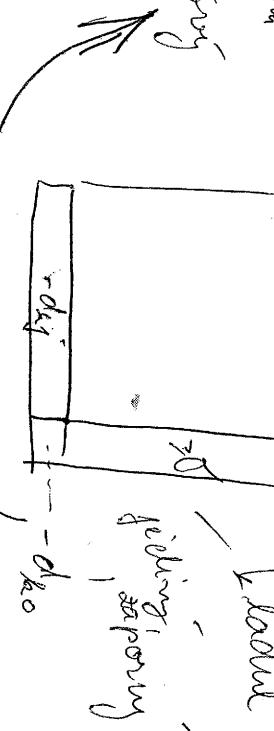
a pewne kedy nisko

$$\max_{\mathbf{x} \in \mathbb{R}^n} \mathbf{c}^T \mathbf{x}$$

$$H_1^+ \cap H_2^+ \cap \dots \cap H_{n-1}^+ \cap H_n^+$$

f - metodow

Znajnu posl. nadelek je klasowy



Przedstawiajemy nadelek nadelek

przy krokach  $\Rightarrow r := r + 1 \rightarrow r$ -ty krok.

Pozn: Za miedzy krok. je 1. gorni krok alg. Konec

M. o. 4. 2008

Krok: metoda CLP

Metoda Branch & Bound danda a Dorigo

$$\text{Zadanie: } \max_{\mathbf{x} \in \mathbb{R}^n} \mathbf{c}^T \mathbf{x} \quad M_C = \left\{ \mathbf{x} \in \mathbb{R}^n \mid A \mathbf{x} \leq \mathbf{b}, \mathbf{x} \geq 0, \mathbf{x} \in \mathbb{Z}^n, \mathbf{x} \subseteq \{1, \dots, n\}^3 \right\}$$

$$A \in \mathbb{R}^{m \times n} \quad h(A) = m$$



$x \in [x_1] \times [x_2]$

1. krok - nizsze ułokuny poziomu  $\max_{\mathbf{x} \in M} \mathbf{c}^T \mathbf{x}$

wys. niz.  $M = \emptyset \Rightarrow M_C = \emptyset$   
Kolejne

wys. niz. 1. położenie  $\mathbf{c}^T \mathbf{x}$   
kiedy niespełnia się warunkiem

$\Rightarrow$  nizsze & nisko nisko  
niskie

$\Rightarrow$  Przedpolałacenie M nie speł.

redukuj op. niz.  $\mathbf{x}^* \in M_C \Rightarrow$  nizsze niz.  
szk.  $\mathbf{x}^*$  op. niz.  $\mathbf{x}^* \in M_C$  jak jasne na krok 2.

2. krok

przeciw  $k = \min \{ \alpha \in \mathcal{C} \mid x_{\alpha}^{\text{old}} \notin \mathbb{Z} \}$   
definiujemy  $H_1 = \sum_{\mathbf{x} \in M} \mathbf{x} \mid x_k \leq \left[ x_{\alpha}^{\text{old}} \right] \}$

$H_2 = \left\{ \mathbf{x} \in M \mid x_k \geq \left[ x_{\alpha}^{\text{old}} \right] + 1 \right\}$

możnosci do

Zadanie 2 ułokuny @  $\max_{\mathbf{x} \in M} \mathbf{c}^T \mathbf{x}$

$M_2$



# ZÁKLADE OPTIMALIZACE

(20) (21) (24)

11.4.2008

## METHODA BRANCH AND BOUND LAMPA A DOIGA

Riešenie  $\max_{\mathbf{x}} \mathbf{c}^T \mathbf{x}$ ,  $\mathcal{M}_c = \{\mathbf{x} \in \mathbb{R}^n \mid \mathbf{A}\mathbf{x} = \mathbf{b}, \mathbf{x} > \mathbf{0}, \mathbf{x}_{j_0} \in \mathbb{Z}, j_0 \in \{1, \dots, n\}\}$

$$1 \leq m \leq n$$

$$\mathbf{A} \in \mathbb{R}^{m \times n}, \mathbf{b}(\mathbf{A}) = \mathbf{m}$$

1. krok: Riešenie súchu sprístupneného  $\max_{\mathbf{x}} \mathbf{c}^T \mathbf{x}$

nesplňuje riešenie, keďže  $\mathcal{M} = \emptyset \Rightarrow \mathcal{M}_c = \emptyset \Rightarrow$  koniec

nesplňuje riešenie, pretože  $\mathbf{c}^T \mathbf{x}$  nie je v noblemení na  $\mathcal{M}$   $\Rightarrow$  nové riešenie hľadáme pretože  $\Rightarrow$  hľadame preťahovanie, rež.  $\mathcal{M}_c$  bude.

Riešenie  $\mathbf{x}^{\text{opt}} \in \mathcal{M}_c \Rightarrow$  máme mánu riešenie riešenia. Koniec

cesky  $\mathbf{x}^{\text{opt}} \notin \mathcal{M}_c$ , potom ideme na krok 2.

2. krok:

$$\text{Násobime } k = \min \{k \in \mathbb{C} \mid x_k^{\text{opt}} \notin \mathbb{Z}\}$$

Definujeme  $\mathcal{M}_1 = \{\mathbf{x} \in \mathcal{M} \mid x_k \leq \lfloor x_k^{\text{opt}} \rfloor\}$

$$\mathcal{M}_2 = \{\mathbf{x} \in \mathcal{M} \mid x_k \geq \lceil x_k^{\text{opt}} \rceil + 1\} \quad / \text{koncové polohy}$$

Riešenie 2 riešení: (1)  $\max_{\mathcal{M}_1} \mathbf{c}^T \mathbf{x}$ , (2)  $\max_{\mathcal{M}_2} \mathbf{c}^T \mathbf{x}$

)

$$a) \mathcal{M}_1 = \emptyset \quad b) \mathcal{M}_2 = \emptyset \Rightarrow \mathcal{M}_c = \emptyset \Rightarrow$$

nesplňuje riešenie. Koniec.

b)  $\exists \mathbf{x}^2 \text{ opt. riešenie } \mathcal{B}$ , násobenie  $\mathbf{x}^2 \in \mathcal{M}_c \Rightarrow \mathbf{x}^2 \text{ je opt. riešenie}$

pr)  $\exists \mathbf{x}^1 \in \mathcal{M}_c$ , potom hľadame  $\mathcal{M}_2$ .  $\mathcal{M} = \mathcal{M}_2$  a krok 2.

b)  $\exists \mathbf{x}^1 \text{ opt. riešenie riešenie } \mathcal{B}$  a)  $\mathcal{M}_2 = \emptyset \Rightarrow \mathbf{x}^1 \text{ je opt. riešenie}$

$$\mathbf{x}^1 \in \mathcal{M}_c$$

Inde,  $\mathbf{x}^2 \text{ je opt. riešenie}$

pr)  $\exists \mathbf{x}^2 \notin \mathcal{M}_c$ . Ak  $\mathbf{c}^T \mathbf{x}^1 \geq \mathbf{c}^T \mathbf{x}^2 \Rightarrow \mathbf{x}^1 \text{ je opt. riešenie}$

ale  $\mathbf{c}^T \mathbf{x}^1 < \mathbf{c}^T \mathbf{x}^2$ , potom násobime

$\mathbf{x}^1, \mathbf{c}^T \mathbf{x}^1$  a dešum  $\mathcal{M}_2$ ,  $\mathcal{M} = \mathcal{M}_1 \rightarrow$  2. krok

c)  $\exists \mathbf{x}^1 \text{ riešenie } \mathcal{B}$  a)  $\mathcal{M}_2 = \emptyset \Rightarrow \mathcal{M} = \mathcal{M}_1$  a krok 2.

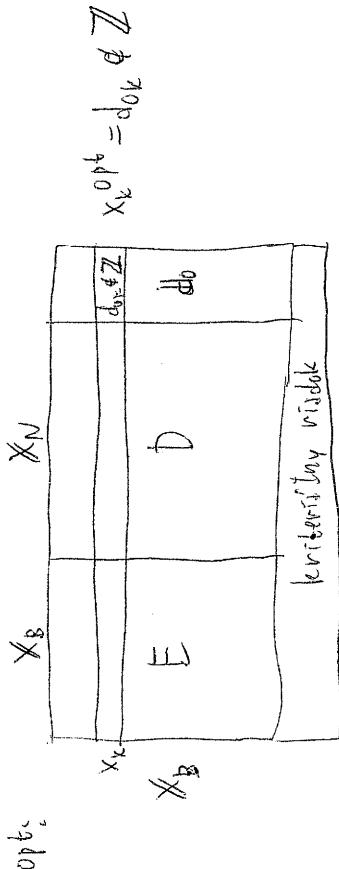
b)  $\exists \mathbf{x}^2 \in \mathcal{M}_c, \mathbf{c}^T \mathbf{x}^1 \leq \mathbf{c}^T \mathbf{x}^2 \Rightarrow \mathbf{x}^2 \text{ je opt. riešenie}$

$\mathbf{c}^T \mathbf{x}^1 > \mathbf{c}^T \mathbf{x}^2 \Rightarrow$  násobime  $\mathbf{x}^2, \mathcal{M} = \mathcal{M}_1 \rightarrow$  2. krok

je)  $\exists x \in M_1$  pro kterou  $M = M_1 \setminus x$  je 2. krok.

Doplníme o výsledek, ab  $|C| = 2, 3$ . Společně  $C = \{1, \dots, n\}$ , protože  
je lze dát pouze jednomu z nich význam.

Pozn:



$$k\text{-ary radikál} : X_k = d_{0k} - \sum_{j \in N} d_{kj} X_j \quad \Rightarrow \quad \xi = [d_{0k}] - \underbrace{[d_{0k}]}_{= d_{0k}} + \sum_{j \in N} d_{kj} X_j \geq 0$$

Mnohoždičkové radikály mají vlastnosti

$$u = -[d_{0k}] + d_{0k} - \xi - \sum_N d_{kj} X_j$$

$X_k$	$X_B$	$D$	$\xi$
$d_{kj}$			
			$d_{0k} - \sum_N d_{kj} X_j$

### PARAMETRICKÉ PROGRANOVANIE

Definícia:

Vektorským násobkom parametrického nástrojovania označujeme:

- i)  $\min_{\substack{\lambda \in \Lambda \\ X \in M(D)}} F(X, \lambda)$ , kde  $F(X, \lambda) : \mathbb{R}^n \times \mathbb{R}^t \rightarrow \mathbb{R}$ ,  $M(D) \subset \mathbb{R}^n$  je množina  
parametrov  $\lambda \in \mathbb{R}^m$

štatistiky  $\lambda_i$ ,  $i \in \mathbb{N}$  sú nazývané parametre.

(20)

(25)

Definícia 1:

Metodou param. prog. (1)

Oborom rišiteľnosti rozumeme

Definícia 2:

Ak je  $\mathbf{x}^0$  optimálne riešenie vlohy (1) pri súčasnej hodine  $\lambda_i, \nu^0$ ,  
 potom oborom stability riešenia  $\mathbf{x}^0$  rozumime

$$\mathcal{N}_{\mathbf{x}^0, \nu} = \{(\lambda, \nu) \in \mathbb{R}^{n+m} \mid \min_{\mathbf{x} \in M(\nu)} F(\mathbf{x}, \lambda) = F_\nu(\mathbf{x}^0, \lambda)\}.$$

Definícia 3:

Funkcia rišiteľnosti vlohy (1) nazívame

$$y(\lambda, \nu) = \min_{\mathbf{x} \in M(\nu)} F(\mathbf{x}, \lambda) \quad (\lambda, \nu) \in \mathcal{N}_{\mathbf{x}^0, \nu}.$$

Definícia 1: jednoparametrické vlohy

2) viacparametrické vlohy

- II 1) lineárne vlohy  
 2) ~~lineárne~~ nelineárne vlohy

### ÚLOHA LINEÁRNEHO JEDNOPARAMETRICKÉHO PROGRAMOVANIA

#### SPARAMETRUM V TIEĽOVEJ FUNKCII'

$$(2) \min_{\mathbf{x}} (\mathbf{c} + \lambda \mathbf{c}')^\top \mathbf{x}, \quad \lambda \in \mathbb{R}, \quad \mathbf{c}, \mathbf{c}' \in \mathbb{R}^n, \quad M = \{\mathbf{x} \mid A\mathbf{x} = \mathbf{b}, \mathbf{x} \geq 0\}, \quad A \in \mathbb{R}^{m \times n}, \quad \mathbf{b} \in \mathbb{R}^m$$

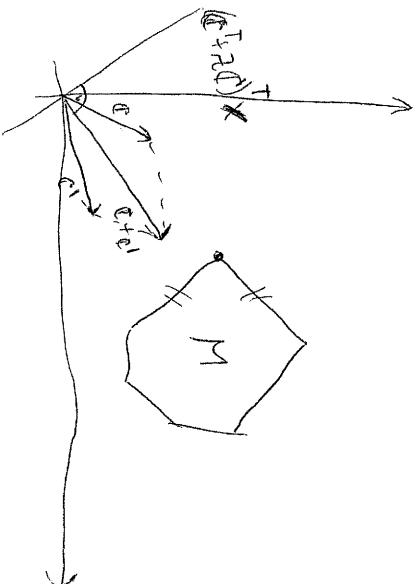
$$M \neq \emptyset, \quad 1 \leq m < n, \quad \text{rank}(A) = m$$

Málokedy obor rišiteľnosti sa nazýva oborom oboru stability.

(obore)

$$\lambda = 1 - \text{param}$$

Umožnenie  $(\mathbf{c} + \lambda \mathbf{c}')^\top \mathbf{x}$  vlohy do počítania  
 nelineárky s polohami konzami





a. Min dosiaľovane rešenie obrazu sa dala by a no' pripravie!  $\lambda$

(26)

- prene'  $\lambda$ , rieš max



(9)

### 1. Veta LAPP

Jedáliz pre prene'  $\lambda_0 \in \mathbb{R}$  ex. opt. riešen'  $\star$  nálohy (2) | potom

$$\exists \underline{\lambda}_1, \bar{\lambda}_1, \overline{\lambda}_1 \leq \bar{\lambda}_1 \text{ tak, že}$$

- 1) pre  $\lambda \in \langle \underline{\lambda}_1, \bar{\lambda}_1 \rangle$  nájdenej opt. rieš. nálohy (2) stále  $\star$
- 2)  $\lambda_0 \in \langle \underline{\lambda}_1, \bar{\lambda}_4 \rangle$
- 3) maximálni  $\star$  degenerované, potom jame získali ešte dva iní riešenia

Diskusi:

Pre prene'  $\lambda_0$  máme viacero LP a tie ňadne SM. Posledného vlastka:

$x_B$	$E$	$D$	$d_0$	$\sigma$
$\alpha$	$c_N + \lambda_0 c'_N$	$c_B - \lambda_0 c'_B$	$\star$	$\star$

$$(c_N + \lambda_0 c'_N) - (c_B + \lambda_0 c'_B)^T D \geq 0$$

Počas M.S.M  $\Rightarrow$  pre  $\{ \lambda \mid (c_N - \lambda c'_N) - (c_B - \lambda c'_B)^T D \geq 0 \}$  je toto riešenie!

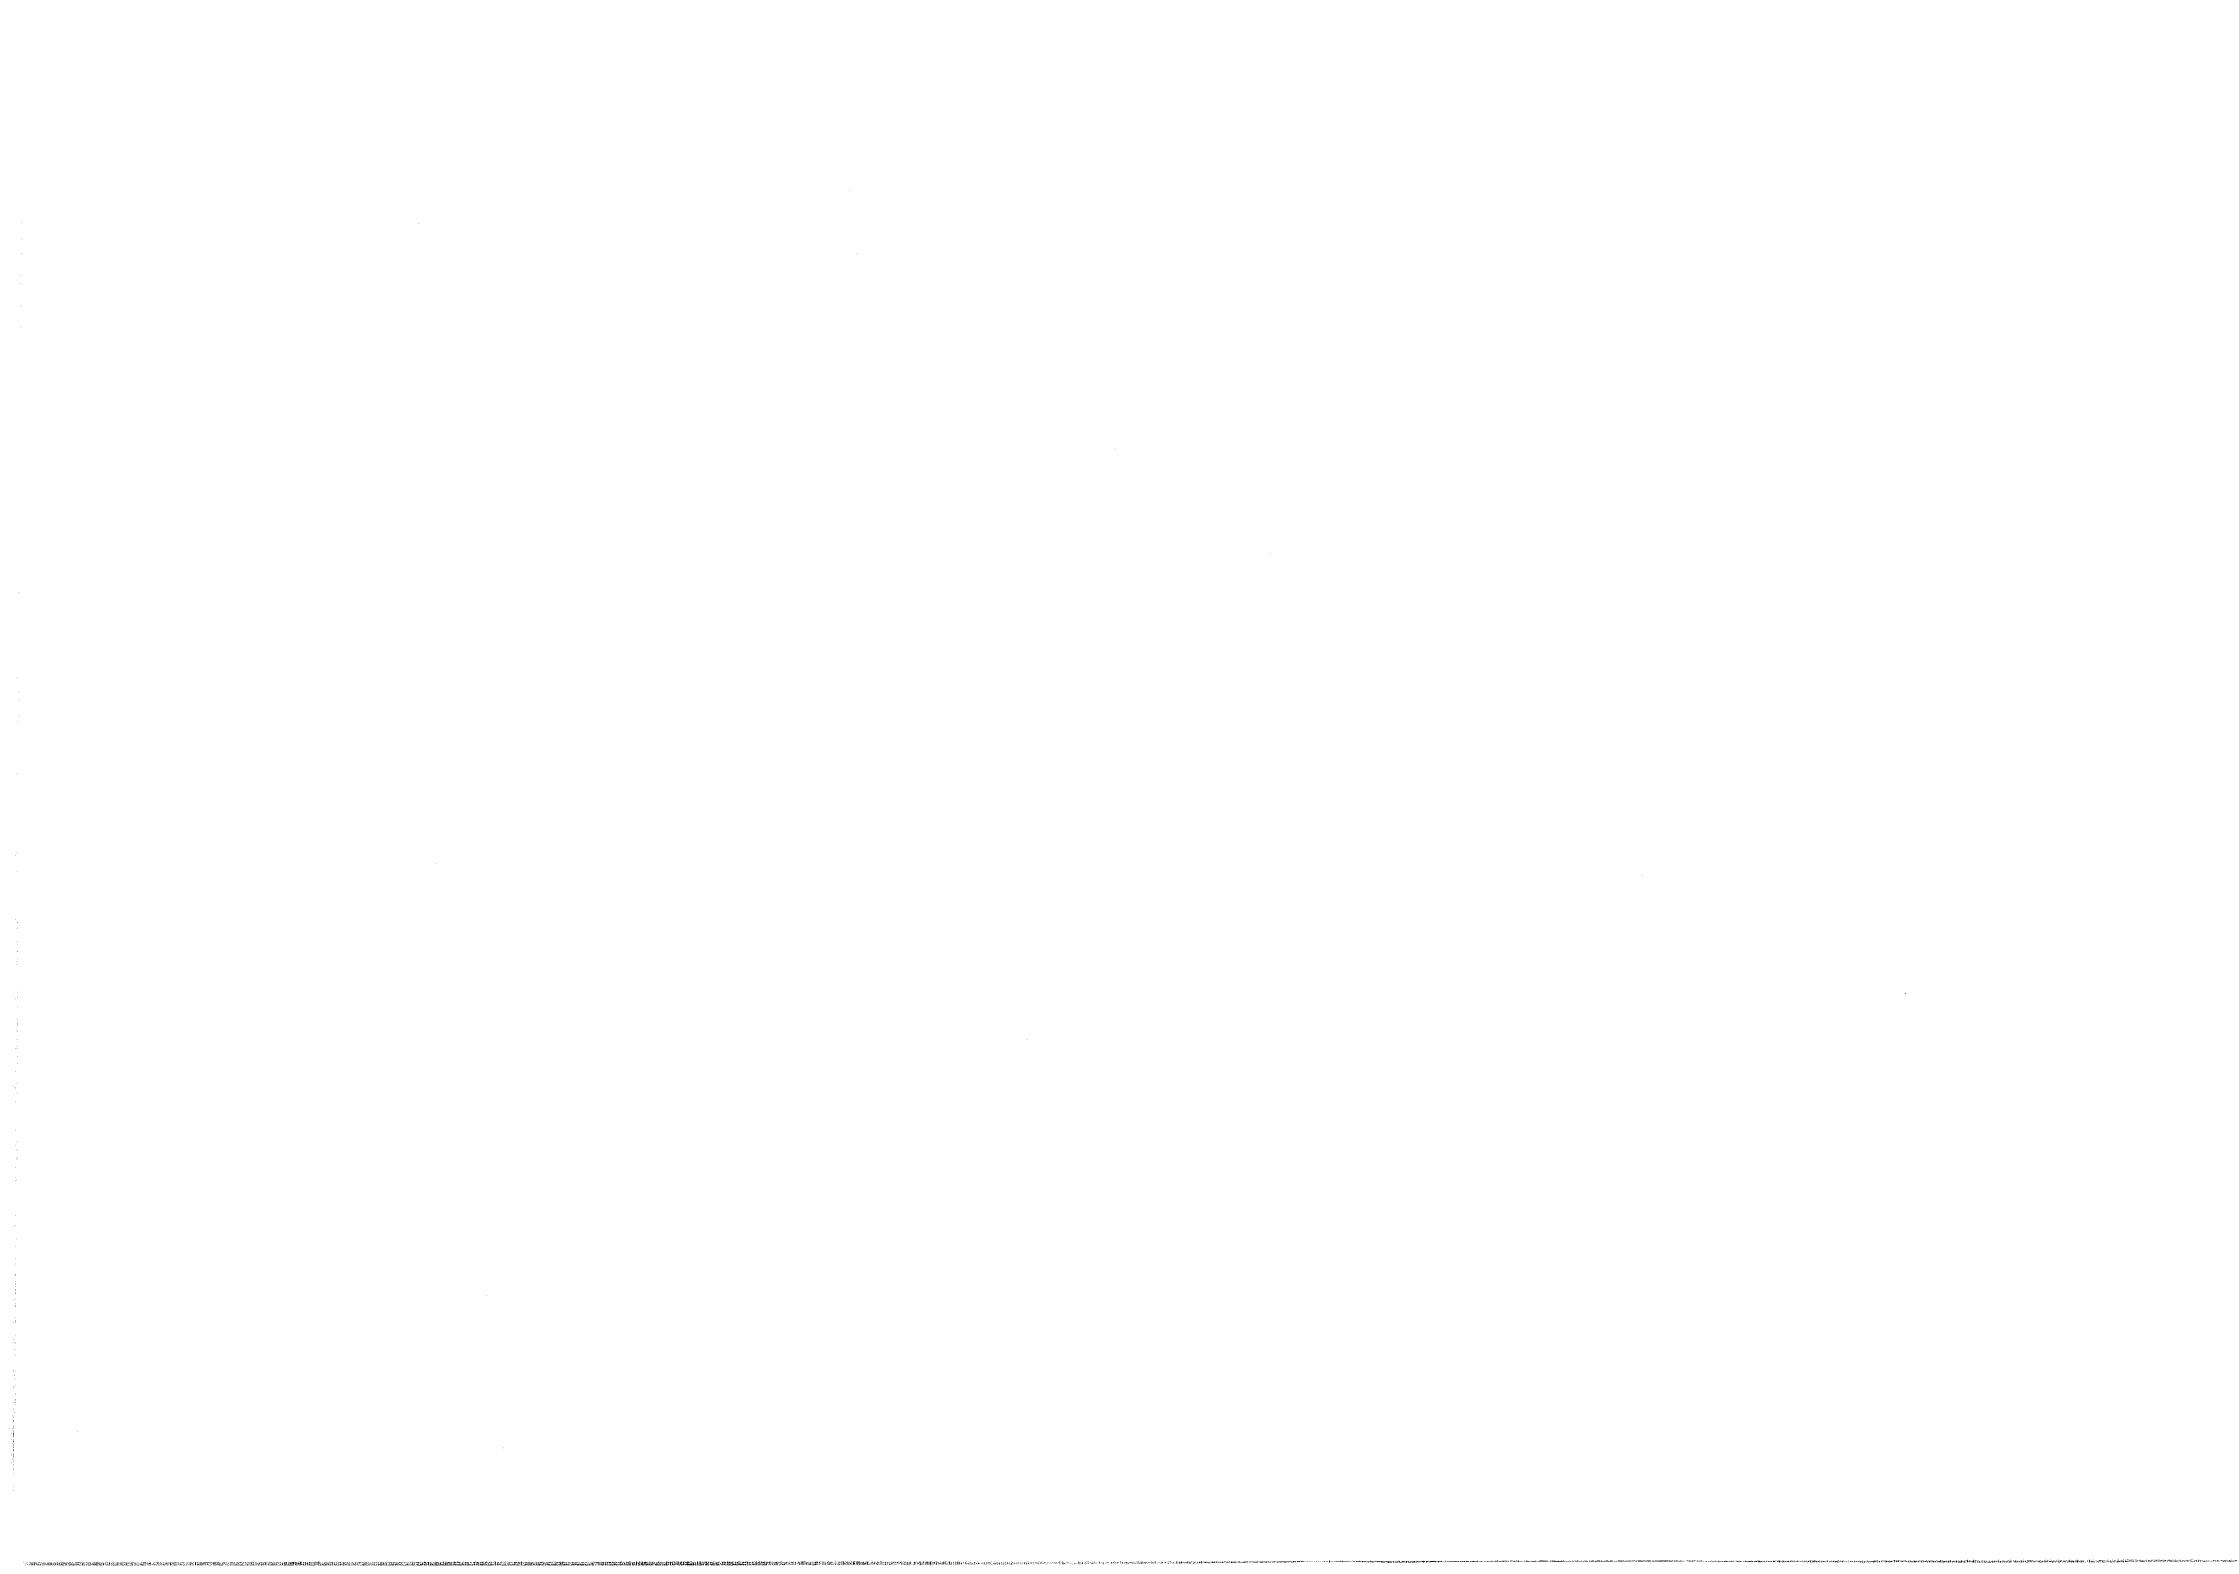
jež. krit.  $(d_0, \sigma)$  optimálne!

$$\text{Pre } \lambda \text{ prene' } C_N - C_B^T D + \lambda (C_N^T - C_B^{T^T} D) = C_N + \lambda V.$$

$$\text{Označme: } I_1 = \left\{ \alpha \in N \mid v_\alpha > 0 \right\}$$

$$I_2 = \left\{ \alpha \in N \mid v_\alpha < 0 \right\}$$

$$I_3 = \left\{ \alpha \in N \mid v_\alpha = 0 \right\}$$



$\Rightarrow$

$$\text{pro } \lambda \in I_1 \Rightarrow \lambda = -\frac{\alpha_i}{\gamma_i} \Rightarrow \lambda \in \left\{ -\frac{\alpha_i}{\gamma_i} \mid i \in I_2 \right\}$$

$$\Rightarrow \lambda \in \sup_{i \in I_1} \left\{ -\frac{\alpha_i}{\gamma_i} \right\} \cup \inf_{i \in I_2} \left\{ -\frac{\alpha_i}{\gamma_i} \right\}$$

$$\lambda = \sup_{i \in I_1} \left\{ -\frac{\alpha_i}{\gamma_i} \right\} \quad \bar{\lambda}_1 = \inf_{i \in I_2} \left\{ -\frac{\alpha_i}{\gamma_i} \right\}$$

- o osadaun' režime'

Poznámka: Stupňové degenerace  $\neq$  dosahom pouze všeobecné obecné stabilitu. K dokázání se E-modifikátora užloha.

Nedostatečnost: Předp. modelu, že používaná SM může vznakat degenerace.

Dostatečnost: Okraj stabilitu ještě pouze kritickou vzdáleností a ještě jich pouze koncový počet.

( $\lambda_i^-, \lambda_i^+$  jsou jednotlivé příslušné vlastnosti  $\lambda \in \mathbb{H}$ )

Kritické je pouze koncový počet)

$\langle \lambda_i^-, \lambda_i^+ \rangle$  jsou

$\begin{cases} \text{mezinárodní užívání} \\ \text{mezinárodní pořízení} \end{cases}$

## 2. Věta LPP:

Alespoň pro každou  $\lambda_0 \in \mathbb{R}$  můžeme nějakou vlastnost  $\lambda_0$  a  $M \neq \emptyset$  potom

$\exists$  co obsahuje interval  $J$ -hále, že:

- pro  $\lambda \in J$  můžeme nějakou vlastnost  $\lambda$ .
- $\lambda_0 \in J$ .

Důkaz: Použij SM dojdeme k tabulce:

$E$	$D$	$d_0$
$\geq 0$	$> 0$	$\leq 0$
$\leq 0$	$\leq 0$	$\geq 0$

Prostředek  $\{d_{ij}\}_{i \in B, j \in A}$  může mít

$$\Rightarrow \left\{ \lambda \mid (\mu_j + \lambda v_j < 0) \right\} \text{ může mít vlastnost vlastnosti vlastnosti } \lambda$$

Máme  $\lambda = \text{mín. možnosti}$ :

$$a) v_j > 0 \Rightarrow \lambda < -\frac{\mu_j}{v_j} \Rightarrow J = (-\infty, -\frac{\mu_j}{v_j})$$

$$b) v_j < 0 \Rightarrow \lambda > -\frac{\mu_j}{v_j} \Rightarrow J = (-\frac{\mu_j}{v_j}, \infty)$$

$$c) v_j = 0 \Rightarrow \mu_j = 0 \Rightarrow J = \mathbb{R}$$

$\forall$ méně než
máme až
májí vlastnosti

vlastnosti

## Moduł 2:

Brak nieskończoności w zbiory (2)  $A = \{x \in \mathbb{R} \mid (2) \text{ ma nieskończoność}\}$   
 pro klasow plaski'  $A = \bigcup_{i \in P} \langle \underline{x}_i, \bar{x}_i \rangle$ , gdzie  $P$  je mnożna indeksu' nieskończoność'  $M$ .

Działanie:

$$\begin{aligned} \text{zbiory } x \in A \text{ sumy} &\xrightarrow{\text{1.LPP}} \text{mają' odc. nieskończoność' nieskończoność' } \\ \Rightarrow \exists i \mid x \in \langle \underline{x}_i, \bar{x}_i \rangle &\Rightarrow x \in \bigcup_{i \in P} \langle \underline{x}_i, \bar{x}_i \rangle \end{aligned}$$

zbiory  $x \in \bigcup_{i \in P} \langle \underline{x}_i, \bar{x}_i \rangle \Rightarrow \exists i \mid x \in \langle \underline{x}_i, \bar{x}_i \rangle$  nieskończoność' odc. nieskończoność'  $i$ .

Twierdzenie (2) dowodzisz  $\Rightarrow x \in A$ .

Rozważmy:

zbiory  $\underline{x}_1, \bar{x}_2 \in A$ , def  $\lambda_3 = \alpha \underline{x}_1 + \beta \bar{x}_2$ ,  $\alpha + \beta = 1$ ,  $\alpha, \beta \geq 0$ .

Kiedy  $\lambda_3 \notin A \Rightarrow$  pro  $\lambda_3$  nie ma odc. nieskończoność' (2)  $\xrightarrow{\text{2.VLAPP}} \exists j \in \text{ośmienny' interwał}$ ,  
 ale nieskończoność' nieskończoność'. Podajemy dla  $\lambda_1$  nieskończoność' dla  $\lambda_2$  dla  $j$  prostej, a dla  $j$  prostej.  
 Wykazujemy: nieskończoność' klasowa klasowa jest dla nieskończoność' mnożna je mnożna.

3.VLAPP: Nieskończoność' klasowa klasowa je klasowa mnożna je mnożna.

je klasowa  $\bar{x}_1 \in \text{VLAPP}$  je klasowa, potomu pro  $\lambda_1 \Rightarrow \bar{x}_1$  nieskończoność' mnożna.

a) pro  $\lambda_1$  nieskończoność' odc.

b)  $\exists j^2$  nieskończoność' nieskończoność'  $\bar{x}_1$  a klasowa  $\langle \underline{x}_2, \bar{x}_2 \rangle$  nieskończoność'  
 a) pro  $\lambda \in \langle \underline{x}_2, \bar{x}_2 \rangle$  nieskończoność' odc. nieskończoność' a nieskończoność'  $\bar{x}_1 = \bar{x}_2$ .

Pon: Analogicznie nieskończoność' i obliczamy pro  $\bar{x}_1$ .

Def: Funkcja  $\varphi(\lambda) = \min_{\mathbb{M}} (\underline{c} - \lambda \underline{c}')^T *$ ,  $\lambda \in A$ , se nazywa' peł' nieskończoność' (2).

4.VLAPP: Funkcja  $\varphi(\lambda)$  je mała po całkach liniowych, & proporcjonalna do konstanty.  
 Dlażazi Nied klasowa  $\langle \underline{x}_1, \bar{x}_1 \rangle$  plaski'  $\varphi(\lambda) = (\underline{c} - \lambda \underline{c}')^T *$   $\bar{x}_1$  - liniowa!

Proste  $A = \bigcup \langle \underline{x}_i, \bar{x}_i \rangle$  a proste 3VLAPP je  $\bar{x}_i = \lambda_{i+1} \bar{x}_i \rightarrow$

$\Rightarrow \varphi$  je całkach liniowych' a mnożka' nad  $A$ .

Wykazujemy:  
 zbiory  $\underline{x}_1, \bar{x}_2 \in A$  a  $\lambda_3 = \alpha \underline{x}_1 + \beta \bar{x}_2$ ,  $\alpha + \beta = 1$ ,  $\alpha, \beta \geq 0$

$$\begin{aligned} \varphi(\lambda_3) &= \min_{\mathbb{M}} ((\alpha + \beta) \underline{c} + \alpha (\underline{x}_1 + \beta \bar{x}_2) \underline{c}' )^T * \\ &+ \beta \min_{\mathbb{M}} (\underline{c} + \lambda_2 \underline{c}')^T * = \alpha \varphi(\underline{x}_1) + \beta \varphi(\bar{x}_2). \end{aligned}$$

Poznajmyka: Prosta  $\lambda \in I$ , gdzie  $I$  je nieskończoność' liniowy' interwał, potomu  
 $\min_{\mathbb{M} \times I} (\underline{c} + \lambda \underline{c}')^T *$  jest ciągły' a dla domena  $I$ ,  $I$  odc.

$$I = \langle \underline{x}_1, \bar{x}_2 \rangle : \begin{cases} \min_{\mathbb{M}} (\underline{c} + \lambda \underline{c}')^T * & \text{mnożna z klasową} \\ \min_{\mathbb{M}} (\underline{c} + \lambda \underline{c}')^T * & \text{mnożna z klasową} \\ \min_{\mathbb{M}} (\underline{c} + \lambda \underline{c}')^T * & \text{mnożna z klasową} \end{cases}$$

Pozor!: Klasa klasowa klasowa jest dla nieskończoność' liniowa istotna.

Nelijnairu' programovani' - re'klaď (konvexu', rozevne' konvexu')

$$\underline{\text{Věta 1:}} \quad \text{Horníma } H = \{ \mathbf{x} \in \mathbb{R}^m \mid g_i(\mathbf{x}) \leq 0 \mid i=1, \dots, m \}, \quad g_i: \mathbb{R}^n \rightarrow \mathbb{R} \text{ konvex},$$

$\mathbf{x}$  konvex!

$$\underline{\text{Dle:}} \quad \begin{matrix} \mathbf{x}_1, \mathbf{x}_2 \in H \\ \mathbf{x}_1 + \beta \mathbf{x}_2 \end{matrix} \quad \mathbf{x}^3 = \alpha \mathbf{x}_1 + \beta \mathbf{x}_2, \quad \alpha + \beta = 1, \quad \alpha, \beta \geq 0$$

$$g_j(\mathbf{x}^3) = g_j(\alpha \mathbf{x}_1 + \beta \mathbf{x}_2) \leq \alpha g_j(\mathbf{x}_1) + \beta g_j(\mathbf{x}_2) \leq 0 \Rightarrow \mathbf{x}^3 \in H$$

Věta 2: Každe lokálni minimum konvexu' funkce je minimum globálni! Platí v  $\mathbb{R}^n$  nebo lib. konvexu' množině  $H \subset \mathbb{R}^n$ .

Důkaz: Nechť  $\mathbf{x}^0$  je lok. min.  $\Rightarrow \exists \delta(\mathbf{x}^0, \varepsilon)$

akoli, že pro  $\mathbf{x} \in \delta(\mathbf{x}^0, \varepsilon) \cap H$  platí

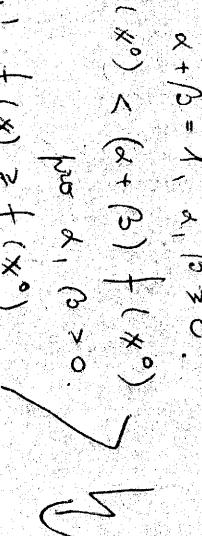
$$f(\mathbf{x}) \geq f(\mathbf{x}^0).$$

Pro důkaz upřednostníme  $\mathbf{x} \in H$  tak, že  $f(\mathbf{x}') < f(\mathbf{x}^0)$ .

$$2. \text{ konverguje } H \Rightarrow \mathbf{x} = \alpha \mathbf{x}_1 + \beta \mathbf{x}^0 \in H \quad \alpha + \beta = 1, \quad \alpha, \beta \geq 0.$$

$$2. \text{ konverguje } f \Rightarrow f(\mathbf{x}) = \alpha f(\mathbf{x}_1) + \beta f(\mathbf{x}^0) < (\alpha + \beta) f(\mathbf{x}^0) \quad \text{pro } \alpha, \beta > 0.$$

$$\text{Pro } \mathbf{x} = \alpha \mathbf{x}_1 + \beta \mathbf{x}^0, \quad \mathbf{x} \in \delta(\mathbf{x}^0, \varepsilon) \text{ je platí } f(\mathbf{x}) \geq f(\mathbf{x}^0) \quad \text{(10)}$$



25.04.2008

Lemma: Funkce  $F(\mathbf{x})$ , kde má 1. kroc. derivace na oboru konvexum mnu.  $H$

(d) je konvexu'  $\Leftrightarrow$  plád:

$$F(\mathbf{x}^2) - F(\mathbf{x}^1) \geq \nabla f(\mathbf{x}^1)^T (\mathbf{x}^2 - \mathbf{x}^1), \quad \forall \mathbf{x}^1, \mathbf{x}^2 \in H.$$

Věta 3: Je-li  $f(\mathbf{x}) \in C^2$  na oboru konvexu' množině  $H$ , potom je konvexu' na  $H$  ( $\Leftrightarrow$ )  $\nabla^2 f(\mathbf{x}) = \mathbf{H}(\mathbf{x}) = \left( \frac{\partial^2 f}{\partial x_1 \partial x_1}, \dots, \frac{\partial^2 f}{\partial x_n \partial x_n} \right)$  je pozitivně semi definovan!

$$\text{Dle: Taylorova měda: } f(\mathbf{x}^2) = f(\mathbf{x}^1) + \nabla f(\mathbf{x}^1)^T (\mathbf{x}^2 - \mathbf{x}^1) + \frac{1}{2} (\mathbf{x}^2 - \mathbf{x}^1)^T \nabla^2 f(\mathbf{x}^1) + \text{(1)}$$

$$+ \textcircled{1} (\mathbf{x}^2 - \mathbf{x}^1)(\mathbf{x}^2 - \mathbf{x}^1)$$

$$1) \quad f(\mathbf{x}) \text{ je konvexu'} \Leftrightarrow f(\mathbf{x}^2) \geq f(\mathbf{x}^1) + \nabla f(\mathbf{x}^1)^T (\mathbf{x}^2 - \mathbf{x}^1) \text{ (1)} \\ \rightarrow (\mathbf{x}^2 - \mathbf{x}^1)^T \nabla^2 f(\mathbf{x}^1) (\mathbf{x}^2 - \mathbf{x}^1) \geq 0 \quad \text{(2)}$$

Pro důkaz upřednostníme  $\mathbf{x}^2$  až  $\nabla^2 f(\mathbf{x})$  mnu' kroc. derivacemi na  $H \Rightarrow$

$$\Rightarrow \exists \mathbf{x}^0 \in H, \quad V + \mathcal{O} \text{ ak, že } \nabla^2 f(\mathbf{x}) V \leq 0.$$

Proces 2. pouze derivace jsou nerozložitelné  $\Rightarrow \exists \delta(\mathbf{x}^0, \varepsilon) \subset H$

akoli, že  $\nabla^2 f(\mathbf{x}) V \leq 0, \quad \forall \mathbf{x} \in \delta(\mathbf{x}^0, \varepsilon)$ .

$$2) \quad \mathcal{O}(\mathbf{x}^0, \varepsilon) \ni \mathbf{x} \text{ ak, že } \nabla^2 f(\mathbf{x}^0, \varepsilon) > 0 \quad (\dim \mathcal{O}(\mathbf{x}^0, \varepsilon) > \dim n)$$

Pořadí ②  $\Rightarrow P^2(\tilde{x} - \tilde{x}^0)^T \nabla^2 f(x)(\tilde{x} - \tilde{x}^0) < 0$  což je nápror n ②  
 prostřednictvím ①  $\Leftrightarrow \tilde{x}^0 + \mathbb{Q}(\tilde{x} - \tilde{x}^0) \in \mathcal{O}(\tilde{x}^0 + \varepsilon) \Rightarrow (\tilde{x} - \tilde{x}^0)^T \nabla^2 f(\tilde{x} + \mathbb{Q}(\tilde{x}^0 - \tilde{x}^1))$   
 L)  $\nabla^2 f(\tilde{x}^1)$  pos. definice  $\tilde{x} \in M \Rightarrow$  pos. dle:  $\tilde{x}_1, \tilde{x}_2 \in M$   
 $(\tilde{x}^2 - \tilde{x}^1)^T$   
 2.

### Zobecněné konvexní funkce

I. zachovávající konvexitu' def. obz.

Definice 2: Funkce  $f(x)$  definovanou na konvexním množině  $M$  má myšlenku

konvexní,  $\Leftrightarrow$  existuje pro lib.  $x_1^1, x_2^2 \in M$  a  $\lambda_1, \lambda_2 \geq 0$   $\lambda_1 + \lambda_2 = 1$

$$\text{platí } f(\lambda_1 x_1^1 + \lambda_2 x_2^2) \leq \max \left\{ f(x_1^1), f(x_2^2) \right\}$$

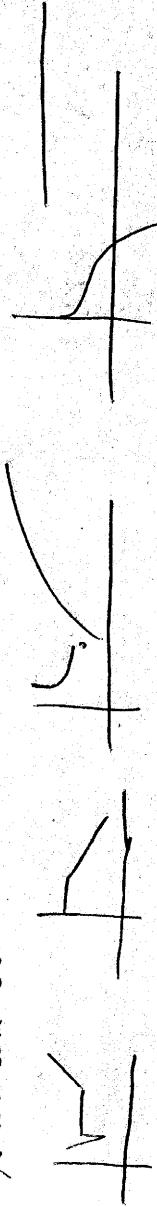
Funkce  $f(x)$  je explicitně konvexní na  $M$ , je-li rovní konvexní a další funkce  $x_1^1, x_2^2 \in M$  a  $\lambda_1, \lambda_2 \geq 0$   $\lambda_1 + \lambda_2 = 1$ ,  $f(x) \neq f(x^2) \Rightarrow$

$$\Rightarrow f(\lambda_1 x_1^1 + \lambda_2 x_2^2) < \max \left\{ f(x_1^1), f(x_2^2) \right\}.$$

Př.: expl. konvexní  $\Rightarrow$  když je možné l|x| se minimální



konvexní



Výtažek: Platí možnost konvexní min.  $M$ , že  $f$  je konvexní  $\Rightarrow$  f expl. konvexní  $\Leftrightarrow$  f je konvexní

$$\text{def: } \forall x_1^1, x_2^2 \in M \quad \lambda_1, \lambda_2 \geq 0 \quad \lambda_1 + \lambda_2 = 0 \quad \text{konvexitu' } f(\lambda_1 x_1^1 + \lambda_2 x_2^2) \leq \lambda_1 f(x_1^1) + \lambda_2 f(x_2^2) \leq$$

$$\leq \max \left\{ f(x_1^1), f(x_2^2) \right\} + \lambda_2 \max \left\{ f(x_1^1), f(x_2^2) \right\} = \max \left\{ f(x_1^1), f(x_2^2) \right\}$$

$$\text{expl. konvexní } \Rightarrow f(x^2) \neq f(x_1^1) \Rightarrow$$

expl. konvexní  $\Rightarrow$  konvexní

Vorlesung 5. Finne für  $f(x)$  def. na konvexe. num.  $H$  je konvexum  $\Leftrightarrow \forall \alpha \in \mathbb{R}$

(29)

Platzl:  $A_\alpha = \{x \in H \mid f(x) \leq \alpha\}$  je konvexe!

Def. konvexität: Zeige  $\lambda \in \mathbb{R}$  a  $x^1, x^2 \in A_\alpha$  u. d. a u. konvexe  $x = \lambda x^1 + (1-\lambda)x^2$

$$\lambda_1, \lambda_2 \geq 0, \quad \lambda_1 + \lambda_2 = 1.$$

Proze H je konvexa  $\Rightarrow x \in H$

$$f(x) \leq \max(f(x^1), f(x^2)) \leq \alpha \Rightarrow A_\alpha \text{ je konvexe!}$$

2) A je konvex  $\Leftrightarrow \forall \alpha \in \mathbb{R} \cdot$  Existenz

zwei x<sup>1</sup>, x<sup>2</sup> ∈ H, λ<sub>1</sub>, λ<sub>2</sub> ≥ 0, λ<sub>1</sub> + λ<sub>2</sub> = 1 a def x = λ<sub>1</sub>x<sup>1</sup> + λ<sub>2</sub>x<sup>2</sup>.

$$\max\{f(x^1), f(x^2)\} = \alpha.$$

Platzl:  $f(x^1) \leq \alpha \text{ do } \Rightarrow f(x^2) \leq \alpha \Rightarrow x^1, x^2 \in A_\alpha \text{ - konvexe } \Rightarrow x \in A_\alpha$

$$\Rightarrow x \in H \text{ & } f(x) \leq \alpha = \max\{f(x^1), f(x^2)\} \Rightarrow \text{konvexida } f$$

Darüdekk: Monotona L = {x ∈ H | f<sub>i</sub>(x) ≤ f<sub>i</sub>(x<sup>i</sup>) (i = 1, ..., m)} ist H je konvexe!

$\lambda_i \in \mathbb{R}, f_i$  konvexa na H  $\forall i$ , je konvexe!

Kriterium: Kandidat minimum expl. konvexa konvexe (fce f(x) na  $\mathbb{R}^m$ )

je absolutes!

Platzl:   $x^0$  og naværende  $x^0$  ja lo lok. min in  $f(x) \in \mathbb{R}^n$ .

$$\Rightarrow \exists O(x^0, \varepsilon) \text{ tale, at for } x \in O(x^0, \varepsilon) \text{ platzl } f(x) \geq f(x^0).$$

Pro oper prædi, at  $x^0$  nuu' gletscht abs. min.  $f \Rightarrow \exists x^1: f(x^1) < f(x^0)$

$$\stackrel{\text{defl.}}{\Rightarrow} \text{pro } \forall x = \lambda_1 x^0 + \lambda_2 x^1 \quad \lambda_1, \lambda_2 \geq 0, \quad \lambda_1 + \lambda_2 = 1$$

kontradiktor

$$f(x) < f(x^0) = \max\{f(x^1), f(x^0)\}. \text{ Pro } x \in O(x^0, \varepsilon) \quad \text{y}$$

Pontalika: f je konvexa  $\Leftrightarrow -f$  je konvexa!

$$\text{expl. } -u \stackrel{\Leftrightarrow}{=} \text{expl. } -f$$

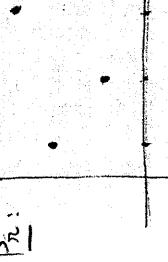
$$\rightarrow f(\lambda_1 x^1 + \lambda_2 x^2) \geq \min\{f(x^1), f(x^2)\}$$

II. 14 mēnuši kārtējā konvexu, ale pārādījums diferenču un līnijas funkcē.

Def'z: Funkcijai  $f(x)$  definovām  $x^0 \in M$  marginalie līdzīgi  $x^0$  diferenču arā, ja

$$f(x) \leq f(x^0) \Rightarrow \nabla f(x^0)^T (x - x^0) \leq 0$$

$$f(x) < f(x^0) \Rightarrow \nabla f(x^0)^T (x - x^0) < 0 \quad x \in M$$



Funkcija  $f(x)$  ir pseudokonvexa ja  $M$ , ja -li loka līne pārādījums

ja  $x \in M$ .

Def'z: Pārādījums fai, ka līdzīgi ar  $x^0$  diferenču arā, ja marginalie  $x^0$  līnijas minimums  $f(x)$  ja  $M$ , ja līdzīgi plakātā  $(x - x^0)^T \nabla f(x^0) \geq 0$ .  $x \in M$ .

Vēta t: Kadēļ vārīne minimūnumu pseudokonvexu funkciju minimizē absolūti.

Dz:  $x^0$  vārīnei min  $\Rightarrow (x - x^0)^T \nabla f(x^0) \geq 0 \quad x \in M$   
Pārādījums pārādījums  $\Rightarrow x^1 \in M$  tātā  $f(x^1) < f(x^0)$   $\xrightarrow{\text{pārādījums}}$

$$\Rightarrow (x^1 - x^0)^T \nabla f(x^0) < 0 \Rightarrow y$$

Dziedek: Kadēļ vārīnei  $y$  ja  $x^1$  pārādījums līdzīgi  $\nabla f(x) = 0$   
ja abs. min. pseudokonvexu funkciju.

Vēta g: ja -li  $M$  konvexu, pārādījums pārādījums līdzīgi konvexu ( $\Rightarrow$  apl. konvexu  $\Rightarrow$  līdzīgi konvexu).

Dz: Pārādījums Riemanns ( $R$ ): pārādījums  $f(x^2) - f(x^1) \geq \nabla f(x^1)^T (x^2 - x^1)$   
 $\geq f(x^2) \leq f(x^1) \Rightarrow \nabla f(x^1)^T (x^2 - x^1) \leq 0$

$\hookleftarrow$

Izmakska: funkcija  $f(x)$  ir pseudokonvexa, ja -li  $-f(x)$  pārādījums

Funkcija  $f(x)$  ir pseudokonvexa, ja -li sākumā pārādījums līdzīgi konvexu.

Pārādījums līdzīgi konvexu!

$f(x) \geq f(x^0) \Rightarrow \nabla f(x^0)^T (x - x^0) \geq 0$

$\Rightarrow$

Pro pseudolinearni

$$f(x) < f(x^*) \Rightarrow \nabla f(x^*)^\top (x - x^*) < 0$$

$$f(x) = f(x^*) \Rightarrow \nabla f(x^*)^\top (x - x^*) = 0$$

$$f(x) > f(x^*) \Rightarrow \nabla f(x^*)^\top (x - x^*) > 0$$

(11)

02.05.2008

(1)  $\min_{\mathcal{N}} f(x) : \mathcal{N} = \{x \in N \mid g_i(x) \leq 0\}$  kde  $f, g_i$  - konvekne na  $N \subseteq \mathbb{R}^m$  kowicze

$$\text{monotona} : \lambda = \lambda_1 \cdots \lambda_m$$

Methode (1) je 'nłożona konweknu' her progresownia.

Pośród mnogich zaz.  $f$  a gi jsou sprzedst. difference koncave 'blue' na  $N$ .

(mogliwosc N otoczeniom ar  $\mathbb{R}^m$ )

Kuhn-Tuckerowy podmiany

Def: Zadanie niespełnione 'w loże' (1).

$$\phi(x, \mu) = f(x) + \mu^\top g(x) \quad i \quad \mu \geq 0, \quad x \in N$$

Definicja: Rzâwanie, zaz.  $(x^*, \mu^*)$  nazywaj Kuhn-Tuckerowy podmiany

(je K-T nascionań) jendzieje plak!

$$(a) \quad \mu^* \geq 0, \quad x^* \in N$$

$$(b) \quad \nabla_x \phi(x^*, \mu^*) \leq 0$$

$$(c) \quad \nabla_x \phi(x^*, \mu^*) = 0$$

$$(d) \quad \nabla_\mu \phi(x^*, \mu^*)^\top \mu^* = 0$$

Przykł K-T na jednor. niespełnione:

$$x \in N \Rightarrow g_i(x^*) \leq 0 \stackrel{(a)}{\Rightarrow} x^* \in N$$

$$(b, d) \Rightarrow \begin{cases} g_i(x^*)^\top \mu^* = 0 \\ \leq 0 \end{cases} \stackrel{(a), (b)}{\Rightarrow} \text{alegion } \{ \text{została } g_i(x^*), \mu_i^* \geq 0 \}$$

$$\mu_i^* = \lambda_1 \cdots \lambda_m$$

Takie podm. se nazywa' podmiany kompletnie niewazy.

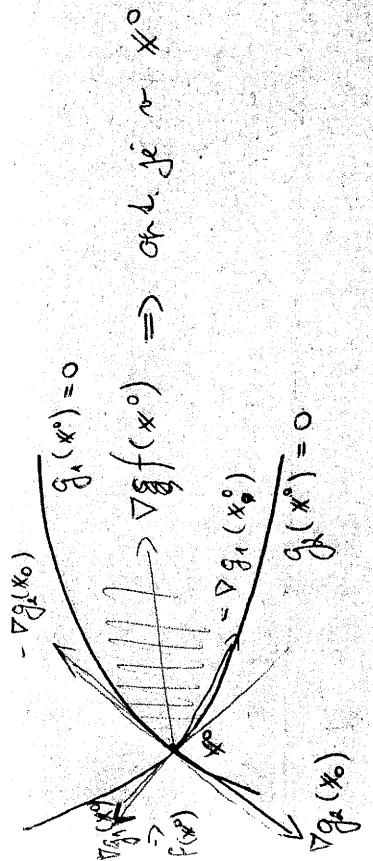
$$(a, c) \Rightarrow \nabla f(x^*) + \mu^* \nabla g(x^*) = 0$$

(zazacim  $J = \{i \in \{1, \dots, m\} \mid g_i(x^*) = 0\}$ ) Taka monotonna je nazyw.

indeksy aktywnie podmiany  $x^*$ .

$$(a, c) \Rightarrow \nabla f(x^*) = - \sum_{i \in J} \mu_i^* \nabla g_i(x^*) \quad (\mu_i^* = 0 \quad i \notin J)$$

(30)



Vista: Jeoblízí  $f \text{ a } g_1, \dots, g_m$  jíou konvexní a nýoji se dílčenovatelná  
na konvexní mno. M. A ještě  $(x^*, \mu^*)$  je K-T stationární body

pokud  $x^*$  je opt. řešení užívající (1).

$$\text{Důkaz: } \forall x \in M, \quad f(x) - f(x^*) \geq \nabla f(x^*)^\top (x - x^*) \quad \forall x \in M \quad (\forall x \in N)$$

$$g_i(x) - g_i(x^*) \geq \nabla g_i(x^*)^\top (x - x^*) \quad \forall x \in M \quad \forall i = 1, \dots, m$$

$$\forall x \in M, \quad \nabla f(x^*) = -\mu^* \nabla g(x^*)$$

$$\begin{aligned} \Rightarrow f(x) - f(x^*) &\geq -\mu^* \nabla g(x^*)^\top (x - x^*) \geq -\mu^* \nabla g(x^*)^\top (g(x) - g(x^*)) = \\ &= -\mu^* \nabla g(x)^* + \mu^* \nabla g(x^*) = -\mu^* \nabla g(x) \geq 0 \quad \forall x \in M \\ &\Rightarrow f(x) \geq f(x^*) \quad \forall x \in M \Rightarrow x^* \text{ je opt. řeš. (1)} \end{aligned}$$

Základ: Pravidelné řady řešení optimalizační užívají me něčím 'ostatným' a nenavazuje (A: K-T podmínky). Specielle ne kódovacího programování! → lineární!

### Duální

Lagrangova dualita

Definice: K užitce (1) dvoj. dualita vložit

$$(2) \max_K \phi(x^*, \mu); \quad K = \{x \in M; \mu \geq 0 \mid \nabla \phi(x, \mu) = 0\}$$

Sebda' některá dualita: Nechť  $f$  a  $g$  jíou konvexní, nýoji se dílčenovatelná na konvexní mno.

Pokud funkce  $\inf_H f \geq \sup \phi(x, \mu)$ .

Důkaz: Je-li  $H = \emptyset$  měl  $K = \emptyset \Rightarrow \inf_H f = \emptyset \Rightarrow \sup \phi(x, \mu) = \emptyset$ .

Nechť  $H \neq \emptyset$ ,  $x^* \in H$  lze:  $K = \{x \in M; \nabla f(x^*)^\top (x - x^*) \leq 0\}$

$$\text{Přídp. } f(x^*) - f(x^2) \geq \nabla f(x^2)^\top (x^1 - x^2)$$

prokázat  
prokázat  
prokázat

$$g_i(x_1) - g_i(x^2) \geq \nabla g_i(x^2)^T (x^1 - x^2) \quad \forall i$$

$$\|x^1 - x^2\|^2 \leq \mu^2$$

(3)

$$x^1 \in M \rightarrow x^1 \in N, g_i(x^1) \leq 0 \quad \forall i$$

$$(x^1, u^1) \in L \Rightarrow (x^1, u^2) \in L \quad x^1 \in N, u^2 \geq 0$$

$$\begin{aligned} \nabla f(x^1) &= u^{2^T} \nabla g(x^2) = 0 \quad \forall (x^1, u^2) \\ \Rightarrow f(x^1) - f(x^2) &\geq -u^{2^T} \nabla g(x^2)(x^1 - x^2) \geq -u^{2^T}(g(x^1) - g(x^2)) = \\ &= \underbrace{-u^{2^T} g(x^1)}_{\leq 0} + u^{2^T} g(x^2) \geq u^{2^T} g(x^2) \end{aligned}$$

$$f(x^1) \geq f(x^2) + u^{2^T} g(x^2) = \phi(x^2, u^2) \quad \square$$

- Platí i nízka místa v dualitě.

I. metody pro malé množiny (minimálního programování)

II. metody pro malé množiny (minimálního programování)  
metodou gradientu

(druhého řádu) (Rada)

metodou gradientu

(prvního řádu) (Rada)

Kvadratické se v pravidelných a nepravidelných množinách  
(když pravidelná množina má všechny extrema na hranicích)

množina má rovný ekstremum

III. metody pro nepravidelných množin (nejčastěji)

• najít extrema a kdy  $x^* \in M$ . ( $\equiv$  nejdříve problém - mají všechna průj. rady)

- 1) Klesající průj. rady
- 2) Klesající delší průj. rady



- funkce a Wofla || Zadání: hledat minimální funkci  $f(x)$  (když  $x \in M$  je jednoduchá (nejpravděpodobně konvexní polyeder))  
• vhodné pro řešení, když  $M$  je jednoduchá (nejpravděpodobně konvexní polyeder)  
• obecnou funkci  $f(x)$ .

Verimotně

III

metody řešení nad množinou  $M$   
• vhodné pro jednoduchou eliptickou funkci  $f(x)$  (když  $x \in M$  je konvexní množina)

- najít extrema v množině  $M$  (nebo aspoň konvexní množinu)  $\exists z_1, z_2, \dots, z_n \in M$   
kde  $z_1, z_2, \dots, z_n$  jsou všechny množinou  $M$   
• obecnou funkci  $f(x)$ .

• formu hmotnosti.

• jinde najít extrema nad množinou  $M$ , když oddíluje  $z^1$  od  $M$

Dostavme  $z_1 = z_1 \cap \{x \mid a^T x \leq b\}$  a něž  $\min_{z_1} f(x)$

Dostavme  $z_2 = z_1 \cap \dots \cap z_n \cap \dots \cap M$ .

## V. Metody optimizačních K-T. p.

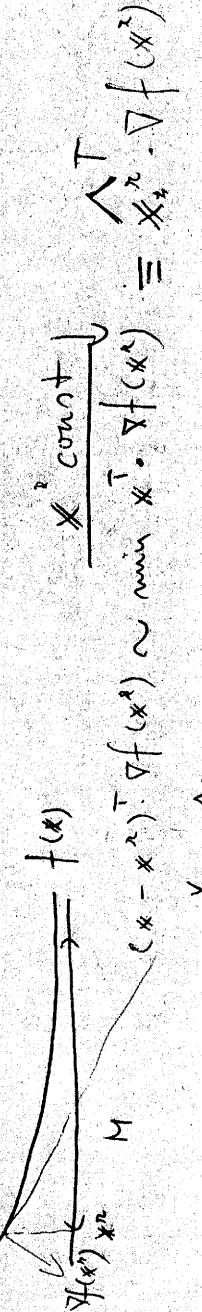
\* Vyhodnocení některého kandidátského programu

### IV. Spec. metody pro spec. problém

#### Hloba Franka Wolfe

min f(x) :  $M = \{x \in \mathbb{R}^n \mid Ax \leq b, x \geq 0\}$ ,  $A \in \mathbb{R}^{m \times n}$  f pseudokonvexní na M.

Předp:  $M \neq \emptyset \Rightarrow x^T f(x)$  je adolec vnitřna až pro  $\hat{x}^n \in M$  (ještě ne, když H poslava)



$$(\hat{x}^n - x^n)^T \nabla f(x^n) \sim \min_{\lambda \in [0,1]} \hat{x}^n + \lambda (\hat{x}^n - x^n)$$

$$\text{příslušný: } \hat{x}^n - x^n$$

$$\min_{0 \leq \lambda \leq 1} f(\hat{x}^n + \lambda (\hat{x}^n - x^n))$$

$$\lambda = 1 \rightarrow x^{n+1} \text{ na hranici } M$$

$$\lambda < 1 \rightarrow x^{n+1} \text{ je kód obdobu.}$$

Alg: 1) Zde užívám LP min. 0. Potom je  $M \neq \emptyset$  doslova  $\hat{x}^n \in M$  myčové  $x=1$   
2) máme  $x^n \in M$ . Ráze užívám min  $x^T \nabla f(x^n)$  SM. Nejdále  $\hat{x}^n$  od L. než.  $\Rightarrow$

$$\Rightarrow (\hat{x}^n - x)^T \nabla f(x^n) \leq 0, \quad x \in M.$$

IV. F. W.: Platíme  $(\hat{x}^n - x)^T \nabla f(x^n) = 0$ , pokud je  $x^n$  opt. resp. zadane vnitřku.

Dle: Prostřednictvím  $x^n \in M \Rightarrow (\hat{x}^n - x^n)^T \nabla f(x^n) \leq 0$

$$\begin{aligned} \leq (\hat{x}^n - x)^T \nabla f(x^n) \leq 0 \Rightarrow & (\hat{x}^n - x)^T \nabla f(x^n) + (\hat{x}^n - x)^T \nabla f(x^n) \leq 0 \\ & \hat{x}^n - x^n \end{aligned}$$

$$\Rightarrow (\hat{x}^n - x)^T \nabla f(x^n) \leq 0 \quad \forall x \in M$$

2. pseudokonvexity  
 $f(x) < f(x^n) \Rightarrow \nabla f(x^n)^T (x - x^n) < 0$

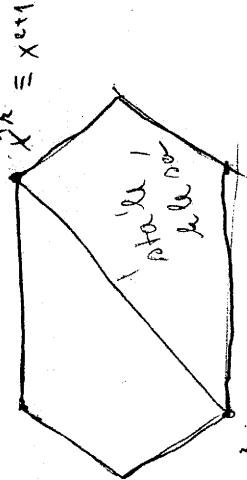
$$x \in M$$

(12)

I-V. F. W.: Ještě platí  $(\hat{x}^n - x^n)^T \nabla f(x^n) < 0$  a  $(\hat{x}^n - x^n)^T \nabla f(\hat{x}^n) \leq 0$

pokud  $x^{n+1} = \hat{x}^n \text{ a } f(x^{n+1}) < f(x^n)$ .

SQ. 05.1008

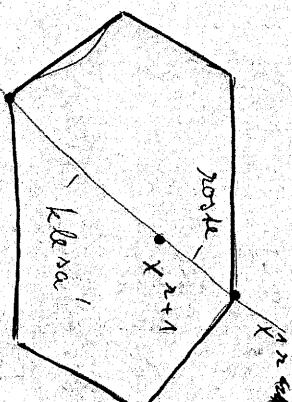


B.V. FV: jedná se o funkci  $f(x)$ , kde  $x \in \mathbb{R}^n$ . Nechť  $\hat{x}^n \in \mathbb{R}^n$  a  $\lambda \geq 0$ . Potom je  $\hat{x}^{n+1} = \hat{x}^n + \lambda(\hat{x}^n - x^n)$  optimální, pokud  $\nabla f(\hat{x}^{n+1}) \leq 0$ . (32)

Když  $\lambda = 0$ , pak  $\hat{x}^{n+1} = \hat{x}^n$  a  $\nabla f(\hat{x}^n) \leq 0$ .

$$(\hat{x}^n - x^n)^T \nabla f(\hat{x}^n + \lambda(\hat{x}^n - x^n)) = 0$$

$$(\hat{x}^n - x^n)^T \nabla f(\hat{x}^n) = 0$$



4.V:  $\{x^*\}$  má charakteristický vlastností, když je optimální řešení.

kadane' učebny.

(když řešení  $x^*$  je optimální řešení)

Vice kladem na 'programování' (nebo když 'optimizace')

$$(1) \max_{\mathcal{M}} f(\mathbf{x}), \quad \mathcal{M} = \{\mathbf{x} \mid g_i(\mathbf{x}) \leq 0\}, \quad \text{kde } f_i(\mathbf{x}), g_i(\mathbf{x}) \quad (i=1, \dots, m)$$

( $i=1, \dots, m$ ) jsou reálné funkce def. na  $\mathbb{R}^n$ .

a) ideální řeš. -  $\max_{\mathcal{M}} f(\mathbf{x}) = f_i(\mathbf{x})$  kde

b) dominantní řeš. -  $\exists i \in \{1, \dots, m\}$  tak, že řešení  $(1)$  optimální řešení max  $M$   $f_i(\mathbf{x})$ .

c) eficientní řeš.

Df: Provek  $x^* \in M$  nazýváme eficientním řešením učebny (1), je-li slze

$\forall x \in M$  tak, aby platilo  ~~$f(x) \leq f(x^*)$~~   $f(x) \geq f(x^*)$ .

Minimální řešení eficientních řešení označuje  $E$ .

Def: Provek  $x^* \in M$  nazýváme relativním eficientním řešením učebny (1),

jestliže  $\exists i \in \{1, \dots, n\}$  takže  $x \in M$  pro kterež  $f_i(x) > f_i(x^*)$

$$\exists \beta > 0 \quad | \quad \exists k \in \{1, \dots, n\} \text{ tak, že } f_k(x) < f_k(x^*)$$

$$\frac{f_k(x^*) - f_k(x)}{f_k(x^*) - f_k(x)} \leq \beta$$

d) homomorūm' nū.  $f(x) \rightarrow F(x)$  pūnādīme gālām' fci

and so (present on sh. derivative)

Panamericana S.A. electrica und  
gas

$$\max_M \mathcal{J}_T^*(x) - \lambda \left\| x - \mathcal{R}^* \right\|^2 \leq 0$$

$$H_{\text{opt}}(x) = \max_M \max_{x^* \in M} f(x) = f(x^*)$$

poison plant meta:

Vectors:  $\bigcup M_{\text{opt}}(\mathbb{K})$  C E.

D<sub>4</sub>: Nach  $\vdash$   $x^e \in \bigcup_{H \in \Sigma} H_{\text{opt}}(\mathbb{N}) \rightarrow \exists \neq 0 \text{ such that } x^e \in H_{\text{opt}}(\mathbb{N})$

$$\Rightarrow \mathbb{K}^T f(x) \leq \mathbb{K}^T f(x^*) \quad \forall x \in H$$

Problematikum nach. e. x.  $\exists$   $\bar{x} \in M$  hat,  $\neg f(\bar{x}) > f(x)$

卷之三

Poznawanie

1) Please describe your linear paleo job or linear

*vice brimia'lin' opd.*

2) Plak' - ri, re fi - klonla - bu! a gi - konnen! pale job or know one  
not experienc - ed one.

卷之三

Fazit: Prog. nicht prog. Platz UHopt(X) = S & E je

— *monogram* — pl. *efic.* — *gen-*  
— *gen-* — *pl.* *efic.* — *gen-*

ପ୍ରକାଶକ ପରିଷଦ

Pro grammer's next step: prog. place  $\cup H_{opt}(x) \subset \Sigma^* \cup H_{opt}(A)$

1974

## 1. Alg. dialogu

$\|_0, \|_1 > 0$  (zvolíme hodnotu vnitřního param.)

Réšené hodnoty 1-param.

$$x^* \in M_{\text{opt}}(\|_0) \cap x^* \in M_{\text{opt}}(\|_1)$$

$$(*) \max_{x \in H} (\|_0 + \lambda_1 (\|_1 - \|_0))^\top f(x) \text{ pro } \lambda \in \mathbb{K}, \lambda > 0$$

jež řeší, že majdeme řeš. Pro  $\lambda = 0$  je  $\max \|\_0^\top f(x)$

$$= \|_0^\top f(x^*) \text{ a tedy } \lambda_1 > 0 \rightarrow \lambda_1 > 0. \text{ Hodnota } f(x^* + \lambda_1 (\|_1 - \|_0))$$

zvýší se i vnitřek a rozloha je:

d) počítací jedna než (\*), pro  $\lambda > \lambda_1$ .

b) zmeníme  $\|_1$  a zůstane (\*)

c) zmeníme  $\|_0, \|_1$

w) vnitřek je upokojiv - konec

## 2. Alg. dialogu

nejprve se aplikuje 1. alg. dialogu

Definujeme  $K \subset \{\lambda_1, \dots, \lambda_N\}$ , kde chce řešit řešení hodnoty

a  $\lambda_i > 0$  o holkach česky řešení řešit řešení hodnoty.

$$\text{Definujeme } M(K, \omega) = \{x \in H \mid f_i(x) \geq f_i(x^*) + \mu_i, i \in K\}$$

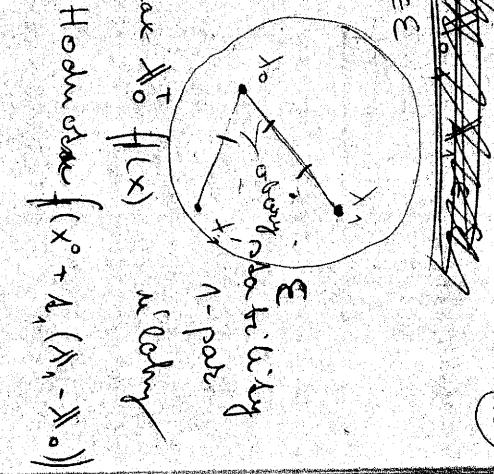
$$\text{Uvaž } K = \{\lambda_1, \dots, \lambda_N\} \setminus K.$$

Réšené hodnoty

$$\max_{x \in H} \sum_{i \in K} x_i f_i(x) \quad 1. \text{ alg. dialogu.}$$

d) máme je upokojiv

b) může zmenit  $K$  na  $\lambda_i$



1) informace o preferenčním mřížce de nedostatečné

- Metoda globálního čloupu funkce

$$\max_{x \in M} f_i(x) = f_i^* \geq f_i$$

$$\min_M \left\{ \sum_{i=1}^n \left( \frac{f_i^* - f_i(x)}{f_i^*} \right)^2 \right\} \quad \mu = 1/2 \epsilon$$

$\Rightarrow$  kompozitní, řešo & dle ne doblasti, ne je eficientní!

2) informace o preferenčním dosahovém pravidlu načáslu výpočtu

- Metoda funkce mřížek

$$\max_M \sum_{i=1}^n w_i f_i(x), \quad w_i > 0, \quad \sum_{i=1}^n w_i = 1$$

$\triangleright$  menovatelné řešení pro délkohodnotu.

3) informace o preferenčním dosahovém křížku výpočtu

- $f_1 = f_i$  — porovnávání 2 funkcí
- $\nabla f_1 = -\nabla f_i$  — → převod na funkci mřížek  
— velice drah, eficientní!

4) informace o p. až po ukončení výpočtu

- aktuální  $x$  a nás. max  $\max_M f(x)$

$x_2$

1) informace o preferenčních mřížových metodách meziřímské

Metoda globálního cílového funkce

$$\max_{x \in M} f_i(x) = f_i^* \geq f_i$$

$$\min_M \left\{ \sum_{i=1}^n \frac{(f_i^* - f_i(x))^{\beta}}{f_i^*} \right\}, \quad \beta = 1, 2, \dots$$

$\Rightarrow$  kompromisní řešení & dle toho doplňkově eficientní

2) informace o preferenčních dosažených příčinách neúspěchu

Metoda funkce mřížového

$$\max_M \sum_{i=1}^n w_i f_i(x), \quad w_i > 0, \quad \sum_{i=1}^n w_i = 1$$

$\triangleright$  mřížová funkce je zde 'bez ohledu' na problem.

3) informace o preferenčních dosažených řešeních myšlenek

$$f_1 = \dots = f_k = \text{porovnávací funkce}$$

$$\nabla f_1 = \dots = \nabla f_k = \text{pravidla pro řešení}$$

- všechna řešení jsou eficientní

4) informace o r. až po mřížovém řešení

$$\nabla f_1 = \dots = \nabla f_k = \max_M \lambda_1 f_1(x)$$

$x_2$

(N)

16.05.2008

Dynamické programování - diskrétní

Systém - předmět matematiky R. Kornmanna. Tento zákonizující mříž. intervaly  $\langle d'_1, d''_1 \rangle$ .

Stav - násobek potřebné informace o agencích a čas. charakteristik  $\approx \langle d'_1, d''_1 \rangle$ .

Zájmu - si dole "A(a, d")" kde d je stav  $d'_1 \subset d''_1 \subset \dots \subset d''_n = d'$ , kde  $d'_1 \approx 1$

potom s daným systémem se dílce  $d'_1$  ne může dát výhodně uspořádánou řadu - nějaký řešeních cíle  $\in \mathbb{R}$ . Minimální řešení potřebujících řadou  $X \subset \mathbb{R}_{\text{pos}}$ .

Stav systému se může měnit pouze o časových charakteristik  $t$  nebo na základě

zadaného - uveřejněn (např. mřížka reálných čí). Mříž řešení může být rozložena do řadou.

Zájmu je dát na jednotkovou transformaci  $x^{k+1} = T(x^k, u^k)$   $u^k = 1, \dots, N$ .



## Dělení:

- ① máme zadán poč. stan.  $x^1$
- ② máme zadán koncový stan.  $x^{N+1}$
- ③ máme zadán poč. stan.  $x^1$  a další i koncový stan.  $x^{N+1}$
- ④ máme zadání  $X^1 \subset X$  a stanov.  $x^1 \in X^1$
- ⑤ — — —  $X^{N+1} \subset X$  a stanov.  $x_{N+1} \in X^{N+1}$

⑥ nejdále máme  $N$  a současné množství možných režimů  $N_1$  pro které je nějaký režim  $x^1$  vlastního mimo pro které dosud máme ještě jinou hodnotu cílové funkce.

$$\text{odtak: } \frac{x_1^{1, u^1} \quad x^2 \quad u^2 \quad x^3 \quad u^3 \quad x^4 \quad u^4}{\Delta^1 = \Delta^N \quad \Delta^2 \quad \Delta^3 \quad \Delta^4 \quad \dots} = \frac{u^N \quad x^{N+1}}{\Delta^N = \Delta^N}$$

Def: Řešitma je násobení int.  $\langle \Delta^1, \Delta^N \rangle$  probíhající diskusemi rozložovací

diskusními krokům, jedná se:

- a) máme dano dělení  $\langle \Delta^1, \Delta^N \rangle$ ,  $\Delta^1 = \Delta^N \subset \dots \subset \Delta^N \equiv \Delta^{N+1}$ ,  $N > 1$
- b)  $x^1$  je daný počáteční stanov
- c)  $\Delta^N$  je může změnit jen na  $\Delta^N$  a podle stanové funkce  $T_i(x^i, u^i)$   $x^{i+1} = T_i(x^i, u^i)$   $i=1, \dots, N$  ( $x^N$  závisejí pouze na stanov.  $x^i$  a provedeném rozložení  $u^i$ )

Def: Pokud  $u^1, \dots, u^N$  je vlastním  $\Delta^N \subset U$ ,  $x^{i+1} = T_i(x^i, u^i) \in X_i, i=1, \dots, N$ ,  $x^1 \in X^1$  nazýváme koupesem stanov. stanov.

Množství všech koupesů stanov. (průkřemích dáných systémů a rozh. diskuz.)

def. procesu) označíme  $\Omega_N(x^1) = \{(u^1, \dots, u^N) | u^i \in U, x^{i+1} = T_i(x^i, u^i) \in X_i, i=1, \dots, N, x^1 \in X^1\}$

Pozn: Dáno  $N$ ,  $x^1 \in X^1$ , ale vždy můžeme počítat vložku pro  $x^1$  ex a měřitých průk

k pro  $f(x)$ .

Abychom měli vložku diskuz. def. dyn. fung. množ. cílovou funkci, kterou

prosadíme rozložovacím procesem opakovat:

$$(1) f_1(x^1, u^1), f_2(x^1, x^2, u^1, u^2), \dots, f_N(x^1, \dots, x^N, u^1, \dots, u^N)$$

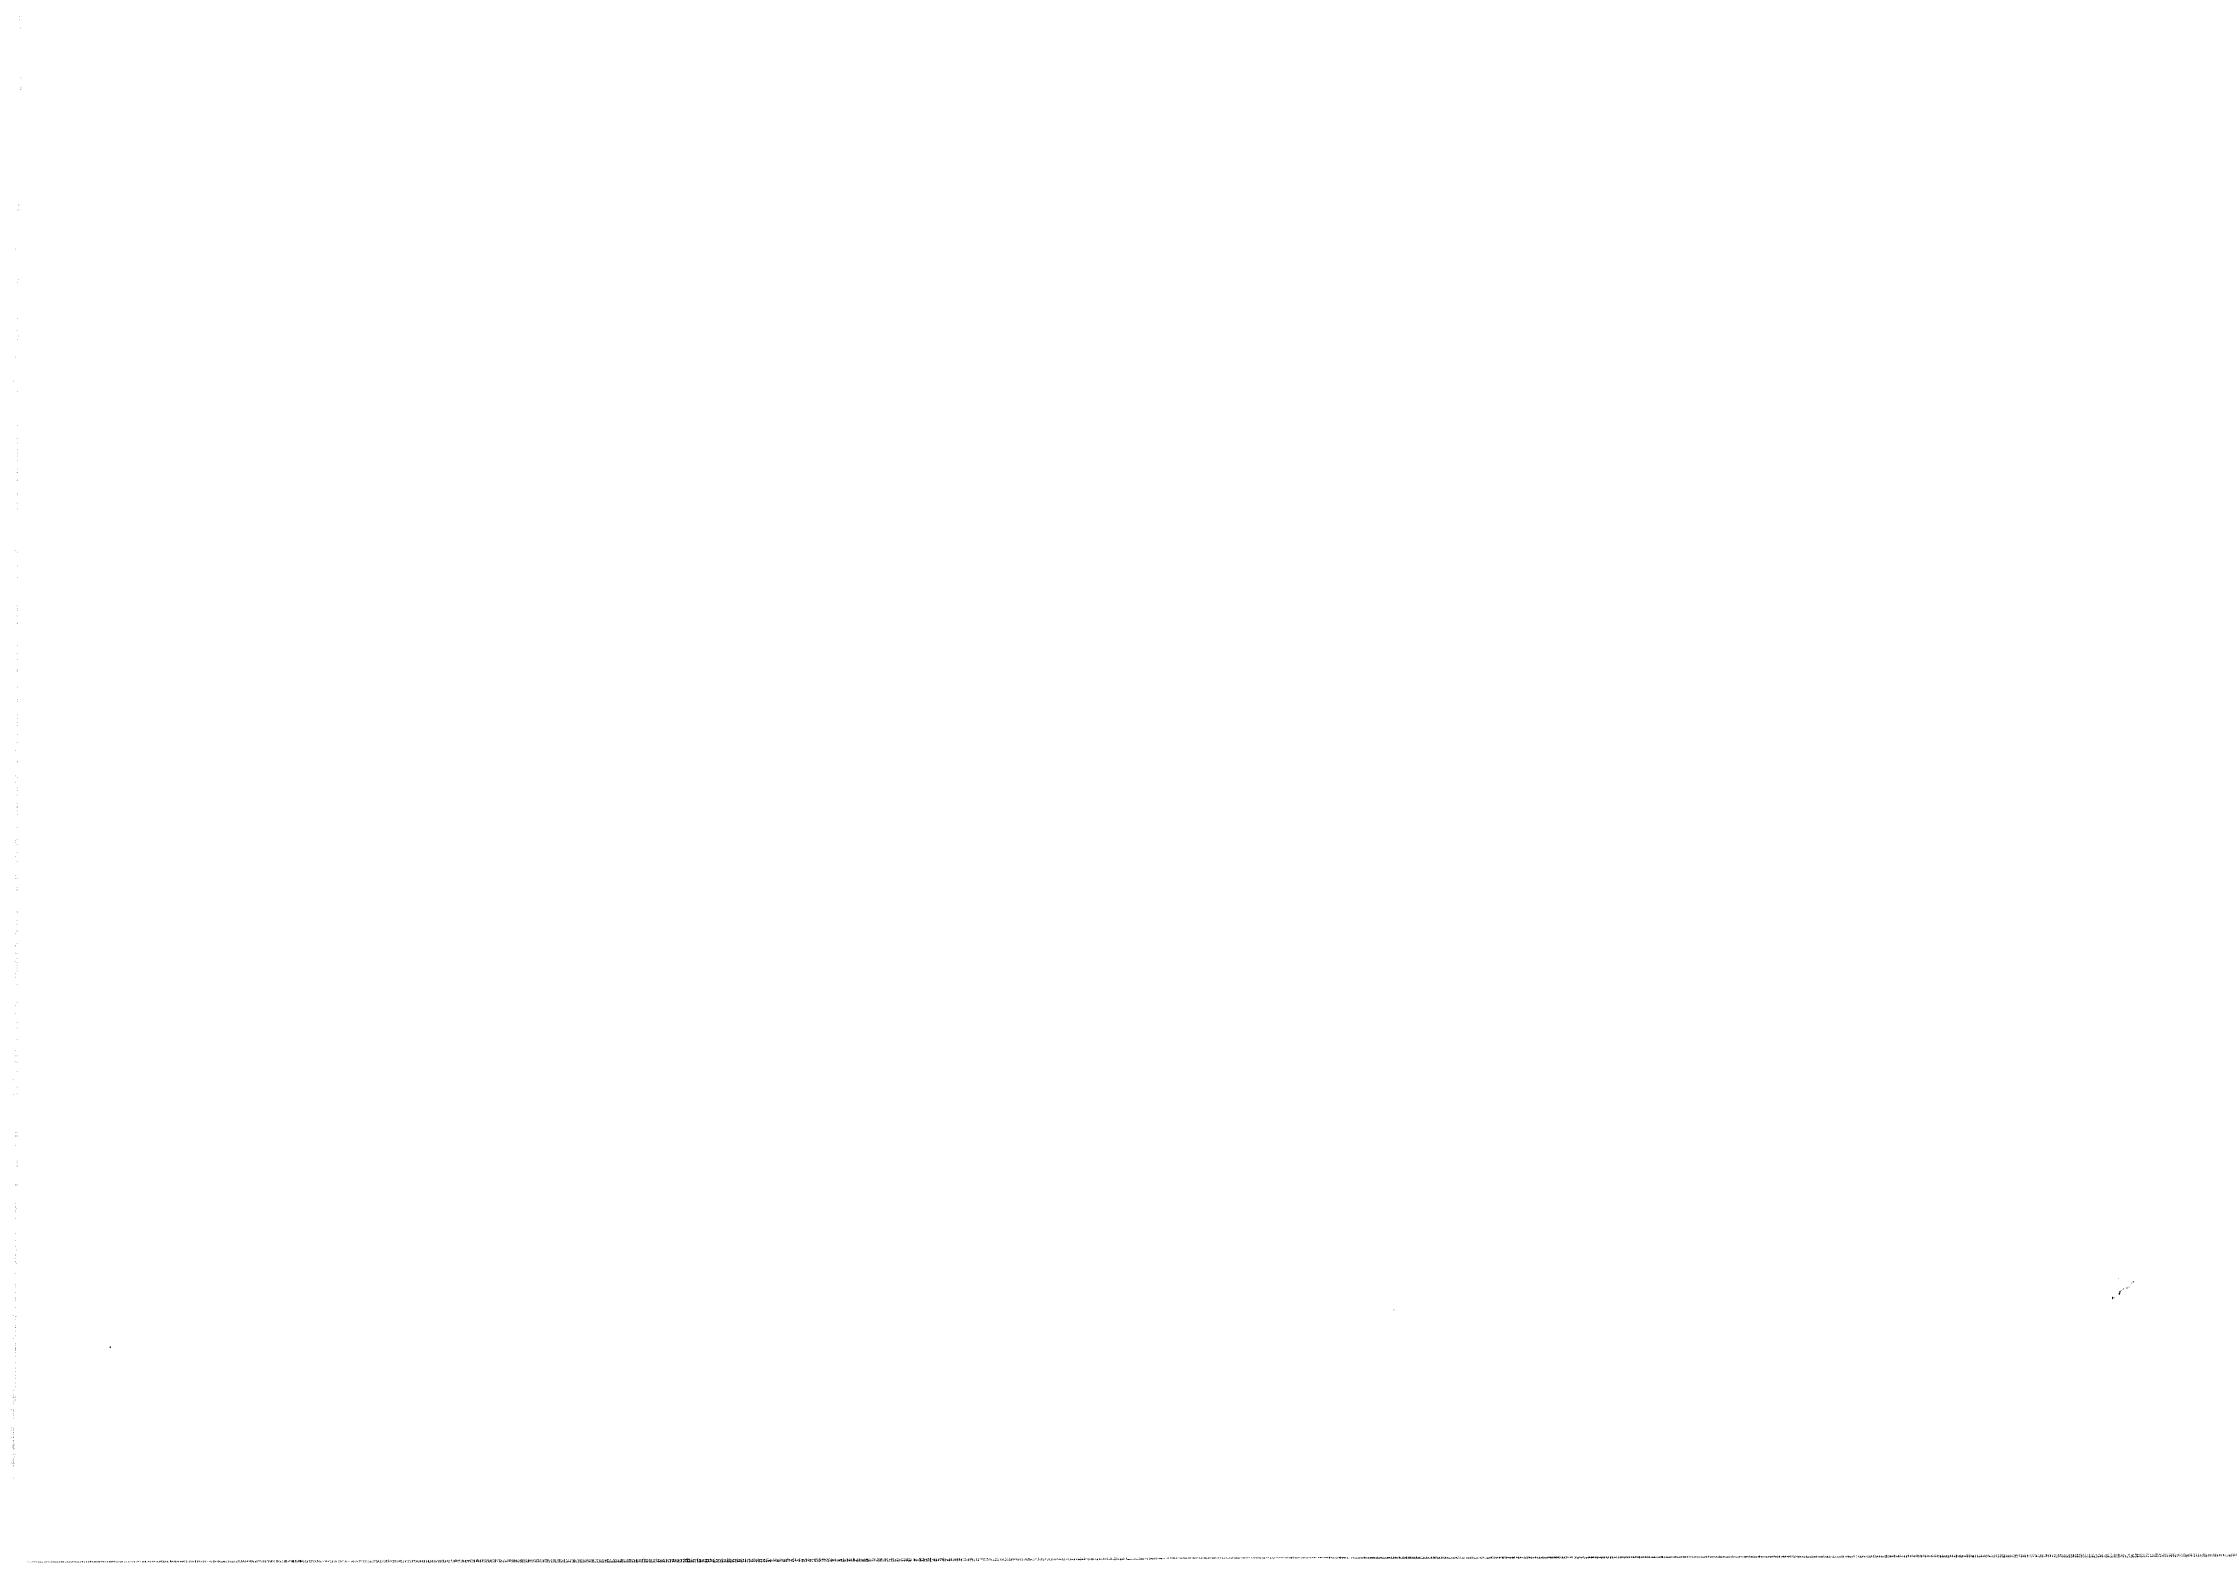
(2) množství vlastnostek:  $\Omega_N$

$$f_N(x^1, \dots, x^N, u^1, \dots, u^N) = \phi(f_{N-1}(x^1, \dots, x^{N-1}, u^1, \dots, u^{N-1}), \phi(x^N, u^N))$$

$$\text{Tu: } f_N(x^1, \dots, x^N, u^1, \dots, u^N) = \sum_{i=1}^N g_i(x^i, u^i)$$

$$\min \left\{ g_1(x^1, u^1), \dots, g_N(x^N, u^N) \right\}$$

et  
už!



Daf: Uložení DDDP rozumíme následov:

$$\max f_N(x^1, \dots, x^n, u^1, \dots, u^n)$$

$$\{u^1, \dots, u^n\} \in \mathcal{U}_N(x^1)$$

$$\text{Počín: Poloha } f(x^1, \dots, x^n, u^1, \dots, u^n) = \sum_{i=1}^n g_i(x^i, u^i)$$

Věta: Jsem-li  $g_i(x^i, u^i)$  dané reálné funkce  $T_i(x^i, u^i)$  dané rovnou

definované pro  $\forall i = 1, \dots, N^*$ ,  $x^i \in X$ ,  $u^i \in U$  a ještě pro dave

$$x^i \in X \quad \text{platí} \quad x^{i+1} = T_i(x^i, u^i) \quad \forall i = 1, \dots, N \text{ a oznámi}$$

$$\max \sum_{u^i \in \mathcal{U}_N(x^1)} g_i(x^i, u^i) = F_N(x^1), \quad 1 \leq N \leq N^*$$

$$\max_{\mathcal{P}(x^2)} \sum g_i(x^i, u^i) = F_{N-1}(x^2), \quad 2 \leq N \leq N^*$$

$$\text{postupně platí} \quad F_N(x^1) = \left\{ \begin{array}{l} (u^1, \dots, u^N) \mid u^i \in U, x^{i+1} = T_i(x^i, u^i) \in X, i=2 \dots N, x^N \end{array} \right\},$$

$$\text{kde } N = 1 \dots N^*, \quad F_0(x^1) = \emptyset \quad \forall x^1 \in X, \quad U(x^1) = \left\{ u^1 \in U \mid x^2 = T_1(x^1, u^1) \in X \right\}$$

$$\text{Algoritmus:}$$

$$1) \text{pro každou } x^{N-1} \in X \text{ počítáme } F_N(x^N) = \max_{u^N \in U(x^N)} g_N(x^N, u^N) \quad U(x^N) = \left\{ u^N \in U \mid x^{N+1} \in X \right\}$$

$$2) \text{pro každou } x^{N-1} \in X \text{ počítáme } F_N(x^{N-1}) = \max_{u^{N-1} \in U(x^{N-1})} g_{N-1}(x^{N-1}, u^{N-1}) + F_N(x^N) =$$

$$= \max \left\{ g_{N-1}(x^{N-1}, u^{N-1}) + F_N(T_{N-1}(x^{N-1}, u^{N-1})) \right\} \equiv g_{N-1}(x^{N-1}, u^{N-1}) + F_N(T_{N-1}(x^{N-1}, u^{N-1}))$$

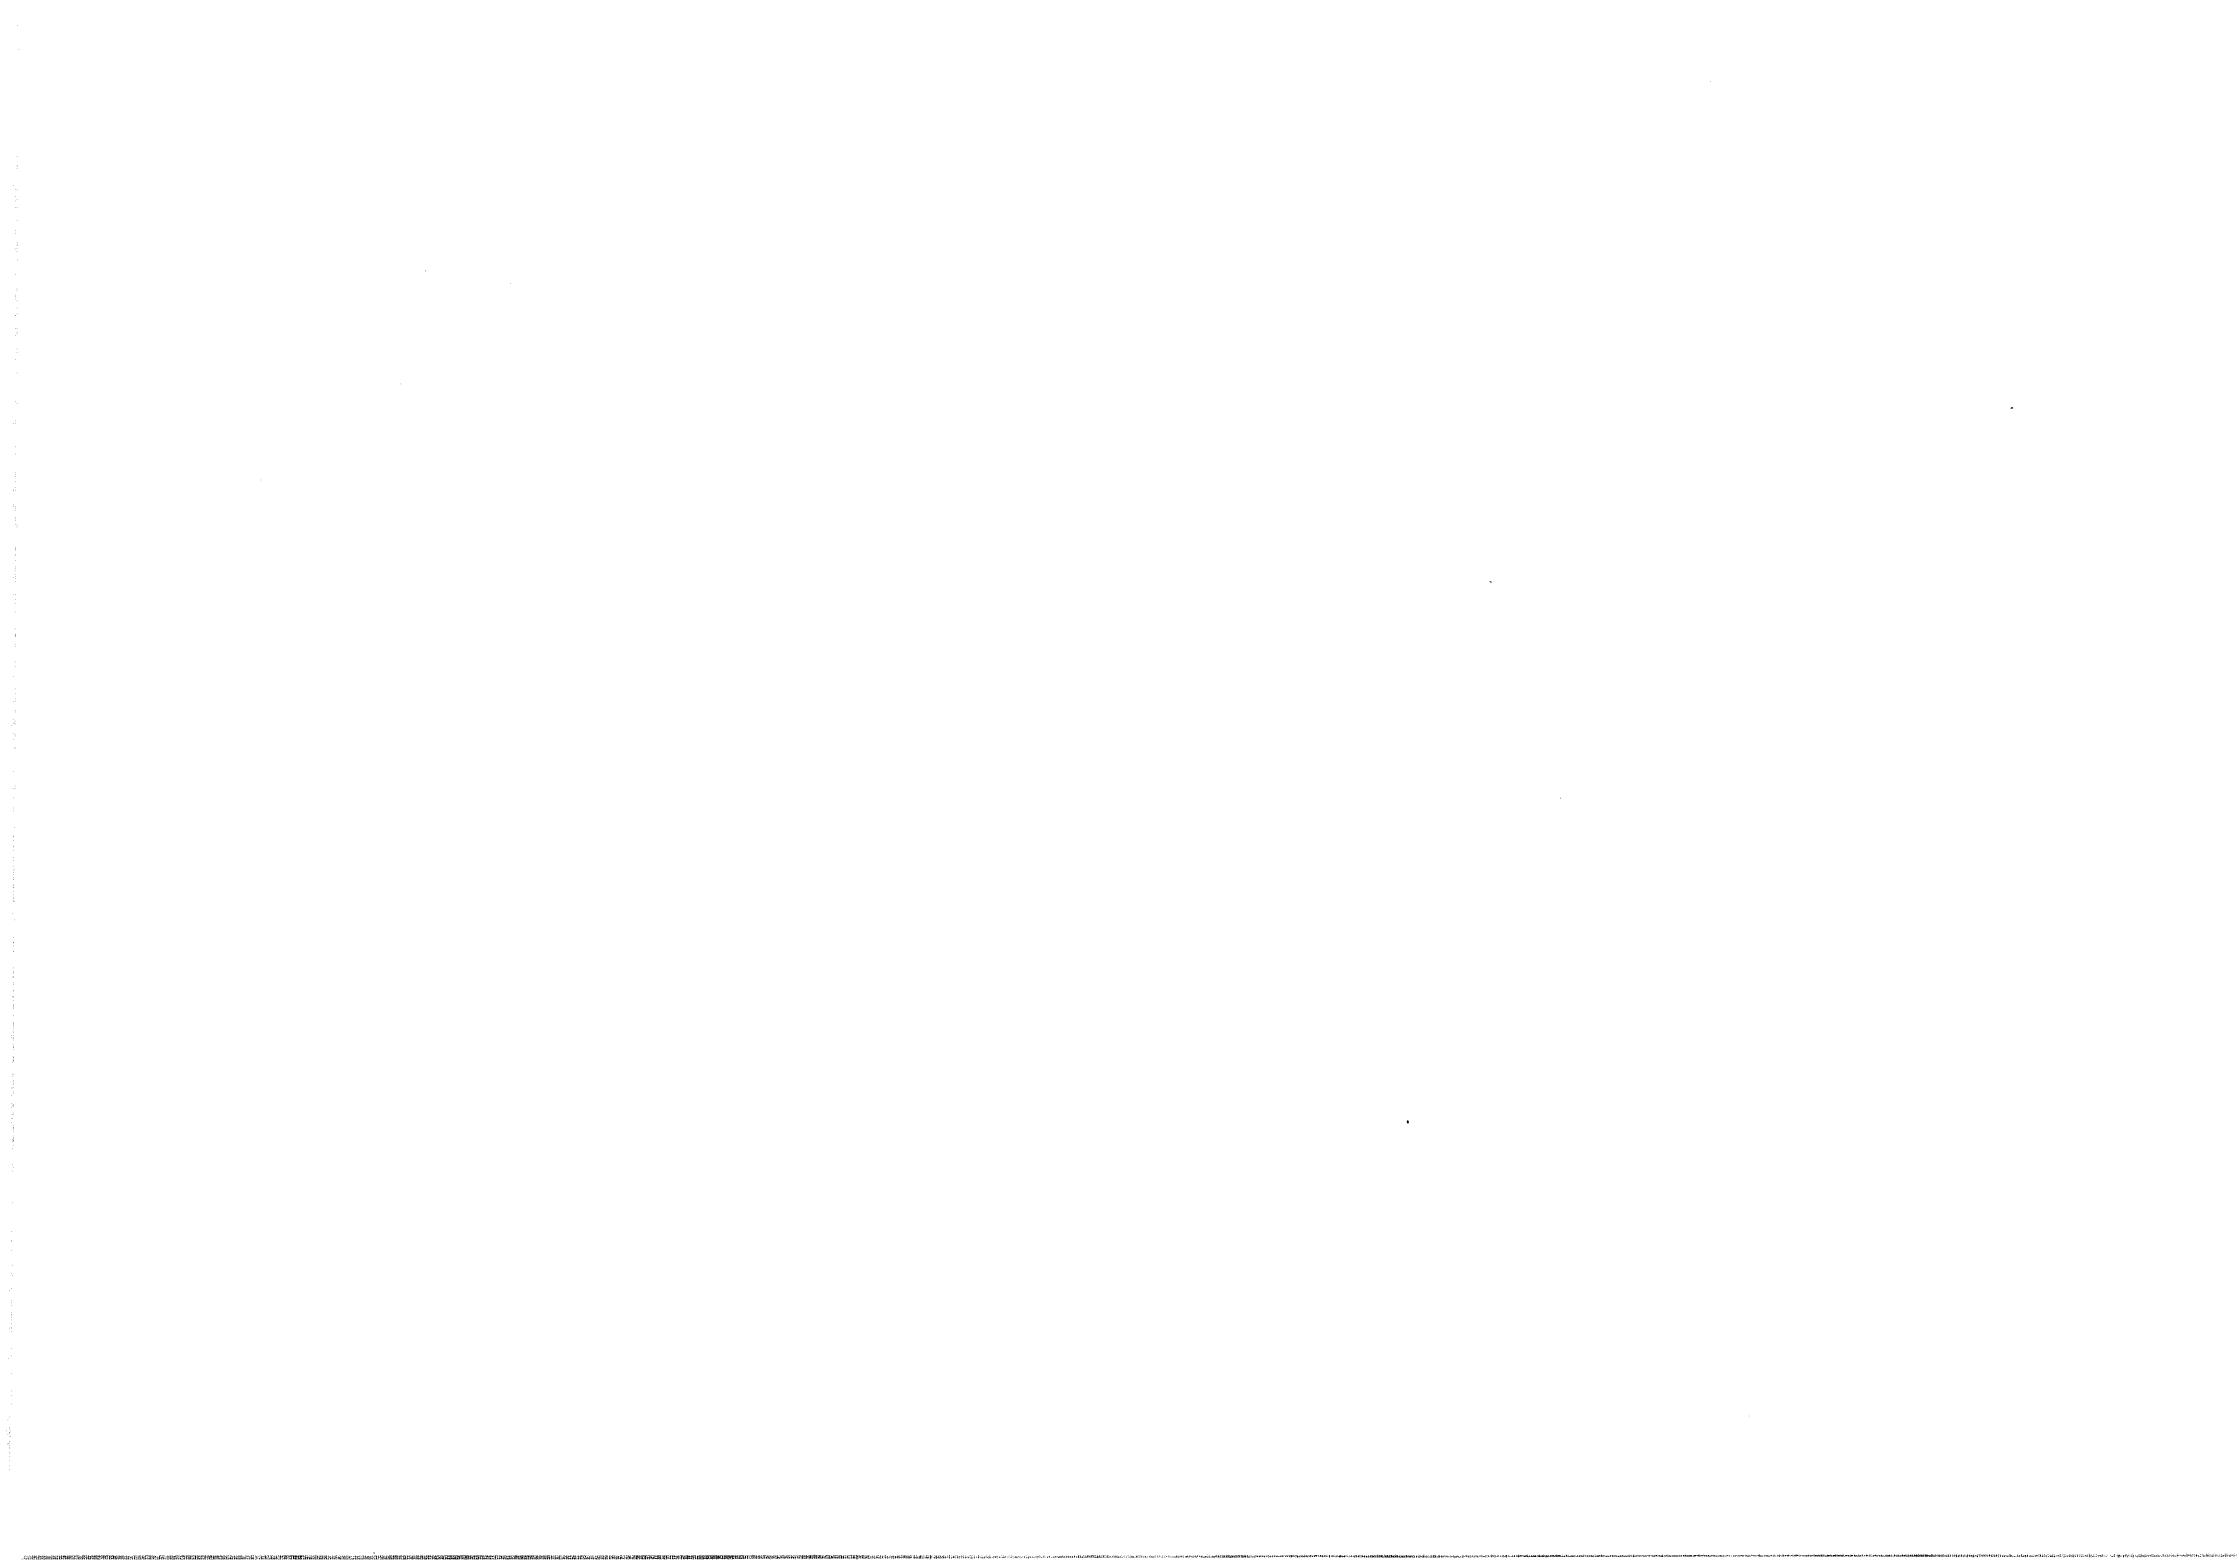
$$\begin{array}{c|c|c|c|c} x & F_N(x^N) & u^N & *N & F_N(x^{N-1}) \\ \hline & & & & u^{N-1} \end{array}$$

$$\begin{array}{c|c|c|c|c} x & F_N(x^N) & u^N & *N & F_N(x^{N-1}) \\ \hline & & & & u^{N-1} \end{array}$$

$$\underline{N-1:} \text{ Pro každou } x^2 \in X \text{ počítáme } F_{N-1}(x^2) = \max_{u^2 \in U(x^2)} \left\{ g_2(x^2, u^2) + F_{N-2}(x^3) \right\}$$

$$\underline{N:} \text{ Pro každou } x^1 \in X \text{ počítáme } F_N(x^1) = \max_{u^1 \in U(x^1)} \left\{ g_1(x^1, u^1) + F_{N-1}(x^2) \right\}$$

(36)



## KONEČNÉ MATICOVÉ HRY DVOCH HRAČOV S NULOVÝM SÚŤOM

Máme dve hry hráčov

1. hráč má k dispozícii  $i \in \{1, \dots, n\}$  strategie pre danú hru
2. —  $\Pi_i$  —  $j \in \{1, \dots, m\}$  —  $\Pi_j$  —

Nové hry sú  $N$ -hry ( $N \in \mathbb{N}, N \geq 2$ ).

Na mali 1. hráč strategiu  $i$  a 2. hráč strategiu  $j$  potom 1. hráč má väčšiu hodnotu ak je 1. hráč 2. hráč strategiu  $(a_{ij} < 0)$  pripravený na hráča

$$\forall i, \forall j \Rightarrow \text{dove } A = (a_{ij})_{i,j}$$

Definícia:

Májeme  $\{x_1, x_2, \dots, x_n\} \subseteq \{y_1, \dots, y_m\}$ ,  $A$  májeme konečnú množinu hra dvoch hráčov s nulovým súťom.

Na hráč 1. hráč máce jednu stratégiu (konečne o číslej stratégii) a hráč 2. hráč je pre nás nezáujemný. Májeme  $x_i$  pravdepodobnosť, že 1. hráč použije stratéguru  $i$  a  $y_j$  pravdepodobnosť, že 2. hráč použije stratéguru  $j$ .

$$\begin{aligned} \text{Definície } [X] &= \{x \in \mathbb{R}^n \mid \eta^T x = 1, x \geq 0\} \\ [Y] &= \{y \in \mathbb{R}^m \mid \eta^T y = 1, y \geq 0\} \end{aligned}$$

Pravdepodobnosť, že sa hráči urobia stratégia  $x_i, y_j$ :

$$\text{Pr } N \text{ hráč je rusk } N \sum_i \sum_j a_{ij} x_i y_j \text{ a teda rusk } \sum_i \sum_j a_{ij} x_i y_j = x^T A y$$

Definícia:

Májeme  $\{x_1, x_2, \dots, x_n\}, [X], x^T A y$  maticovu znieleným rozšírením maticej hry v maticu  $x^T A y$  maticovou cenu hry.

Kladame  $x^* \in [X]$  a  $y^* \in [Y]$ , aby  $x^T A y^* \leq x^* T A y^* \leq x^* T A y^*$ ,  $x \in [X], y \in [Y]$ .

1. hráč maximálizuje  $x^T A y^*$  a 2. hráč ju minimalizuje.

Definícia:

Maximálne  $x^*$  a  $y^*$  maticovu optimálnymi stratégiami sú  $x^T A y^*$  optimálnou cenou hry.

## Veta 1:

ak je  $\bar{x}^*$ ,  $\bar{y}^*$  a  $\bar{\lambda}$  řešení normálního optimálního dualního programu

$$\bar{x}^*{}^\top A \bar{y}^* = \bar{x}^*{}^\top A \bar{y}.$$

Dokaz:

$$\bar{x}^\top \bar{y} - \text{opt.} \stackrel{\text{def.}}{=} \bar{x}^\top A \bar{y} \leq \bar{x}^\top A \bar{y}^* \leq \bar{x}^\top A \bar{y}^* \leq \bar{x}^\top A \bar{y} \quad \xleftarrow{\bar{x}^\top \bar{y} = \text{opt.}}$$

Lemni:

$$\text{Defin. } \bar{\lambda} = (1)_{n \times m} \text{ s } \bar{\lambda} \geq 1 - \min_{i,j} x_{ij} \quad (\text{protože } \bar{A} = A + \lambda J > 0)$$

Dokaz:

$$\text{Pro každou } i \in \{1, \dots, n\} \quad \bar{x}_{ii} = x_{ii} + \lambda \Rightarrow \min_{i,j} x_{ij} + \lambda = 1 \Rightarrow \bar{\lambda} > 0.$$

Veta 2:

Je-li  $\bar{x}^0$  a  $\bar{y}^0$  optimální řešení níže uvedené LP (normální dualní)

$$(P) \quad \min_{\bar{y}} \bar{y}^\top \bar{x} \quad M = \{x \mid \bar{A}^\top x \leq 1, x \geq 0\}$$

$$(D) \quad \max_{\bar{N}} \bar{N}^\top \bar{y} \quad N = \{y \mid \bar{A}^\top y \leq 1, y \geq 0\}$$

$$\text{Potom } \bar{x}^* \equiv \frac{\bar{x}^0}{\bar{A}^\top \bar{x}^0} \quad \bar{y}^* = \frac{\bar{y}^0}{\bar{A}^\top \bar{x}^0} \text{ je optimální řešení LP}$$

a  $\bar{x}^*{}^\top \bar{y}^*$  je optimální cena kry.

Dokaz:

$$\begin{aligned} \text{Defin. } & \bar{N} \in \mathbb{N} \Rightarrow \bar{N} \neq \emptyset. \\ \text{Defin. } & \bar{A} > 0 \Rightarrow \bar{N} \neq \emptyset \text{ dle vlastnosti} \\ \text{Kry principus duality} \Rightarrow & (P) \text{ má řešení } \bar{x}^0 \text{ a proto } \bar{N}^\top \bar{x}^0 = \bar{N}^\top \bar{y}^0. \end{aligned}$$

$\bar{x}^*$  definice  $\bar{x}^*$  a  $\bar{y}^*$   $\Rightarrow \bar{x}^* \in [X], \bar{y}^* \in [Y]$ .

Kry principus duality  $\bar{x} \in [X] \Rightarrow \bar{x} \geq 0, \bar{x}^\top \bar{x} = 1$   
a kry principus duality  $\bar{y} \in [Y] \Rightarrow \bar{y} \geq 0, \bar{N}^\top \bar{y} = 1$

Bei  $\gamma^0$  gilt  $A\gamma^0 = 1/\gamma \Rightarrow \gamma^T A \gamma^0 \leq 1 \Rightarrow \gamma^T A \gamma^* \leq \frac{1}{\gamma^T \gamma^0}$ . (20)

Bei  $\gamma^0$  gilt  $\bar{A}^T \gamma^0 = \gamma^{0T} \bar{A} \geq 1/\gamma \Rightarrow \gamma^{0T} \bar{A} \gamma^* \geq 1^T \gamma = 1 / \frac{1}{\gamma^T \gamma^0}$ .

$$\Rightarrow \gamma^T \bar{A} \gamma^* \geq \frac{1}{\gamma^T \gamma^0} = \frac{1}{\gamma^T \gamma^0} \geq \gamma^T \bar{A} \gamma^* \quad \forall \gamma \in [X], \gamma^* \in [Y]$$

Es folgt:

$$\gamma^{*\top} (A + \lambda I) \gamma^* \geq \gamma^T (A + \lambda I) \gamma^{*T}$$

$$\gamma^{*\top} A \gamma^* + \lambda \geq \gamma^T A \gamma^{*T} + \lambda \quad \forall \gamma, \gamma^*$$

Letzte Zeile:

$$\begin{aligned} \gamma^{*\top} A \gamma^* &\geq \gamma^{*\top} A \gamma^{*T} \\ \gamma^{*\top} A \gamma^* &\geq \gamma^T A \gamma^{*T} \end{aligned} \Rightarrow \gamma^T A \gamma^{*T} \leq \gamma^{*\top} A \gamma^* \leq \gamma^{*\top} A \gamma^* \quad \forall \gamma, \gamma^* \Rightarrow$$

$\Rightarrow$  lokales Optimum.

Dies bedeutet:

Viele exakte optimale Strategien können mal eben kein durch hohen  $\gamma$ -Wert gewonnen werden.

Theoretisch hier

Intagonistische - niemals mögliche Option  
neutrale -

Kooperativ  
nukleopativ

